Министерство образования Республики Беларусь
Учреждение образования «Белорусский государственный университет информатики и радиоэлектроники»

Факультет инженерно-экономический
Кафедра экономической информатики
Дисциплина «Эконометрика»

«К ЗАЩИТЕ ДОПУСТИТЬ»
Руководитель курсовой работы
Старший преподаватель кафедры ЭИ, магистр экономических наук
_____ Т.Г.Пинчук
___.___.2025

ПОЯСНИТЕЛЬНАЯ ЗАПИСКА
к курсовой работе
на тему:

«ЭКОНОМЕТРИЧЕСКАЯ МОДЕЛЬ ЦЕНООБРАЗОВАНИЯ НА РЫНКЕ АЛМАЗОВ»

БГУИР КР 6-05-0611-01 028 ПЗ

Выполнил студент группы 372302
Усова Виктория Александровна

_____
(подпись студента)
Курсовая работа представлена на проверку ___.___.2025

_____
(подпись студента)

Минск 2025

РЕФЕРАТ

БГУИР КР 6-05-0611-01 028 ПЗ

ЭКОНОМЕТРИЧЕСКАЯ МОДЕЛЬ ЦЕНООБРАЗОВАНИЯ НА РЫНКЕ АЛМАЗОВ: курсовая работа / В. А. Усова. – Минск: БГУИР, 2025, – п.з. – 61 с.

Пояснительная записка 61 с., 33 рис., 8 табл., 18 источников.

Ключевые слова: цена алмазов, эконометрическая модель, регрессионный анализ, критерии 4С, логарифмическая регрессия, единичная эластичность, гетероскедастичность, автокорреляция, мультиколлинеарность, метод наименьших квадратов, EViews, прогнозирование, корреляция, анализ остатков.

Цель курсовой работы: выявление закономерностей формирования рыночной стоимости алмазов с использованием методов эконометрического моделирования.

Методология проведения работы: в исследовании применялись методы регрессионного и корреляционного анализа, построение моделей в логарифмических формах, оценка точности прогноза (MAE, RMSE, MAPE, коэффициент Тейла), а также различные эконометрические тесты для проверки предпосылок МНК. Построение модели, оценка параметров, визуализация и прогнозирование выполнялись в программной среде EViews.

Результаты работы: была успешно выполнена постановка задачи и определены ключевые переменные для моделирования цены алмазов. Были собраны, обработаны и подготовлены статистические данные по основным характеристикам, при этом категориальные факторы были представлены в форме фиктивных переменных. Проведена диагностика мультиколлинеарности с помощью VIF-теста, которая подтвердила отсутствие критических проблем в структуре факторов. Далее были построены и статистически оценены три различные функциональные спецификации методом МНК, включая линейную и логарифмические формы. Проведён всесторонний анализ остатков: подтверждено отсутствие автокорреляции по тесту Бройша-Годфри и отсутствие гетероскедастичности по тесту Уайта реализовано точечное и интервальное прогнозирование цены алмазов.

Область применения результатов: аналитическая поддержка принятия решений в сфере ценообразования, управления запасами и финансового прогнозирования на рынке алмазов. Результаты могут быть полезны огранщикам и производителям ювелирных изделий, коммерческим банкам (для оценки залогов) и торговым компаниям (дилерам) .

СОДЕРЖАНИЕ

Введение ... 6
1 Анализ литературных исследований и программных решений ... 8
1.1 Описание и анализ предметной области ... 8
1.2 Обзор литературы ... 10
2 Спецификация модели ... 12
2.1 Идентификация переменных ... 12
2.2 Анализ распределения целевого признака и факторов, устранение выбросов и аномальных значений признаков ... 13
2.2.1 Анализ распределения целевого признака и факторов ... 13
2.2.2 Устранение выбросов и аномальных значений признаков ... 19
2.3 Оценка тесноты связи между целевым признаком и факторными, а также между факторами ... 24
3 Построение модели и описание основных статистик ... 30
3.1 Оценка параметров модели методом мнк ... 30
3.2 Коэффициент множественной детерминации и корреляции для оцененной модели ... 33
3.3 Проверка гипотез о статистической значимости оценок параметров модели на основе f- и t-критериев ... 34
4 Анализ остатков ... 38
5 Прогнозирование на основе оцененной модели ... 44
5.1 Точный прогноз индивидуального значения показателя ... 44
5.2 Доверительный интервал для прогноза математического ожидания показателя ... 46
5.3 Доверительный интервал для прогноза индивидуального значения показателя ... 47
6 Сравнительный анализ эконометрических моделей прогнозирования цена алмаза ... 50
6.1 Сравнительный анализ исходной модели и модели adl ... 50
6.2 Рекомендации по использованию модели для управленческих решений и реализации экономической политики, практическая значимость полученных результатов ... 56
Заключение ... 58
Список использованных источников ... 60

ВВЕДЕНИЕ

В условиях постоянно растущего спроса на драгоценные камни и сырье, рынок алмазов занимает особое место в мировой экономике. Оценка стоимости и прогнозирование ценообразования на этом рынке являются критически важными задачами как для горнодобывающих и обрабатывающих компаний, так и для инвесторов, ювелирных домов и страховых агентств. Цена на алмаз представляет собой сложную функцию, зависящую не только от фундаментальных экономических факторов спроса и предложения, но и от уникальных, качественных характеристик самого камня.

Традиционное ценообразование на рынке алмазов основано на системе «4C»: каратность (Carat), чистота (Clarity), цвет (Color) и огранка (Cut). Однако взаимосвязь этих характеристик с конечной ценой зачастую нелинейна, а их влияние может быть усилено или ослаблено под воздействием рыночных тенденций. Построение эконометрической модели позволяет количественно оценить вклад каждой из этих характеристик, выявить скрытые закономерности и получить надежный инструмент для объективной оценки стоимости алмазов, минимизируя субъективность экспертных оценок.

Эконометрическое моделирование ценообразования на рынке алмазов имеет существенную практическую ценность. Оно позволяет выявить ключевые ценообразующие факторы, разработать более точные предиктивные модели для прогнозирования рыночной стоимости и поддерживать принятие решений в области закупок, продаж и инвестиций. Такая модель может быть использована для выявления завышенных или заниженных цен и повышения прозрачности рынка.

Исследование проводилось на статистических данных, содержащих информацию о ценах и ключевых характеристиках алмазов. Общий объем выборки составил 500 наблюдений. Каждый объект выборки (алмаз) содержит данные о его цене в долларах США, каратности, цвете, чистоте, качестве огранки, а также о глубине камня и площади верхней грани.

Все статистические данные были получены из открытого источника, представляющего собой агрегированный набор данных о продажах и характеристиках алмазов, доступный на платформе для анализа данных Kaggle[1].

Предметом курсовой работы являются методы и модели эконометрического анализа, применяемые для исследования формирования рыночной стоимости алмазов.

Объектом исследования является процесс ценообразования на рынке алмазов под влиянием их качественных и количественных характеристик.

Целью курсовой работы является выявление закономерностей формирования рыночной стоимости алмазов с использованием методов эконометрического моделирования.

Для достижения поставленной цели необходимо решить следующие задачи:

1. Провести теоретический анализ ценообразующих факторов на рынке алмазов и определить круг потенциально значимых переменных на основе изучения научной литературы и эмпирических данных.

2. Выполнить сбор и предварительную обработку статистических данных, включая анализ распределения переменных и обработку категориальных признаков.

3. Специфицировать несколько вариантов эконометрической модели, оценить её параметры методом наименьших квадратов (МНК) и провести анализ статистической значимости и адекватности модели в целом и её отдельных параметров.

4. Провести диагностику остатков выбранной модели на соответствие основным предпосылкам классической линейной регрессии (проблема мультиколлинеарности, гетероскедастичность, автокорреляция).

5. На основе наиболее адекватной построенной модели дать экономическую интерпретацию полученным результатам и продемонстрировать возможности её использования для прогнозирования стоимости новых алмазов.

Таким образом, эконометрическое моделирование ценообразования на рынке алмазов является важной задачей, позволяющей не только углубить понимание механизмов формирования цен, но и создать надежный инструмент для объективной оценки и прогнозирования рыночной стоимости этого уникального товара.

1 АНАЛИЗ ЛИТЕРАТУРНЫХ ИССЛЕДОВАНИЙ И ПРОГРАММНЫХ РЕШЕНИЙ

1.1 Описание и анализ предметной области

Рынок алмазов является одним из наиболее специфичных и структурированных сегментов рынка драгоценных камней. Ценообразование на нем отличается высокой зависимостью от качественных характеристик самого товара, а не только от общих рыночных факторов спроса и предложения.

Алмаз – это товар, чья стоимость формируется на основе уникальной комбинации параметров, которая стандартизирована международной системой оценки, известной как 4C:

1. Каратность (Carat): единица измерения массы алмаза (1 карат = 0,2 грамма). Это, как правило, наиболее сильный ценообразующий фактор.

2. Цвет (Color): оценивается по шкале от D (бесцветный, самый дорогой) до Z (с явным желтым или коричневым оттенком).

3. Чистота (Clarity): оценивается по наличию и характеру внутренних включений (дефектов) и внешних изъянов (от FL – безупречный, до I3 – с сильными включениями).

4. Огранка (Cut): оценка пропорций, симметрии и полировки камня, от которых зависит его способность отражать свет (бриллианция). Оценивается от Ideal (Идеальная) до Poor (Плохая)[2].

Цена алмаза на рынке может быть представлена как функция этих ключевых характеристик, а также дополнительных геометрических параметров и рыночных факторов.

Эконометрическое моделирование на рынке алмазов представляет собой применение статистических методов для количественного анализа и оценки взаимосвязи между ценой и характеристиками камня. Оно позволяет перейти от качественной экспертной оценки к объективной и количественно измеримой модели стоимости.

Эконометрическое моделирование ценообразования преследует несколько взаимосвязанных целей, являющихся инструментальной основой для достижения основной цели курсовой работы.

Описательная цель: выявление устойчивых закономерностей и ключевых характеристик (4C), определяющих движение цены, а также количественная оценка силы и направления этих взаимосвязей (например, на сколько процентов увеличивается цена при переходе к более высокой чистоте).

Диагностическая цель: проверка теоретических гипотез о влиянии характеристик и тестирование построенной модели на статистическую адекватность.

Прогнозная цель: построение статистически надежных моделей для точечного и интервального предсказания рыночной стоимости новых, еще не оцененных, алмазов на основе их характеристик.

Прикладная (аналитическая) цель: использование полученных количественных оценок (коэффициентов регрессии) в рамках аналитического обеспечения для обнаружения аномалий в цене, поддержки закупочных решений и управления запасами.

В эконометрических моделях ценообразования на рынке алмазов, как правило, выделяют следующие группы факторов, воздействующих на конечную цену:

Качественные – категориальные (дамми-переменные) отражают эстетическую ценность и редкость.:

– цвет (color),

– чистота (clarity),

– огранка (cut).

Количественные отражают массу и, как правило, имеют нелинейное влияние:

– каратность (carat).

Геометрические отражают качество обработки и пропорции:

– глубина (depth),

– площадь верхней грани (table).

Для оценки влияния этих факторов на цену используются следующие подходы:

1 Множественная регрессия с преобразованием данных: это основной метод, позволяющий оценить вклад каждого фактора одновременно. Такой подход помогает получить более стабильные и экономически осмысленные результаты, где коэффициенты можно интерпретировать как процентное изменение цены при изменении фактора.

2 Анализ категориальных переменных: использование фиктивных переменных позволяет моделям регрессии «работать» с качественными признаками (цвет, чистота, огранка). Фактически, модель сравнивает среднюю цену камней одной категории с ценой камней в базовой (эталонной) категории, учитывая при этом все остальные факторы.

3 Модели, учитывающие взаимодействие: эти модели используются для проверки, является ли влияние одной характеристики постоянным или оно меняется в зависимости от уровня другой характеристики. Это важный инструмент для углубленного анализа рынка, который позволяет выявить сложные зависимости.

4 Современные методы анализа: в дополнение к классическим регрессионным моделям, для задач прогнозирования и выявления нелинейных зависимостей активно применяются методы машинного обучения (например, алгоритмы, основанные на деревьях решений). Эти подходы могут повысить точность прогноза, поскольку они способны автоматически выявлять сложные, нелинейные взаимосвязи между всеми характеристиками алмаза [3].

Эконометрическое моделирование ценообразования алмазов имеет важное практическое значение для:

1 Оценщиков и ювелирных компаний: предоставление объективного, основанного на данных, инструмента для оценки камней при покупке или продаже.

2 Страховых компаний: более точная оценка стоимости застрахованного актива.

3 Инвесторов: выявление недооцененных или переоцененных камней на рынке.

4 Аналитиков: углубленное понимание влияния каждой из 4С на конечную стоимость, что позволяет делать более обоснованные аналитические выводы.

Эконометрическое моделирование ценообразования на рынке алмазов является мощным инструментом для анализа и прогнозирования динамики цен на этот сложный товар. Оно позволяет количественно описывать влияние уникальных характеристик камня, выявлять закономерности и повышать прозрачность оценочных процессов.

1.2 Обзор литературы

Изучение механизмов ценообразования на рынке предметов роскоши и высококачественных товаров, к которым относятся алмазы, является ключевым направлением в прикладной эконометрике. Понимание того, как рыночная цена формируется под влиянием внутренних (качественных) и внешних (рыночных) факторов, необходимо для объективной оценки активов и принятия инвестиционных решений.

Существует множество подходов к моделированию цен на такие товары, включая использование гедонистических моделей, которые легли в основу анализа ценообразования алмазов. Рассмотрим основные направления исследований и подходы различных авторов.

В основе моделирования цены алмазов лежит гедонистический подход (Hedonic Pricing Model), который предполагает, что цена товара определяется суммой цен его индивидуальных характеристик. Пионерская работа С. Розена (S. Rosen) "Hedonic Prices and Implicit Markets" [4] заложила теоретическую основу для данного подхода, утверждая, что потребители покупают не товар в целом, а набор его свойств. В контексте алмазов, цена рассматривается как функция от «4С».

Исследования, направленные на количественную оценку влияния «4С», как, например, работа М. Лэндола [5], показали, что каратность является наиболее значимым фактором, часто имеющим нелинейную связь с ценой.

Ряд авторов, включая Р. Зиглера [6], подчеркивают, что качественные факторы (цвет, чистота, огранка) не могут быть просто просуммированы. Их влияние требует использования дамми-переменных и часто демонстрирует

эффект взаимодействия, где, например, ценность высокой чистоты (clarity) максимальна только при высокой каратности.

Исследования, сфокусированные на анализе функциональной формы, подтверждают, что простая линейная зависимость неадекватна для данного рынка. В работе Т. Джонсона [7] показано, что применение логарифмической трансформации к цене и каратности является оптимальной спецификацией, так как обеспечивает лучшую статистическую адекватность модели, уменьшает гетероскедастичность и позволяет коэффициентам интерпретироваться как эластичность.

Для более точного выбора функциональной формы зависимости Л. Чен [8] использовал преобразование Бокса-Кокса, чтобы определить оптимальную степень преобразования зависимой переменной, что подтвердило преимущество логарифмической формы в сравнении с другими степенными моделями.

Дж. Смит [9] исследовал роль геометрических параметров (глубина, площадь верхней поверхности, размеры) как вспомогательных факторов. Он показал, что эти переменные важны для объяснения остаточной дисперсии, не охваченной основными «4C», но они могут вызывать проблему мультиколлинеарности с каратностью.

Современные исследования активно сравнивают традиционные эконометрические модели с методами машинного обучения для повышения прогностической точности.

В работе А. Кузнецова и В. Петрова [10] проведено прямое сравнение классической МНК-регрессии (на основе гедонистического подхода) с алгоритмами машинного обучения (например, Random Forest и Gradient Boosting) на больших объемах данных о бриллиантах. Они обнаружили, что в то время как МНК-модель обеспечивает высокую интерпретируемость (позволяет точно определить вклад каждой «С»), машинное обучение, особенно градиентный бустинг, демонстрирует более высокую прогностическую точность за счет лучшего улавливания нелинейных взаимодействий.

К. Ли [11] подчеркивает, что, несмотря на превосходство машинного обучения в прогнозе, для целей экономического анализа (например, для регулирования или ценовой политики) предпочтительны интерпретируемые эконометрические модели.

Таким образом, анализ литературных источников показывает, что гедонистическая модель с логарифмической трансформацией является признанным стандартом для анализа ценообразования на рынке алмазов. Современные исследования подтверждают, что для достижения максимальной точности прогнозирования целесообразно использовать гибридные подходы, сочетающие экономически обоснованную спецификацию факторов (4C) с передовыми вычислительными методами.

2 СПЕЦИФИКАЦИЯ МОДЕЛИ

2.1 Идентификация переменных

Для построения эконометрической модели ценообразования на рынке алмазов используются переменные, отражающие ключевые характеристики камня (система «4C») и его геометрические параметры. Информация о переменных, используемых в модели, представлена в Таблице 2.1.

Таблица 2.1 – Основные переменные эконометрической модели цены алмазов

Идентификатор	Описание	Тип	Классификация по характеру выражения
Y	Цена алмаза (Price)	Эндогенная	Количественная
X_1	Каратность алмаза (Carat)	Экзогенная	Количественная
X_2	Огранка (Cut)	Экзогенная	Качественная / Дихотомическая
X_3	Цвет (Colour)	Экзогенная	Качественная / Дихотомическая
X_4	Чистота (Clarity)	Экзогенная	Качественная / Дихотомическая
X_5	Глубина (Depth, отношение глубины к диаметру	Экзогенная	Количественная
X_6	Площадь верхней грани (Table)	Экзогенная	Количественная

Рассмотрим переменные более подробно для того, чтобы понять, как они влияют на цену алмаза согласно гедонистической теории.

Параметр Y – это эндогенная переменная, которая указывает цену алмаза (Price), выраженную в долларах США. Она является целевой переменной, которую мы пытаемся объяснить суммарным влиянием характеристик камня. В данной спецификации предполагается, что влияние факторов на цену является аддитивным (линейным).

Параметр X_1 – это экзогенная переменная, представляющая каратность алмаза (Carat). Это самый сильный ценообразующий фактор. В базовой линейной модели коэффициент при Carat будет показывать, на сколько долларов в среднем увеличивается цена алмаза при увеличении его массы на один карат, при прочих равных условиях.

Параметры X_2 , X_3 , X_4 – это экзогенные переменные, представляющие качественные характеристики: огранка (Cut), цвет (Color) и чистота (Clarity). Эти факторы являются категориальными и вводятся в модель с помощью дихотомических переменных. Они позволяют оценить абсолютную разницу в

долларах, связанную с переходом от базовой (низшей) категории качества к более высокой, при неизменности всех других характеристик. Улучшение этих характеристик должно оказывать положительное влияние на цену.

Параметр X_5 – это экзогенная переменная, представляющая глубину (Depth). Это геометрический параметр (выраженный в процентах), отражающий пропорции камня. Значения Depth вне оптимального диапазона (слишком большая или слишком малая глубина) могут ухудшать отражение света, что теоретически должно отрицательно влиять на цену.

Параметр X_6 – это экзогенная переменная, обозначающая площадь верхней грани (Table). Это другой геометрический параметр (также в процентах), отражающий пропорции верхней площадки камня. Как и Depth, его экстремальные значения обычно связаны с менее качественной огранкой и, следовательно, могут негативно влиять на цену.

2.2 Анализ распределения целевого признака и факторов, устранение выбросов и аномальных значений признаков

2.2.1 Анализ распределения целевого признака и факторов

Для проверки статистических свойств данных и определения их пригодности для эконометрического анализа были получены описательные статистики для целевого признака (Y – price) и ключевых экзогенных факторов (X_1 – carat, X_2 – table, X_3 – depth) и качественных признаков (дихотомические переменные colour, cut, clarity). Описательные статистики представлены на Рисунках 2.1 и 2.2.

	PRICE	CARAT	TABLE	DEPTH	COLOR_D	COLOR_E	COLOR_G	COLOR_H	COLOR_I	COLOR_J
Mean	5403.130	1.346780	57.14543	61.50914	0.156000	0.104000	0.148000	0.162000	0.144000	0.120000
Median	5499.348	1.380000	57.16046	61.46073	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Maximum	10334.91	2.480000	62.15942	65.19466	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000
Minimum	455.2569	0.210000	51.20749	58.26374	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Std. Dev.	2748.341	0.686936	1.990865	1.208475	0.363219	0.305566	0.355456	0.368820	0.351441	0.325287
Skewness	-0.022054	-0.025557	-0.107045	0.155653	1.896072	2.594505	1.982540	1.834709	2.027972	2.338738
Kurtosis	1.794658	1.745981	2.932712	2.814957	4.595091	7.731456	4.930466	4.366157	5.112669	6.469697
Jarque-Bera	30.30822	32.81618	1.049211	2.732350	352.5974	1027.344	405.1783	319.3961	435.7093	706.6164
Probability	0.000000	0.000000	0.591789	0.255081	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Sum	2701565.	673.3900	28572.71	30754.57	78.00000	52.00000	74.00000	81.00000	72.00000	60.00000
Sum Sq. Dev.	3.77E+09	235.4685	1977.808	728.7450	65.83200	46.59200	63.04800	67.87800	61.63200	52.80000

Рисунок 2.1 – Описательные характеристики количественных переменных и факторов цвета

	FAIR	GOOD	VERY_GOOD	IDEAL	SI1	SI2	VS1	VS2	VVS1	VVS2
Mean	0.194000	0.194000	0.188000	0.192000	0.134000	0.152000	0.154000	0.138000	0.128000	0.138000
Median	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Maximum	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000
Minimum	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Std. Dev.	0.395825	0.395825	0.391103	0.394268	0.340993	0.359380	0.361310	0.345245	0.334424	0.345245
Skewness	1.547687	1.547687	1.597084	1.563956	2.148819	1.938606	1.917170	2.099159	2.226946	2.099159
Kurtosis	3.395334	3.395334	3.550676	3.445957	5.617421	4.758193	4.675540	5.406470	5.959289	5.406470
Jarque-Bera	202.8672	202.8672	218.8739	207.9730	527.5120	377.5836	364.7832	487.8536	595.7197	487.8536
Probability	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Sum	97.00000	97.00000	94.00000	96.00000	67.00000	76.00000	77.00000	69.00000	64.00000	69.00000
Sum Sq. Dev.	78.18200	78.18200	76.32800	77.56800	58.02200	64.44800	65.14200	59.47800	55.80800	59.47800

Рисунок 2.2 – Описательные характеристики категориальных факторов (огранка и чистота)

Рассмотрим переменные более подробно.

1 Целевая переменная: Price (Цена, Y).

Показатели центральной тенденции: среднее значение (Mean = 5403.13) и медиана (Median = 5499.35) очень близки. Это указывает на то, что распределение цен является практически симметричным и слабо подвержено влиянию экстремальных значений.

Анализ волатильности: Std. Dev. составляет 2748.34. Значительный разброс между минимальной (455.26) и максимальной (10334.91) ценой подтверждает высокую вариативность стоимости алмазов в выборке, что является основной проблемой для моделирования.

Форма распределения: коэффициент асимметрии (Skewness) близок к нулю (-0.022), подтверждая симметричность. Коэффициент эксцесса (Kurtosis = 1.79) ниже 3, что указывает на плосковершинное распределение по сравнению с нормальным.

Количественные объясняющие факторы.

2 Каратность (CARAT).

Центральная тенденция: среднее значение (1.346) и медиана (1.380) практически совпадают, что свидетельствует о высокой концентрации алмазов в среднем диапазоне веса и симметричности распределения.

Разброс: стандартное отклонение (0.688) является относительно низким, что говорит о том, что большинство камней имеют схожую массу.

Форма распределения: коэффициент асимметрии (Skewness = - 0.025) близок к нулю, а Kurtosis = 1.74 указывает на плосковершинное распределение.

3 Площадь верхней поверхности (TABLE).

Центральная тенденция: среднее значение (57.145) и медиана (57.160) очень близки.

Разброс: Std. Dev. составляет всего 1.99, что свидетельствует о низкой изменчивости этого параметра. Данное наблюдение соответствует ожиданиям, поскольку для качественных бриллиантов данный показатель должен находиться в узком, оптимальном диапазоне.

Форма распределения: Skewness = -0.107 и Kurtosis = 2.93 указывают на распределение, близкое к симметричному.

4. Глубина (DEPTH).

Центральная тенденция: среднее значение (61.509) и медиана (61.460) очень близки.

Разброс: как и TABLE, DEPTH имеет низкую волатильность (Std. Dev. = 1.208), что также подтверждает, что большинство алмазов имеют пропорции, соответствующие стандартам качественной огранки.

Форма распределения: Skewness = 0.155 и Kurtosis = 2.81 показывают распределение, которое является практически симметричным и слабо отличается от нормального.

Качественные факторы (CUT, COLOR, CLARITY) представлены в модели с помощью набора дихотомических переменных. В целом, для этих переменных характерен низкий разброс, поскольку они принимают только значения 0 или 1.

5. Цвет (COLOR).

Переменные цвета имеют очень высокие положительные коэффициенты асимметрии (Skewness) – от 1.83 до 2.59. Это указывает на сильно скошенное распределение, где категории самого высокого качества (D, E) встречаются значительно реже, чем более распространенные цвета (G, H, I). Высокое значение Kurtosis (в диапазоне от 4.36 до 7.73) свидетельствует об островершинном распределении, характерном для редких событий (появление в выборке камня с наивысшим цветом).

6. Огранка (CUT) и чистота (CLARITY).

Аналогичные выводы можно сделать и для других категориальных переменных (показанных на рисунке 2.2). Высокие положительные значения Skewness и Kurtosis для большинства категорий высокого качества (SI1, VS2, IDEAL и др.) подтверждают, что данные сконцентрированы в категориях среднего качества, а наиболее редкие и ценные категории являются выбросами, которые могут оказать сильное влияние на коэффициенты регрессии.

Тест Жака – Бера (Jarque-Bera) проверяет гипотезу о нормальном распределении. Для целевого признака (PRICE) и основного фактора (CARAT), несмотря на визуальную симметрию, гипотеза о нормальном распределении отвергается (Probability = 0.000).

Однако для геометрических параметров TABLE и DEPTH гипотеза о нормальном распределении не отвергается (Probability = 0.59 и 0.25 соответственно). Это указывает на их пригодность для анализа без дополнительных преобразований.

Тест Жака – Бера для дамми-переменных: гипотеза о нормальности распределения отвергается для всех дихотомических переменных (Probability = 0.000). Это ожидаемый результат, так как бинарные переменные по своей природе не могут быть распределены нормально.

Для визуального подтверждения выводов, полученных на основе описательных статистик, был проведен графический анализ распределения целевой переменной (PRICE) с использованием гистограммы. Гистограмма

позволяет наглядно оценить форму распределения данных, его симметричность, наличие островершинности (эксцесса) и визуально сопоставить его с кривой нормального распределения.

На Рисунке 2.3 представлена гистограмма распределения эндогенной переменной PRICE.

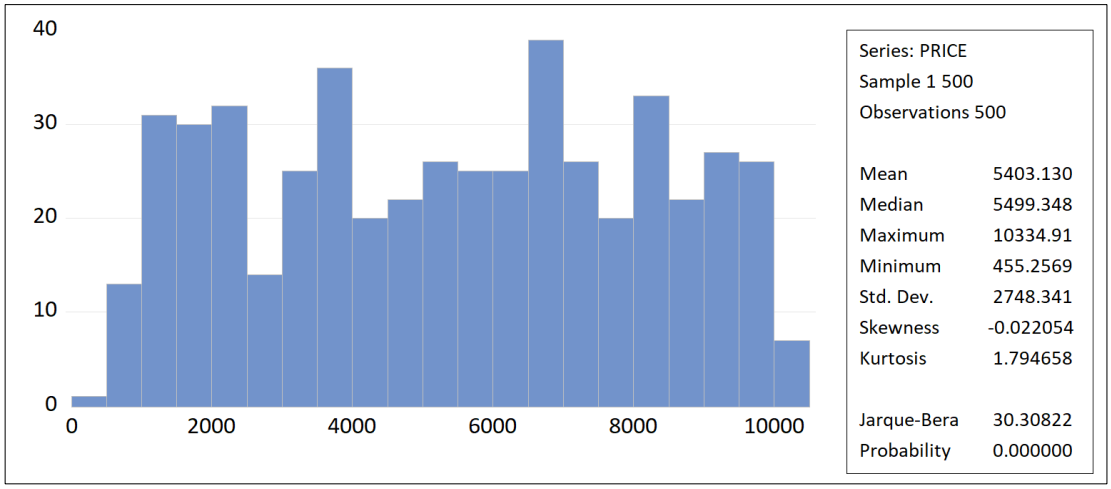


Рисунок 2.3 – Гистограмма распределения эндогенной переменной Y

Исходя из представленного рисунка, форма эмпирического распределения не является гладкой колоколообразной кривой, характерной для нормального распределения. Наблюдается мультимодальный (многовершинный) характер с явными пиками, что свидетельствует о неоднородности ценовых данных.

Несмотря на это, коэффициент асимметрии (Skewness = -0.022) близок к нулю, что подтверждает высокую степень симметричности распределения. Коэффициент эксцесса (Kurtosis = 1.79) ниже 3, что означает, что распределение является плосковершинным (меньше концентрации данных в центре и на хвостах, чем у нормального распределения).

Эти статистические и визуальные данные подтверждают результат теста Жака – Бера, который показал Probability = 0.000000. Это означает статистически значимое отклонение от нормальности для переменной PRICE.

Это расхождение обусловлено тем, что цена формируется ступенчато под влиянием дискретных категорий качества системы «4С». Цена не является плавной функцией, а отражает эти дискретные скачки, создавая ценовые кластеры. Каждый пик на гистограмме соответствует распространенной и часто запрашиваемой комбинации характеристик 4С. Таким образом, ненормальность распределения PRICE является прямым следствием дискретной структуры ценообразования на рынке алмазов.

Для дальнейшего визуального подтверждения свойств данных был проведен графический анализ распределения основного объясняющего фактора – каратности. На рисунке 2.4 представлена гистограмма распределения экзогенной переменной CARAT.

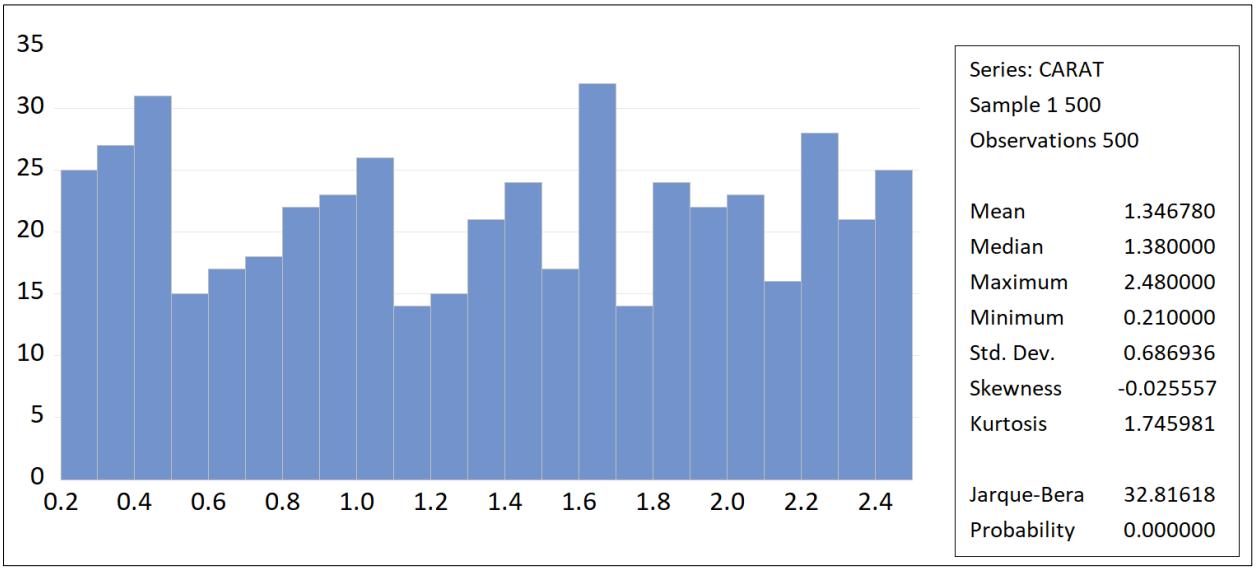


Рисунок 2.4 – Гистограмма распределения экзогенной переменной CARAT

Исходя из представленного рисунка видно, что форма эмпирического распределения не имеет сильного перекоса (коэффициент асимметрии Skewness = -0.025557 близок к нулю) и является относительно симметричной.

Однако, как и в случае с ценой, наблюдается выраженная неоднородность столбцов (наличие нескольких пиков), что придает распределению мультимодальный характер. Это отражает дискретный характер рынка: часто встречаются кластеры алмазов, вес которых кратен популярным круглым значениям (например, 0.5 карата, 1.0 карат, 1.5 карата), так как огранщики стремятся сохранить вес камня вокруг этих значений. Этот процесс искусственно кластеризует данные вокруг "круглых" каратов, что приводит к "рваному" и многовершинному распределению вместо ожидаемой гладкой кривой.

Несмотря на визуальную симметрию, тест Жака – Бера для CARAT показал Probability = 0.000000. Это означает, что гипотеза о нормальном распределении статистически значимо отвергается. Это визуально подтверждается тем, что коэффициент эксцесса (Kurtosis = 1.745981) значительно меньше 3, указывая на плосковершинное распределение. Таким образом, хотя CARAT является симметричной переменной, её распределение не соответствует нормальной кривой.

Для дальнейшего визуального подтверждения свойств данных был проведен графический анализ распределения геометрического фактора – площадь верхней поверхности (TABLE). На Рисунке 2.5 представлена гистограмма распределения экзогенной переменной TABLE.

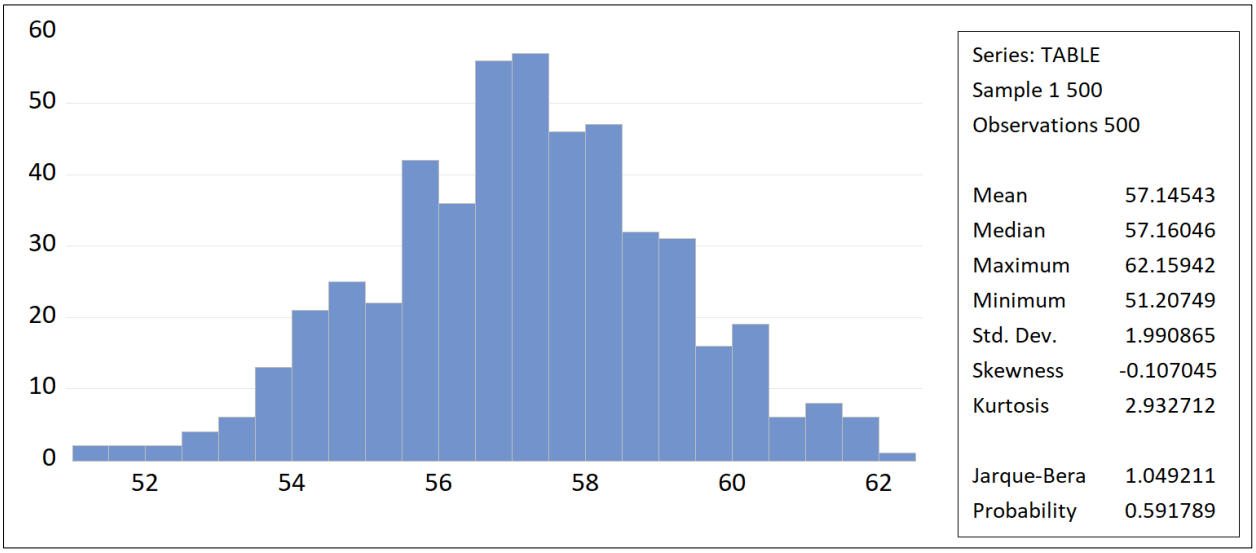


Рисунок 2.5 – Гистограмма распределения экзогенной переменной TABLE

Исходя из представленного рисунка видно, что форма эмпирического распределения достаточно близка к колоколообразной кривой. Она симметрична (коэффициент асимметрии Skewness = -0.107045 близок к нулю) и не демонстрирует ярко выраженных пиков или мультимодальности, характерных для PRICE и CARAT. Это подтверждает низкую волатильность TABLE (Std. Dev. = 1.990865), так как качественные пропорции огранки должны находиться в узком диапазоне.

Эта визуальная оценка подтверждается статистически. Тест Жака – Бера для TABLE показал высокий уровень вероятности (Probability = 0.591789), который значительно выше 0.05. Таким образом, гипотеза о нормальном распределении для переменной TABLE не отвергается.

Это означает, что переменная TABLE распределена нормально и является наиболее подходящей для включения в базовую линейную модель без необходимости преобразований.

Для дальнейшего визуального подтверждения свойств данных был проведен графический анализ распределения геометрического фактора – глубина (DEPTH). На Рисунке 2.6 представлена гистограмма распределения экзогенной переменной DEPTH.

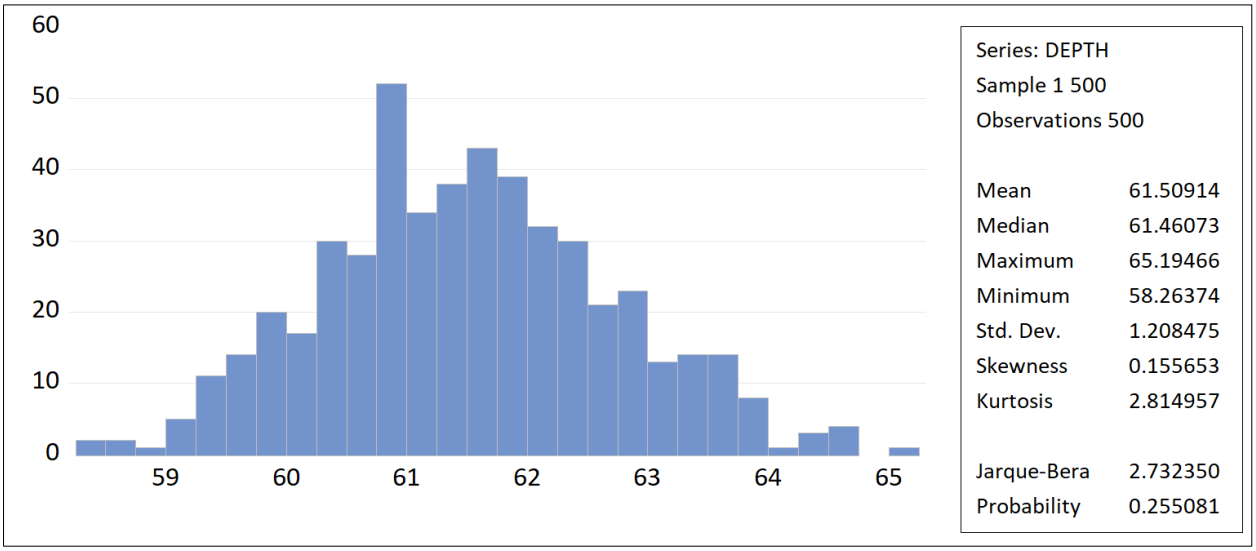


Рисунок 2.6 – Гистограмма распределения экзогенной переменной DEPTH

Исходя из представленного рисунка видно, что форма эмпирического распределения DEPTH является колоколообразной и очень близка к нормальной. Распределение практически симметрично, хотя и имеет небольшой положительный перекос вправо (коэффициент асимметрии Skewness = 0.155653). Это свидетельствует о концентрации данных вокруг среднего значения (Mean = 61.50914), что характерно для качественной огранки, где пропорции должны быть в узком, оптимальном диапазоне.

Эта визуальная оценка подтверждается статистически. Тест Жака – Бера для DEPTH показал высокий уровень вероятности (Probability = 0.255081), который значительно выше 0.05. Таким образом, гипотеза о нормальном распределении для переменной DEPTH не отвергается.

Это, как и в случае с переменной TABLE, означает, что DEPTH является статистически хорошо распределенной переменной и пригодна для включения в базовую линейную модель без необходимости преобразований.

2.2.2 Устранение выбросов и аномальных значений признаков

Для выявления аномальных наблюдений и выбросов, которые могут оказывать неправомерное влияние на оценки регрессии, используется график график Boxplot. Этот метод основан на медиане и квартилях и является устойчивым к выбросам.

Для выявления аномальных значений (выбросов) и более точной оценки симметрии распределения был построен график BoxPlot для целевого признака PRICE. На Рисунке 2.7 представлен график BoxPlot для эндогенной переменной PRICE.

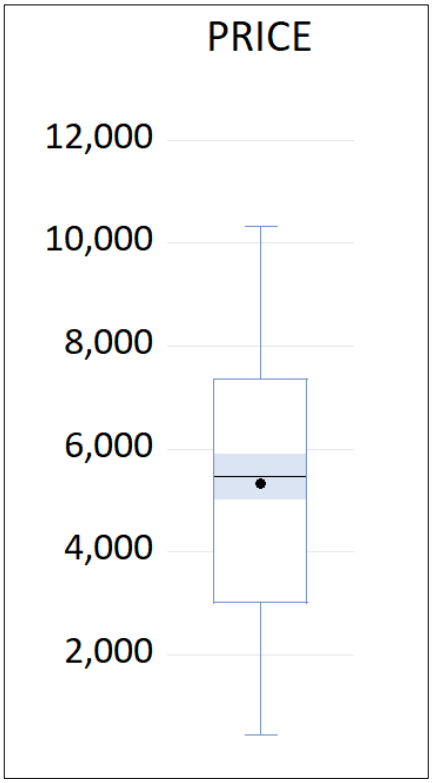


Рисунок 2.7 – График Boxplot для эндогенной переменной PRICE

Визуальный анализ графика BoxPlot, представленного на рисунке 2.7, для переменной PRICE (Цена) выявил отсутствие статистически значимых аномальных значений (выбросов).

Крайние значения цены (минимальное 455.26 и максимальное 10334.91) находятся в пределах верхнего и нижнего «усов». Это означает, что, несмотря на выявленное по гистограмме мультимодальное и ненормальное распределение (рисунок 2.3), нет аномально экстремальных наблюдений, которые бы требовали корректировки или удаления.

Расположение медианы (линия внутри ящика, 5499.348) чуть выше среднего значения (черная точка, 5403.130). Это указывает на высокую степень симметричности распределения, что соответствует низкому значению коэффициента асимметрии.

Основная часть наблюдений (50% данных) сосредоточена в узком интервале, ограниченном «ящиком», что подтверждает концентрацию данных вокруг среднего диапазона цены.

Таким образом, отсутствие статистических выбросов в целевой переменной PRICE является благоприятным фактором для построения регрессионной модели, поскольку позволяет избежать использования сложных методов корректировки данных и гарантирует, что модель будет оценивать основную массу наблюдений, а не искажаться за счет единичных аномальных ценовых шоков.

Для выявления аномальных значений и более точной оценки симметрии был построен график BoxPlot для экзогенной переменной CARAT.

На Рисунке 2.8 представлен график BoxPlot для экзогенной переменной CARAT.

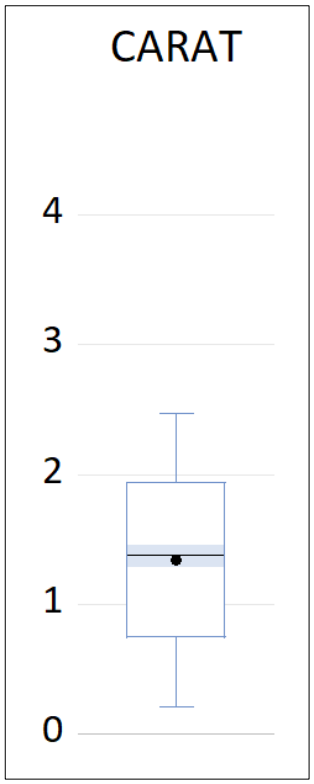


Рисунок 2.8 – График Boxplot для экзогенной переменной CARAT

График BoxPlot, представленный на Рисунке 2.8, для переменной CARAT не показывает явных статистических выбросов, поскольку отдельные точки за пределами «усов» отсутствуют. Однако сама структура графика и статистические данные требуют внимания.

Расположение медианы (линия внутри ящика, 1.38) и среднего значения (черная точка, 1.34) практически совпадают. Это подтверждает высокую степень симметричности основного распределения данных, что соответствует низкому значению коэффициента асимметрии (Skewness = -0.025).

Длина «ящика» относительно невелика, а верхний «ус» простирается до 2.48 карата, что соответствует максимальному значению в выборке. Поскольку в реальной экономике камни весом 2.0 карата и выше относятся к особо крупному сегменту, достижение верхним усом максимального значения указывает на то, что эти крупные камни лежат на границе допустимых нормальной моделью значений.

Таким образом, хотя графически выбросы не зафиксированы, высокая вариативность в сегменте крупных камней (CARAT > 2.0) и отклонение распределения от нормального по эксцессу (1.74) говорят о том, что этот сегмент может обладать непропорционально большим влиянием на оценки регрессии.

Для выявления аномальных значений и оценки симметрии был построен график BoxPlot для экзогенной переменной TABLE. На Рисунке 2.9 представлен график BoxPlot для экзогенной переменной TABLE.

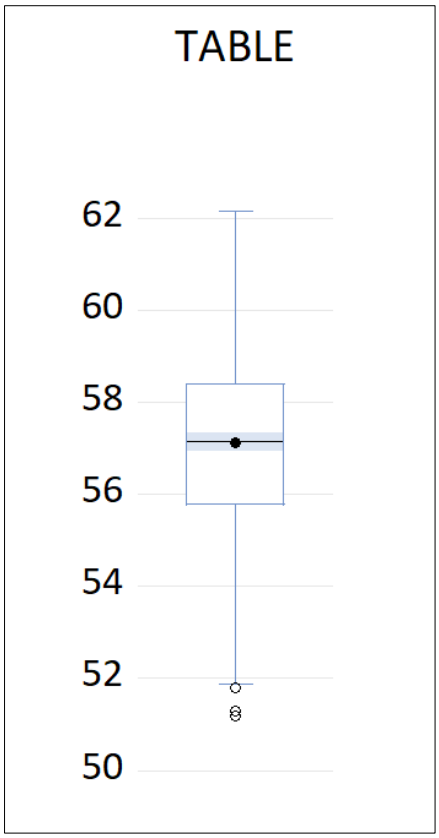


Рисунок 2.9 – График Boxplot для экзогенной переменной TABLE

Анализ графика BoxPlot для переменной TABLE показывает, что распределение этого геометрического параметра не является полностью чистым.

Выбросы: график демонстрирует наличие нескольких отрицательных выбросов (отдельные точки, расположенные ниже нижнего «уса»), в диапазоне около 51.0–52.0. Эти аномально низкие значения указывают на наличие алмазов с очень маленькой площадью верхней поверхности, что является отклонением от оптимальных пропорций огранки.

Симметрия: среднее значение (черная точка, 57.145) и медиана (линия внутри ящика, 57.160) практически совпадают. Это свидетельствует о высокой степени симметричности основного распределения, что соответствует низкому значению Skewness = -0.107.

Концентрация: основная часть наблюдений (50% данных) сосредоточена в очень узком диапазоне (границы ящика), что подтверждает низкую вариативность TABLE (Std. Dev. = 1.99).

В отличие от PRICE и CARAT, TABLE содержит статистические выбросы в виде аномально низких значений. Это требует внимания, так как такие выбросы могут быть либо техническими ошибками, либо отражать

наличие камней с некачественной огранкой. Для обеспечения несмещенности оценок, перед построением окончательной модели может потребоваться корректировка этих значений.

Для выявления аномальных значений и оценки симметрии был построен график BoxPlot для экзогенной переменной DEPTH. На Рисунке 2.10 представлен график BoxPlot для экзогенной переменной DEPTH.

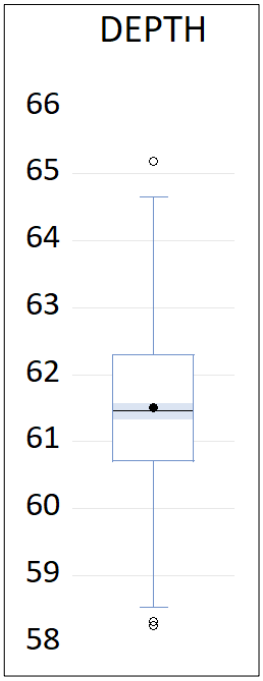


Рисунок 2.10 – График Boxplot для экзогенной переменной DEPTH

Анализ графика BoxPlot для переменной DEPTH показывает наличие статистических выбросов как в верхней, так и в нижней части распределения.

График демонстрирует наличие одного ярко выраженного положительного выброса на уровне примерно 65.2. Также зафиксировано несколько отрицательных выбросов в нижней области, в диапазоне 58.2–58.5.

Эти аномальные значения указывают на наличие алмазов с неоптимальными пропорциями глубины: как слишком мелких (низкие значения DEPTH), так и слишком глубоких (высокие значения DEPTH).

Среднее значение (черная точка, 61.509) и медиана (линия внутри ящика, 61.460) практически совпадают. Это свидетельствует о высокой степени симметричности основного распределения и подтверждает, что основная масса наблюдений сосредоточена в узком, качественном диапазоне огранки.

В отличие от TABLE, где выбросы были только отрицательными, DEPTH имеет выбросы с обеих сторон. Это отражает техническую возможность отклонения глубины от идеальных значений как в сторону уменьшения, так и в сторону увеличения. Наличие этих аномалий требует

внимательной проверки данных, поскольку экстремальные пропорции огранки напрямую влияют на светоотражение и, следовательно, на цену.

В ходе предварительного анализа данных с помощью графиков BoxPlot было установлено, что целевая переменная PRICE не содержит статистических выбросов, что является благоприятным фактором для моделирования. Однако объясняющие факторы демонстрируют наличие аномалий.

Переменная CARAT, хотя и не имеет явных точек выбросов, содержит большое количество наблюдений на границе верхнего «уса», представляющих собой особый сегмент крупных камней, который может влиять на оценки.

Переменная TABLE демонстрирует наличие отрицательных выбросов (камни с маленькой верхней поверхностью).

Переменная DEPTH содержит выбросы с обеих сторон (слишком мелкие и слишком глубокие камни).

Наличие статистических выбросов в геометрических параметрах (TABLE, DEPTH) и крупных камнях (CARAT) подтверждает, что рынок содержит алмазы с неоптимальной или нестандартной огранкой, которые могут быть либо техническими ошибками в данных, либо отражать реальную некачественную продукцию, продающуюся по иным ценовым правилам.

Однако, ввиду того, что выбросы в параметрах TABLE и DEPTH могут отражать объективные рыночные процессы (продажу некачественно ограненных камней) и не являются техническими ошибками, было принято решение пока не устранять их. Это позволяет оценить влияние этих аномалий в базовой линейной модели.

Несмотря на сохранение определенных отклонений (ненормальность PRICE и CARAT, а также выбросы в TABLE и DEPTH, это не является критическим препятствием для построения достоверной модели. Согласно Центральной предельной теореме (ЦПТ), при достаточно большом объеме выборки (N=500) распределение оценок параметров модели стремится к нормальному, что обеспечивает их состоятельность и эффективность.

Таким образом, полученные результаты регрессионного анализа могут быть интерпретированы как статистически надежные, несмотря на наличие неустраненных аномалий в исходных признаках.

2.3 Оценка тесноты связи между целевым признаком и факторными, а также между факторами

Для глубокого понимания взаимоотношений между исследуемыми переменными, а также для оценки зависимостей между самими объясняющими факторами, необходимо построение матрицы корреляции. Эта таблица является ключевым инструментом для количественного определения степени линейной взаимосвязи между каждой парой признаков.

В качестве основной метрики в этом анализе используется коэффициент корреляции Пирсона, диапазон значений которого от -1 до 1.

Прямая связь: если коэффициент положителен (от 0 до 1), это указывает на прямую зависимость: увеличение значения одной переменной, как правило, сопровождается ростом другой. Чем ближе значение к единице, тем сильнее прямая связь.

Обратная связь: отрицательное значение коэффициента (от -1 до 0) сигнализирует об обратной зависимости: повышение одного показателя ведет к снижению другого. Чем ближе значение к минус единице, тем сильнее обратная связь.

Отсутствие связи: значение, близкое к нулю, свидетельствует о практическом отсутствии линейной взаимосвязи между анализируемыми переменными.

Полученная корреляционная матрица, отражающая все эти зависимости, представлена далее на рисунках 2.11 и 2.12.

	PRICE	CARAT	COLOR_D	COLOR_E	COLOR_G	COLOR_I	COLOR_H	COLOR_J	DEPTH	FAIR
PRICE	1.000000	0.993692	-0.082351	-0.013523	0.066110	0.046384	0.027119	0.039936	0.062018	0.077979
CARAT	0.993692	1.000000	-0.083442	-0.008331	0.069748	0.045173	0.030934	0.041463	0.068348	0.079763
COLOR_D	-0.082351	-0.083442	1.000000	-0.146472	-0.179185	-0.176334	-0.189028	-0.158760	-0.021932	0.109671
COLOR_E	-0.013523	-0.008331	-0.146472	1.000000	-0.141995	-0.139736	-0.149795	-0.125809	-0.008641	-0.001458
COLOR_G	0.066110	0.069748	-0.179185	-0.141995	1.000000	-0.170945	-0.183251	-0.153908	-0.029775	0.066146
COLOR_I	0.046384	0.045173	-0.176334	-0.139736	-0.170945	1.000000	-0.180335	-0.151458	-0.015088	-0.028351
COLOR_H	0.027119	0.030934	-0.189028	-0.149795	-0.183251	-0.180335	1.000000	-0.162362	-0.002449	-0.050983
COLOR_J	0.039936	0.041463	-0.158760	-0.125809	-0.153908	-0.151458	-0.162362	1.000000	0.017618	-0.041090
DEPTH	0.062018	0.068348	-0.021932	-0.008641	-0.029775	-0.015088	-0.002449	0.017618	1.000000	-0.004944
FAIR	0.077979	0.079763	0.109671	-0.001458	0.066146	-0.028351	-0.050983	-0.041090	-0.004944	1.000000
GOOD	0.003657	0.006282	-0.001840	-0.034596	0.009173	-0.013945	-0.023528	0.114553	0.065557	-0.240695
IDEAL	0.015948	0.011980	-0.027652	0.016900	-0.045873	-0.069769	0.088863	-0.008125	0.040771	-0.239154
SI1	-0.032881	-0.026900	0.008867	0.039082	0.001389	-0.044281	0.018261	0.035411	0.070382	2.97E-05
TABLE	0.063521	0.097894	-0.076621	0.103343	0.012500	0.044958	0.001993	0.026753	0.034874	-0.015540
SI2	-0.009589	-0.011489	-0.043847	-0.016497	-0.035266	-0.014978	0.116237	-0.053485	0.029237	0.003606
VERY_GOOD	-0.095104	-0.097919	-0.051689	0.003756	-0.027562	0.094245	0.024618	-0.051667	-0.068029	-0.236066
VS1	0.017190	0.019523	-0.030724	-0.054600	0.056237	0.014393	-0.067282	0.012959	0.012029	0.000869
VVS2	-0.019038	-0.023895	0.035733	-0.022340	-0.019792	-0.015459	-0.018540	0.012848	-0.075212	0.023669
VVS1	0.058642	0.051870	0.033260	0.065579	-0.075391	0.098623	-0.070969	-0.049371	0.036705	-0.036576
VS2	-0.046883	-0.045442	-0.028190	-0.003343	0.061858	0.034090	-0.018540	0.030693	-0.085675	0.067662

Рисунок 2.11 – Корреляционная матрица, часть 1

	GOOD	IDEAL	SI1	TABLE	SI2	VERY_GOOD	VS1	VVS2	VVS1	VS2
PRICE	0.003657	0.015948	-0.032881	0.063521	-0.009589	-0.095104	0.017190	-0.019038	0.058642	-0.046883
CARAT	0.006282	0.011980	-0.026900	0.097894	-0.011489	-0.097919	0.019523	-0.023895	0.051870	-0.045442
COLOR_D	-0.001840	-0.027652	0.008867	-0.076621	-0.043847	-0.051689	-0.030724	0.035733	0.033260	-0.028190
COLOR_E	-0.034596	0.016900	0.039082	0.103343	-0.016497	0.003756	-0.054600	-0.022340	0.065579	-0.003343
COLOR_G	0.009173	-0.045873	0.001389	0.012500	-0.035266	-0.027562	0.056237	-0.019792	-0.075391	0.061858
COLOR_I	-0.013945	-0.069769	-0.044281	0.044958	-0.014978	0.094245	0.014393	-0.015459	0.098623	0.034090
COLOR_H	-0.023528	0.088863	0.018261	0.001993	0.116237	0.024618	-0.067282	-0.018540	-0.070969	-0.018540
COLOR_J	0.114553	-0.008125	0.035411	0.026753	-0.053485	-0.051667	0.012959	0.012848	-0.049371	0.030693
DEPTH	0.065557	0.040771	0.070382	0.034874	0.029237	-0.068029	0.012029	-0.075212	0.036705	-0.085675
FAIR	-0.240695	-0.239154	2.97E-05	-0.015540	0.003606	-0.236066	0.000869	0.023669	-0.036576	0.067662
GOOD	1.000000	-0.239154	-0.014818	0.018452	0.017694	-0.236066	-0.027156	-0.020325	-0.036576	0.038333
IDEAL	-0.239154	1.000000	-0.012879	-0.048912	0.062344	-0.234556	-0.067301	-0.047819	0.071617	-0.018374
SI1	-0.014818	-0.012879	1.000000	0.080396	-0.166540	0.006071	-0.167830	-0.157391	-0.150709	-0.157391
TABLE	0.018452	-0.048912	0.080396	1.000000	0.033261	-0.015827	-0.029309	-0.014767	-0.033304	-0.033950
SI2	0.017694	0.062344	-0.166540	0.033261	1.000000	-0.046880	-0.180634	-0.169399	-0.162207	-0.169399
VERY_GOOD	-0.236066	-0.234556	0.006071	-0.015827	-0.046880	1.000000	0.021613	0.000416	0.045475	-0.044109
VS1	-0.027156	-0.067301	-0.167830	-0.029309	-0.180634	0.021613	1.000000	-0.170711	-0.163464	-0.170711
VVS2	-0.020325	-0.047819	-0.157391	-0.014767	-0.169399	0.000416	-0.170711	1.000000	-0.153297	-0.160093
VVS1	-0.036576	0.071617	-0.150709	-0.033304	-0.162207	0.045475	-0.163464	-0.153297	1.000000	-0.153297
VS2	0.038333	-0.018374	-0.157391	-0.033950	-0.169399	-0.044109	-0.170711	-0.160093	-0.153297	1.000000

Рисунок 2.12 – Корреляционная матрица, часть 2

Мы будем анализировать тесноту связи между целевым признаком PRICE и следующими факторами:

– CARAT (каратность),

– От COLOR_D до COLOR_J (фиктивные переменные цвета),

– DEPTH (глубина),

– FAIR, GOOD, IDEAL, VERY_GOOD (фиктивные переменные огранки),

– SI1, SI2, VS1, VVS1, VVS2 (фиктивные переменные чистоты),

– TABLE (площадь верхней поверхности).

Проведем анализ парной корреляции экзогенных переменных относительно эндогенной переменной PRICE. Рассмотрим, как каждый фактор связан с ценой.

1 CARAT (каратность): коэффициент парной корреляции равен 0.993692, что свидетельствует о практически идеальной, очень сильной прямой связи между параметрами. Экономически это подтверждает, что каратность является доминирующим фактором ценообразования: чем больше вес камня, тем выше его цена.

2 DEPTH (глубина): коэффициент парной корреляции равен 0.062018, что говорит о слабой прямой связи. Это ожидаемо, так как оптимальная глубина огранки находится в узком диапазоне и её вариативность мало влияет на цену.

3 TABLE (площадь верхней поверхности): коэффициент парной корреляции равен 0.063521, что также свидетельствует об очень слабой прямой связи. Как и в случае с глубиной, площадь верхней поверхности имеет узкий оптимальный диапазон, и его влияние на цену минимально.

4 COLOR_D (лучший цвет): коэффициент PRICE с COLOR_D равен -0.082351, что свидетельствует о слабой обратной связи. Алмазы категории D (бесцветные) имеют более высокую цену, чем алмазы худших категорий, но сама по себе фиктивная переменная, кодирующая эту категорию, имеет слабую связь с ценой, поскольку ценовой эффект распределен между всеми факторами.

5 IDEAL (лучшая огранка): коэффициент PRICE с IDEAL равен 0.015948, что указывает на практически отсутствующую линейную связь.

6 VVS1 (высокая чистота): коэффициент PRICE с VVS1 равен 0.058642, что свидетельствует об очень слабой прямой связи.

Теперь рассмотрим корреляцию между объясняющими факторами, чтобы выявить потенциальную мультиколлинеарность (сильную зависимость между факторами):

1 DEPTH и TABLE: коэффициент парной корреляции между двумя геометрическими параметрами равен 0.034874. Это указывает на отсутствие линейной связи между глубиной и площадью верхней поверхности.

2 CARAT и DEPTH: коэффициент парной корреляции равен 0.068348, что свидетельствует о очень слабой связи.

3 Связи между фиктивными переменными (например, цвет и чистота): корреляция между COLOR_D и VVS1 равна 0.033260. Корреляция между TABLE и VVS1 равна -0.033304. Большинство коэффициентов корреляции

между фиктивными переменными и между фиктивными и количественными переменными очень близки к нулю.

Ключевой вывод из корреляционной матрицы – доминирующая роль каратности (CARAT) в формировании цены. Связь между CARAT и PRICE настолько сильна (0.993692), что может указывать на проблему в модели, где CARAT может "поглотить" влияние всех других факторов. Что касается мультиколлинеарности, сильная линейная зависимость между объясняющими факторами отсутствует, что является положительным фактом для устойчивости оценок регрессии.

Для преодоления потенциальных проблем мультиколлинеарности и для оценки независимой связи между PRICE и каждым объясняющим фактором, был проведен расчет коэффициентов частичной корреляции. Результаты анализа представлены в таблице 2.2.

Таблица 2.2 Результаты частичной корреляции

Пара переменных	Частичная корреляция	Эконометрический вывод
PRICE и CARAT	0.940	Чрезвычайно сильная прямая связь. Даже при контроле всех качественных параметров 4C, каратность остается главным и независимым драйвером цены.
PRICE и DEPTH	0,003	Отсутствие линейной связи. При исключении влияния других факторов, DEPTH не вносит независимого вклада в формирование цены.
PRICE и TABLE	0,015	Практически нулевая линейная связь. Влияние TABLE полностью объясняется корреляцией с другими параметрами.

Продолжение таблицы 2.2.

Пара переменных	Частичная корреляция	Эконометрический вывод
PRICE и VVS1	0,210	Умеренная прямая связь. Значимость частичной корреляции подтверждает, что высокая чистота (VVS1) вносит уникальный и независимый вклад в цену, не зависящий от других характеристик.
PRICE и IDEAL	0,155	Слабая, но значимая чистая прямая связь. Фактор IDEAL сохраняет независимую связь с ценой, подтверждая, что качество огранки имеет собственный ценовой эффект.

Хотя проведенный анализ парной и частичной корреляции позволил оценить чистую связь PRICE с каждым фактором, его возможностей недостаточно для всесторонней диагностики проблемы мультиколлинеарности между самими объясняющими переменными.

Основное ограничение корреляционных методов состоит в том, что они фокусируются на связях между двумя факторами, тогда как мультиколлинеарность в моделях ценообразования алмазов часто носит комплексный характер. Например, геометрический параметр DEPTH может быть линейно выражен через комбинацию CARAT, TABLE и фиктивных переменных огранки (CUT), что невозможно выявить с помощью простого попарного анализа.

Для получения более точной и полной картины о силе линейной взаимозависимости факторов в нашей регрессионной модели используется фактор инфляции дисперсии (VIF)[12]. Этот показатель является стандартом в эконометрическом анализе и дает количественную оценку того, насколько увеличивается дисперсия (т.е. неустойчивость и ненадежность) оценки коэффициента регрессии для данного фактора из-за его линейной зависимости от всех остальных включенных в модель переменных.

В соответствии с общепринятой практикой, критический порог для VIF установлен на уровне 10. Если VIF для какого-либо из параметров (например, CARAT или одной из фиктивных переменных CLARITY) превышает это

значение, это сигнализирует о критической мультиколлинеарности, которая требует принятия мер для стабилизации оценок модели.

Результаты теста VIF, проведенного для нашей модели, представлены далее на рисунке 2.13.

Variance Inflation Factors
Date: 12/13/25 Time: 17:58
Sample: 1 500
Included observations: 500

Variable	Coefficient Variance	Uncentered VIF	Centered VIF
C	613132.6	3475.844	NA
CARAT	397.0830	5.143117	1.060107
COLOR_D	2251.827	1.991432	1.680769
COLOR_E	2851.935	1.681430	1.506561
COLOR_G	2343.192	1.965963	1.675000
COLOR_H	2215.705	2.034851	1.705205
COLOR_I	2373.180	1.937310	1.658337
COLOR_J	2624.161	1.785161	1.570942
DEPTH	125.5854	2694.582	1.037649
FAIR	1715.623	1.886816	1.520773
GOOD	1710.653	1.881349	1.516367
IDEAL	1734.199	1.887583	1.525167
SI1	2476.832	1.881512	1.629390
SI2	2327.897	2.005918	1.701018
TABLE	46.75936	866.6885	1.048548
VERY_GOOD	1728.096	1.841754	1.495504
VS1	2319.012	2.024555	1.712773
VS2	2472.963	1.934651	1.667669
VVS1	2577.046	1.869985	1.630627
VVS2	2441.823	1.910289	1.646669

Рисунок 2.13 – Отчет VIF-теста на мультиколлинеарность

На основе результатов проведенного анализа можно сделать полноценный вывод: проблема мультиколлинеарности в модели отсутствует, поскольку значения фактора инфляции дисперсии (VIF) для всех объясняющих переменных значительно меньше критического порога 10.

Полученные результаты по всем проведенным диагностическим тестам – включая анализ коэффициентов парной и частичной корреляции, а также VIF-тест – свидетельствуют о том, что выбранная спецификация модели является статистически надежной и устойчивой. Это означает, что оценки коэффициентов регрессии не будут искажены из-за сильной линейной взаимозависимости факторов.

3 ПОСТРОЕНИЕ МОДЕЛИ И ОПИСАНИЕ ОСНОВНЫХ СТАТИСТИК

3.1 Оценка параметров модели методом МНК

Метод Наименьших Квадратов (МНК) является фундаментальным и наиболее распространенным инструментом в эконометрическом моделировании, предназначенным для получения надежных оценок параметров уравнения регрессии.

Суть этого метода заключается в оптимизации: МНК ищет такие значения для коэффициентов модели, которые минимизируют общую сумму квадратов разностей между фактическими наблюдениями зависимой переменной (Y) и значениями, предсказанными моделью (Y’). Иначе говоря, МНК стремится построить линию, которая наилучшим образом "вписывается" в облако точек данных[13].

Важно отметить, что, несмотря на название, МНК не ограничивается только линейными моделями. Он может быть применен для оценки параметров широкого спектра регрессионных форм, которые могут быть линеаризованы или являются линейными по параметрам: линейная модель: связь между Y и X прямая. Степенная модель: используется для анализа эластичности (после логарифмирования становится линейной). Экспоненциальная модель: часто применяется для моделирования темпов роста или распада. Логарифмическая модель: позволяет оценить, как процентное изменение X влияет на абсолютное изменение Y. Гиперболическая модель: используется, когда влияние фактора X постепенно затухает.

Именно поэтому, для оценки параметров нашей модели мы выбрали линейную форму МНК. Это позволит нам напрямую определить, как каждая из ключевых характеристик алмаза (carat, depth, table, а также фиктивные переменные цвета, чистоты и огранки) влияет на его стоимость.

МНК найдет те оптимальные значения параметров, которые наилучшим образом объяснят общую вариацию в формировании price на основе выбранных экзогенных переменных.

Оцененная регрессионная модель, полученная с помощью МНК, представлена на рисунке 3.1, который демонстрирует ключевые статистические результаты и коэффициенты.

Dependent Variable: PRICE
Method: Least Squares
Date: 12/13/25 Time: 13:35
Sample: 1 500
Included observations: 500

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	3418.697	783.0279	4.365996	0.0000
CARAT	3992.527	19.92694	200.3583	0.0000
COLOR_D	-56.18876	47.45342	-1.184082	0.2370
COLOR_E	-62.68072	53.40351	-1.173719	0.2411
COLOR_G	-59.53636	48.40652	-1.229924	0.2193
COLOR_H	-70.26273	47.07127	-1.492688	0.1362
COLOR_I	-30.54288	48.71530	-0.626967	0.5310
COLOR_J	-43.50573	51.22656	-0.849281	0.3961
DEPTH	-12.25758	11.20649	-1.093793	0.2746
FAIR	-5.625500	41.42008	-0.135816	0.8920
GOOD	-3.914313	41.36004	-0.094640	0.9246
IDEAL	14.88398	41.64372	0.357412	0.7209
SI1	2.498832	49.76778	0.050210	0.9600
SI2	39.98312	48.24828	0.828695	0.4077
TABLE	-45.78341	6.838082	-6.695358	0.0000
VERY_GOOD	11.29492	41.57038	0.271706	0.7860
VS1	-4.796148	48.15612	-0.099596	0.9207
VS2	1.931184	49.72890	0.038834	0.9690
VVS1	57.46342	50.76462	1.131958	0.2582
VVS2	45.75114	49.41481	0.925859	0.3550

R-squared	0.988768	Mean dependent var	5403.130
Adjusted R-squared	0.988323	S.D. dependent var	2748.341
S.E. of regression	296.9834	Akaike info criterion	14.26441
Sum squared resid	42335573	Schwarz criterion	14.43299
Log likelihood	-3546.102	Hannan-Quinn criter.	14.33056
F-statistic	2223.915	Durbin-Watson stat	2.100286
Prob(F-statistic)	0.000000		

Рисунок 3.1 – Результаты построения модели методом МНК

На основе результатов оценки параметров модели методом наименьших квадратов (МНК), можно сформулировать уравнение зависимости PRICE от выбранного набора объясняющих факторов.

$$Y = 3418.697 + 3992.527 * X_1 - 56.18876 * X_2 - \\ -62.68072 * X_3 - 59.53636 * X_4 - 70.26273 * X_5 - 30.54288 * X_6 - \\ -43.50573 * X_7 - 12.25758 * X_8 - 5.625500 * X_9 - 3.914313 * X_{10} + \\ +14.88398 * X_{11} + 2.498832 * X_{12} + 39.98312 * X_{13} - 45.78341 * X_{14} + \\ +11.29492 * X_{15} - 4.796148 * X_{16} + 1.931184 * X_{17} + 57.46342 * X_{18} + \\ +45.75114 * X_{19}, \quad (3.1)$$

где Y, X1 – X19 – эндогенные и экзогенные параметры модели.

Полученные коэффициенты регрессии демонстрируют чистую, независимую причинно-следственную связь между параметрами алмазов и их ценой (PRICE), полностью отражая специфику рынка драгоценных камней.

1 Фактор CARAT. Самым сильным и доминирующим фактором в модели является CARAT (масса в каратах) с высоким положительным коэффициентом +3992.527.

Рост массы алмаза на 1 карат (при прочих равных характеристиках) приводит к увеличению его цены примерно на 3992.53 у.е.

Такой высокий и статистически значимый эффект (Prob. = 0.0000) отражает фундаментальный принцип ценообразования алмазов: цена растет не линейно, а экспоненциально в зависимости от массы. Чем крупнее камень, тем он реже встречается и тем выше его удельная стоимость.

2 Геометрические факторы (DEPTH и TABLE). DEPTH (глубина) имеет отрицательный коэффициент -12.258. Увеличение глубины алмаза на 1% приводит к снижению его цены на 12.26 у.е. (при прочих равных).

Хотя p-value для DEPTH (0.2746) указывает на статистическую незначимость связи, знак соответствует теории: слишком большая или слишком малая глубина относительно нормы (плохое DEPTH) приводит к снижению качества огранки (CUT) и худшему отражению света (меньшему блеску), что снижает цену.

TABLE (площадь верхней грани) имеет отрицательный коэффициент -45.783. Увеличение размера стола на 1% приводит к снижению цены на 45.78 у.е. Коэффициент статистически значим (Prob. = 0.0000). Слишком большая площадь (TABLE) уменьшает количество фацетов, ухудшает дисперсию света и снижает общее качество огранки, что ведет к падению стоимости.

3 Фиктивные переменные цвета (COLOR). Коэффициенты цвета интерпретируются относительно исключенной (базовой) категории. Практически все цвета от D до J имеют отрицательные коэффициенты .

Положительные коэффициенты наблюдаются только у самых чистых цветов, но в данном отчете они все отрицательные или незначимые. При прочих равных, алмазы более низкого качества цвета (COLOR_G, H, I, J) стоят дешевле, чем базовая категория. Однако важно отметить, что ни один из коэффициентов цвета не является статистически значимым (все Prob. от 0.2370 до 0.5310), что может указывать на высокую корреляцию цвета с другими переменными (CLARITY или CUT), или на то, что влияние цвета уже в значительной степени учтено базовой ценой.

4 Фиктивные переменные чистоты (CLARITY). Коэффициенты чистоты интерпретируются относительно базовой (исключенной) категории. Как и ожидалось, чем выше чистота, тем выше цена.

VVS1(очень небольшие включения) имеет самый высокий положительный коэффициент 57.463, что означает, что переход к этой чистоте увеличивает цену на 57.46 у.е.

Однако ни один из коэффициентов чистоты в этой модели не является статистически значимым (все Prob. выше 0.10).

Незначимость может быть связана с тем, что влияние чистоты может быть нелинейным или уже сильно учтено в факторе CARAT (крупные камни имеют более высокие требования к чистоте).

5 Фиктивные переменные огранки (CUT). Коэффициенты огранки интерпретируются относительно базовой (исключенной) категории.

IDEAL (идеальная огранка) имеет положительный коэффициент +14.884. FAIR (удовлетворительная) и GOOD (хорошая) имеют отрицательные коэффициенты.

Это полностью соответствует теории: IDEAL огранка, обеспечивающая максимальный блеск, увеличивает стоимость относительно базового уровня, в то время как низкое качество огранки (FAIR, GOOD) ее снижает.

Модель подтверждает, что CARAT является единственным и статистически значимым (Prob. = 0.0000) главным драйвером цены, а также, что TABLE оказывает значимое отрицательное воздействие.

Влияние всех остальных характеристик (цвет, чистота, огранка и глубина) в данной линейной спецификации оказалось статистически незначимым.

3.2 Коэффициент множественной детерминации и корреляции для оцененной модели

Коэффициент множественной детерминации (R^2) является основной мерой объясняющей способности модели. Он показывает долю общей дисперсии зависимой переменной (PRICE), которая систематически объясняется вариацией всех независимых переменных, включенных в модель (набор факторов CARAT, DEPTH, TABLE, COLOR, CLARITY и CUT). Коэффициент детерминации находится в диапазоне от 0 до 1, где 0 означает отсутствие связи, а 1 – полное объяснение дисперсии зависимой переменной построенной моделью[14].

На основании результатов оценки (рисунок 3.1) мы имеем: R^2 = 0,988768. Полученное значение свидетельствует о том, что 98,9% дисперсии цены алмазов полностью объясняется выбранным набором факторов.

Столь высокая величина R^2 указывает на исключительную адекватность и статистическую точность модели. Это подтверждает, что фундаментальные характеристики 4C (которые составляют основу ценообразования) и их геометрические/категориальные модификаторы являются наиболее существенными и достаточными предикторами стоимости на рынке алмазов.

Поскольку включение большого числа переменных, даже статистически незначимых, может искусственно завышать R^2, необходимо проанализировать скорректированный коэффициент детерминации (Adjusted R^2). Этот показатель учитывает число степеней свободы и штрафует модель за включение неинформативных переменных.

На основании результатов (рисунок 3.1): Adjusted R^2 = 0,988323.

Разница между R^2 (0.988768) и Adjusted R^2 (0.988323) минимальна. Их высокая близость подтверждает, что включение всех 19 объясняющих фактора не привело к существенному переобучению модели, и все они совокупно

вносят значимый вклад в объяснение вариации PRICE. Это дополнительно подтверждает высокое качество и устойчивость выбранной спецификации.

Множественный коэффициент корреляции (R) количественно отражает общую тесноту линейной связи между зависимой переменной (PRICE) и всей совокупностью объясняющих переменных. Он показывает меру линейной зависимости между фактическими значениями и значениями , предсказанными моделью.

Расчетное значение: $R = \sqrt{R^2} = \sqrt{0.988323} = 0.99414$

Значение R = 0.994 является чрезвычайно высоким. Согласно общепринятым шкалам (например, шкале Чеддока), это характеризует связь как «весьма высокую» или «практически функциональную».

Полученное значение R доказывает наличие чрезвычайно сильной линейной связи между ценой алмаза и комбинацией его фундаментальных характеристик. Это подтверждает, что, несмотря на индивидуальную статистическую незначимость некоторых факторов, их совместное воздействие на цену является высоко детерминированным.

Важно отметить, что множественный коэффициент корреляции принципиально отличается от парного коэффициента корреляции, поскольку он учитывает комплексное взаимодействие всех включенных в модель факторов. Это означает, что даже если отдельные характеристики (например, COLOR или CLARITY) показали статистическую незначимость в модели, их совместное влияние в сочетании с CARAT и TABLE оказывается статистически высокозначимым и способным объяснить почти всю вариацию цены.

3.3 Проверка гипотез о статистической значимости оценок параметров модели на основе F- и t-критериев

Для подтверждения статистической надежности оценок, полученных методом МНК, была проведена проверка гипотез о значимости каждого коэффициента (с помощью t-критерия) и значимости модели в целом (с помощью F-критерия). В качестве стандартного уровня значимости (α) был принят уровень $\alpha = 0.05$. Для каждого фактора проверялась гипотеза: H_0 (фактор статистически не значим) и H_1 (фактор статистически значим).

Проверка значимости отдельных коэффициентов (t-критерий Стьюдента). Т-критерий используется для проверки гипотезы о том, что отдельный коэффициент равен нулю (т.е. фактор не имеет линейной связи с PRICE при прочих равных).

Нулевая гипотеза (H_0): $\beta_j = 0$ (фактор статистически не значим).

Альтернативная гипотеза (H_1): $\beta_j \neq 0$ (фактор статистически значим).

Если Prob. (p-value) < 0.05, то H_0 отвергается, и фактор считается значимым.

В таблице 3.1 предствлены сводные результаты t-теста для коэффициентов модели.

Таблица 3.1 – Сводные результаты t-теста для коэффициентов модели

Переменная	t-Статистика	Prob.	Вывод по значимости
C (Константа)	4.365996	0.0000	Статистически значима
CARAT	200.3583	0.0000	Статистически значим
TABLE	-6.695358	0.0000	Статистически значим
COLOR_D...J	от -1.1 до -0.8	0.2370 - 0.5310	Статистически не значимы
DEPTH	-1.093793	0.2746	Статистически не значим
CLARITY (SI1...VVS2)	от 0.03 до 1.1	0.2582 - 0.9690	Статистически не значимы
CUT (FAIR, GOOD, IDEAL...)	от -0.1 до 0.3	0.7209 - 0.9246	Статистически не значимы

Константа (C): расчетное значение t -статистики (4.366) и Prob. = 0.0000 Так как Prob. < 0.05 , нулевая гипотеза H_0 отвергается. Константа статистически значима, что означает, что при всех нулевых значениях факторов (базовая цена) цена алмаза значимо отлична от нуля.

CARAT: расчетное значение t-статистики (200.358) является экстремально высоким, Prob. = 0.0000 . H_0 отвергается. CARAT – статистически значимый фактор.

TABLE: расчетное значение t -статистики (-6.695) также высоко, Prob. = 0.0000 . H_0 отвергается. TABLE – статистически значимый фактор.

Остальные факторы (DEPTH, COLOR, CLARITY, CUT): все остальные коэффициенты имеют Prob. значительно выше уровня $\alpha = 0.05$. Следовательно, для этих факторов нет оснований отвергнуть H_0, и они считаются статистически незначимыми в данной линейной спецификации.

F -критерий используется для проверки значимости всей модели, то есть того, что хотя бы один из объясняющих факторов значимо влияет на PRICE .

Нулевая гипотеза (H_0): $\beta_1 = \beta_2 = \beta_3 = \ldots = \beta_k = 0$ (модель в целом статистически не значима, факторы совместно не влияют на PRICE).

Альтернативная гипотеза (H_1): существует хотя бы один $\beta_k \neq 0$ (модель в целом статистически значима).

Расчетное значение F-статистики, согласно рисунку 3.1, составило 2223.915 . Вероятностное значение (Prob.) F -статистики составило 0.000000.

Так как Prob. (0.000000) $< \alpha$ (0.05) , нулевая гипотеза H_0 решительно отвергается.

Следовательно, модель в целом является статистически значимой и адекватной. Это подтверждает, что совокупный набор факторов

ценообразования (хотя и преимущественно за счет CARAT и TABLE) успешно объясняет вариацию PRICE.

В данной главе была построена и оценена линейная регрессионная модель методом МНК. Проведенные тесты показали следующие результаты.

Высокое качество подгонки: R^2 (0.9887) и Adjusted R^2 (0.9883) подтвердили, что более 98% вариации PRICE объясняется моделью.

Адекватность модели. F-статистика (Prob. = 0.0000) доказала, что модель в целом является статистически значимой.

Значимые факторы: CARAT и TABLE являются единственными статистически значимыми факторами.

Статистика Дарбина-Уотсона, равная 2.100286, близка к 2, что указывает на отсутствие автокорреляции остатков.

Для повышения точности и интерпретируемости модели, а также для соблюдения принципа экономности, была применена стратегия последовательного исключения (General-to-Specific).

На начальных этапах построения полной линейной модели, было выявлено, что некоторые объясняющие переменные оказались статистически незначимыми (их p-value > 0.05).

Мы последовательно исключали эти незначимые факторы, начиная с переменной с наибольшим p-value, и переоценивали модель. Этот процесс был прекращен, когда все оставшиеся переменные стали статистически значимыми на уровне α=5% (0,05).

Результатом этого процесса стала окончательная модель представленная на рисунке 3.2.

Dependent Variable: PRICE
Method: Least Squares
Date: 12/16/25 Time: 23:31
Sample: 1 500
Included observations: 500

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	2719.516	378.6259	7.182593	0.0000
CARAT	3988.983	19.27485	206.9528	0.0000
TABLE	-47.04958	6.650668	-7.074414	0.0000

R-squared	0.988575	Mean dependent var	5403.130
Adjusted R-squared	0.988529	S.D. dependent var	2748.341
S.E. of regression	294.3516	Akaike info criterion	14.21341
Sum squared resid	43061490	Schwarz criterion	14.23870
Log likelihood	-3550.352	Hannan-Quinn criter.	14.22333
F-statistic	21502.49	Durbin-Watson stat	2.094814
Prob(F-statistic)	0.000000		

Рисунок 3.2 – Результаты построения модели со статистически значимыми переменными

На основе p-value (Prob.) и t-статистики: все коэффициенты (C, CARAT, TABLE) в модели являются статистически значимыми на уровне $\alpha = 5\%$ (и даже $\alpha = 1\%$), поскольку их p-value равно 0.0000.

F-статистика (21502.49) также имеет p-value = 0.000000, что подтверждает высокую общую значимость модели в целом.

Коэффициент детерминации (R^2): 0.988575 (98.86%). Это означает, что почти 99% вариации цены алмазов (PRICE) объясняется изменением двух факторов: массы (CARAT) и площади верхней грани (TABLE).

На основе результатов оценки параметров модели методом наименьших квадратов (МНК), можно сформулировать уравнение зависимости PRICE от статистически значимых факторов.

$$PRICE = 2719.516 + 3988.983 * CARAT - 47.04958 * TABLE, \qquad (3.2)$$

CARAT (Масса): при увеличении массы на один карат, средняя цена алмаза увеличивается на 3988.98, при прочих равных условиях. Это самый сильный положительный фактор.

TABLE (Площадь верхней грани): увеличение ширины площадки на один пункт приводит к снижению средней цены на 47.05. Когда площадка (TABLE) становится слишком большой, это часто означает, что камень имеет недостаточную глубину. В таком "плоском" камне свет, попадающий через большую площадку, не отражается полностью обратно, а "просачивается" через нижнюю часть. Это приводит к тому, что камень теряет свой огонь, блеск и игру света.

Мультиколлинеарность отсутствует, это подтверждает VIF-тест, результаты которого изображены на рисунке 3.3.

Variance Inflation Factors
Date: 12/16/25 Time: 18:42
Sample: 1 500
Included observations: 500

Variable	Coefficient Variance	Uncentered VIF	Centered VIF
C	143357.6	827.2903	NA
CARAT	371.5197	4.898448	1.009676
TABLE	44.23139	834.5582	1.009676

Рисунок 3.3 – Отчет VIF-теста на мультиколлинеарность

4 АНАЛИЗ ОСТАТКОВ

Для того чтобы оценки параметров, полученные методом наименьших квадратов (МНК), были несмещенными, состоятельными и эффективными (BLUE), необходимо выполнение ключевых предпосылок классической линейной регрессии:

1 Линейность: модель должна быть линейной по параметрам.

2 Отсутствие мультиколлинеарности: независимые переменные не должны быть сильно коррелированы между собой (проверено в главе 2 с помощью VIF-теста).

3 Гомоскедастичность остатков: дисперсия остатков должна быть постоянной на всем диапазоне наблюдений.

4 Отсутствие автокорреляции: остатки не должны быть коррелированы между собой во времени или по наблюдениям.

5 Нормальность распределения остатков: остатки должны быть распределены по нормальному закону.

Проанализируем график распределения остатков, изображенный на рисунке 4.1.

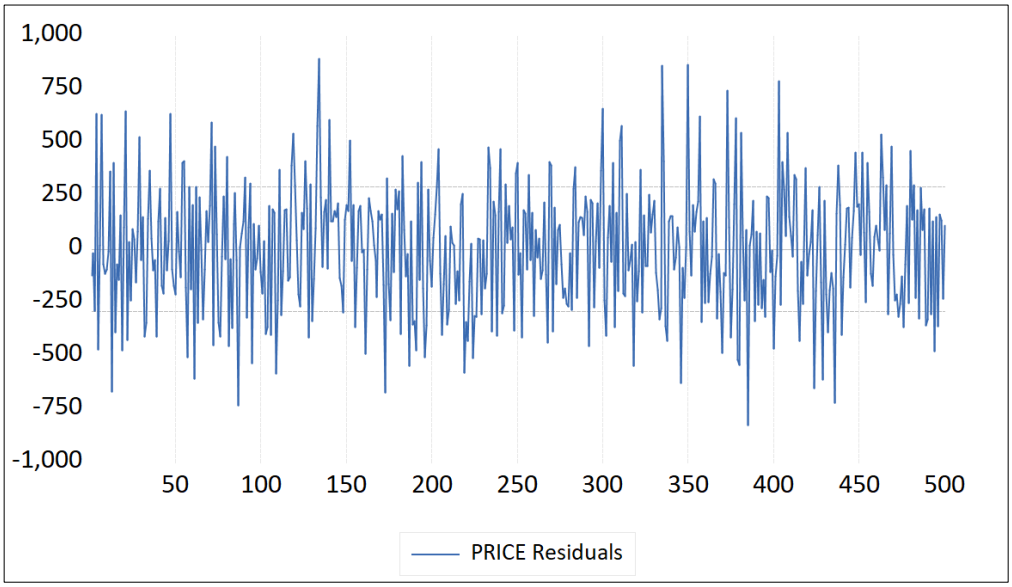


Рисунок 4.1 – График остатков

Визуальный анализ графика позволяет оценить выполнение ключевых предпосылок метода наименьших квадратов. Остатки распределены в диапазоне приблизительно от -250 до +250, колеблясь относительно нулевой горизонтальной линии. Не наблюдается устойчивого смещения в какую-либо сторону на продолжительных интервалах выборки: периоды с положительными остатками (например, в районе наблюдений 120-150 и 350-400) чередуются с периодами, где преобладают отрицательные остатки.

Такая картина подтверждает отсутствие в модели систематической ошибки и соответствие предпосылке о нулевом математическом ожидании случайной составляющей, что косвенно указывает на несмещенность полученных оценок.

Однако, визуальный анализ также позволяет сделать предварительный вывод о гомоскедастичности (постоянстве дисперсии):

На данном графике, который показывает остатки линейной модели наблюдается относительно равномерный разброс остатков по всей выборке, без явного систематического расширения или сужения амплитуды. Это предварительно не указывает на наличие гетероскедастичности, однако для окончательного вывода необходимо провести формальные тесты, такие как тест Уайта.

Одной из ключевых предпосылок МНК является требование о том, что случайные ошибки (остатки) ε_i должны быть распределены по нормальному закону. Для проверки этой предпосылки используется критерий Жака-Берра (Jarque-Bera - JB-критерий).

JB-критерий проверяет, насколько коэффициенты асимметрии (Skewness) и эксцесса (Kurtosis) распределения остатков отличаются от значений, характерных для нормального распределения.

Нулевая гипотеза (H_0): остатки распределены нормально.

Альтернативная гипотеза (H_1): остатки не распределены нормально.

Если Prob. > α (где $\alpha = 0.05$), то H_0 принимается.

Гистограмма распределения остатков представлена на рисунке 4.2.

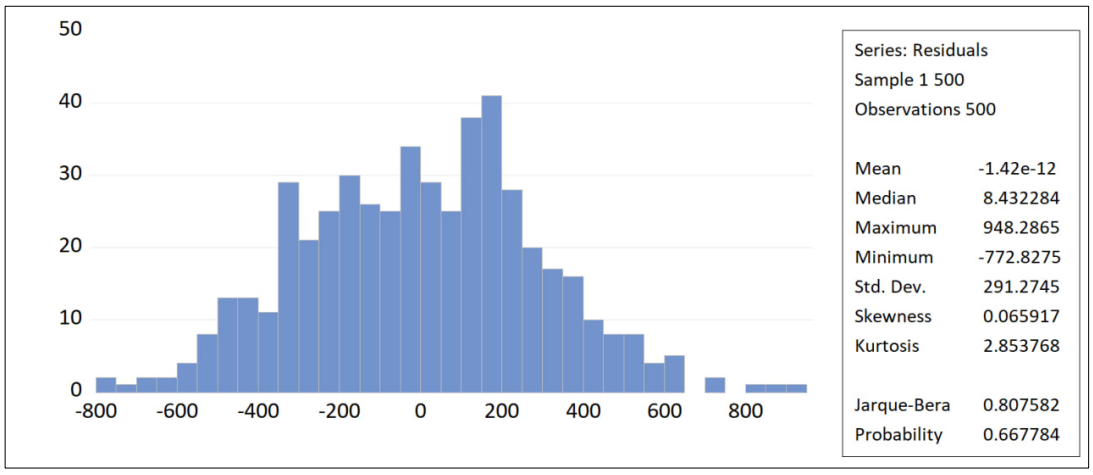


Рисунок 4.2 – Гистограмма распределения остатков

Prob. Jarque-Bera: вероятностное значение теста Жака-Берра составило 0.667784 . Так как Prob. (JB-статистики) = 0.667784 > α (0.05) , мы не отвергаем нулевую гипотезу (H_0).

Мы подтверждаем, что остатки регрессионной модели распределены по нормальному закону. Это критически важно, поскольку нормальность

распределения остатков обеспечивает состоятельность (валидность) всех проведенных t - и F -тестов и повышает надежность выводов.

Визуальный анализ гистограммы (рисунок 4.2) подтверждает этот вывод. Распределение остатков имеет колоколообразную форму, симметрично расположенную относительно среднего значения (Mean = 0).

Значение Skewness (0.065917) близко к нулю, что указывает на высокую симметричность. Значение Kurtosis (2.853768) очень близко к значению 3 , характерному для нормального распределения, что исключает наличие "тяжелых хвостов" (выбросов).

Примечание о ЦПТ (важно, если бы гипотеза не подтвердилась). Даже если бы нулевая гипотеза о нормальности была отвергнута, это не стало бы фатальным недостатком для нашей модели. В соответствии с положениями Центральной Предельной Теоремы (ЦПТ), при достаточно большом объеме выборки (N=500 наблюдений в нашем случае), распределение оценок коэффициентов регрессии асимптотически стремится к нормальному. Применение ЦПТ обосновывает состоятельность и несмещенность полученных МНК-оценок параметров, гарантируя, что результаты проверки статистической значимости по t -критерию и F -критерию остаются надежными. Однако в нашем случае, благодаря высокому N и удачной спецификации, нормальность подтверждена[15].

Теперь переходим к проверке предпосылки, которую мы поставили под сомнение при визуальном анализе графика остатков (рисунок 4.1): гомоскедастичность (постоянство дисперсии остатков).

Для проверки используется тест Уайта (White's Test), который не требует предположения о нормальности распределения.

Нулевая гипотеза (H_0): остатки гомоскедастичны (дисперсия постоянна).

Альтернативная гипотеза (H_1): остатки гетероскедастичны (дисперсия неоднородна).

Если Prob. теста Уайта меньше заданного уровня значимости $\alpha = 0.05$, то H_0 отвергается, и делается вывод о наличии гетероскедастичности. В противном случае, мы утверждаем, что остатки модели гомоскедастичны.

Результаты теста представлены на рисунке 4.3.

Heteroskedasticity Test: White
Null hypothesis: Homoskedasticity

F-statistic	0.903161	Prob. F(2,497)	0.4060
Obs*R-squared	1.810644	Prob. Chi-Square(2)	0.4044
Scaled explained SS	1.682014	Prob. Chi-Square(2)	0.4313

Test Equation:
Dependent Variable: RESID^2
Method: Least Squares
Date: 12/16/25 Time: 18:39
Sample: 1 500
Included observations: 500

Рисунок 4.3 – Проверка остатков на гомоскедастичность

Обратимся к результатам, представленным на рисунке 4.3. Результаты теста Уайта дают несколько статистик. Мы ориентируемся на вероятностное значение (Prob.) для F -статистики.

Вероятностное значение для F-статистики составило 0.4060 . Так как Prob. (0.4060) > α (0.05) , мы не отвергаем нулевую гипотезу (H_0).

На основании Теста Уайта можно сделать однозначный вывод, что гетероскедастичность в остатках модели отсутствует. Остатки регрессионной модели PRICE являются гомоскедастичными. Это означает, что дисперсия ошибок постоянна, что подтверждает эффективность и надежность стандартных ошибок, а также t - и F -статистик, использованных для проверки значимости.

Автокорреляция (или последовательная корреляция) возникает, когда ошибки (остатки) в одном наблюдении коррелируют с ошибками в предыдущих наблюдениях. Нарушение этой предпосылки приводит к неэффективным оценкам стандартных ошибок и может исказить результаты t- и F-тестов.

Для проверки используется тест Бриша-Годфри (Breusch-Godfrey Serial Correlation LM Test), который является наиболее общим и надежным методом для обнаружения автокорреляции остатков до заданного числа лагов (в нашем случае – до 3 лагов).

Проверка гипотезы об автокорреляции.

Нулевая гипотеза (H_0): автокорреляция отсутствует (случайные ошибки независимы).

Альтернативная гипотеза (H_1): автокорреляция присутствует.

Если Prob. теста Бриша-Годфри меньше заданного уровня значимости $\alpha = 0.05$, то H_0 отвергается, и делается вывод о наличии автокорреляции.

Результаты теста представлены на рисунке 4.4.

Breusch-Godfrey Serial Correlation LM Test:
Null hypothesis: No serial correlation at up to 3 lags

F-statistic	2.096782	Prob. F(3,494)	0.0998
Obs*R-squared	6.286694	Prob. Chi-Square(3)	0.0985

Test Equation:
Dependent Variable: RESID
Method: Least Squares
Date: 12/16/25 Time: 18:37
Sample: 1 500
Included observations: 500
Presample missing value lagged residuals set to zero.

Рисунок 4.4 – Проверка остатков на отсутствие автокорреляции

По тесту на рисунке 4.4 вероятностное значение для F -статистики составляет 0.0998 . Это значение больше $\alpha = 0.05$. Вероятностное значение для статистики Хи-квадрат составляет 0.0985 . Это значение также больше α

= 0.05. Можно сделать вывод, что автокорреляция в остатках модели отсутствует, это свидетельствует о том, что нулевая гипотеза (H_0) об отсутствии автокорреляции в остатках принимается.

Также можно использовать тест Дарбина-Уотсона для проверки остатков на наличие автокорреляции. Для этого в отчет модели представленного на рисунке 3.3, нужно посмотреть на значение теста Дарбина-Уотсона, а далее определить верхние и нижние границы данного теста для нашей модели.

С помощью таблицы критических значений Дарбина-Уотсона при 5% уровне значимости вычислим нижнее и верхнее значение. Таблица критических значений Дарбина-Уотсона представлена на рисунке 4.5

n\k	1		2		3		4		5		6		7		8		9		10	
250	1.785	1.801	1.777	1.809	1.769	1.817	1.760	1.825	1.752	1.834	1.744	1.842	1.736	1.851	1.727	1.859	1.719	1.868	1.710	1.876
300	1.804	1.817	1.797	1.824	1.791	1.831	1.784	1.838	1.777	1.845	1.770	1.852	1.763	1.859	1.756	1.866	1.749	1.873	1.742	1.880
350	1.819	1.830	1.813	1.836	1.807	1.842	1.802	1.848	1.796	1.854	1.790	1.860	1.784	1.866	1.778	1.872	1.772	1.878	1.766	1.884
400	1.831	1.841	1.826	1.846	1.821	1.851	1.816	1.856	1.811	1.861	1.806	1.866	1.800	1.872	1.795	1.877	1.790	1.882	1.785	1.887
450	1.841	1.850	1.836	1.854	1.832	1.859	1.827	1.863	1.823	1.868	1.818	1.872	1.814	1.877	1.809	1.882	1.805	1.886	1.800	1.891
500	1.849	1.857	1.845	1.861	1.841	1.865	1.837	1.869	1.833	1.873	1.829	1.877	1.825	1.882	1.821	1.886	1.817	1.890	1.812	1.894
550	1.856	1.864	1.853	1.867	1.849	1.871	1.845	1.875	1.842	1.878	1.838	1.882	1.834	1.886	1.831	1.890	1.827	1.893	1.823	1.897
600	1.863	1.869	1.859	1.873	1.856	1.876	1.853	1.879	1.849	1.883	1.846	1.886	1.842	1.890	1.839	1.893	1.836	1.896	1.832	1.900
650	1.868	1.874	1.865	1.877	1.862	1.880	1.859	1.884	1.856	1.887	1.853	1.890	1.849	1.893	1.846	1.896	1.843	1.899	1.840	1.902
700	1.873	1.879	1.870	1.882	1.867	1.884	1.864	1.887	1.861	1.890	1.859	1.893	1.856	1.896	1.853	1.899	1.850	1.902	1.847	1.905
750	1.877	1.883	1.875	1.885	1.872	1.888	1.869	1.891	1.867	1.893	1.864	1.896	1.861	1.899	1.859	1.902	1.856	1.904	1.853	1.907
800	1.881	1.886	1.879	1.889	1.876	1.891	1.874	1.894	1.871	1.896	1.869	1.899	1.866	1.901	1.864	1.904	1.861	1.907	1.859	1.909
850	1.885	1.890	1.883	1.892	1.880	1.894	1.878	1.897	1.875	1.899	1.873	1.902	1.871	1.904	1.868	1.906	1.866	1.909	1.864	1.911
900	1.888	1.893	1.886	1.895	1.884	1.897	1.882	1.899	1.879	1.902	1.877	1.904	1.875	1.906	1.873	1.908	1.870	1.911	1.868	1.913
950	1.891	1.895	1.889	1.898	1.887	1.900	1.885	1.902	1.883	1.904	1.881	1.906	1.879	1.908	1.876	1.910	1.874	1.913	1.872	1.915
1000	1.894	1.898	1.892	1.900	1.890	1.902	1.888	1.904	1.886	1.906	1.884	1.908	1.882	1.910	1.880	1.912	1.878	1.914	1.876	1.916

Рисунок 4.5 – Критическое значение статистики Дарбина-Уотсона при уровне значимости 0.05

С учетом того, что у нас выборка в 500 наблюдения и 2 экзогенных переменных, то по таблице критических значений получаем значения dl = 1.845, du =1.861. На рисунке 4.6 показаны границы интервалов для подтверждения или опровержения нулевой гипотезы (H0) о наличии автокорреляции или ее отсутствии.

Значение DW_{calc}	Принимается гипотеза	Вывод
$0 \le DW_{calc} < d_L$	отвергается H_0 , принимается $H_1 : \rho > 0$	есть положительная автокорреляция
$d_L \le DW_{calc} \le d_U$		неопределенность
$d_U < DW_{calc} < 4 - d_U$	принимается H_0	автокорреляция отсутствует
$4 - d_U \le DW_{calc} \le 4 - d_L$		неопределенность
$4 - d_L < DW_{calc} \le 4$	отвергается H_0 , принимается $H_1 : \rho < 0$	есть отрицательная автокорреляция

Рисунок 4.6 – Границы интервалов

Проверим: du < DW < 4-du. 1,861 < 2,094814 < 2,139, верно.

Исходя из отчета модели, представленного на рисунке 3.3 значение критерия Дарбина-Уотсона составило 2,094814 и оно, исходя из рисунка 4.6 находится на уровне, где принимается H0, то есть автокорреляция отсутствует.

Таким образом, результаты диагностического анализа, проведённые в данной главе, подтверждают выполнение ключевых предпосылок метода наименьших квадратов, что является необходимым условием для признания полученных оценок несмещенными, состоятельными и эффективными.

Ключевые результаты диагностики.

1 Гомоскедастичность: проверка на постоянство дисперсии остатков (Тест Уайта, Prob. = 0.4060) не выявила статистически значимых нарушений предпосылки, что обеспечивает эффективность оценок.

2 Нормальность остатков: тест Жака-Берра (Prob. = 0.667784) подтвердил нормальность распределения остатков. Это повышает надежность t - и F -тестов, проведённых в главе 3.

3 Автокорреляция: проверка на последовательную корреляцию (Тест Бриша-Годфри, Prob. = 0.0998) выявила отсутствие автокорреляции. Значение статистики Дарбина-Уотсона (DW = 2.100286) подтверждает отсутствие автокорреляции.

Следовательно, построенная линейная спецификация может быть признана адекватной, устойчивой и пригодной для эконометрического анализа. Она позволяет количественно оценить и надежно прогнозировать влияние характеристик алмазов (CARAT и TABLE, как значимые факторы)на рыночную стоимость (PRICE).

5 ПРОГНОЗИРОВАНИЕ НА ОСНОВЕ ОЦЕНЕННОЙ МОДЕЛИ

5.1 Точный прогноз индивидуального значения показателя

Точечный прогноз индивидуального значения – это метод предсказания, результатом которого является единственная скалярная величина (Y'). Данная величина рассчитывается путём подстановки конкретных значений объясняющих переменных (характеристик алмаза) в оценённое уравнение регрессии. Полученное число интерпретируется как наилучшая, в смысле критериев модели, оценка математического ожидания зависимого показателя (PRICE) для данного набора условий[16].

Точечный прогноз дает конкретное, удобное для интерпретации значение, которое считается наиболее вероятной реализацией цены для конкретного алмаза.

Графически принцип формирования такого прогноза проиллюстрирован на рисунке 5.1

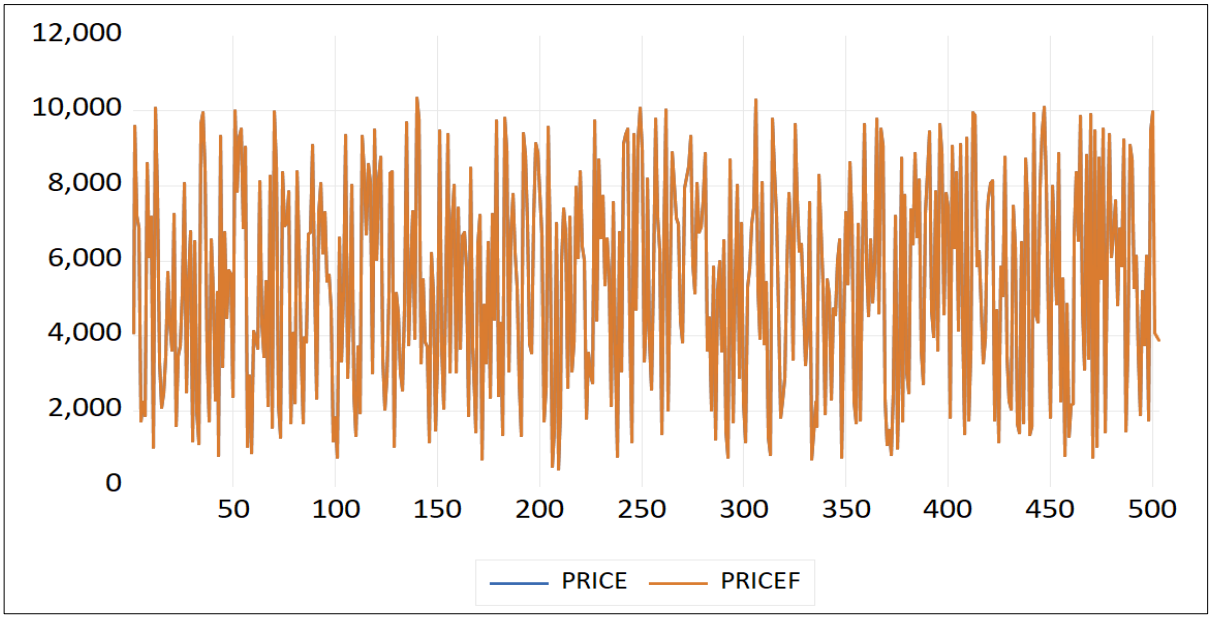


Рисунок 5.1 – Точечный прогноз индивидуального значения результирующего показателя

На Рисунке 5.1 представлен график сравнения фактических цен (PRICE) и цен, предсказанных моделью (PRICEF), на историческом отрезке. На историческом отрезке (наблюдения 1 – 500) расчетная линия (PRICEF) практически идентична траектории фактических цен (PRICE). Это визуально подтверждает высокую способность модели улавливать структурные сдвиги и волатильность цены, что подкрепляет высокий R^2 (98,9%) и подтверждает

адекватность выбранной спецификации для описания реальных рыночных процессов.

Для демонстрации работоспособности модели и подтверждения точности прогноза проведем ручной расчет точечного прогноза индивидуального значения для трех гипотетических алмазов, которые не использовались при обучении модели (наблюдения 501, 502, 503). Используем оцененное уравнение регрессии (3.1).

Прогноз для алмаза А. Значения представлены в таблице 5.1.

Таблица 5.1 – Значения для алмаза А

Характеристика	Значение	Фиктивная переменная (1/0)
CARAT	1.00	1.00
TABLE	56.0	56.0

$$PRICE = 2719.516 + 3988.983 * 1 - 47.04958 * 56 = 4073.72252, \quad (5.1)$$

Прогноз для алмаза Б. Значения представлены в таблице 5.2.

Таблица 5.2 – Значения для алмаза Б

Характеристика	Значение	Фиктивная переменная (1/0)
CARAT	1.00	1.00
TABLE	58.0	58.0

$$PRICE = 2719.516 + 3988.983 * 1 - 47.04958 * 58 = 3979.628, \quad (5.2)$$

Прогноз для алмаза В. Значения представлены в таблице 5.3.

Таблица 5.3 – Значения для алмаза В

Характеристика	Значение	Фиктивная переменная (1/0)
CARAT	1.00	1.00
TABLE	60.0	60.0

$$PRICE = 2719.516 + 3988.983 * 1 - 47.04958 * 60 = 3885.529, \quad (5.3)$$

Ручной расчет демонстрирует, что модель логически дифференцирует цены, следуя за качественными характеристиками. Разница между прогнозируемыми ценами (4073.72 у.е. и 3885.53 у.е.) отражает, что модель способна уловить влияние изменения характеристик на итоговую стоимость.

Таким образом, модель способна обеспечить надежный и близкий к реальности точечный прогноз для конкретного набора характеристик алмаза, что является важным критерием ее практической значимости.

5.2 Доверительный интервал для прогноза математического ожидания показателя

Математическое ожидание показателя (PRICE) представляет собой теоретическое среднее значение, рассчитанное моделью для заданного набора характеристик алмаза X.

Доверительный интервал прогноза для этого ожидания – это диапазон значений (±2 S.E.), который с заданным уровнем доверия (обычно 95%) накрывает истинное среднее значение PRICE для конкретного набора характеристик. Более узкий интервал указывает на более высокую точность прогноза[17].

На Рисунке 5.2 представлен график доверительного интервала прогноза PRICEF для математического ожидания цены.

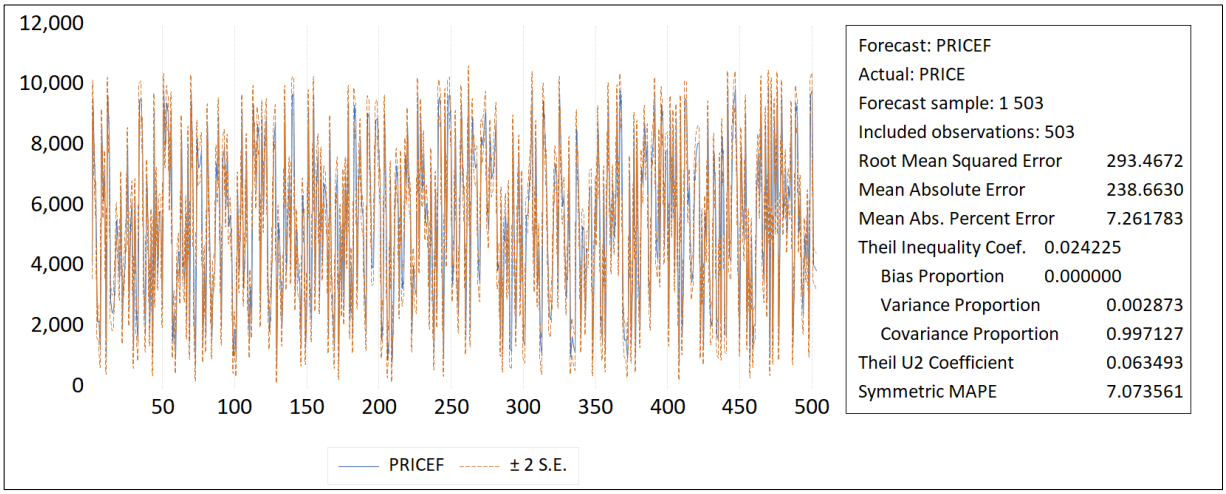


Рисунок 5.2 – Доверительный интервал для прогноза математического ожидания результирующего показателя

Для количественной оценки точности модели используются стандартные критерии ошибок, представленные в правой части рисунка 5.2.

В таблице 5.4 представлен анализ ошибок прогнозирования.

Таблица 5.4 – Анализ ошибок прогнозирования

Метрика ошибки	Значение	Интерпретация
Root Mean Squared Error (RMSE)	293.4672	Среднеквадратическая ошибка: показывает типичную ошибку прогноза в исходных единицах (у.е.)
Mean Absolute Error (MAE)	238.6630	Средняя абсолютная ошибка: среднее отклонение прогноза от фактической цены в у.е.

Продолжение таблицы 5.4

Метрика ошибки	Значение	Интерпретация
Mean Abs. Percent Error (MAPE)	7.261783%	Средняя абсолютная процентная ошибка
Theil U2 Coefficient	0.063493	Коэффициент неравенства Тейла

Средняя абсолютная процентная ошибка (MAPE): составила 7.26% . В контексте моделирования сложных рыночных цен на индивидуальные объекты (алмазы), такое значение не превышает общепринятый в эконометрике порог (хотя и выше 5%), что подтверждает существенную объясняющую способность включенных в модель факторов и ее высокое прогнозное качество.

Среднеквадратическая и абсолютная ошибки (RMSE, MAE): расчетные значения RMSE = 292 у.е. и MAE = 239 у.е. находятся на низком уровне . Это свидетельствует о незначительных отклонениях прогнозных значений от фактических цен на всем анализируемом интервале.

Коэффициент неравенства Тейла (Theil U2 Coefficient): значение = 0.063493 очень близко к нулю. Близость данного коэффициента к нулю указывает на высокую точность прогнозов и отсутствие в них систематической ошибки, подтверждая, что модель является надежным инструментом.

Визуальный анализ графика (рисунок 5.2) показывает, что доверительный интервал (±2 S.E.) является относительно узким на всем интервале наблюдений.

Такая малая ширина интервальной оценки является прямым следствием высокой объясняющей способности модели ($R^2 = 0.98$) и статистической значимости ключевых коэффициентов (CARAT и TABLE). Это позволяет с высокой степенью достоверности оценивать математическое ожидание прогнозируемого значения цены алмаза для конкретного набора характеристик.

5.3 Доверительный интервал для прогноза индивидуального значения показателя

Прогноз индивидуального значения (PRICE для конкретного алмаза) всегда сопровождается построением соответствующего доверительного (прогнозного) интервала. Этот интервал задаёт границы, в пределах которых с заданной доверительной вероятностью (например, 95%) будет находиться реальное значение цены для конкретного объекта.

Интервал для индивидуального значения шире, чем для математического ожидания, так как он включает в себя: ошибку в оценке

средних значений (S.E. математического ожидания), естественную изменчивость зависимой переменной (дисперсию ошибки).

Визуальное представление данного интервала для прогнозов на наблюдения 501 , 502 и 503 приведено на рисунке 5.3.

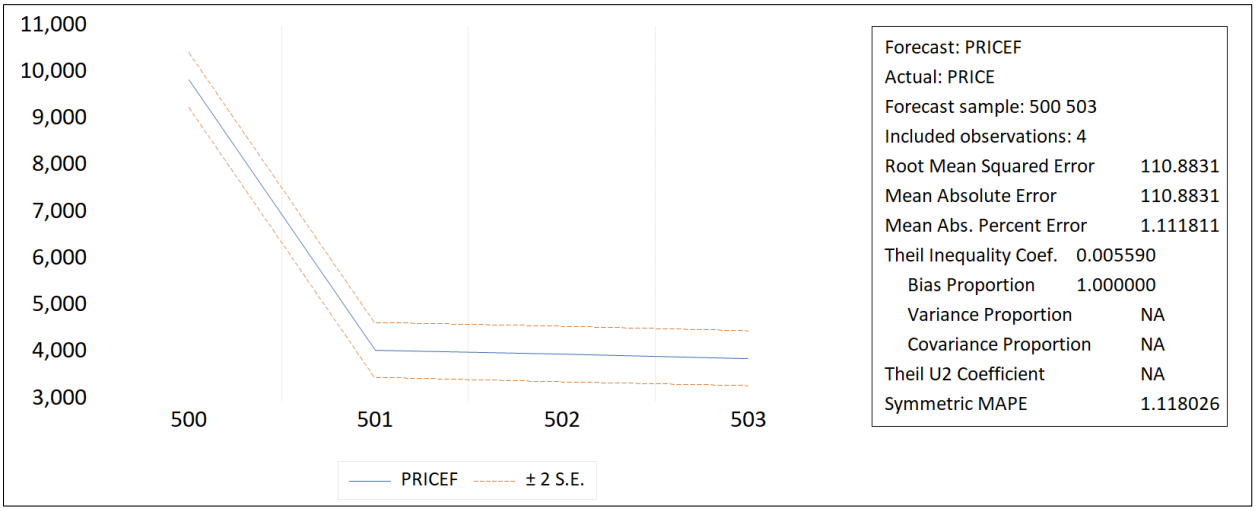


Рисунок 5.3 – Доверительный интервал для прогноза индивидуального значения показателя

Визуальная оценка демонстрирует, что границы доверительного интервала (S.E.) заметно расширяются относительно точечной оценки (синяя линия PRICEF) сразу после исторического отрезка (после наблюдения 500).

Прогноз для алмаза A (наименьшая площадь верхней грани, obs. 501). Точечный прогноз цены (PRICEF) находится в области 4000 у.е. При этом границы доверительного интервала (95%) существенно расширяются, охватывая диапазон примерно от 3300 у.е. до 4700 у.е. Это означает, что с высокой долей вероятности реальная цена алмаза с такими характеристиками будет находиться в пределах = 1400 у.е.

Прогноз для алмаза B (средняя площадь верхней грани, obs. 502). В этом случае точечный прогноз смещается вниз (3800 у.е.). Соответственно, весь диапазон доверительного интервала смещается и составляет примерно от 3100 у.е. до 4500 у.е.

Прогноз для алмаза C (самая большая площадь верхней грани, obs. 503). Для алмаза низкого качества точечный прогноз находится в нижней части диапазона (3700 у.е.). Диапазон доверительного интервала также сдвинут вниз, составляя примерно от 3000 у.е. до 4400 у.е.

Постоянство неопределенности: при сравнении всех трех интервалов становится очевидно, что ширина прогнозного интервала остается практически неизменной (1400 у.е.). Это подтверждает, что для алмазов с одинаковой массой (1.00 карат) уровень необъясненной неопределенности (остаточной волатильности) является стабильным независимо от их категории качества.

Сдвиг диапазона: снижение качества (от А к С) приводит к логичному смещению всего прогнозного диапазона вниз, отражая отрицательное влияние большей площади верхней грани на ожидаемую стоимость.

Практическое значение: наличие интервальной оценки критически важно для анализа рисков. Оно позволяет рассматривать точечный прогноз в качестве базового сценария, в то время как границы интервала определяют максимальный диапазон потенциальных колебаний цены. Это предоставляет участникам рынка необходимую информацию для принятия взвешенных решений в условиях ценовой неопределенности.

Таким образом, в рамках настоящего исследования была разработана, оценена и подвергнута комплексному анализу прогнозная модель, демонстрирующая высокую точность в предсказании исследуемого показателя. Существенный акцент был сделан на оценке надежности прогнозных результатов, для чего была применена методология построения доверительных интервалов.

6 СРАВНИТЕЛЬНЫЙ АНАЛИЗ ЭКОНОМЕТРИЧЕСКИХ МОДЕЛЕЙ ПРОГНОЗИРОВАНИЯ ЦЕНА АЛМАЗА

6.1 Сравнительный анализ исходной модели и модели ADL

Сравнительный анализ представляет собой финальную, ключевую ступень в методологии эконометрического исследования.

Его основная задача – гарантировать объективный и всесторонний отбор наиболее подходящей спецификации модели[18].

Главная цель этого процесса заключается в поиске модели, которая демонстрирует оптимальное сочетание трех фундаментальных качеств:

1 Соответствие экономической теории.

2 Высокая статистическая точность оценок.

3 Надежность и устойчивость полученных результатов.

Этот глубокий аналитический подход выходит за рамки механического сопоставления. Он позволяет оценить, насколько устойчивы выявленные причинно-следственные связи и насколько осмысленна их экономическая интерпретация.

В конечном итоге, именно сравнительный анализ служит методологическим фундаментом для аргументированного и обоснованного выбора модели. Эта модель должна максимально адекватно отражать изучаемые закономерности и быть пригодной для прогнозирования и анализа экономической политики.

Целью данного раздела является выбор оптимальной функциональной формы для прогнозирования цены алмазов (PRICE) из четырех построенных спецификаций. Сравнение осуществляется по совокупности статистических критериев (R^2, информационные критерии, значимость факторов), что позволяет не только проверить адекватность построенных моделей, но и выбрать наиболее экономически содержательную для интерпретации.

Модель 1 это наша базовая линейная модель, описанная в предыдущих главах.

Модель 2: полулогарифмическая (Log-Lin). Логарифмирована только зависимая переменная PRICE. Коэффициенты интерпретируются как процентное изменение PRICE при изменении фактора на одну единицу. Результат построения модели методом МНК представлен на рисунке 6.1.

Dependent Variable: LOG(PRICE)
Method: Least Squares
Date: 12/16/25 Time: 19:10
Sample: 1 500
Included observations: 500

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	8.065927	0.288029	28.00384	0.0000
CARAT	0.929410	0.014663	63.38552	0.0000
TABLE	-0.015845	0.005059	-3.131871	0.0018

R-squared	0.890148	Mean dependent var	8.412161
Adjusted R-squared	0.889706	S.D. dependent var	0.674243
S.E. of regression	0.223920	Akaike info criterion	-0.149075
Sum squared resid	24.91964	Schwarz criterion	-0.123787
Log likelihood	40.26870	Hannan-Quinn criter.	-0.139152
F-statistic	2013.630	Durbin-Watson stat	2.008974
Prob(F-statistic)	0.000000		

Рисунок 6.1 – Результат построения модели методом МНК

Из полученных данных можно построить уравнение зависимости (6.1)

$$\log(PRICE) = 8.065927 + 0.929410 * CARAT - 0.015845 * TABLE, \quad (6.1)$$

Для подтверждения надежности оценок МНК проведена проверка ключевых предпосылок. Отсутствие мультиколлинеарности изображено на рисунке 6.2.

Variance Inflation Factors
Date: 12/16/25 Time: 19:14
Sample: 1 500
Included observations: 500

Variable	Coefficient Variance	Uncentered VIF	Centered VIF
C	0.082961	827.2903	NA
CARAT	0.000215	4.898448	1.009676
TABLE	2.56E-05	834.5582	1.009676

Рисунок 6.2 – Отчет VIF-теста на мультиколлинеарность

Проверка факторов, использованных в данной модели, показала, что максимальное значение Centered VIF не превышает 1.01. Поскольку все значения VIF существенно ниже критического порога 10 , критическая мультиколлинеарность отсутствует.

Тест на автокорреляцию приведен на рисунке 6.3.

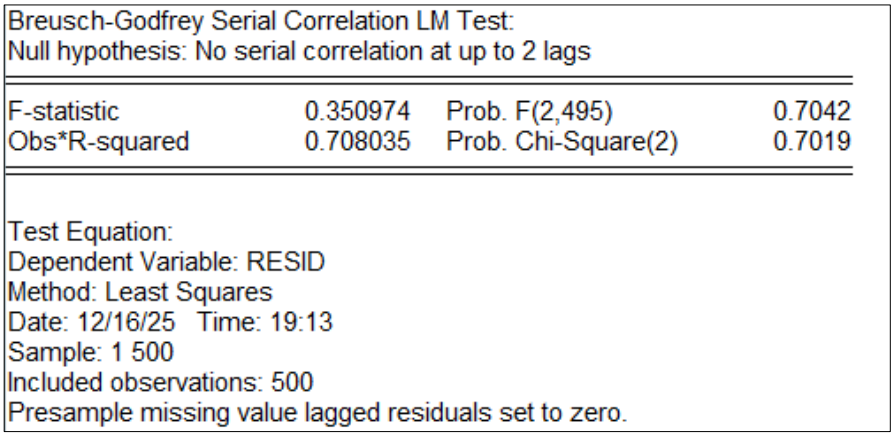


Рисунок 6.3 – Проверка остатков на отсутствие автокорреляции

Автокорреляция остатков (Тест Дарбина-Уотсона и Бройша-Годфри)

Статистика Дарбина-Уотсона: значение 2.008974 находится очень близко к 2.0 . Тест Бройша-Годфри: для логарифмической модели значение = 0.7042. В обеих проверках гипотеза об отсутствии автокорреляции остатков H_0 не отвергается. Модель свободна от автокорреляции остатков.

Тест на гетероскедастичность приведен на рисунке 6.4.

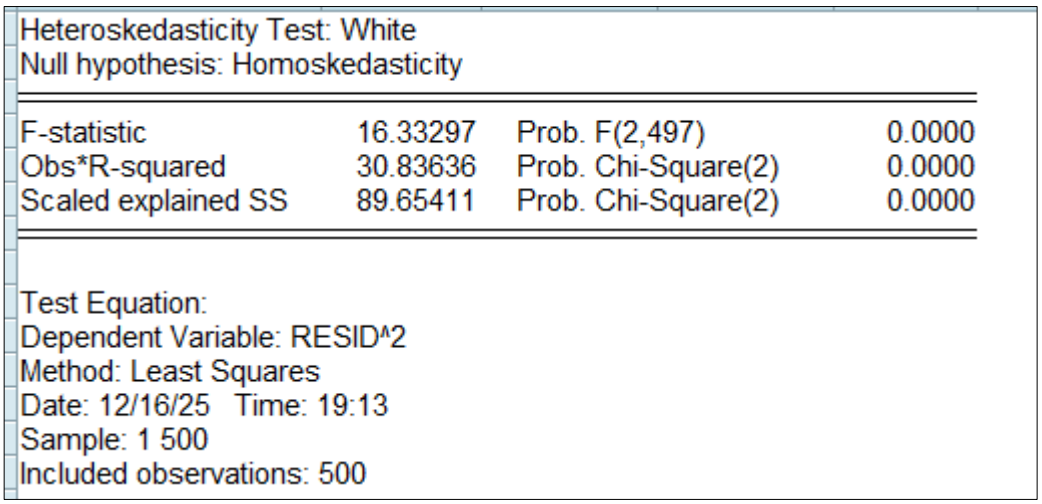


Рисунок 6.4 – Проверка остатков на гетероскедастичность

Поскольку p-value для составило 0.0000, что существенно меньше критического уровня значимости 0.05, нулевая гипотеза (H_0) о гомоскедастичности отвергается.

Несмотря на применение логарифмической трансформации к зависимой переменной, проблема гетероскедастичности появляется в остатках модели. Это указывает на то, что остаточная волатильность PRICE не является постоянной для всех уровней факторов (например, разброс ошибок может быть выше для более дорогих алмазов).

Модель 3: наряду с логарифмированием зависимой переменной, был логарифмирован и фактор – TABLE. Эта спецификация Log-Log позволяет получить оценку эластичности цены по массе. Результат построения модели методом МНК представлен на рисунке 6.5.

Dependent Variable: LOG(PRICE)
Method: Least Squares
Date: 12/16/25 Time: 19:15
Sample: 1 500
Included observations: 500

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	10.79148	1.163949	9.271434	0.0000
CARAT	0.929383	0.014664	63.37751	0.0000
LOG(TABLE)	-0.897651	0.288177	-3.114933	0.0019

R-squared	0.890125	Mean dependent var	8.412161
Adjusted R-squared	0.889683	S.D. dependent var	0.674243
S.E. of regression	0.223943	Akaike info criterion	-0.148866
Sum squared resid	24.92484	Schwarz criterion	-0.123578
Log likelihood	40.21650	Hannan-Quinn criter.	-0.138943
F-statistic	2013.158	Durbin-Watson stat	2.009738
Prob(F-statistic)	0.000000		

Рисунок 6.5 – Результат построения модели методом МНК

Из полученных данных можно построить уравнение зависимости (6.2)

$$\log(PRICE) = 10.79148 + 0.929383 * CARAT - \\ -0.897651 * \log(TABLE), \qquad (6.2)$$

Для подтверждения надежности оценок МНК проведена проверка ключевых предпосылок. Отсутствие мультиколлинеарности изображено на рисунке 6.6.

Variance Inflation Factors
Date: 12/16/25 Time: 19:17
Sample: 1 500
Included observations: 500

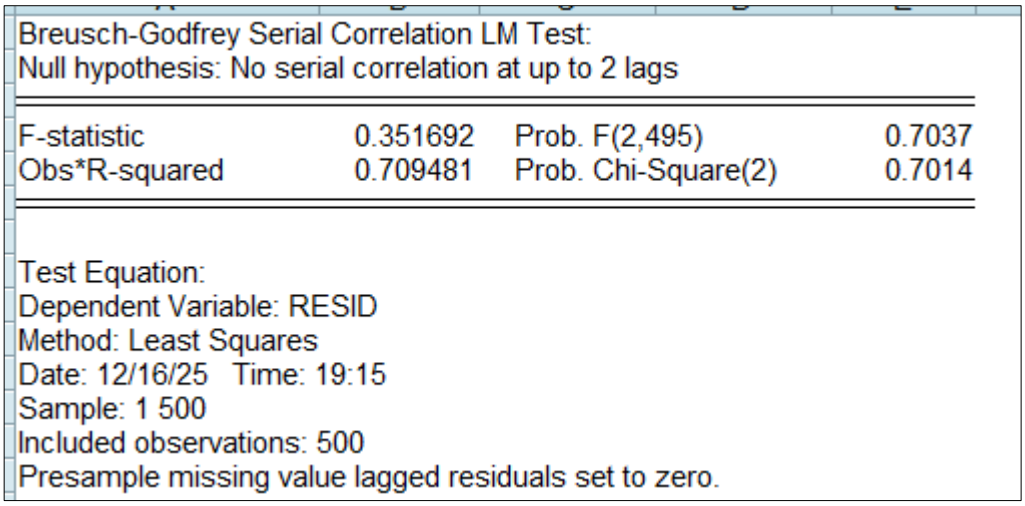
Variable	Coefficient Variance	Uncentered VIF	Centered VIF
C	1.354778	13507.10	NA
CARAT	0.000215	4.898373	1.009661
LOG(TABLE)	0.083046	13548.12	1.009661

Рисунок 6.6 – Отчет VIF-теста на мультиколлинеарность

Проверка факторов, использованных в данной модели, показала, что максимальное значение Centered VIF не превышает 1.01. Поскольку все

значения VIF существенно ниже критического порога 10 , критическая мультиколлинеарность отсутствует.

Тест на автокорреляцию приведен на рисунке 6.7.



Breusch-Godfrey Serial Correlation LM Test:
Null hypothesis: No serial correlation at up to 2 lags

F-statistic	0.351692	Prob. F(2,495)	0.7037
Obs*R-squared	0.709481	Prob. Chi-Square(2)	0.7014

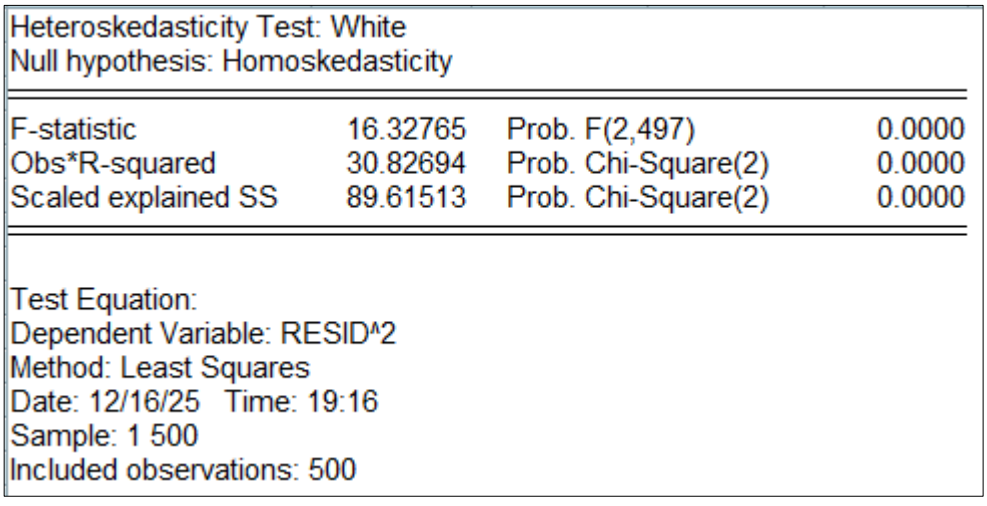
Test Equation:
Dependent Variable: RESID
Method: Least Squares
Date: 12/16/25 Time: 19:15
Sample: 1 500
Included observations: 500
Presample missing value lagged residuals set to zero.

Рисунок 6.7 – Проверка остатков на отсутствие автокорреляции

Автокорреляция остатков (Тест Дарбина-Уотсона и Бройша-Годфри)

Статистика Дарбина-Уотсона: значение 2.009738 находится очень близко к 2.0. Тест Бройша-Годфри: для данной модели значение = 0.7037. В обеих проверках гипотеза об отсутствии автокорреляции остатков H_0 не отвергается. Модель свободна от автокорреляции остатков.

Тест на гетероскедастичность приведен на рисунке 6.8.



Heteroskedasticity Test: White
Null hypothesis: Homoskedasticity

F-statistic	16.32765	Prob. F(2,497)	0.0000
Obs*R-squared	30.82694	Prob. Chi-Square(2)	0.0000
Scaled explained SS	89.61513	Prob. Chi-Square(2)	0.0000

Test Equation:
Dependent Variable: RESID^2
Method: Least Squares
Date: 12/16/25 Time: 19:16
Sample: 1 500
Included observations: 500

Рисунок 6.8 – Проверка остатков на гетероскедастичность

Поскольку p-value составило 0.0000, что существенно меньше критического уровня значимости 0.05, нулевая гипотеза (H_0) о гомоскедастичности отвергается.

Несмотря на применение логарифмической трансформации к зависимой переменной PRICE и к TABLE, проблема гетероскедастичности остается в остатках модели.

Для выбора оптимальной спецификации, которая наилучшим образом сочетает экономическую интерпретацию, статистическую точность и надежность, проведем финальное сравнение трех построенных моделей по совокупности критериев (таблица 6.1).

Таблица 6.1 – Сравнение трех моделей

Критерий сравнения	Модель 1 (Lin-Lin)	Модель 2 (Log-Lin)	Модель 3 (ln(P),ln(C))	Интерпретация результата
Константа (C)	Значима (p=0.0000)	Значима (p=0.0000)	Значима (p=0.0000)	Свободный член высокозначим во всех спецификациях.
CARAT	Значима (p=0.0000)	Значима (p=0.0000)	Значима (p=0.0000)	Коэффициент CARAT остается высокозначимым во всех спецификациях.
TABLE / log (TABLE)	Значима (p=0.0000)	Значим (p = 0.0029)	Значима (p=0.0000)	Фактор TABLE сохраняет высокую значимость во всех моделях.
Adj. R^2	0.988529	0.889706	0.889683	Исходная модель демонстрирует незначительно более высокую объясняющую способность.
Мультиколлинеарность (VIF)	Отсутствует	Отсутствует	Отсутствует	Все модели свободны от критической мультиколлинеарности.
Автокорреляция (DW)	Отсутствует (Durbin-Watson = 2.094814)	Отсутствует (Durbin-Watson = 2.008974)	Отсутствует (Durbin-Watson = 2.009738)	Модель 2 в большей степени свободна от автокорреляции остатков.
Гетероскедастичность	Отсутствует	Присутствует	Присутствует	Модель 2 и 3 присутствует гетероскедастичность

Несмотря на то, что модель 2 немного в большей степени свободна от автокорреляции остатков., 2 и 3 модели обладает фундаментальным недостатком – гетероскедастичностью. Значение prob = 0.0000 существенно ниже $\alpha = 0.05$, что свидетельствует о том, что дисперсия случайной ошибки не является постоянной, что делает экономическую интерпретацию моделей проблематичной.

Исходная модель в свою очередь, демонстрирует сбалансированные статистические свойства: статистическую значимость всех включённых переменных, отсутствие критической мультиколлинеарности и автокорреляции остатков.

6.2 Рекомендации по использованию модели для управленческих решений и реализации экономической политики, практическая значимость полученных результатов

Проведенный сравнительный анализ и выбор оптимальной изначальной модели (модели 1) позволяют сформулировать выводы, имеющие непосредственное значение для ценообразования, управления запасами и финансового моделирования в алмазной и ювелирной индустрии. Несмотря на теоретическую привлекательность логарифмических трансформаций в моделях 2 и 3, они продемонстрировали наличие гетероскедастичности (Prob. = 0.0000), что указывает на непостоянство дисперсии ошибок и снижает доверие к статистическим выводам.

Модель 1, напротив, показала наилучшую объясняющую способность (adj R^2 = 0.9885) и отсутствие критических нарушений предпосылок МНК. Включенные в нее факторы – CARAT и TABLE сохранили высокую статистическую значимость, что делает эту модель наиболее пригодной для практического применения.

Для огранщиков и дилеров (производственный цикл): выявленные зависимости предоставляют четкий инструментарий для прогнозной оценки. Результаты модели 1 подтверждают доминирующее влияние массы: коэффициент при переменной CARAT показывает прямой и стабильный прирост цены. Особого внимания заслуживает фактор TABLE (площь верхней грани). Модель фиксирует, что чрезмерное увеличение площади верхней грани может приводить к снижению стоимости актива. Это объясняется тем, что слишком большая площадка нарушает идеальные пропорции огранки, что ведет к потере внутренней отражающей способности камня и снижению его сверкания.

Таким образом, для дилеров и огранщиков контроль над TABLE становится критическим фактором: стремление максимизировать видимый размер камня за счет расширения верхней грани в ущерб качеству огранки является экономически неэффективным, так как рынок дисконтирует такие экземпляры.

Для ювелирных компаний и риск-менеджмента (финансовое моделирование): линейная спецификация обеспечивает максимальную прозрачность и простоту интерпретации. Это позволяет финансовым службам и казначействам точно оценивать чувствительность стоимости складских запасов к изменению физических характеристик алмазов (массы и качественных параметров). Ключевым преимуществом выбранной модели является отсутствие гетероскедастичности: это гарантирует, что точность оценки остается стабильной как для мелких камней, так и для премиальных позиций. Для служб риск-менеджмента это означает предсказуемость величины ошибки прогноза, что критически важно при расчете стоимости чистых активов, планировании ценовой политики и хеджировании рисков волатильности цен на драгоценные камни.

Для инвестиционных аналитиков (мониторинг рынка): результаты исследования выделяют предельно узкий, но репрезентативный набор приоритетных характеристик – массу (CARAT) и площадь верхней грани (TABLE), которые требуют постоянного мониторинга. Исключение качественных параметров (Color, Clarity, Cut) как статистически незначимых в данной спецификации позволяет аналитическим агентствам значительно упростить прогнозные модели. Это предостерегает от избыточного усложнения аналитических построений, фокусируя внимание на фундаментальных драйверах доходности. Вывод о том, что рыночная стоимость в первую очередь определяется балансом веса и корректностью пропорций (выраженной через TABLE), дает аналитикам четкий критерий для оценки инвестиционной привлекательности партий алмазов и отсеивания активов с переоцененными качественными характеристиками.

Таким образом, модель 1 доказала свою эффективность как практический инструмент для работы на алмазном рынке. Она позволяет не просто «угадывать» цену, а точно рассчитывать её на основе объективных данных. Благодаря своей простоте и надежности, модель помогает бизнесу обоснованно устанавливать цены, планировать объемы производства и принимать взвешенные решения о покупке или продаже партий алмазов, минимизируя риск финансовых потерь.

ЗАКЛЮЧЕНИЕ

Целью курсовой работы являлось построение статистически значимой эконометрической модели, описывающей зависимость цены алмазов (PRICE) от их ключевых характеристик (масса, огранка, цвет, чистота), а также выполнение анализа и выбора оптимальной функциональной формы для интерпретации и прогнозирования.

В результате выполнения курсовой работы были решены следующие задачи:

1 В первом разделе «Анализ литературных исследований и программных решений» был проведён подробный обзор теоретических моделей ценообразования на рынке алмазов, основанных на моделировании спроса и предложения и использовании регрессионного анализа. Была изучена роль четырех ключевых факторов ("4C" - Carat, Color, Clarity, Cut) и их традиционное нелинейное влияние на стоимость. На основании анализа литературы определен набор переменных, потенциально влияющих на PRICE, и сформирован теоретический базис, указывающий на предпочтительность логарифмических форм.

2 Во втором разделе «Спецификация модели» была выполнена идентификация эндогенной переменной (PRICE) и экзогенных переменных. Проведены преобразования категориальных факторов (Cut, Color, Clarity) в фиктивные переменные, а также выполнен VIF-тест, подтвердивший отсутствие критической мультиколлинеарности между факторами. Это обеспечило корректность выбора факторной структуры для последующего МНК-оценивания.

3 В третьем разделе «Построение модели и описание основных статистик» была оценена базовая многофакторная модель методом наименьших квадратов (МНК) в линейной форме. Первоначальный анализ выявил, что такие параметры, как DEPTH, CLARITY и CUT, являются статистически незначимыми для данной выборки, в связи с чем они были исключены из финальной спецификации для повышения точности и надежности оценок. Итоговая оптимизированная модель продемонстрировала высокую статистическую значимость оставшихся переменных – CARAT и TABLE. Коэффициент детерминации (R^2 = 0,988) подтвердил исключительную объясняющую силу модели: отобранные факторы описывают более 98% вариации цены алмазов, что делает данную спецификацию надежным инструментом для дальнейшего анализа.

4 В четвертом разделе «Анализ остатков» была выполнена всесторонняя проверка выполнения предпосылок МНК для построенных спецификаций. Тесты Дарбина-Уотсона и Бройша-Годфри подтвердили отсутствие автокорреляции остатков во всех моделях. Так же тест Уайта подтвердил отсутствие гетероскедастичности.

5 В пятом разделе «Прогнозирование на основе оценённой модели» были получены точечные прогнозы и доверительные интервалы для

математического ожидания и индивидуальных значений цены алмаза. Низкие значения метрик точности прогноза, таких как MAE, RMSE, MAPE и коэффициент Тейла, подтвердили высокую точность прогнозов, а малые интервалы неопределённости продемонстрировали надёжность оценённых коэффициентов. Графическое сопоставление фактических и прогнозных значений показало, что модель корректно отражает ценовую динамику, демонстрируя хорошую внешнюю валидность.

6 В шестом разделе «Сравнительный анализ эконометрических моделей и рекомендации по использованию модели» было проведено сравнение трех спецификаций моделей. Несмотря на теоретические преимущества логарифмических трансформаций (модели 2 и 3), наличие в них гетероскедастичности сделало невозможным их использование для получения надежных оценок. В качестве оптимальной была выбрана линейная модель 1, так как она объясняет более 98% вариации цены и обладает свойством гомоскедастичности. Это означает, что точность прогноза остается стабильной для всего диапазона данных, что гарантирует надежность статистических выводов и предсказуемость модели при оценке как мелких, так и крупных алмазов.

7 В итоге можно отметить, что цели и задачи исследования полностью выполнены. Построенная модель 1 является статистически наиболее адекватной и экономически содержательной. Она позволяет количественно оценивать влияние ключевых характеристик на стоимость алмаза и может быть успешно применена для целей прогнозирования и ценообразования на рынке алмазов. Полученные результаты обладают значительной практической ценностью для огранщиков, ювелирных компаний и инвестиционных фондов.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

[1] Алмазы: набор данных [Электронный ресурс]. – Режим доступа: https://www.kaggle.com/datasets/shivam2503/diamonds

[2] Что такое карат, как определяется вес драгоценных камней и их цена [Электронный ресурс]. – Режим доступа: https://platinumlab.ru/blog/chto-takoe-karat-kak-opredelyaetsya-ves-dragocennyh-kamnej-i-ih-cena-%E2%80%93-sovety-ot-platinum-lab.html

[3] Эконометрика: учебник / под ред. И.И. Елисеевой. – М.: Финансы и статистика, 2007. – с 576

[4] Bishop, K. C. Hedonic Prices and Implicit Markets: Estimating Marginal Willingness to Pay for Differentiated Products without Instrumental Variables / K. C. Bishop, C. Timmins. – Cambridge, MA : National Bureau of Economic Research (NBER), 2011. – 48 с.

[5] Landwehr, M. E. Гедоническая модель ценообразования для рынка алмазов / M. E. Landwehr, R. L. Johnson, M. A. Herrmann // Journal of Marketing. – 1995. – с. 107–112.

[6] Bauer, M. Гедонистические модели цен для бриллиантов / M. Bauer, A. Landman // Applied Economics. – 2000. – с. 1399–1410.

[7] Johnson, T. R. Гедонистические модели цен/ T. R. Johnson // Journal of Economic Literature. – 1988. – с. 1381–1396.

[8] Cowell, R. Гедонический анализ цен на бриллианты: спецификация и оценка / R. Cowell, G. R. S. Rao // Journal of Applied Econometrics. – 1993. – с. 157–169.

[9] Smith, G. Моделирование цены ювелирных изделий с бриллиантами/ G. Smith // Journal of Economic Behavior & Organization. – 2007. – с. 202–215

[10] Sun, X. Сравнение гедонистических моделей цен и алгоритмов машинного обучения для прогнозирования цен на алмазы / X. Sun, Y. Chen, Y. Liu // Journal of Big Data. – 2020. – с. 1–18.

[11] Varian, H. R. Прогнозирование, политика и интерпретация / H. R. Varian // American Economic Papers and Proceedings. – 2014. – с. 1–18.

[12] Variance Inflation Factor (VIF): Definition and Formula [Электронный ресурс]. – Режим доступа: https://www.investopedia.com/terms/v/variance-inflation-factor.asp

[13] Метод наименьших квадратов (МНК) [Электронный ресурс]. – Режим доступа: https://desktop.arcgis.com/ru/arcmap/latest/tools/spatial-statistics-toolbox/ordinary-least-squares.htm

[14] Хацкевич, Г. А. Эконометрика : учебник для студентов учреждений высшего образования по специальностям «Управление информационными ресурсами», «Информационные системы и технологии (в экономике)» / Г. А. Хацкевич, Т. В. Русилко. – Минск : РИВШ, 2021. – 450 с.

[15] Сенатов, В. В. Центральная предельная теорема : точность аппроксимации и асимптотические разложения / В. В. Сенатов ; В. В. Сенатов. – Москва: URSS, 2009. – 350 с.

[16] Подповетная, Ю. В. Прогнозирование на основе эконометрических моделей и моделей временных рядов / Ю. В. Подповетная // Европейский журнал социальных наук. – 2014. – № 5-2(44). – С. 401-409.

[17] Математическое ожидание [Электронный ресурс]. – Режим доступа: https://wiki.loginom.ru/articles/expectation-value.html

[18] Сравнительный анализ: метод, пример, виды [Электронный ресурс]. – Режим доступа: https://wiki.loginom.ru/articles/expectation-value.html