Министерство образования Республики Беларусь
Учреждение образования «Белорусский государственный университет информатики и радиоэлектроники»

Факультет инженерно-экономический
Кафедра экономической информатики
Дисциплина «Алгоритмы и модели машинного обучения»

«К ЗАЩИТЕ ДОПУСТИТЬ»
Руководитель курсовой работы
Старший преподаватель кафедры ЭИ, магистр экономических наук
_____ Т.Г.Пинчук
___.___.2026

**ПОЯСНИТЕЛЬНАЯ ЗАПИСКА**
к курсовой работе
на тему:

# «МОДЕЛИРОВАНИЕ ЦЕНООБРАЗОВАНИЯ НА РЫНКЕ НЕФТЕПРОДУКТОВ»

БГУИР КР 6-05-0611-01 028 ПЗ

Выполнил студент группы 372302
Усова Виктория Александровна
_____
(подпись студента)
Курсовая работа представлена на проверку ___.___.2026
_____
(подпись студента)

Минск 2026

Бланк заданий

Бланк заданий

# РЕФЕРАТ

БГУИР КР 6-05-0611-01 028 ПЗ

МОДЕЛИРОВАНИЕ ЦЕНООБРАЗОВАНИЯ НА РЫНКЕ НЕФТЕПРОДУКТОВ: курсовая работа / В. А. Усова. – Минск: БГУИР, 2026, – п.з. – 79 с.

Пояснительная записка 79 с., 42 рис., 8 табл., 16 источников, 1 приложение.

**Ключевые слова**: розничные цены на топливо, эконометрическое моделирование, машинное обучение, временные ряды, ARIMA, GARCH, регрессионный анализ, ADF-тест, коинтеграция, мировые цены на нефть, индекс цен производителей, промышленное производство, потребительские настроения, прогнозирование.

*Цель курсовой работы*: повышение качества анализа и прогнозирования динамики цен на нефтепродукты посредством сравнительного исследования эконометрических моделей и алгоритмов машинного обучения, а также определения ключевых факторных признаков, формирующих ценовую динамику.

*Методология проведения работы*: в исследовании использованы методы анализа временных рядов, корреляционного и регрессионного анализа, проверка стационарности с применением ADF-теста, коинтеграционный анализ на основе теста Энгла–Грейнджера, методы моделирования условной гетероскедастичности (GARCH), а также алгоритмы машинного обучения: Random Forest, Gradient Boosting, Ridge Regression и K-Nearest Neighbors. Оценка моделей осуществлялась посредством процедуры walk-forward cross-validation по метрикам RMSE, MAE и MAPE. Все расчёты выполнены с использованием языка программирования Python.

*Результаты работы*: проведён обзор теоретических подходов к моделированию ценообразования на рынке нефтепродуктов; сформирована и обработана база ежемесячных данных по шести переменным; исследованы статистические свойства временных рядов, подтверждена коинтеграция в многомерной системе; сформировано итоговое пространство из 13 признаков; построены и сравнены шесть прогностических моделей на пяти горизонтах прогнозирования; установлено лидерство Ridge Regression и Gradient Boosting; определены ключевые детерминанты цен на нефтепродукты – индекс цен производителей нефтепереработки PCU и цена нефти WTI.

*Область применения результатов*: полученные результаты могут быть использованы для прогнозирования цен на энергоносители, оценки инфляционных рисков и формирования ценовой политики на топливном рынке. Практическую ценность они представляют для нефтяных компаний, розничных операторов АЗС, транспортных предприятий, государственных регуляторов энергетического рынка и аналитических центров.

# СОДЕРЖАНИЕ

Введение ..... 6
1 Анализ литературных исследований и программных решений ..... 8
1.1 Описание и анализ предметной области ..... 8
1.2 Обзор существующих подходов к моделированию и прогнозированию целевого признака ..... 12
1.2.1 Теоретические модели ценообразования на рынке нефтепродуктов ..... 12
1.2.2 Классические модели временных рядов ..... 14
1.2.3 Модели волатильности финансовых временных рядов ..... 14
1.2.4 Методы машинного обучения в прогнозировании цен на топливо 15
2 Спецификация модели ..... 17
2.1 Идентификация признаков ..... 17
2.2 Визуальный и статистический анализ структуры и динамики признаков ..... 19
2.2.1 Анализ распределения целевого признака и факторов ..... 19
2.2.2 Устранение выбросов и аномальных значений признаков ..... 24
2.2.3 Визуальный анализ динамики признаков ..... 26
2.3 Анализ корреляционных свойств и стационарности временных рядов 29
2.3.1 Анализ стационарности временных рядов ..... 29
2.3.2 Анализ автокорреляционных функций (ACF и PACF) временных рядов ..... 31
2.3.3 Анализ тренда и сезонности временного ряда ..... 36
2.4 Извлечение признаков ..... 44
3 Модели прогнозирования целевого признака ..... 49
3.1 Описание моделей и процедуры анализа ..... 49
3.2 Подбор оптимальных значений гиперпараметров ..... 57
3.3 Результаты прогнозирования ..... 59
4 Анализ важности факторных признаков ..... 68
Заключение ..... 75
Список использованных источников ..... 77
Приложение А (обязательное) Отчет о проверке на заимствования в системе «Антиплагиат» ..... 79

# ВВЕДЕНИЕ

Рынок нефтепродуктов является одной из ключевых составляющих современной экономики, поскольку его функционирование оказывает значительное влияние на уровень цен, инфляционные процессы, издержки производства и транспортную доступность. Ценообразование на рынке нефтепродуктов затрагивает интересы государства, бизнеса и населения, определяя экономическую устойчивость и социальную стабильность.

Процесс ценообразования на рынке нефтепродуктов носит сложный и многофакторный характер. На уровень цен влияют как внешние факторы, связанные с динамикой мировых цен на нефть и нефтепродукты, так и внутренние макроэкономические условия, рыночные факторы. В совокупности это формирует необходимость применения количественных методов для выявления устойчивых экономических закономерностей.

Традиционные эконометрические методы – ARIMA, GARCH и модели на основе МНК – на протяжении десятилетий являлись основным инструментарием для описания динамики цен на энергоносители. Вместе с тем их способность улавливать сложные нелинейные зависимости и взаимодействия между факторами ограничена. В последние годы активное развитие методов машинного обучения открыло новые возможности для повышения точности прогнозирования: ансамблевые алгоритмы, такие как Gradient Boosting и Random Forest, а также регуляризованные модели Ridge Regression и непараметрический метод K-Nearest Neighbors демонстрируют конкурентоспособные результаты при работе с реальными финансовыми и сырьевыми данными. Сравнительный анализ классических и современных подходов в задаче прогнозирования цен на нефтепродукты представляет как теоретический, так и практический интерес.

Процесс ценообразования на рынке нефтепродуктов подвержен влиянию широкого спектра факторов: мировых котировок нефти (Brent, WTI), уровня инфляции и индекса потребительских цен, состояния промышленного производства и нефтепереработки, потребительских настроений и реальных располагаемых доходов населения, объёмов розничных продаж на заправочных станциях, курса доллара США, а также сезонной составляющей, связанной с динамикой спроса. Эконометрическое моделирование и алгоритмы машинного обучения позволяют структурировать это влияние, проверить теоретические гипотезы и получить количественные оценки силы взаимосвязей.

Исследование проводилось на помесячных данных, полученных из открытой базы данных Федеральной резервной системы США (FRED) [1]. В качестве результирующего признака выступает розничная цена автомобильного бензина в США (GASREGM, долл./галлон). Факторными признаками являются: цена нефти WTI (DCOILWTICO), уровень безработицы (UNRATE), индекс потребительских настроений (UMCSENT), индекс цен

производителей нефтепереработки (PCU32411032411012) и индекс промышленного производства нефтегазового сектора (IPG211S).

Предметом курсовой работы являются методы и модели эконометрического анализа и машинного обучения, применяемые для исследования динамики и детерминант ценообразования на рынке нефтепродуктов.

Объектом исследования является процесс формирования розничных цен на нефтепродукты под влиянием комплекса макроэкономических и рыночных факторов.

Целью курсовой работы является повышение качества анализа и прогнозирования динамики цен на нефтепродукты посредством сравнительного исследования эконометрических моделей и алгоритмов машинного обучения, а также определения ключевых факторных признаков, формирующих ценовую динамику.

Для достижения поставленной цели необходимо решить следующие задачи:

1 Провести анализ предметной области и теоретических подходов к моделированию цен на нефтепродукты, определить круг потенциально значимых факторов на основе изучения научной литературы.

2 Выполнить сбор и предварительный анализ данных, проверить временные ряды на стационарность, выявить и обработать аномальные наблюдения, а также сформировать итоговое пространство признаков для построения моделей.

3 Построить и оптимизировать прогностические модели двух классов: эконометрических (ARIMA, GARCH) и алгоритмов машинного обучения (Gradient Boosting, Random Forest, Ridge Regression, K-Nearest Neighbors), и провести их сравнительную оценку на различных горизонтах прогнозирования посредством walk-forward кросс-валидации.

4 Выполнить анализ важности факторных признаков на основе внутренних механизмов ансамблевых алгоритмов и стандартизованных коэффициентов Ridge Regression, дать содержательную экономическую интерпретацию полученных результатов.

Таким образом, моделирование ценообразования на рынке нефтепродуктов с применением как классических эконометрических методов, так и современных алгоритмов машинного обучения представляет собой актуальную и практически значимую задачу. Комплексный подход к анализу позволяет не только повысить точность прогнозов, но и получить более глубокое понимание механизмов формирования цен на энергоносители. Полученные результаты могут быть востребованы нефтяными компаниями, регуляторами энергетических рынков, розничными сетями АЗС, а также аналитическими центрами и финансовыми институтами для повышения обоснованности стратегических и оперативных решений в условиях нестабильности глобальных сырьевых рынков.

# 1 АНАЛИЗ ЛИТЕРАТУРНЫХ ИССЛЕДОВАНИЙ И ПРОГРАММНЫХ РЕШЕНИЙ

## 1.1 Описание и анализ предметной области

Мировой рынок нефти и нефтепродуктов является одной из важнейших составляющих глобальной экономической системы. Нефть выступает стратегическим сырьевым ресурсом, определяющим развитие энергетики, промышленности и транспортного сектора. Цены на нефть и нефтепродукты оказывают существенное влияние на макроэкономические показатели стран-экспортёров и стран-импортёров, формирование бюджетных доходов, инфляционные процессы и динамику экономического роста.

Мировой нефтяной рынок сформировался в конце XIX – начале XX века в результате промышленного освоения нефти как источника энергии и сырья для переработки. Первые крупные месторождения нефти были открыты в США в 1859 году, что положило начало развитию нефтедобывающей промышленности и формированию первых транснациональных нефтяных компаний [2]. В этот период нефть использовалась преимущественно для производства керосина, а рынок носил локальный характер.

В первой половине XX века, с развитием автомобилестроения и авиации, нефть стала ключевым энергетическим ресурсом, что привело к быстрому росту спроса на нефтепродукты. В этот период происходила вертикальная интеграция нефтяных компаний, объединявших добычу, транспортировку, переработку и сбыт нефти.

Значимым этапом в истории нефтяного рынка стало создание в 1960 году Организации стран – экспортёров нефти (ОПЕК), объединившей ведущие нефтедобывающие страны с целью координации нефтяной политики и защиты их экономических интересов [3]. С этого момента институциональные факторы стали играть важную роль в формировании мировых цен на нефть. Нефтяные кризисы 1973 и 1979 годов, вызванные сокращением добычи и эмбарго со стороны стран ОПЕК, продемонстрировали высокую чувствительность мировой экономики к изменениям предложения нефти и привели к резкому росту цен.

Рынок нефтепродуктов представляет собой сложную многоуровневую экономическую систему, в рамках которой осуществляется производство, переработка, транспортировка и реализация продуктов переработки нефти. Его сущность заключается в согласовании интересов производителей, переработчиков, трейдеров и потребителей нефти в условиях ограниченности ресурсов и высокой зависимости от внешних факторов [4]. К основным видам нефтепродуктов относятся автомобильные бензины, дизельное топливо, авиационное топливо и мазут, которые широко используются в транспортном секторе, промышленности и коммунальном хозяйстве.

Экономическая роль нефтяного рынка обусловлена стратегическим значением нефти как основного источника энергии и сырья для химической

промышленности. По данным международных энергетических агентств, нефть и нефтепродукты занимают значительную долю в мировом энергопотреблении, что делает цены на нефть важным макроэкономическим индикатором. Колебания нефтяных цен напрямую отражаются на инфляции, платёжных балансах и бюджетных доходах стран [5].

Для стран-экспортёров нефти нефтяной сектор является ключевым источником валютных поступлений и государственных доходов. Для стран-импортёров – одним из основных факторов формирования издержек производства и транспортных расходов.

Структура мирового нефтяного рынка включает несколько взаимосвязанных сегментов. Первым сегментом является добыча нефти, которая сосредоточена в ограниченном числе стран и регионов. К крупнейшим производителям нефти относятся страны Ближнего Востока, США и Россия, на долю которых приходится значительная часть мирового предложения [6].

Вторым сегментом является транспортировка нефти, осуществляемая с использованием трубопроводов, морских танкеров и железнодорожных перевозок. Транспортные издержки и географические особенности поставок оказывают влияние на региональные различия в ценах на нефть и нефтепродукты [7].

Третьим сегментом является переработка нефти на нефтеперерабатывающих заводах [8]. Именно на этом этапе формируется предложение нефтепродуктов, включая автомобильный бензин, дизельное топливо и авиационный керосин. Степень глубины переработки и технологический уровень НПЗ определяют структуру выпуска и себестоимость продукции.

Заключительным сегментом является сбыт нефтепродуктов конечным потребителям. Цены на нефтепродукты формируются с учётом мировых цен на нефть, налоговой нагрузки, транспортных расходов и особенностей государственного регулирования.

Организация стран – экспортёров нефти (ОПЕК) играет ключевую роль в регулировании мирового нефтяного рынка. Основной целью ОПЕК является координация нефтяной политики стран-участниц и стабилизация цен на нефть путём управления объёмами добычи. Механизм воздействия ОПЕК основан на системе квот, ограничивающих или увеличивающих добычу нефти в зависимости от рыночной конъюнктуры.

С 2016 года особое значение приобрёл формат ОПЕК+, объединяющий страны ОПЕК и крупнейших производителей нефти, не входящих в организацию. Расширение координации позволило усилить контроль над предложением нефти и повысить предсказуемость ценовой динамики. В эконометрических исследованиях решения ОПЕК и ОПЕК+ часто рассматриваются как институциональный фактор, влияющий на цены нефти и нефтепродуктов.

Сегодня существуют два основных метода ценообразования, которые широко используются на мировом рынке нефтепродуктов. Это биржевое

(спотовое и фьючерсное) ценообразование и внебиржевой (контрактный) рынок [9].

Биржевое ценообразование основано на торговле нефтью и нефтепродуктами на организованных товарных биржах, таких как Нью-Йоркская товарная биржа (NYMEX) и Межконтинентальная биржа (ICE). В рамках данного механизма цены формируются в результате взаимодействия спроса и предложения на стандартизированные контракты, в первую очередь на эталонные марки нефти – Brent и WTI. Биржевые котировки выполняют функцию ценовых индикаторов и широко используются в качестве базисных цен при заключении контрактов на поставку нефти и нефтепродуктов.

Биржевое ценообразование характеризуется высокой прозрачностью и оперативной реакцией на изменения рыночной конъюнктуры. Цены на биржах быстро отражают ожидания участников рынка, геополитические риски, макроэкономические новости и решения ключевых производителей нефти [10]. Вместе с тем, ряд авторов отмечает, что значительная роль финансовых инвесторов и спекулятивных операций может усиливать краткосрочную волатильность цен, не всегда связанную с фундаментальными факторами спроса и предложения.

Внебиржевое ценообразование осуществляется на основе двусторонних контрактов между производителями, трейдерами, переработчиками и крупными потребителями нефтепродуктов. В рамках данного механизма цена, как правило, формируется на основе биржевых котировок с учётом корректировок на качество продукции, условия поставки, транспортные издержки и налоговую нагрузку. Внебиржевой рынок играет ключевую роль в физической поставке нефтепродуктов и обеспечивает стабильность долгосрочных торговых отношений.

Исследования показывают, что внебиржевое ценообразование позволяет снижать ценовые риски за счёт использования долгосрочных контрактов и формул ценообразования, привязанных к средним биржевым ценам за определённый период. При этом данный механизм менее прозрачен по сравнению с биржевым рынком, что ограничивает доступность информации о фактических ценах сделок.

В ряде работ подчёркивается, что биржевой и внебиржевой механизмы ценообразования не являются взаимоисключающими, а дополняют друг друга. Биржевые цены выполняют функцию ориентиров и индикаторов рыночных ожиданий, тогда как внебиржевой рынок обеспечивает основную массу физических поставок нефтепродуктов. Такое сочетание механизмов ценообразования усложняет анализ цен и требует использования комплексных эконометрических моделей, учитывающих влияние как рыночных, так и институциональных факторов.

С конца 1980-х гг. мировой рынок нефти является уже не столько исключительно рынком товарным, сколько, по сути, преимущественно рынком финансовым (рынком нефтяных фьючерсов и нефтяных финансовых

деривативов – производных от нефтяных фьючерсов финансовых инструментов).

Хотя до сих пор существуют авторы, стоящие на позициях, что динамика цен определяется исключительно уровнями потребления жидкого топлива и технологического развития отрасли (т. е. исключительно характеристиками рынка физической нефти), но полностью игнорирующие наличие финансового компонента в динамике цен (трансформацию нефти из физического товара сначала в товар биржевой, а затем и в финансовый актив), отрицающие тем самым процессы коммодитизации и финансиализации рынка нефти и возрастающую роль именно этих факторов в формировании цен на нефть [11].

Основную роль на этом рынке играют две группы игроков с противоположно направленными интересами: хеджеры и спекулянты [12]. Хеджеры – это обычно производители и торговцы реальным товаром, т. е. участники рынка физической нефти. К их числу относятся нефтедобывающие компании, в том числе крупнейшие нефтяные мэйджоры, НПЗ, компании-трейдеры, потребители нефтепродуктов, зарабатывающие свою прибыль на марксовой метаморфозе «деньги – товар – деньги». Хеджеры используют фьючерсы и другие производные финансовые инструменты для снижения риска, который они несут в связи с потенциальными будущими колебаниями нефтяных цен, т. е. для страхования от роста или падения цены на товар (нефть и (или) нефтепродукты) в будущем. Нефтяные компании страхуют нефть новых месторождений от падения цен на несколько лет вперед (правда, конечно, не могут технически сделать это сразу на весь, измеряемый десятилетиями, срок разработки месторождения). Крупные потребители нефтепродуктов, например авиакомпании, защищаются от роста цен на закупаемое топливо.

Хеджеры заинтересованы в стабилизации ценовых колебаний, в установлении предсказуемых на долгосрочную перспективу цен на нефть, поскольку эти участники рынка (особенно производители) зарабатывают свою прибыль на длинном инвестиционном плече финансирования инвестиционных проектов с жизненным циклом порядка 30-40-50 лет и периодом окупаемости капиталовложений в проект (измеряемых, как правило, миллиардами долларов) порядка пять-семь лет.

Спекулянты на рынке нефти – это торговцы нефтяными контрактами («бумажной» нефтью) и их производными (нефтяными деривативами, т. е. производными финансовыми инструментами на нефтяные контракты, которые обычно не предусматривают поставку реального). К этой категории игроков относятся обычно инвестиционные банки и другие категории финансовых инвесторов, зарабатывающие свою прибыль на марксовой метаморфозе «деньги – деньги». Спекулянты зарабатывают свою прибыль на коротком плече финансовых операций. В отличие от хеджеров, желающих избежать ценовых рисков, спекулянты открывают свою позицию на рынке, ставя на то, что цена будет повышаться или понижаться. Спекулянт не покупает и не продает реальный товар, но принимает на себя риск в надежде

получить прибыль на фьючерсном рынке. Деньги спекулянтов – это обычно высоколиквидные финансовые ресурсы, обладающие высокой мобильностью и склонностью к оперативной миграции в те сегменты мировых валютно-финансовых рынков, где им сегодня обеспечена наивысшая отдача на коротком временном плече. Для специализированных нефтяных спекулянтов работа на «бумажном» сегменте нефтяного рынка имеет первостепенное значение. Они не работают на рынке физической нефти, но могут работать за пределами нефтяного рынка – на рынках финансовых инструментов в различных сегментах мирового валютнофинансового рынка.

Так, по данным Комиссии по торговле товарно-сырьевыми фьючерсами (CFTC) США, в феврале 2007 г. доля спекулянтов на NYMEX составила 30%, в июне 2008 г. – уже 70%. По результатам неформальных опросов европейских нефтяных брокеров, доля спекулянтов на нефтяном рынке на пике нефтяных цен в середине 2008 г. составила 70–80%. А на ICE, по данным самой биржи, доля хеджеров (компаний товарного сектора) составляет в настоящее время снова примерно 2/3. Очевидна жесткая корреляция между активностью биржевых спекулянтов на рынке нефти и ценой на нефть. Некоторые эксперты [13] возлагают на деятельность нефтяных (биржевых) спекулянтов ответственность примерно за 25–30% цены на нефть на пике нефтяных котировок летом 2008 г. (или за дополнительные 30–40 долл./баррель в цене нефти 125 долл./баррель, существовавшей в июне 2008 г.).

## 1.2 Обзор существующих подходов к моделированию и прогнозированию целевого признака

Цены на нефтепродукты – один из наиболее исследуемых объектов в энергетической экономике и прикладном прогнозировании. Их изучение важно не только для участников топливного рынка, но и для государственных регуляторов, поскольку стоимость моторного топлива напрямую влияет на издержки производства, транспортные расходы и благосостояние домохозяйств. Разнообразие факторов, определяющих ценовую динамику – от глобальных нефтяных котировок до поведенческих характеристик потребителей, – обусловило широкий спектр методологических подходов к моделированию этого рынка.

### 1.2.1 Теоретические модели ценообразования на рынке нефтепродуктов

В экономической литературе существует несколько подходов к объяснению механизмов ценообразования на рынке нефтепродуктов. В рамках неоклассической теории цена рассматривается как результат взаимодействия спроса и предложения. Так, Р. Пиндайк отмечает, что динамика цен на сырьевые товары, включая нефть, определяется

фундаментальными факторами, связанными с балансом производства и потребления [14].

В то же время ряд исследователей указывает на ограниченность данного подхода. В частности, Л. Килиан подчеркивает, что нефтяной рынок характеризуется сложной структурой, где ценовая динамика определяется не только текущим балансом спроса и предложения, но и ожиданиями экономических агентов, а также различными типами шоков – спросовыми и предложенческими [15]. Таким образом, в отличие от Пиндайка, Килиан рассматривает рынок нефти как более сложную систему, требующую учета дополнительных факторов.

Отдельное направление исследований связано с теорией хранения. Её основоположник Х. Уоркинг утверждает, что уровень коммерческих запасов нефти играет ключевую роль в формировании ценовой структуры и разницы между спотовыми и фьючерсными ценами [16]. Поддерживая данный подход, Х. Геман также отмечает, что запасы выполняют функцию буфера, сглаживающего ценовые колебания [17]. Однако, в отличие от них, некоторые исследователи указывают, что в условиях резких внешних шоков влияние запасов может быть ограниченным, и они не всегда способны стабилизировать рынок.

Значительный вклад в развитие теории ценообразования внес Дж. Гамильтон, который показал, что нефтяные шоки носят асимметричный характер. По его мнению, рост цен на нефть оказывает более сильное негативное влияние на экономику, чем сопоставимое снижение – положительное [18]. Данная точка зрения получила развитие в последующих работах. Вместе с тем некоторые авторы отмечают, что степень асимметрии может снижаться по мере адаптации экономики к ценовым колебаниям, что свидетельствует о неоднозначности данного эффекта.

Существенное внимание в литературе уделяется роли институциональных факторов, прежде всего деятельности ОПЕК. Согласно официальным материалам организации, координация добычи позволяет стабилизировать рынок и предотвращать резкие ценовые колебания [19]. Эту позицию частично поддерживает Дж. Смит, который рассматривает ОПЕК как важного участника, способного влиять на предложение нефти [20]. Однако Б. Фаттух и Л. Махадева указывают, что влияние ОПЕК со временем ослабло из-за роста добычи нефти вне картеля и усиления конкуренции [21]. Таким образом, в научной литературе отсутствует единое мнение относительно эффективности регулирования рынка со стороны ОПЕК.

Кроме того, в последние десятилетия активно развивается подход, связанный с ростом роли финансового сектора нефтяного рынка. Так, М. Адельман рассматривает нефть прежде всего как физический товар, цена которого определяется фундаментальными факторами [22]. В противоположность этому К. Танг и В. Сюн утверждают, что значительную роль в формировании цен играет финансовый рынок и деятельность инвесторов, что усиливает краткосрочную волатильность [23].

Таким образом, анализ научной литературы показывает, что теоретические модели ценообразования на рынке нефтепродуктов существенно различаются. Одни авторы акцентируют внимание на фундаментальных факторах спроса и предложения, другие – на роли запасов, институционального регулирования и финансовых рынков. Наличие различных подходов отражает сложность и многогранность процессов ценообразования и обосновывает необходимость применения комплексных моделей при их анализе.

### 1.2.2 Классические модели временных рядов

Классические методы анализа временных рядов широко применяются для моделирования и прогнозирования цен на нефтепродукты. К ним относятся авторегрессионные модели, модели скользящего среднего и их комбинации (ARIMA), а также многомерные модели. Методология ARIMA была разработана Дж. Боксом и Г. Дженкинсом [24] и позволяет эффективно описывать инерционность ценовых рядов и строить краткосрочные прогнозы без привлечения внешних факторов.

В то же время ряд исследователей указывает на ограничения одновариантных моделей. В частности, Дж. Гамильтон [25] отмечает, что такие модели не учитывают влияние макроэкономических факторов и могут давать ограниченную экономическую интерпретацию результатов.

Более информативными являются многомерные подходы. Векторные авторегрессионные модели (VAR), предложенные Х. Люткеполем [26], позволяют анализировать взаимное влияние цен на нефть, объёмов переработки и показателей спроса. В исследованиях нефтяного рынка показано, что VAR-модели выявляют эффект запаздывания: изменения мировых цен на нефть отражаются в розничных ценах на топливо с временным лагом.

Метод коинтеграционного анализа, разработанный Дж. Йохансеном [27], позволяет выявлять долгосрочные устойчивые зависимости между временными рядами. Это служит основой для построения моделей коррекции ошибок, описывающих процесс возврата системы к равновесию после отклонений.

Таким образом, классические модели временных рядов широко используются в качестве базовых решений при анализе цен на нефтепродукты, с которыми сравниваются более сложные эконометрические и машинные методы.

### 1.2.3 Модели волатильности финансовых временных рядов

Одной из ключевых особенностей ценовых рядов на нефтяном рынке является выраженная кластеризация волатильности, при которой периоды относительной стабильности чередуются с эпизодами резких ценовых

колебаний. Подобное поведение связывается с влиянием геополитических факторов, изменениями квот добычи, а также макроэкономическими потрясениями.

Для моделирования подобных процессов в научной литературе широко применяются модели семейства ARCH/GARCH. Так, в работе Э. Энгла [28] было предложено использовать ARCH-модели для описания изменяющейся во времени дисперсии, что стало важным шагом в развитии финансовой эконометрики. Однако, как отмечает Т. Боллерслев [29], базовая ARCH-структура имеет ограничения, связанные с необходимостью учета более длительной памяти процесса, что привело к разработке обобщённой GARCH-модели, обеспечивающей более устойчивое и точное описание динамики волатильности.

В дальнейшем ряд авторов предложили расширения данной модели. Например, П. Садорски [30] применяет асимметричные модификации GARCH, такие как EGARCH и TGARCH, и показывает, что рынок по-разному реагирует на положительные и отрицательные шоки. В частности, отрицательные ценовые изменения, как правило, вызывают более сильный рост волатильности по сравнению с аналогичными по величине положительными изменениями.

Аналогичные выводы подтверждаются и в исследованиях, посвящённых сырьевым рынкам, где отмечается наличие эффекта «рычага», проявляющегося в асимметричном влиянии новостей на дисперсию доходностей.

Таким образом, современные модификации моделей семейства ARCH/GARCH позволяют более точно описывать особенности нефтяных временных рядов, включая кластеризацию и асимметрию волатильности. Это делает их особенно полезными при формировании признаков для последующего применения методов машинного обучения в задачах прогнозирования цен.

### 1.2.4 Методы машинного обучения в прогнозировании цен на топливо

Нелинейность и многофакторность ценообразования на рынке нефтепродуктов создают благоприятную почву для применения алгоритмов машинного обучения. Ансамблевые методы – Random Forest и Gradient Boosting – позволяют выявлять сложные взаимодействия между переменными, такими как цена нефти WTI, индекс доллара и макроэкономические показатели, которые трудно формализовать в рамках линейных моделей [31].

Регуляризованные линейные модели, в частности Ridge Regression, обеспечивают устойчивость оценок при высокой коррелированности признаков, характерной для макроэкономических данных [32]. Метод k-

ближайших соседей позволяет учитывать локальные особенности данных без жёстких предположений о форме зависимости.

В работе Й. Чжао [33] исследуется применение рекуррентных нейронных сетей LSTM, которые способны учитывать временную структуру данных и обеспечивать высокую точность краткосрочных прогнозов, в ряде случаев превосходя классические методы.

В целом методы машинного обучения характеризуются высокой прогностической точностью и способностью обрабатывать разнородные данные большого объёма, однако уступают традиционным подходам по интерпретируемости и требуют тщательной настройки.

Анализ существующих подходов показывает, что прогнозирование цен на нефтепродукты является сложной задачей, обусловленной влиянием множества факторов и выраженной нелинейностью динамики. Теоретические и классические модели позволяют выявить базовые закономерности и служат основой для сравнительного анализа, тогда как модели волатильности учитывают кластеризацию рисков и асимметрию ценовых шоков.

Современные методы машинного обучения демонстрируют высокую эффективность, особенно ансамблевые и нейросетевые подходы, обеспечивающие точные краткосрочные прогнозы. Вместе с тем они требуют значительных ресурсов и уступают по интерпретируемости.

Таким образом, наилучшие результаты достигаются при комбинировании классических методов и алгоритмов машинного обучения, что позволяет обеспечить баланс между точностью прогнозирования и интерпретируемостью результатов.

# 2 СПЕЦИФИКАЦИЯ МОДЕЛИ

## 2.1 Идентификация признаков

Идентификация переменных представляет собой ключевой этап построения прогностических моделей ценообразования на рынке нефтепродуктов. Корректный выбор факторных признаков определяет как экономическую содержательность модели, так и её прогностическую точность. В рамках данной работы формируется многофакторная система переменных, охватывающая сырьевые, производственные, макроэкономические и поведенческие детерминанты розничных цен на моторное топливо.

Информационной базой исследования служат официальные ежемесячные данные базы Федеральной резервной системы США (FRED) [14]. Все показатели имеют единую периодичность наблюдений (monthly) и приведены в сопоставимом виде. Сведения о переменных представлены в таблице 2.1.

Таблица 2.1 – «Основные признаки модели»

| Идентификатор | Описание | Тип | Классификация по характеру выражения |
|---|---|---|---|
| GASREGM | Розничная цена бензина | Эндогенная (целевая) | Количественная |
| DCOILWTICO | Цена нефти WTI | Экзогенная (факторная) | Количественная |
| PCU32411032411012 | Индекс цен производителей нефтепереработки | Экзогенная (факторная) | Количественная |
| IPG211S | Индекс промышленного производства нефтегазового сектора | Экзогенная (факторная) | Количественная |
| UNRATE | Уровень безработицы | Экзогенная (факторная) | Количественная |
| UMCSENT | Индекс потребительских настроений | Экзогенная (факторная) | Количественная |

Рассмотрим экономический смысл каждого признака и ожидаемый характер его влияния на целевую переменную.

GASREGM – целевая эндогенная переменная, представляющая среднюю розничную цену автомобильного бензина регулярного класса всех формулировок в США, выраженную в долларах за галлон. Данный показатель непосредственно отражает уровень цен на моторное топливо для конечных потребителей и формируется под совокупным воздействием мировых

нефтяных котировок, издержек переработки и внутренних макроэкономических условий.

DCOILWTICO – цена нефти марки WTI в точке поставки, выраженная в долларах за баррель. Стоимость сырой нефти составляет наибольшую долю в структуре издержек нефтепереработки, поэтому данный показатель является основным ценовым драйвером рынка нефтепродуктов. Ожидается положительная зависимость: рост котировок WTI влечёт за собой удорожание бензина на розничном рынке.

PCU324110324110 12 – индекс цен производителей в отрасли нефтепереработки, отражающий динамику отпускных цен на моторный бензин и его компоненты. Показатель выступает промежуточным звеном в цепочке ценообразования между сырьевым рынком и розничной торговлей: его рост сигнализирует об увеличении производственных издержек, которые впоследствии транслируются в конечные потребительские цены. Ожидается положительное влияние на целевую переменную.

IPG211S – индекс промышленного производства в секторе добычи нефти и газа, характеризующий объёмы добычи углеводородного сырья. Увеличение добычи расширяет предложение на рынке нефтепродуктов, что при прочих равных условиях оказывает сдерживающее воздействие на ценовую динамику. Ожидается отрицательная связь данного показателя с розничными ценами на бензин.

UNRATE – уровень безработицы в США, скорректированный с учётом сезонности и выраженный в процентах. Данный индикатор отражает общее состояние рынка труда и покупательную способность населения. Рост безработицы сопровождается снижением реальных доходов и ослаблением потребительского спроса, в том числе на моторное топливо, что создаёт понижательное давление на цены. Ожидается отрицательная зависимость.

UMCSENT – индекс потребительских настроений Мичиганского университета, измеряющий уверенность домохозяйств в текущей и будущей экономической ситуации. Высокий уровень потребительского оптимизма стимулирует транспортную активность и спрос на топливо, что при ограниченном предложении способствует росту розничных цен. Ожидается положительное влияние на целевую переменную.

Таким образом, сформированная система признаков охватывает четыре ключевых аспекта ценообразования на рынке нефтепродуктов: сырьевой (DCOILWTICO), производственный (PCU324110324110 12, IPG211S), макроэкономический (UNRATE) и поведенческий (UMCSENT). Эндогенной переменной модели выступает розничная цена бензина GASREGM, тогда как остальные показатели рассматриваются как экзогенные факторы, формирующие её динамику. Данная система переменных служит основой для дальнейшего анализа структуры и стационарности временных рядов, извлечения признаков и построения прогностических моделей.

## 2.2 Визуальный и статистический анализ структуры и динамики признаков

### 2.2.1 Анализ распределения целевого признака и факторов

Для оценки статистических свойств исходных данных и определения их пригодности для эконометрического моделирования были рассчитаны описательные статистики для целевой переменной GASREGM и всех экзогенных факторов. Результаты представлены в таблице 2.2.

Таблица 2.2 – «Описательные статистики переменных модели»

| Показатель | Mean | Median | Std. Dev. | Skewness | Kurtosis | J-B | Prob |
|---|---|---|---|---|---|---|---|
| GASREGM | 2.984 | 3.005 | 0.618 | 0.136 | -0.556 | 3.49 | 0.1743 |
| DCOILWTICO | 74.434 | 77.905 | 20.765 | -0.364 | -0.847 | 10.98 | 0.0041 |
| PCU32411032411012 | 258.135 | 251.06 | 71.430 | 0.084 | -0.573 | 3.27 | 0.1954 |
| IPG211S | 101.233 | 99.075 | 29.474 | -0.006 | -1.351 | 15.89 | 0.0004 |
| UMCSENT | 78.336 | 76.600 | 13.515 | 0.047 | -1.092 | 10.56 | 0.0051 |
| UNRATE | 5.95 | 5.100 | 2.258 | 0.873 | 0.161 | 26.43 | 0.0000 |

Анализ показателей центральной тенденции свидетельствует о том, что для большинства переменных среднее значение и медиана расположены достаточно близко, что указывает на отсутствие грубого смещения распределений. Целевая переменная GASREGM имеет среднее 2,984 долл./галлон при медиане 3,005 долл./галлон – незначительное превышение медианы над средним говорит о лёгкой левосторонней асимметрии. Для цены нефти DCOILWTICO картина обратная: среднее (74,43 долл./барр.) заметно ниже медианы (77,91 долл./барр.), что отражает наличие периодов резкого снижения котировок. Для UNRATE разрыв между средним (5,95%) и медианой (5,10%) наиболее выражен среди всех переменных, что обусловлено эпизодом резкого скачка безработицы в период пандемии.

Оценка разброса значений показывает, что наибольшей абсолютной изменчивостью обладает индекс цен производителей нефтепереработки PCU32411032411012 (Std. Dev. = 71,43), что отражает высокую чувствительность отпускных цен к сырьевой конъюнктуре. Значительная волатильность характерна также для цены нефти DCOILWTICO (20,77 долл./барр.) и индекса потребительских настроений UMCSENT (13,52). Уровень безработицы UNRATE, несмотря на относительно небольшое стандартное отклонение (2,26%), демонстрирует наибольший разброс в относительном выражении из-за резкого всплеска в кризисный период.

Параметры формы распределений показывают, что большинство переменных имеют отрицательный эксцесс, то есть распределения являются плосковершинными – это означает, что экстремальные отклонения встречаются реже, чем при нормальном законе. Наиболее выраженная плосковершинность характерна для IPG211S (Kurtosis = −1,351) и UMCSENT

(−1,092), что отражает широкий разброс наблюдений без доминирующего центра. Положительный эксцесс зафиксирован лишь у UNRATE (0,161), что связано с островершинностью вблизи низких значений безработицы. По показателям асимметрии выделяется UNRATE (Skewness = 0,873) – правосторонний хвост формируется за счёт кризисного периода. Остальные переменные демонстрируют умеренную асимметрию, близкую к нулю.

По результатам теста Жака–Бера гипотеза о нормальности распределения отвергается для DCOILWTICO (Prob. = 0,0041), IPG211S (Prob. = 0,0004), UMCSENT (Prob. = 0,0051) и UNRATE (Prob. = 0,0000). Для GASREGM (Prob. = 0,1743) и PCU32411032411012 (Prob. = 0,1954) нулевая гипотеза о нормальности не отвергается, что делает эти два показателя наиболее близкими к нормальному закону среди всех исследуемых переменных. Выявленные отклонения от нормальности для остальных факторов являются экономически закономерными и не препятствуют дальнейшему моделированию: требование нормальности в классической регрессии предъявляется к остаткам модели, а не к исходным данным, и при достаточном объёме выборки оценки МНК остаются состоятельными в силу центральной предельной теоремы.

Для визуального подтверждения статистических свойств построены гистограммы с наложенными кривыми ядерной оценки плотности (KDE). KDE представляет собой непараметрический метод оценки функции плотности вероятности: в отличие от гистограммы, которая разбивает данные на дискретные интервалы, кривая KDE строит сглаженную непрерывную оценку распределения, суммируя вклад каждого наблюдения через ядерную функцию. Это позволяет более наглядно выявлять многовершинность, асимметрию и другие структурные особенности распределений, которые могут быть сглажены при выборе неподходящей ширины интервалов гистограммы.

На рисунке 2.1 представлена гистограмма целевой переменной GASREGM.

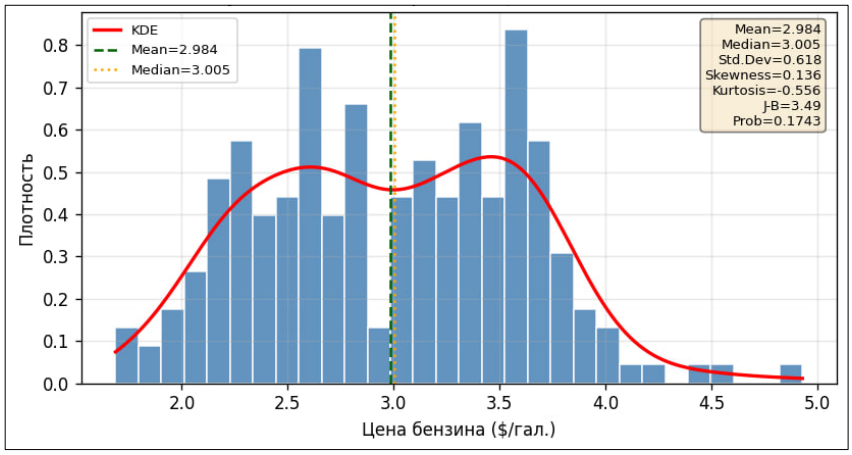



Рисунок 2.1 – Гистограмма распределения эндогенной переменной GASREGM

Гистограмма целевой переменной GASREGM демонстрирует двухвершинную структуру с пиками около 2,6 и 3,6 долл./галлон, отражающую два устойчивых ценовых режима в исследуемом периоде. Близость среднего и медианы, незначительная асимметрия и отрицательный эксцесс подтверждают относительную симметричность и широту распределения. Кривая KDE отчётливо фиксирует оба пика и подтверждает бимодальность распределения, которая указывает на наличие структурных сдвигов в динамике розничных цен на бензин.

На рисунке 2.2 представлена гистограмма экзогенной переменной DCOILWTICO.

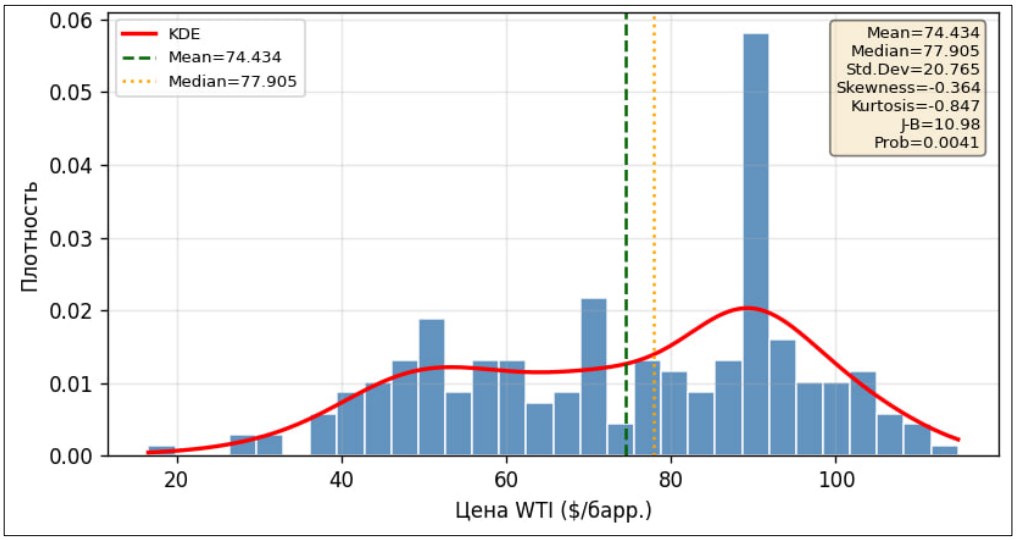



Рисунок 2.2 – Гистограмма распределения экзогенной переменной DCOILWTICO

Гистограмма фактора DCOILWTICO демонстрирует широкое неравномерное распределение. Кривая KDE принимает пологую форму с основным сосредоточением плотности в диапазоне 70–100 долл./барр. и постепенным спадом в сторону низких значений, что визуально подтверждает отрицательную асимметрию ряда: периоды экстремально низких нефтяных котировок встречались значительно реже, чем периоды умеренных и высоких цен.

На рисунке 2.3 представлена гистограмма экзогенной переменной UNRATE.

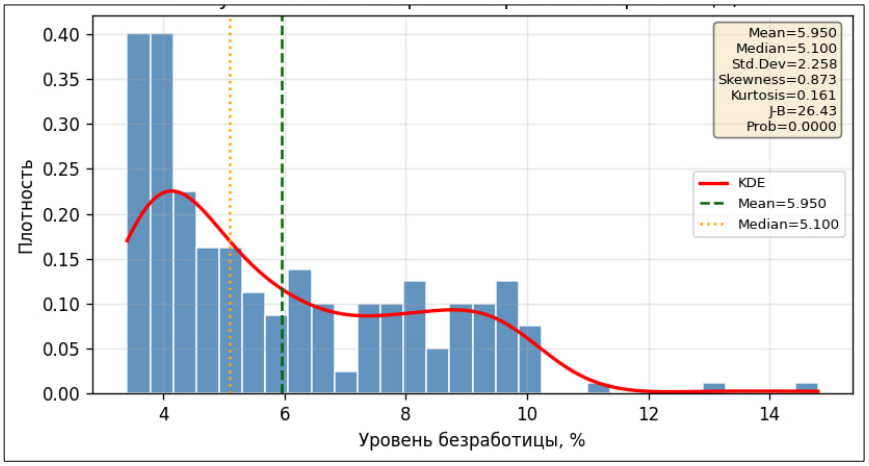



Рисунок 2.3 – Гистограмма распределения экзогенной переменной UNRATE

Гистограмма фактора UNRATE имеет выраженную правостороннюю асимметрию: наибольшая концентрация наблюдений приходится на диапазон 3,5–5%, что отражает типичное состояние рынка труда в рассматриваемом периоде. Кривая KDE наглядно демонстрирует основной пик в области низких значений и протяжённый правый хвост, соответствующий эпизоду резкого роста безработицы в кризисный период. Это единственная переменная с положительным эксцессом, что подчёркивает остроту и нетипичность данного всплеска относительно остальных наблюдений.

На рисунке 2.4 представлена гистограмма экзогенной переменной UMCSENT.

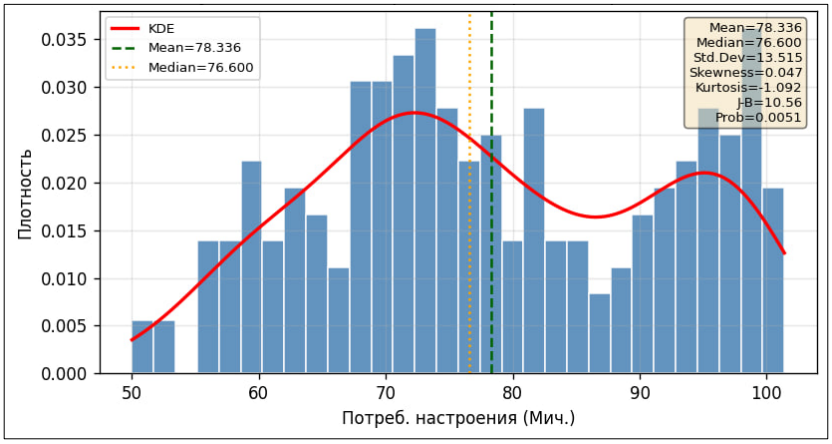



Рисунок 2.4 – Гистограмма распределения экзогенной переменной UMCSENT

Гистограмма фактора UMCSENT близка к симметричной, однако выражена бимодальность с пиками около 70 и 97. Кривая KDE чётко фиксирует два обособленных максимума плотности, отражающих циклическое чередование периодов потребительского пессимизма и оптимизма. Такая структура распределения свидетельствует о том, что индекс

потребительских настроений на протяжении исследуемого периода устойчиво тяготел к двум полярным состояниям, не задерживаясь длительно в промежуточных значениях.

На рисунке 2.5 представлена гистограмма экзогенной переменной IPG211S.

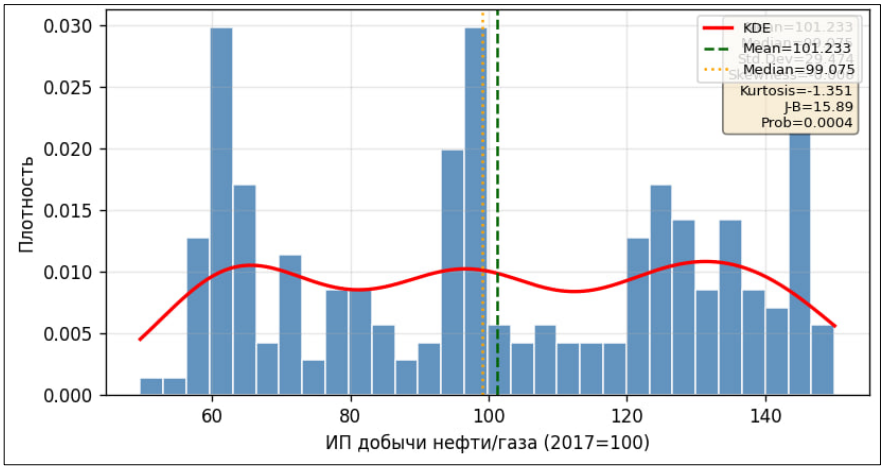



Рисунок 2.5 – Гистограмма распределения экзогенной переменной IPG211S

Гистограмма фактора IPG211S наглядно демонстрирует бимодальность с двумя обособленными группами наблюдений. Кривая KDE принимает форму с двумя выраженными пиками, разделёнными провалом плотности, что отражает качественный переход нефтегазовой отрасли на принципиально иной уровень добычи вследствие широкого внедрения технологий добычи сланцевой нефти в США. Таким образом, распределение данного признака фиксирует не случайный разброс, а реальный структурный перелом в динамике производства.

На рисунке 2.6 представлена гистограмма экзогенной переменной PCU32411032411012.

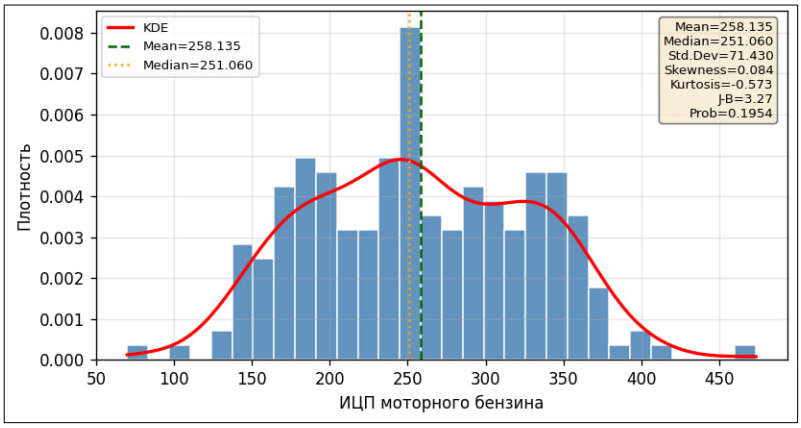



Рисунок 2.6 – Гистограмма распределения экзогенной переменной PCU32411032411012

Гистограмма фактора PCU32411032411012 характеризуется наиболее равномерным распределением среди всех рассматриваемых переменных: значения рассредоточены в широком диапазоне 150–350. Кривая KDE принимает пологую одновершинную форму без выраженных пиков или провалов, что согласуется с результатом теста Жака–Бера, не отвергающего гипотезу о нормальности для данного ряда. Подобная равномерность отражает постепенное и относительно монотонное изменение отпускных цен производителей нефтепереработки на протяжении исследуемого периода.

Следует отметить, что выявленные отклонения от нормальности отдельных временных рядов не являются критическим ограничением для дальнейшего анализа. В классической линейной регрессии требование нормальности относится прежде всего к распределению остатков модели, а не к исходным значениям объясняющих переменных. При достаточном объеме выборки оценки коэффициентов, полученные методом наименьших квадратов, остаются нормальными в силу центральной предельной теоремы. Более того, для макроэкономических и ценовых временных рядов ненормальность распределений рассматривается как типичное свойство, отражающее реальные экономические процессы, а не как признак некорректности данных.

### 2.2.2 Устранение выбросов и аномальных значений признаков

Выявление аномальных наблюдений является необходимым этапом подготовки данных, поскольку выбросы способны существенно искажать оценки параметров эконометрических моделей и снижать точность прогнозирования. Для их обнаружения применялся метод межквартильного размаха (IQR-метод): наблюдение считается выбросом, если оно выходит за пределы допустимого диапазона [Q1 − 1,5·IQR; Q3 + 1,5·IQR], где Q1 и Q3 – первый и третий квартили, а IQR = Q3 − Q1. Результаты анализа представлены на рисунке 2.7 – 2.8.

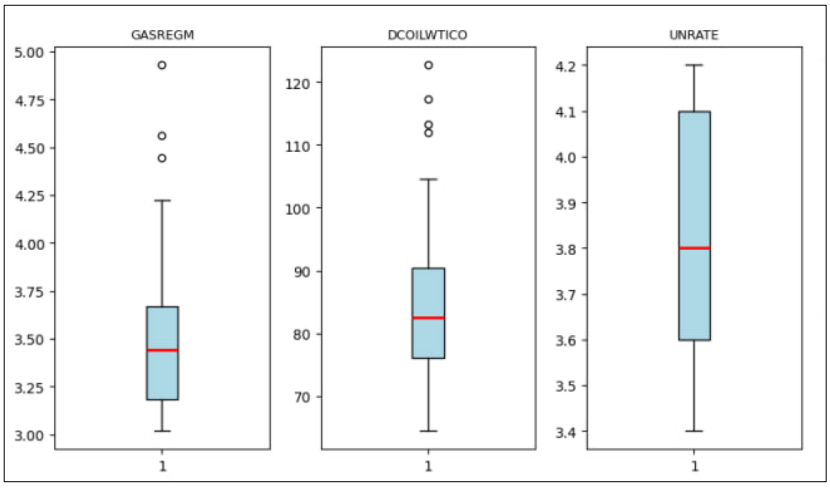



Рисунок 2.7 – График Boxplot для признаков модели

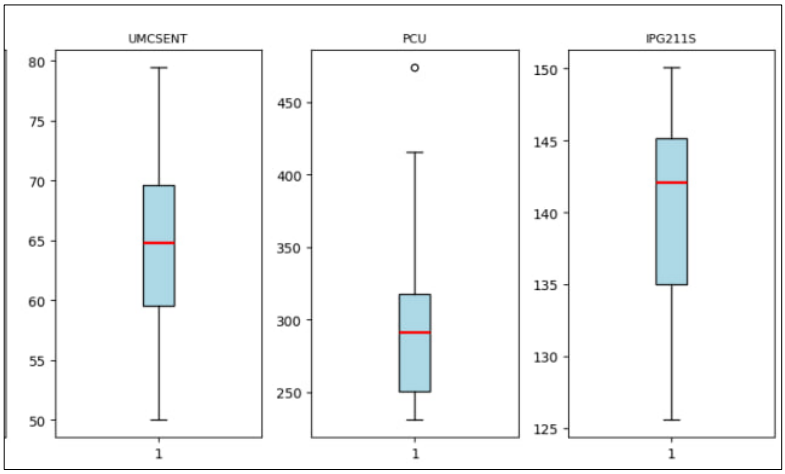



Рисунок 2.8 – График Boxplot для признаков модели

По итогам анализа выбросы были обнаружены в трёх переменных. Наибольшее число аномальных наблюдений зафиксировано в ряду цены нефти DCOILWTICO – 4 выброса, соответствующих периодам резких скачков мировых нефтяных котировок выше верхней границы допустимого диапазона (около 105 долл./барр.). В целевой переменной GASREGM выявлено 3 выброса – наблюдения с розничной ценой бензина выше 4,3 долл./галлон, связанные с эпизодами экстремального роста топливных цен. Для индекса цен производителей нефтепереработки PCU32411032411012 обнаружен 1 выброс – аномально высокое значение отпускных цен, превышающее верхнюю границу около 420. Для переменных UNRATE, UMCSENT и IPG211S выбросов не выявлено, что соответствует более сглаженной природе этих макроэкономических и производственных индикаторов.

Экономическая природа выявленных выбросов не вызывает сомнений: они связаны с реальными рыночными событиями – геополитическими шоками, ограничениями предложения нефти и кризисными периодами, – а не с ошибками измерения или сбором данных. Тем не менее их присутствие в обучающей выборке может привести к смещению оценок коэффициентов регрессии и снижению обобщающей способности моделей машинного обучения, что обусловливает необходимость их обработки.

Удаление аномальных значений привело бы к существенной потере информации и сокращению и без того ограниченного массива данных. В связи с этим в качестве метода обработки выбросов был применён винсоризинг (Winsorizing) – замена аномальных значений на граничные допустимые значения диапазона [Q1 − 1,5·IQR; Q3 + 1,5·IQR]. Данный подход позволяет сохранить полный объём выборки и временну́ю структуру рядов, устранив при этом дестабилизирующее влияние экстремальных наблюдений на оценки моделей.

В результате применения винсоризинга 3 значения в ряду GASREGM, 4 значения в ряду DCOILWTICO и 1 значение в ряду PCU32411032411012 были заменены соответствующими граничными значениями IQR-диапазона. Объём

выборки сохранён в полном размере. После обработки все переменные не содержат выбросов, что подтверждается визуальным анализом boxplot-диаграмм после устранения (рисунки 2.9 – 2.10).

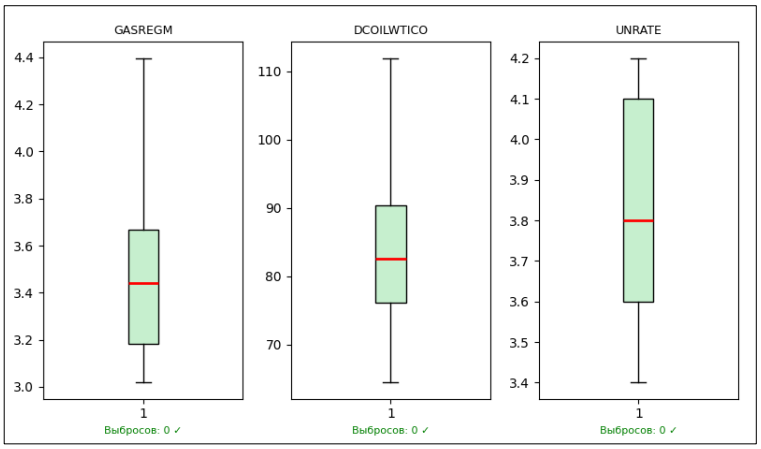



Рисунок 2.9 – График Boxplot без выбросов

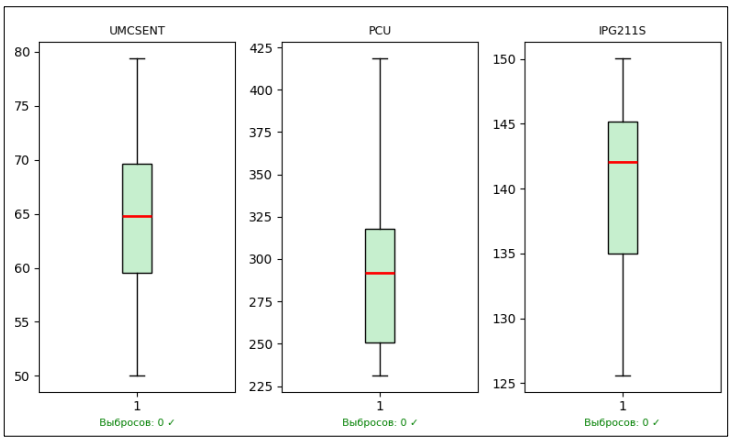



Рисунок 2.10 – График Boxplot без выбросов

Очищенный массив данных использовался во всех последующих этапах моделирования.

### 2.2.3 Визуальный анализ динамики признаков

После проведения очистки данных был выполнен визуальный анализ временных рядов всех переменных модели. Графическое исследование динамики позволяет выявить общие тенденции, структурные сдвиги, сезонные закономерности и характер взаимосвязи между целевым и факторными признаками. На рисунке 2.11 представлена динамика целевой переменной GASREGM – розничной цены бензина в США за период с января 2022 по июль 2025 года.

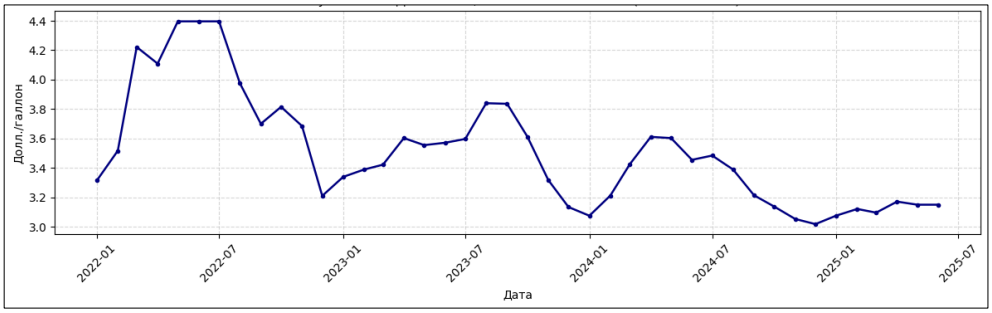



Рисунок 2.11 – Динамика цены бензина

Ряд демонстрирует выраженный нисходящий тренд на всём горизонте наблюдений, однако с отчётливо выраженной волнообразной структурой. В начале 2022 года цены стремительно выросли с 3,3 до пикового значения около 4,4 долл./галлон к середине года, что обусловлено резким удорожанием нефти на фоне геополитической напряжённости. Затем последовало столь же быстрое снижение до уровня около 3,2 долл./галлон к началу 2023 года. В середине 2023 года наблюдается повторный отскок до 3,8 долл./галлон с последующим снижением. Начиная с 2024 года ряд приобретает более стабильный характер, постепенно консолидируясь в диапазоне 3,0–3,2 долл./галлон. Визуальный анализ указывает на нестационарность ряда, наличие нисходящего тренда и высокую чувствительность к внешним ценовым шокам.

На рисунке 2.12 представлена динамика факторных признаков модели.

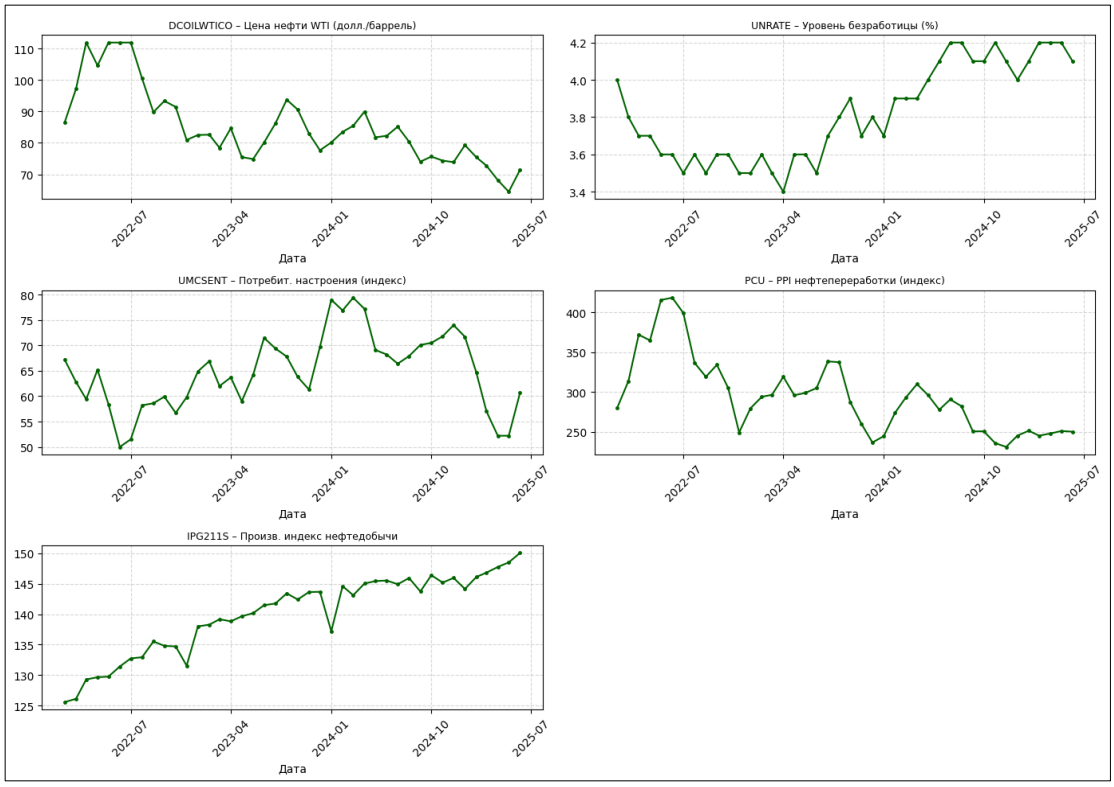



Рисунок 2.12 – Динамика факторных признаков модели

Ряд DCOILWTICO (цена нефти WTI) демонстрирует динамику, практически зеркально повторяющую поведение целевой переменной: резкий рост до 110–111 долл./барр. в первой половине 2022 года с последующим снижением до 70–75 долл./барр. к середине 2023 года. В дальнейшем цена нефти стабилизировалась в диапазоне 75–90 долл./барр. с умеренными колебаниями, однако к середине 2025 года возобновила снижение до уровня около 65–70 долл./барр. Столь тесное визуальное сходство с динамикой GASREGM подтверждает фундаментальную роль нефтяных котировок в формировании розничных цен на топливо.

Ряд UNRATE (уровень безработицы) демонстрирует устойчивую восходящую тенденцию на протяжении всего периода наблюдений. В начале 2022 года показатель находился на уровне около 4,0%, затем снизился до минимума 3,4–3,5% к середине 2023 года, после чего началось планомерное восстановление до 4,1–4,2% к 2025 году. Ряд характеризуется плавной динамикой без резких скачков, что типично для агрегированных макроэкономических индикаторов. Общая тенденция к росту безработицы в конце периода может сигнализировать об ослаблении потребительского спроса на топливо.

Ряд UMCSENT (индекс потребительских настроений) отличается наибольшей волатильностью среди всех факторных признаков. В начале 2022 года индекс резко упал с 68 до 50 пунктов – минимальное значение за весь период, – после чего на протяжении 2022–2024 годов демонстрировал волнообразное восстановление с достижением локального максимума около 79 пунктов в конце 2023 года. К середине 2025 года индекс вновь снизился до уровня около 52–60 пунктов. Выраженная цикличность этого показателя отражает чередование периодов потребительского оптимизма и пессимизма и его чувствительность к инфляционным ожиданиям и ценам на топливо.

Ряд PCU32411032411012 (индекс цен производителей нефтепереработки) по характеру динамики близок к целевой переменной и ряду DCOILWTICO: резкий рост до 400–420 пунктов в первой половине 2022 года сменился столь же быстрым снижением до 240–250 пунктов к началу 2023 года. В дальнейшем ряд демонстрирует умеренные колебания с постепенным затуханием волатильности и стабилизацией вблизи 245–255 пунктов к 2025 году. Синхронность динамики с ценой нефти и розничными ценами на бензин свидетельствует о том, что данный показатель является важным промежуточным звеном в цепочке ценообразования.

Ряд IPG211S (производственный индекс нефтедобычи) принципиально отличается от остальных переменных устойчивым восходящим трендом на протяжении всего периода наблюдений: значение выросло с 125–126 пунктов в начале 2022 года до 148–150 пунктов к середине 2025 года. Единственное заметное отклонение от тренда – кратковременное снижение до 137 пунктов в начале 2024 года с последующим быстрым восстановлением. Монотонный рост индекса отражает последовательное наращивание объёмов добычи нефти

и газа в США, что в долгосрочной перспективе оказывает сдерживающее воздействие на ценовую динамику.

Таким образом, визуальный анализ временных рядов позволяет выделить несколько ключевых закономерностей. Целевая переменная GASREGM и факторы DCOILWTICO и PCU32411032411012 демонстрируют схожую динамику с выраженным ценовым пиком в 2022 году и последующим снижением, что свидетельствует об их тесной взаимосвязи. UNRATE и IPG211S характеризуются трендовыми компонентами противоположного знака – первый умеренно растёт, второй устойчиво снижает ценовое давление за счёт роста предложения. UMCSENT отличается наибольшей краткосрочной волатильностью. Все ряды визуально являются нестационарными, что обусловливает необходимость проведения формальных тестов на стационарность на следующем этапе анализа.

## 2.3 Анализ корреляционных свойств и стационарности временных рядов

### 2.3.1 Анализ стационарности временных рядов

Перед построением прогностических моделей необходимым этапом является проверка стохастических свойств временных рядов. Пренебрежение данным шагом создаёт риск получения «ложной» регрессии (spurious regression), при которой высокие значения $R^2$ и статистически значимые коэффициенты возникают не вследствие реальной экономической взаимосвязи, а из-за наличия общего тренда в нестационарных рядах.

Временной ряд считается стационарным, если его математическое ожидание, дисперсия и ковариационная структура не изменяются во времени. Нарушение хотя бы одного из этих условий свидетельствует о нестационарности процесса и требует соответствующего преобразования данных перед моделированием.

Для формальной проверки стационарности применялся расширенный тест Дики–Фуллера (ADF). Нулевая гипотеза $H_0$ данного теста предполагает наличие единичного корня, то есть нестационарность ряда. Если расчётное p-value оказывается ниже выбранного уровня значимости $\alpha = 0{,}05$, нулевая гипотеза отвергается и ряд признаётся стационарным. Тестирование проводилось в два этапа: сначала для исходных уровней всех переменных, затем – для их первых разностей. Результаты первого этапа представлены в таблице 2.3.

Таблица 2.3 – «Результаты ADF-теста для уровней переменных»

| Переменная | ADF-статистика | p-value | Статус |
|---|---|---|---|
| GASREGM | -1,5846 | 0,4913 | Нестационарен |
| DCOILWTICO | -1,4146 | 0,5753 | Нестационарен |
| UNRATE | -1,1769 | 0,6835 | Нестационарен |
| UMCSENT | -2,8613 | 0,0500 | Нестационарен |

Продолжение таблицы 2.3

| Переменная | ADF-статистика | p-value | Статус |
|---|---|---|---|
| PCU32411032411012 | -2,1296 | 0,2328 | Нестационарен |
| IPG211S | -1,9391 | 0,3139 | Нестационарен |

Результаты тестирования на уровнях однозначны: для всех шести переменных p-value превышает критический порог 0,05, что не позволяет отвергнуть нулевую гипотезу о наличии единичного корня. Особого внимания заслуживает переменная UMCSENT, p-value которой в точности равно 0,050 – пограничное значение, не дающее оснований для признания ряда стационарным. Таким образом, все переменные модели являются нестационарными процессами и требуют преобразования.

Для устранения нестационарности был осуществлён переход к первым разностям (Δ). Результаты повторного тестирования представлены в таблице 2.4.

Таблица 2.4 – «Результаты ADF-теста для первых разностей переменных»

| Переменная | ADF-статистика | p-value | Статус |
|---|---|---|---|
| ΔGASREGM | -5,2853 | 0,0000 | Стационарен |
| ΔDCOILWTICO | -4,4153 | 0,0003 | Стационарен |
| ΔUNRATE | -5,6416 | 0,0000 | Стационарен |
| ΔUMCSENT | -3,1780 | 0,0213 | Стационарен |
| ΔPCU32411032411012 | -5,0195 | 0,0000 | Стационарен |
| ΔIPG211S | -11,0793 | 0,0000 | Стационарен |

После взятия первых разностей картина кардинально изменилась. Для всех шести преобразованных рядов p-value многократно опускается ниже критического порога, что позволяет уверенно отвергнуть нулевую гипотезу о наличии единичного корня. ADF-статистики по модулю существенно превышают критические значения на уровне значимости 1%, 5% и 10%. Наиболее выраженный переход к стационарности демонстрирует IPG211S: статистика изменилась с −1,94 на уровнях до −11,08 на первых разностях. Все переменные идентифицированы как интегрированные процессы первого порядка I(1), что является типичным свойством макроэкономических и ценовых временных рядов.

Несмотря на то что классический подход предписывает работу с первыми разностями, в задачах машинного обучения переход к разностям влечёт потерю информации о долгосрочных уровневых зависимостях между переменными. Для проверки возможности работы с исходными уровнями был проведён тест Энгла–Грейнджера на коинтеграцию, реализованный в два этапа: попарное тестирование целевой переменной с каждым из факторов и многомерная проверка на основе остатков OLS-регрессии.

Попарный анализ показал, что долгосрочная равновесная связь с целевой переменной подтверждается для двух факторов – цены нефти DCOILWTICO (p-value = 0,0112) и индекса цен производителей

нефтепереработки PCU32411032411012 (p-value = 0,0179). Это экономически закономерно: именно эти два показателя формируют основу цепочки ценообразования от сырой нефти до розничного бензина. Для остальных трёх факторов – UNRATE, UMCSENT и IPG211S – попарная коинтеграция с GASREGM не подтверждается, что указывает на отсутствие устойчивой долгосрочной зависимости в двусторонних отношениях с целевой переменной.

Вместе с тем наличие коинтеграции в многомерной системе определяется не только попарными связями, но и совместным поведением всех переменных. По результатам многомерного теста на основе остатков OLS-регрессии ADF-статистика составила −4,8957 при p-value = 0,0000, что значительно ниже критических значений на всех стандартных уровнях значимости. Нулевая гипотеза о нестационарности остатков уверенно отвергается – остатки многомерной регрессии являются стационарным процессом I(0).

Стационарность совместных остатков при нестационарных уровнях всех переменных свидетельствует о наличии коинтеграционного вектора в системе в целом. Это означает, что совокупность факторов DCOILWTICO, UNRATE, UMCSENT, PCU32411032411012 и IPG211S образует с розничной ценой бензина устойчивую долгосрочную равновесную зависимость, даже несмотря на отсутствие попарной коинтеграции у ряда факторов. Построенные на уровнях модели не будут являться ложными и будут отражать реальные экономические взаимосвязи. Данный результат теоретически обосновывает правомерность использования исходных уровней признаков как для эконометрических моделей (ARIMA, GARCH), так и для алгоритмов машинного обучения.

### 2.3.2 Анализ автокорреляционных функций (ACF и PACF) временных рядов

Для визуального подтверждения результатов ADF-теста и предварительной идентификации структуры стохастических процессов был проведён анализ графиков автокорреляционной (ACF) и частной автокорреляционной (PACF) функций. Данный инструментарий позволяет не только диагностировать нестационарность, но и получить предварительные сведения о порядке авторегрессионной компоненты (AR) и компоненты скользящего среднего (MA), необходимые для спецификации эконометрических моделей.

На рисунке 2.13 представлена ACF ряда GASREGM на исходном уровне.

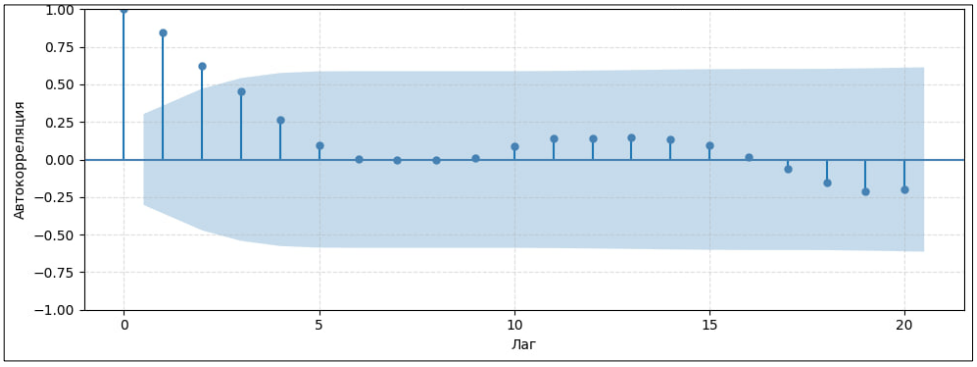



Рисунок 2.13 – График ACF ряда GASREGM на исходном уровне

График демонстрирует характерный паттерн нестационарного процесса: значение автокорреляции на первом лаге близко к 0,85, затем следует относительно быстрое, но неравномерное затухание – с заметными выбросами на лагах 2–3 (около 0,6 и 0,45) и последующим постепенным снижением до нуля к лагу 6–7. Значения на лагах 10–20 колеблются вблизи нуля, однако ряд из них выходит за границы доверительного интервала, что указывает на сохранение остаточной «памяти» ряда. Подобное поведение ACF свидетельствует о нестационарности и наличии стохастического тренда в данных.

На рисунке 2.14 представлена PACF ряда GASREGM на исходном уровне.

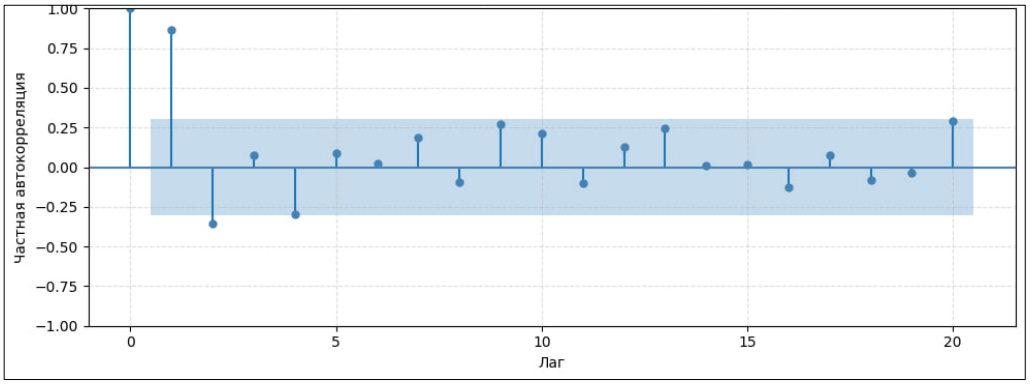



Рисунок 2.14 – График PACF ряда GASREGM на исходном уровне

Наблюдается резкий и значимый выброс на первом лаге (значение около 0,85), после чего функция обрывается и большинство последующих значений входят в зону статистической незначимости, хотя отдельные лаги (2, 4) демонстрируют умеренные отрицательные значения около −0,30.

Сочетание медленно затухающей ACF и PACF с доминирующим первым лагом является классическим диагностическим признаком процесса AR(1) с единичным корнем, что полностью согласуется с выводами ADF-теста.

На рисунке 2.15 представлены ACF и PACF ряда GASREGM после первого дифференцирования.

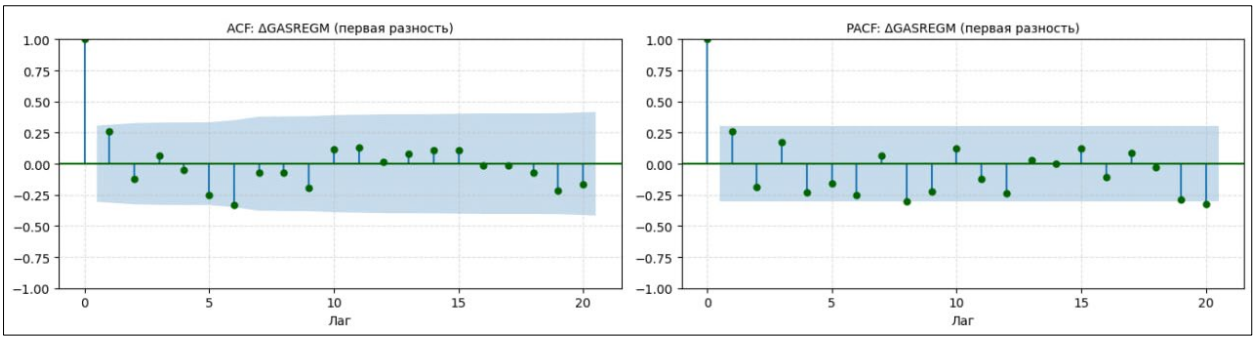



Рисунок 2.15 – Графики ACF и PACF ряда GASREGM после первого дифференцирования

Картина кардинально изменилась: на обоих графиках значение первого лага снизилось примерно до 0,25, а начиная со второго лага все коэффициенты располагаются преимущественно внутри доверительного интервала, лишь незначительно выходя за его пределы на отдельных лагах. Отсутствие выраженной структуры и быстрое затухание к нулю однозначно указывают на стационарность первых разностей, подтверждая результат ADF-теста.

На рисунке 2.16 представлены графики ACF и PACF факторной переменной DCOILWTICO на исходном уровне.

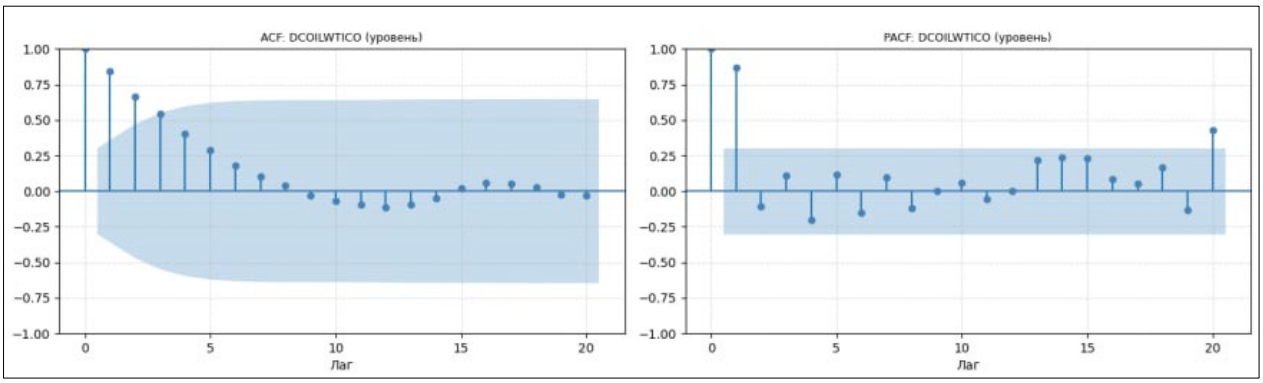



Рисунок 2.16 – Графики ACF и PACF ряда DCOILWTICO на исходном уровне

Ряд DCOILWTICO демонстрирует постепенное затухание ACF от высокого значения на первом лаге (0,85) с умеренными выбросами на лагах 2–4 (0,55–0,60), после чего коэффициенты плавно снижаются к нулю к лагу 10–12. PACF ограничивается значимым первым лагом (0,85) и несколькими умеренными отрицательными значениями на лагах 2–3, после чего входит в зону статистической незначимости. Подобная структура коррелограмм – медленно затухающая ACF в сочетании с резким обрывом PACF после

первого лага – является классическим диагностическим признаком AR(1)-процесса с единичным корнем, что полностью согласуется с результатами ADF-теста.

На рисунке 2.17 представлены графики ACF и PACF факторной переменной UNRATE на исходном уровне.

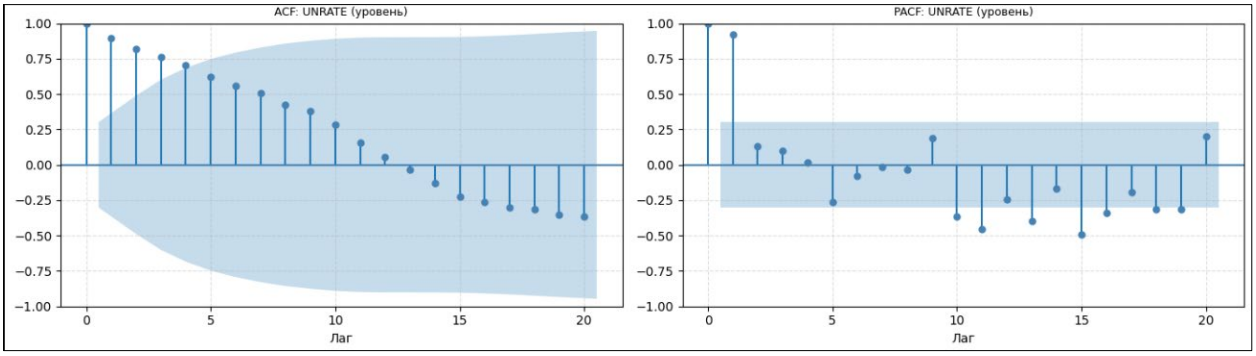



Рисунок 2.17 – Графики ACF и PACF ряда UNRATE на исходном уровне

Ряд UNRATE отличается наиболее выраженным и устойчивым затуханием ACF среди всех факторных переменных: коэффициенты остаются статистически значимыми вплоть до лага 10–12, снижаясь плавно от 0,85 до нуля. PACF обрывается после первого лага (0,95) и демонстрирует ряд значимых отрицательных выбросов на лагах 7–9 (−0,50). Столь устойчивая автокорреляционная структура свидетельствует о высокой инерционности ряда, что соответствует природе показателя безработицы как медленно меняющегося макроэкономического индикатора, реагирующего на изменения экономической конъюнктуры с существенным запаздыванием.

На рисунке 2.18 представлены графики ACF и PACF факторной переменной UMCSENT на исходном уровне.

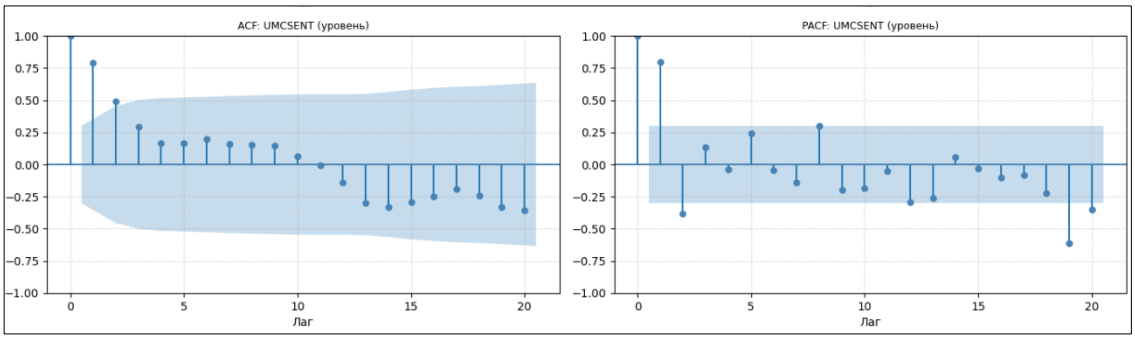



Рисунок 2.18 – Графики ACF и PACF ряда UMCSENT на исходном уровне

Ряд UMCSENT демонстрирует более быстрое затухание ACF по сравнению с остальными факторами: значения становятся незначимыми уже к лагу 8–9. PACF имеет значимый первый лаг (0,75) и умеренный второй лаг (0,25), после чего входит в зону незначимости, хотя отдельные выбросы на

глубоких лагах (20) выходят за границы доверительного интервала. Менее выраженная инерционность ряда по сравнению с ценовыми переменными соответствует более волатильной природе индекса потребительских настроений, который чутко реагирует на текущие экономические события и быстро меняет направление.

На рисунке 2.19 представлены графики ACF и PACF факторной переменной PCU на исходном уровне.

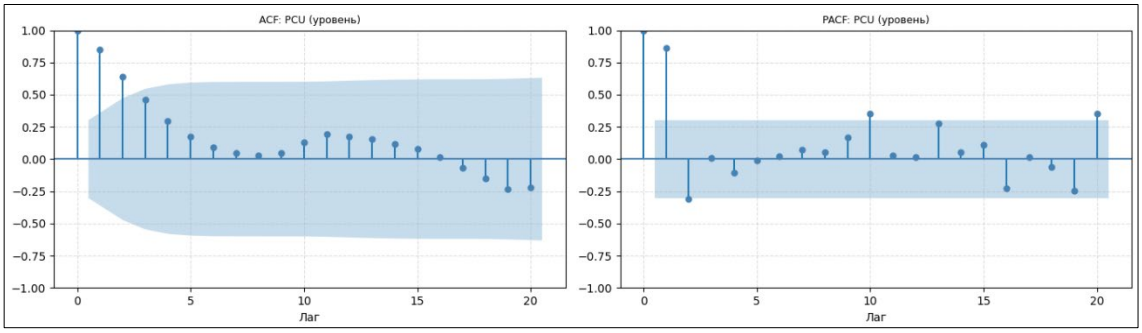



Рисунок 2.19 – Графики ACF и PACF ряда PCU на исходном уровне

Структура коррелограмм PCU близка к DCOILWTICO: ACF затухает от 0,80 на первом лаге с умеренными выбросами на лагах 2–3 (0,55), после чего значения входят в зону незначимости к лагу 6–7. PACF значима на первом лаге (0,80) и демонстрирует умеренное отрицательное значение на втором лаге (−0,25), тогда как все последующие лаги располагаются в пределах доверительного интервала. Сходство автокорреляционной структуры PCU с DCOILWTICO отражает тесную экономическую связь между ценами производителей нефтепереработки и котировками сырой нефти: оба ряда формируются под воздействием единого сырьевого рынка и демонстрируют схожую динамику.

На рисунке 2.20 представлены графики ACF и PACF факторной переменной IPG211S на исходном уровне.

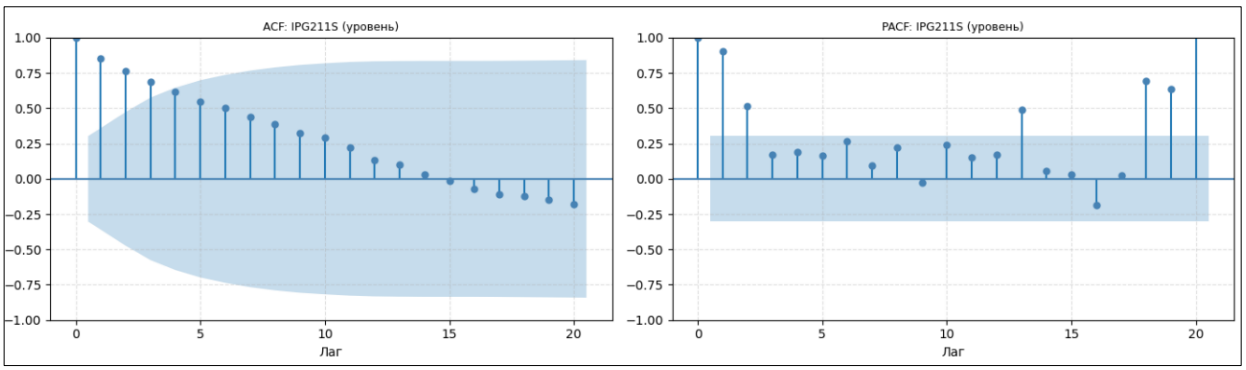



Рисунок 2.20 – Графики ACF и PACF ряда IPG211S на исходном уровне

Ряд IPG211S демонстрирует медленное, но устойчивое затухание ACF: коэффициенты сохраняют статистическую значимость вплоть до лага 7–8, снижаясь постепенно от 0,85. PACF характеризуется значимым первым (0,85) и вторым (0,50) лагами, а также отдельными выбросами на более глубоких лагах (12, 20), что может свидетельствовать о более сложной авторегрессионной структуре по сравнению с остальными факторами. Устойчивость автокорреляционной структуры отражает трендовый характер производственного индекса нефтедобычи: наращивание объёмов добычи является постепенным процессом, определяемым долгосрочными инвестиционными решениями и технологическими ограничениями отрасли.

Таким образом, анализ ACF и PACF всех факторных переменных на исходных уровнях подтверждает их нестационарность и полностью согласуется с результатами формального ADF-теста. Все пять рядов демонстрируют характерную для интегрированных процессов структуру – медленно затухающую ACF и значимый первый лаг PACF, – что обосновывает необходимость перехода к первым разностям при построении эконометрических моделей класса ARIMA.

### 2.3.3 Анализ тренда и сезонности временного ряда

Следующим этапом предварительного анализа является исследование структуры временного ряда целевого признака GASREGM на предмет наличия детерминированных составляющих – долгосрочного тренда и сезонной компоненты. Корректная интерпретация этих составляющих необходима для обоснованного выбора спецификации прогнозных моделей и формирования информативного пространства признаков.

Для формального разложения ряда на структурные компоненты применялся метод аддитивной декомпозиции, представляющий исходный ряд в виде суммы трёх составляющих: тренда ($T_t$), сезонности ($S_t$) и случайного остатка ($\varepsilon_t$):

$$Y_t = T_t + S_t + \varepsilon_t \qquad (2.1)$$

Период сезонности задан равным 6 месяцам, что соответствует стандартному допущению при анализе помесячных данных. Результаты разложения представлены на рисунке 2.21.

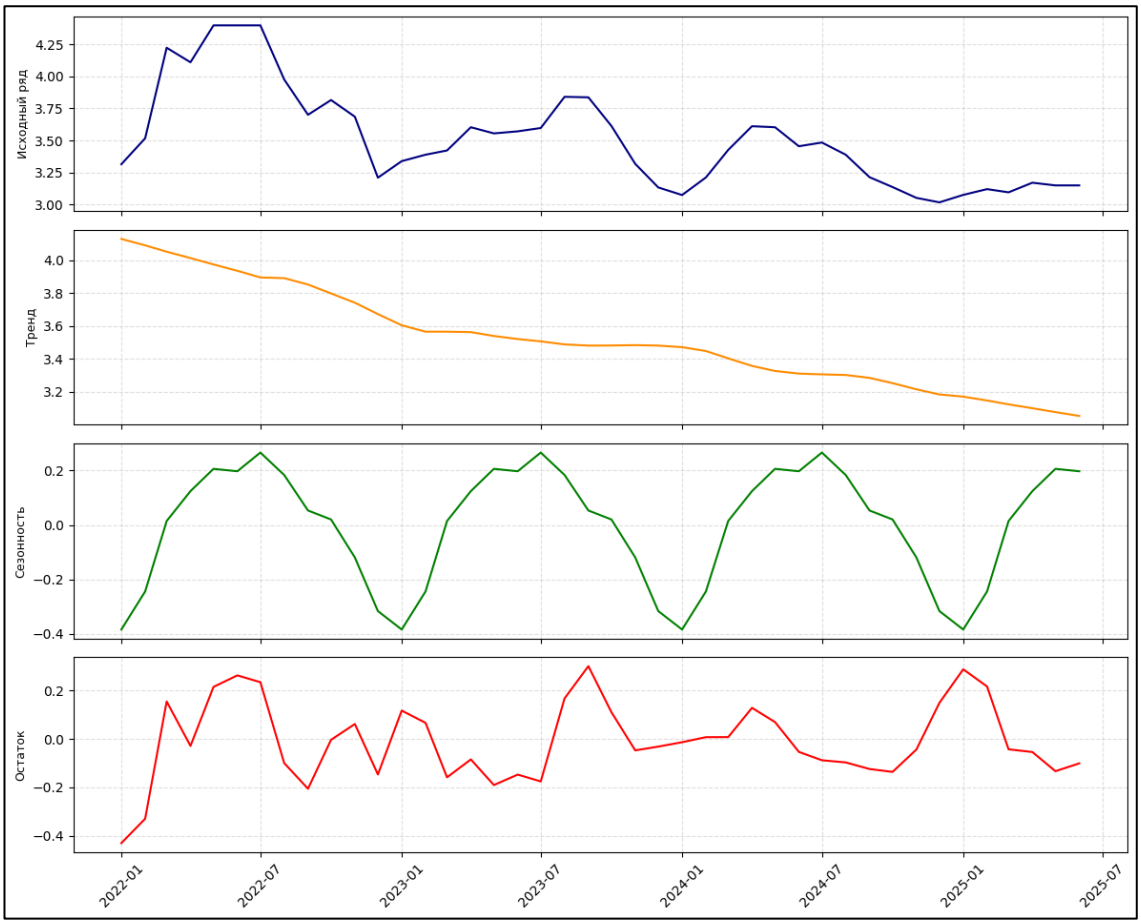



Рисунок 2.21 – Аддитивное разложение временного ряда GASREGM

Трендовая составляющая демонстрирует устойчивую нисходящую динамику на протяжении всего исследуемого периода с января 2022 по июль 2025 года: значение тренда снижается с уровня около 4,2 долл./галлон в начале периода до примерно 3,05 долл./галлон к его концу. Снижение не является строго монотонным – в середине периода (2022–2023 годы) наблюдается фаза относительной стабилизации тренда вблизи 3,5–3,6 долл./галлон, после чего нисходящее движение возобновляется. Трендовая составляющая отражает общее долгосрочное удешевление бензина в США за рассматриваемый период на фоне нормализации нефтяных котировок после пика 2022 года.

Сезонная составляющая характеризуется выраженной и правильной периодической структурой с амплитудой колебаний от примерно −0,40 до +0,30 долл./галлон. Форма сезонного цикла воспроизводится устойчиво на протяжении всех четырёх лет наблюдений: снижение в зимние месяцы и рост в весенне-летний период. Это указывает на наличие реальной сезонности в ценах на бензин, обусловленной сезонным спросом на топливо – повышенным в летний туристический сезон и пониженным в зимние месяцы.

Остаточная составляющая демонстрирует нерегулярные колебания с наиболее выраженным положительным выбросом около +0,60 в середине 2022 года, соответствующим резкому ценовому шоку вследствие геополитических событий. В остальные периоды остаток колеблется в диапазоне +/- 0,20–0,35,

что свидетельствует об умеренной случайной изменчивости вокруг трендово-сезонной компоненты.

Поскольку для дальнейшего моделирования используется стационарный (дифференцированный) ряд ΔGASREGM, возникла необходимость проверить наличие сезонной составляющей именно в нем, а не только в исходных данных. Это обусловлено тем, что наличие сезонности в нестационарном ряду не дает надежных оснований для введения лаговых переменных в модель.

В связи с этим было проведено аддитивное разложение первой разности целевого показателя (рисунок 2.22)

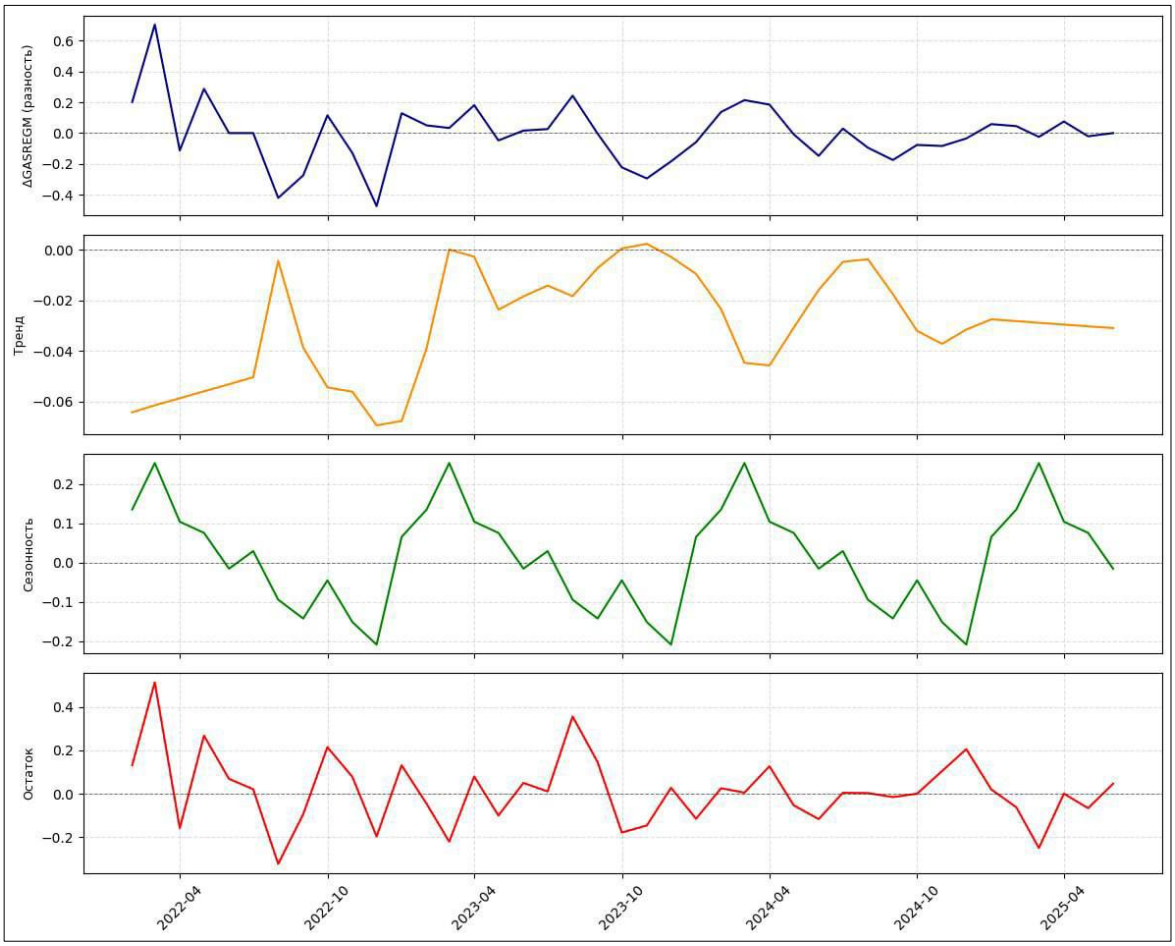



Рисунок 2.22 – Аддитивное разложение дифференцированного временного ряда ΔGASREGM

Визуальный анализ декомпозиции дифференцированного ряда на первый взгляд указывает на сохранение сезонных колебаний. Однако для подтверждения их статистической значимости был проведен анализ автокорреляционной функции (ACF).

На графиках ACF и PACF первой разности (рис. 2.15) значения корреляций, начиная со второго лага, находятся внутри доверительного интервала.

Это подтверждает, что выявленная цикличность носит формальный характер и обусловлена принудительным разложением ряда на компоненты, в то время как объективные показатели автокорреляции не подтверждают наличие устойчивых сезонных закономерностей.

Несмотря на отсутствие строгой статистической значимости сезонных пиков на графике ACF, переменная MONTH была сохранена в пространстве признаков. Это решение обосновано способностью алгоритмов машинного обучения (в частности, случайного леса и градиентного бустинга) улавливать слабые нелинейные паттерны, которые могут быть полезны для повышения точности прогноза. Анализ важности признаков подтверждает наличие низкого, но ненулевого вклада данного фактора в итоговую модель.

Для детального изучения внутригодовой изменчивости построены диаграммы размаха значений GASREGM в разрезе календарных месяцев, представленные на рисунке 2.23.

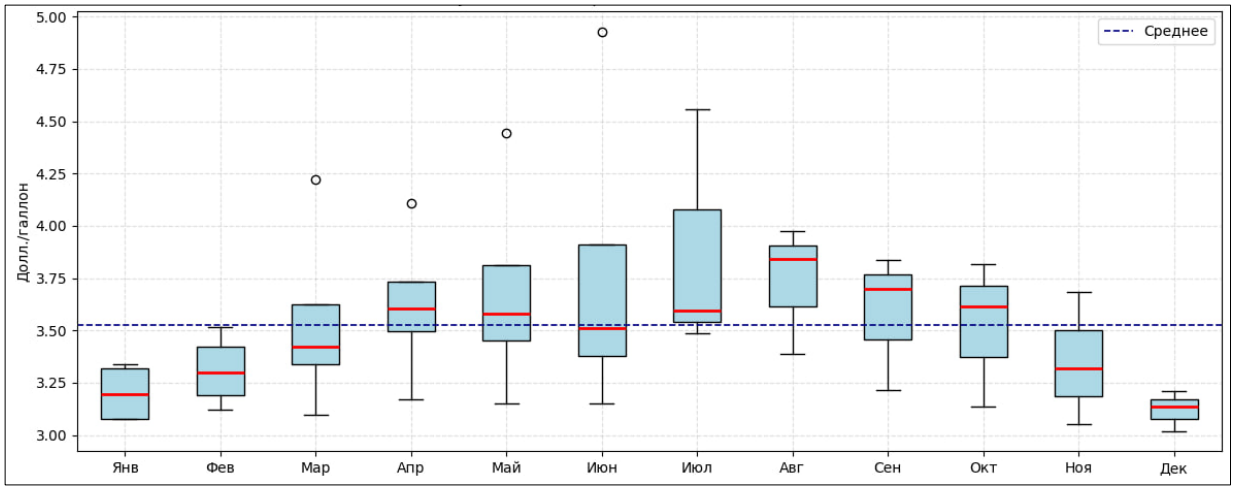



Рисунок 2.23 – Распределение значений GASREGM по месяцам

Визуальный анализ подтверждает наличие выраженной сезонной закономерности. Медианные значения цены бензина существенно варьируются по месяцам: наиболее низкий уровень характерен для декабря (3,10 долл./галлон) и января (3,20 долл./галлон), тогда как максимальные медианные значения наблюдаются в летние месяцы – июне и июле (3,55–3,60 долл./галлон). Общий среднегодовой уровень, обозначенный пунктирной линией (3,50 долл./галлон), пересекается с медианой примерно в апреле–мае и сентябре–октябре, что соответствует переходным периодам сезонного цикла. Наиболее широкий межквартильный размах наблюдается в июле, что отражает наибольшую неопределённость летних цен, связанную с волатильностью спроса в пиковый туристический сезон.

Аналогичный анализ был проведён для дифференцированного ряда ΔGASREGM с целью проверки сохранения внутригодовых закономерностей после преобразования. Результаты представлены на рисунке 2.24.

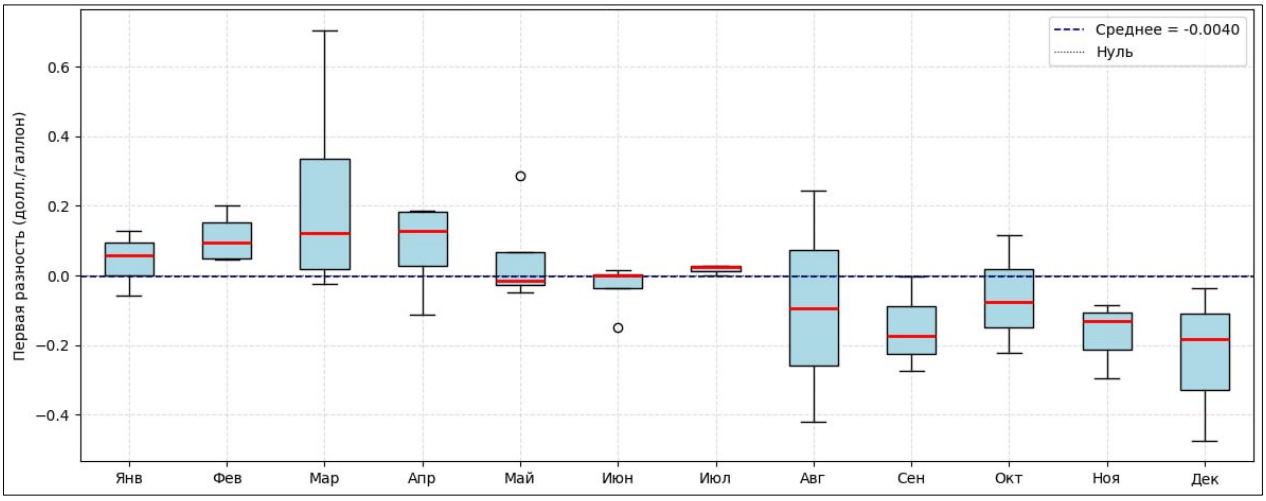



Рисунок 2.24 – Распределение значений ΔGASREGM по месяцам

Диаграммы размаха первой разности демонстрируют характерную внутригодовую структуру. В зимне-весенние месяцы (январь–апрель) медианные значения ΔGASREGM положительны, что соответствует типичному сезонному росту цен в начале года. Обратная картина наблюдается с августа по декабрь: медианные значения смещены в отрицательную зону, отражая сезонное снижение цен во второй половине года. Среднее значение первой разности за весь период практически равно нулю (−0,004 долл./галлон), что согласуется с результатами ADF-теста о стационарности ряда ΔGASREGM. Наибольший разброс значений зафиксирован в марте и декабре, что свидетельствует о повышенной неопределённости ценовой динамики в переходные сезонные периоды.

Несмотря на визуальные различия медиан по месяцам, анализ ACF не выявил статистически значимых сезонных пиков в ряду ΔGASREGM (значения со второго лага не выходят за доверительный интервал). Это означает, что наблюдаемая на диаграмме размаха внутригодовая дифференциация не формирует устойчивых автокорреляционных паттернов и обусловлена ограниченным объёмом выборки. Таким образом, строгой статистической сезонности в дифференцированном ряду не обнаружено.

Для количественной оценки сезонных эффектов были рассчитаны средние сезонные индексы по каждому месяцу, представленные на рисунке 2.25.

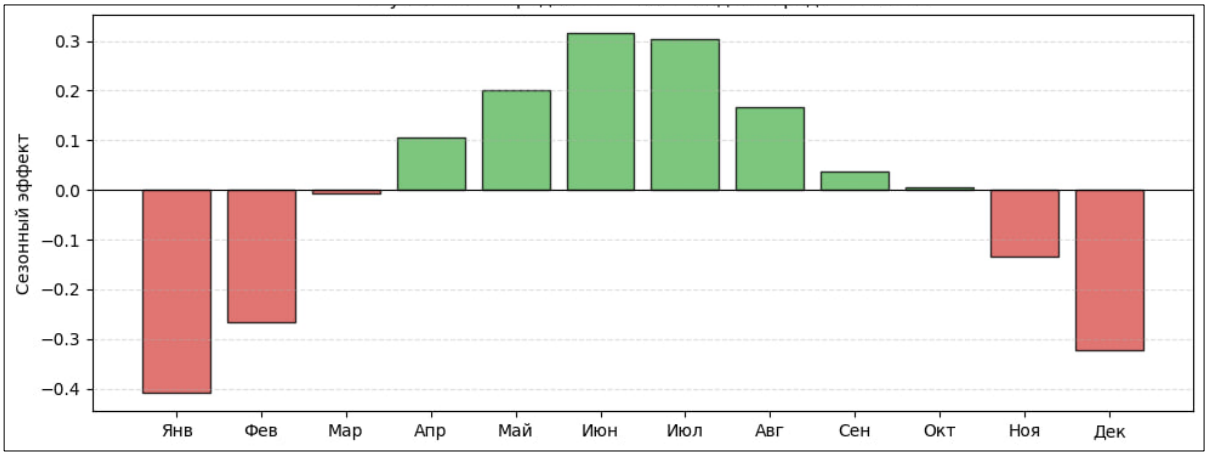



Рисунок 2.25 – Средние сезонные индексы ряда GASREGM по месяцам

График наглядно демонстрирует два выраженных периода: отрицательный сезонный эффект в зимние месяцы (январь: −0,40; февраль: −0,27; декабрь: −0,30; ноябрь: −0,12) и положительный – в весенне-летний период (июнь: +0,31; июль: +0,30; май: +0,20). Март, апрель и сентябрь–октябрь характеризуются практически нулевым сезонным эффектом, выступая переходными месяцами. Совокупный размах сезонных индексов составляет около 0,71 долл./галлон, что относительно среднего уровня цены (3,50 долл./галлон) составляет порядка 20% – весьма существенная величина, подтверждающая практическую значимость сезонной компоненты для прогнозирования.

Аналогичный расчёт сезонных индексов был выполнен для дифференцированного ряда ΔGASREGM. Результаты представлены на рисунке 2.26.

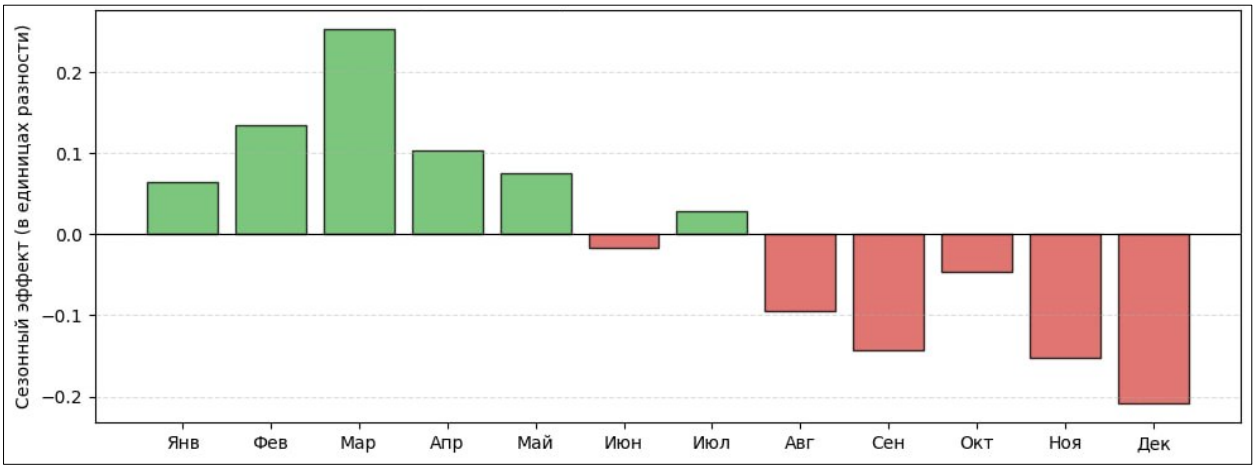



Рисунок 2.26 – Средние сезонные индексы ряда ΔGASREGM по месяцам

График сезонных индексов первой разности подтверждает наблюдения, сделанные по диаграммам размаха. Положительные значения индексов сосредоточены в первой половине года: наибольший прирост характерен для

марта (+0,26 долл./галлон), февраля (+0,13) и апреля (+0,10), что соответствует сезонному ускорению роста цен в весенний период. Май и июль также демонстрируют умеренно положительные значения (+0,08 и +0,03 соответственно). Отрицательные индексы доминируют во второй половине года: наиболее выраженное снижение приходится на декабрь (−0,20), сентябрь (−0,15) и август (−0,11), тогда как октябрь и ноябрь характеризуются умеренно отрицательными значениями. Июнь располагается вблизи нуля, выступая переходным месяцем между двумя фазами цикла.

Совокупный размах сезонных индексов дифференцированного ряда составляет около 0,46 долл./галлон, что заметно скромнее аналогичного показателя для исходного ряда (0,71 долл./галлон). Это закономерно: дифференцирование устраняет уровневые различия и оставляет лишь информацию об изменениях цены, поэтому амплитуда сезонных эффектов в разностном ряду всегда меньше.

На рисунке 2.27 представлен график ACF выделенной сезонной составляющей.

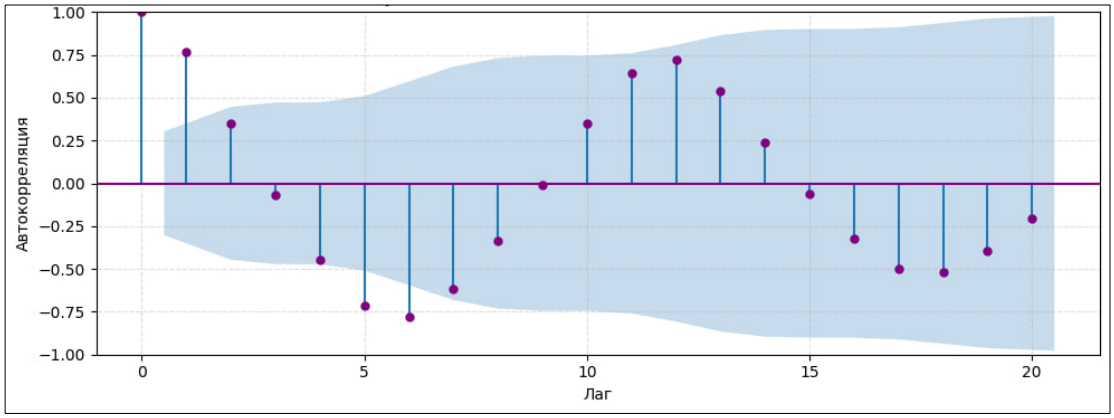



Рисунок 2.27 – ACF сезонной составляющей

Коррелограмма демонстрирует характерную структуру с высоким значением на первом лаге (0,75) и резкими знакочередующимися выбросами на лагах 5–7 (около −0,75 и −0,80) с последующим восстановлением на лагах 10–12 (+0,60–0,70). Данный паттерн отражает внутреннюю структуру извлечённой сезонной компоненты с периодом 6 месяцев и является математически ожидаемым результатом декомпозиции. Вместе с тем широкий доверительный интервал на средних и глубоких лагах указывает на статистическую неустойчивость ряда части выбросов, что обусловлено относительно небольшим объёмом выборки.

Для сопоставления была также построена ACF сезонной составляющей дифференцированного ряда ΔGASREGM, представленная на рисунке 2.28.

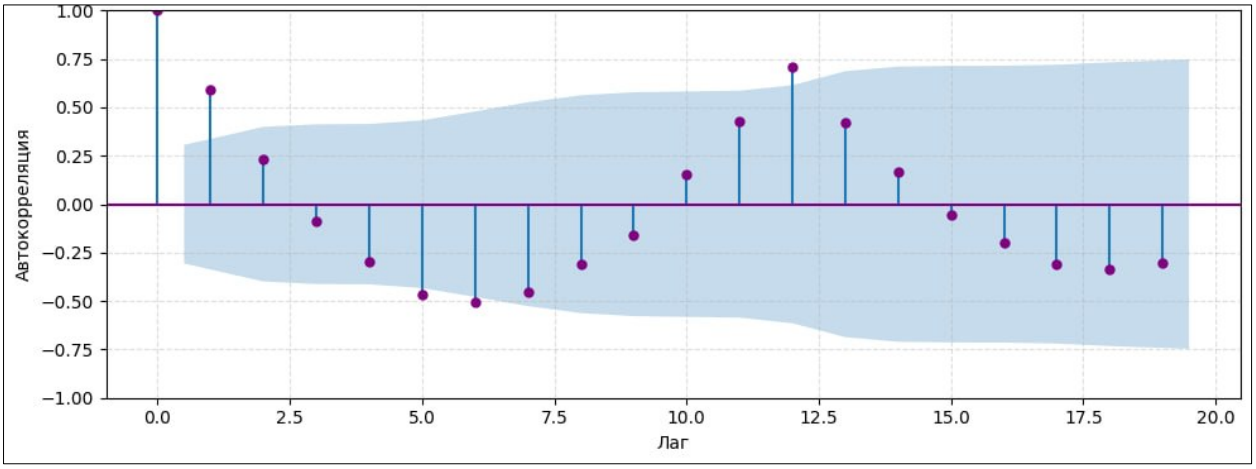



Рисунок 2.28 – ACF сезонной составляющей ΔGASREGM

Коррелограмма сезонной составляющей дифференцированного ряда демонстрирует нерегулярную структуру. Значение на первом лаге составляет около +0,60, после чего на лагах 4–7 наблюдаются устойчивые отрицательные выбросы в диапазоне от −0,50 до −0,55, выходящие за границы доверительного интервала. На лагах 11–12 функция резко восстанавливается до +0,70 и +0,45, также превышая доверительные границы. Подобное знакочередующееся поведение является математически ожидаемым результатом принудительного разложения короткого ряда на компоненты с заданным периодом и не свидетельствует об устойчивой сезонности: структура ACF воспроизводит навязанный алгоритмом декомпозиции цикл, а не реальный периодический процесс в данных. Данный результат согласуется с выводами анализа ACF и PACF первой разности (рис. 2.15) и дополнительно подтверждает, что переменная MONTH включается в пространство признаков как носитель слабого нелинейного сигнала, а не как отражение статистически значимой сезонной закономерности.

Таким образом, проведённый анализ позволяет сформулировать следующие выводы. Динамика розничной цены бензина GASREGM определяется устойчивым нисходящим трендом, отражающим долгосрочную нормализацию цен на энергоносители после шока 2022 года. Декомпозиция исходного ряда выявляет визуально выраженную сезонную компоненту с амплитудой до 0,71 долл./галлон, однако данный результат следует интерпретировать с осторожностью. Поскольку исходный ряд является нестационарным, наблюдаемая сезонность не может служить надёжным основанием для включения сезонных переменных в модель.

Аддитивное разложение дифференцированного ряда ΔGASREGM также демонстрирует визуально регулярную сезонную компоненту с амплитудой около 0,46 долл./галлон. Вместе с тем формальная проверка с помощью ACF показывает, что данная цикличность носит искаженный характер: значения автокорреляции, начиная со второго лага, располагаются внутри доверительного интервала, то есть алгоритм декомпозиции принудительно

выделяет сезонную компоненту даже там, где устойчивых периодических закономерностей в действительности нет. Таким образом, визуальная регулярность сезонной кривой обусловлена математической природой метода, а не реальной структурой данных. Переменная MONTH сохраняется в пространстве признаков, так как алгоритмы машинного обучения способны улавливать слабые нелинейные паттерны, недоступные для формальных тестов на ограниченных выборках.

### 2.4 Извлечение признаков

Этап извлечения признаков является связующим звеном между первичной обработкой данных и построением прогнозных моделей. Исходный набор данных содержит пять факторных переменных в их текущих значениях. Однако для адекватного моделирования ценовой динамики на рынке нефтепродуктов одних текущих значений недостаточно: цены реагируют на изменения факторов с задержкой, а сам ряд обладает выраженной инерционностью. Поэтому на данном этапе исходное пространство признаков было существенно расширено за счёт создания производных переменных трёх типов: лаговых значений целевой переменной, лаговых значений факторов и скользящих статистик.

Анализ ACF, проведённый в разделе 2.3.2, показал, что ряд GASREGM обладает высокой автокорреляцией: коэффициенты остаются значимыми на нескольких первых лагах. Это означает, что цена бензина в текущем месяце тесно связана с её значениями в предшествующих периодах. Данное свойство обусловлено экономической природой рынка топлива: розничные цены не меняются мгновенно – операторы АЗС и нефтепереработчики корректируют прайс-листы постепенно, ориентируясь на предыдущий ценовой уровень.

На основании этого в пространство признаков были включены три авторегрессионных лага:

– Y_LAG_1 – цена бензина месяц назад (t−1): наиболее сильный предиктор, отражающий прямую инерцию ценового ряда (r = 0,895);

– Y_LAG_2 – цена бензина два месяца назад (t−2): фиксирует среднесрочную инерцию (r = 0,705);

– Y_LAG_3 – цена бензина три месяца назад (t−3): улавливает более отдалённые ценовые тенденции (r = 0,546).

Постепенное снижение корреляции с увеличением глубины лага подтверждает, что влияние прошлых значений затухает, и включение лагов глубже третьего порядка нецелесообразно.

Для характеристики локальной динамики ценового ряда были сформированы скользящие признаки, вычисленные исключительно по прошлым наблюдениям с применением операции сдвига, что исключает утечку данных из будущего:

– Y_ROLL_MEAN_3 – скользящее среднее цены бензина за последние 3 месяца: отражает краткосрочный ценовой тренд (r = 0,760);

– Y_ROLL_MEAN_6 – скользящее среднее за 6 месяцев: характеризует среднесрочную тенденцию (r = 0,583);

– Y_ROLL_STD_3 – скользящее стандартное отклонение за 3 месяца: измеряет текущий уровень ценовой волатильности (r = 0,482).

Скользящие средние позволяют моделям улавливать направление тренда, тогда как стандартное отклонение несёт информацию о турбулентности рынка – периодах повышенной неопределённости, типичных для нефтяных шоков.

Ценообразование на рынке нефтепродуктов не является мгновенным процессом. Изменения каждого из факторов проходят через цепочку экономических механизмов, прежде чем отражаются в розничной цене.

Цена нефти WTI (DCOILWTICO) транслируется в розничные цены через этапы переработки, транспортировки и дистрибуции, что занимает несколько недель. Поэтому наряду с текущим значением (r = 0,857) включён лаг первого порядка DCOILWTICO_LAG1 (r = 0,777).

Индекс цен производителей нефтепереработки PCU отражает отпускные цены переработчиков, которые в свою очередь реагируют на сырьевой рынок с задержкой. Лаг PCU_LAG1 (r = 0,930) оказался даже более сильным предиктором, чем DCOILWTICO в текущем периоде, что подтверждает важность учёта производственного звена цепочки с запаздыванием.

Уровень безработицы UNRATE воздействует на потребительский спрос на топливо через изменение реальных доходов населения с характерным для рынка труда лагом. Включён UNRATE_LAG1 (r = −0,595).

Индекс потребительских настроений UMCSENT формирует ожидания домохозяйств относительно будущих расходов, в том числе на топливо. Эффект реализуется с задержкой через фактическое изменение транспортной активности. Включён UMCSENT_LAG1 (r = −0,291).

Производственный индекс нефтедобычи IPG211S расширяет предложение сырья на рынке постепенно – новые скважины вводятся в эксплуатацию со значительным временным лагом. Включён IPG211S_LAG1 (r = −0,610).

По результатам анализа, проведённого в разделе 2.3.3, декомпозиция исходного ряда GASREGM выявляет визуально выраженный внутригодовой цикл, однако формальная проверка на дифференцированном ряду ΔGASREGM не подтверждает его статистической значимости: ACF первой разности не фиксирует значимых сезонных пиков, а наблюдаемая цикличность обусловлена принудительным разложением ряда на компоненты. Тем не менее переменная MONTH – порядковый номер месяца от 1 до 12 – сохранена в пространстве признаков. Несмотря на практически нулевую линейную корреляцию с целевой переменной (r = 0,003), данный признак позволяет нелинейным алгоритмам машинного обучения улавливать слабые внутригодовые паттерны, которые не поддаются обнаружению формальными тестами на выборке ограниченного объёма. Анализ важности признаков

подтверждает наличие низкого, но ненулевого вклада данного фактора в итоговую модель.

Матрица корреляции исходных переменных, представленная на рисунке 2.29, выявляет ряд важных взаимосвязей.




Рисунок 2.29 – Матрица корреляции признаков модели

Наиболее высокая попарная корреляция зафиксирована между PCU и GASREGM (r = 0,98) и между PCU и DCOILWTICO (r = 0,91) – прямое следствие того, что индекс цен производителей нефтепереработки является промежуточным звеном между ценой сырой нефти и розничной ценой бензина. Сильная отрицательная связь между IPG211S и DCOILWTICO (r = −0,73) отражает закономерность: рост добычи нефти оказывает понижательное давление на её котировки. Умеренная положительная корреляция между UNRATE и IPG211S (r = 0,64) объясняется тем, что период активного наращивания добычи совпал с восстановлением рынка труда после пандемии. Несмотря на наличие мультиколлинеарности между рядом предикторов, все переменные сохранены в итоговом пространстве признаков, поскольку представляют качественно различные экономические каналы, а применяемые ансамблевые методы машинного обучения устойчивы к коллинеарным входным данным.

Итоговый состав пространства признаков приведён в таблице 2.5.

Таблица 2.5 – «Итоговое пространство признаков для моделей машинного обучения»

| Идентификатор | Описание | Группа | Экономическое обоснование |
|---|---|---|---|
| Y_LAG_1 | Цена бензина, t−1 | Авторегрессионные | Инерционность ценового ряда |
| Y_LAG_2 | Цена бензина, t−2 | Авторегрессионные | Краткосрочная память ряда |
| Y_LAG_3 | Цена бензина, t−3 | Авторегрессионные | Среднесрочная память ряда |
| Y_ROLL_MEAN_3 | Скользящее среднее за 3 мес. | Скользящие | Краткосрочный ценовой тренд |
| Y_ROLL_MEAN_6 | Скользящее среднее за 6 мес. | Скользящие | Среднесрочный ценовой тренд |
| Y_ROLL_STD_3 | Скользящее ст. откл. за 3 мес. | Скользящие | Текущая ценовая волатильность |
| DCOILWTICO | Цена нефти WTI, t | Сырьевые | Основной ценовой драйвер |
| DCOILWTICO_LAG1 | Цена нефти WTI, t-1 | Сырьевые | Запаздывание передачи цены сырья |
| PCU | PPI нефтепереработки, t | Производственные | Издержки переработки |
| PCU_LAG1 | PPI нефтепереработки, t-1 | Производственные | Производственные издержки с задержкой |
| UNRATE | Уровень безработицы, t | Макроэкономические | Потребительский спрос на топливо |
| UNRATE_LAG1 | Уровень безработицы, t-1 | Макроэкономические | Спрос с задержкой |
| UMCSENT | Потреб. настроения, t | Поведенческие | Ожидания потребителей |
| UMCSENT_LAG1 | Потреб. настроения, t-1 | Поведенческие | Ожидания с задержкой |
| IPG211S | Индекс нефтедобычи, t | Производственные | Фактор предложения сырья |
| IPG211S_LAG1 | Индекс нефтедобычи, t-1 | Производственные | Предложение с задержкой |
| MONTH | Номер месяца (1–12) | Временные | Сезонный спрос на топливо |

Корреляция всех извлечённых признаков с целевой переменной представлена на рисунке 2.30.

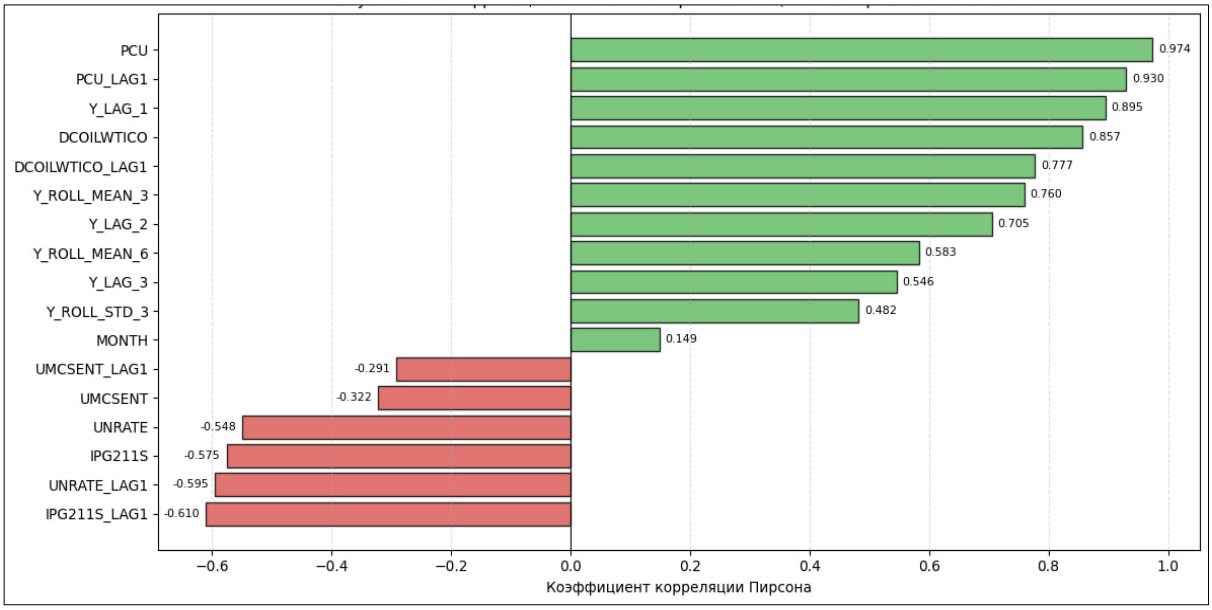



Рисунок 2.30 – Корреляция извлечённых признаков с целевой переменной GASREGM

Наиболее сильными предикторами оказались PCU (r = 0,974) и PCU_LAG1 (r = 0,930), подтверждая ключевую роль производственного звена нефтепереработки. Высокую прогностическую ценность также демонстрируют авторегрессионные признаки Y_LAG_1 (r = 0,895) и текущая цена нефти DCOILWTICO (r = 0,857). Факторы предложения и занятости – IPG211S_LAG1 (r = −0,610), UNRATE_LAG1 (r = −0,595) – формируют группу значимых отрицательных предикторов. Наименьшую линейную связь с целевой переменной имеют UMCSENT_LAG1 (r = −0,291) и MONTH (r = 0,149), однако они сохраняются в пространстве признаков как носители нелинейной и сезонной информации.

В результате проведённого извлечения сформирован итоговый вектор из 17 признаков. После удаления наблюдений с пропущенными значениями, возникших вследствие применения лаговых операций и скользящего окна, объём выборки составил 39 наблюдений. Сформированное пространство признаков охватывает все ключевые каналы ценообразования на рынке нефтепродуктов: сырьевой, производственный, макроэкономический, поведенческий и инерционный.

# 3 МОДЕЛИ ПРОГНОЗИРОВАНИЯ ЦЕЛЕВОГО ПРИЗНАКА

## 3.1 Описание моделей и процедуры анализа

Для решения задачи прогнозирования цен на нефтепродукты в данной работе реализован двухуровневый аналитический подход. На первом уровне применяются классические эконометрические методы, обладающие строгой статистической базой и позволяющие улавливать авторегрессионную структуру временного ряда. На втором уровне используются алгоритмы машинного обучения, ориентированные на захват нелинейных зависимостей и сложных взаимодействий между факторными переменными. Совместное применение этих двух групп методов даёт возможность провести разностороннее сравнение и выбрать наиболее точный инструмент прогнозирования для конкретного горизонта.

Прогнозы строятся и оцениваются на горизонтах h = 1, 3, 6, 9 и 12 месяцев, что охватывает как оперативные, так и стратегические задачи управления ценообразованием на топливном рынке.

ARIMA (p, d, q) – авторегрессионная интегрированная модель скользящего среднего. Модель ARIMA является одним из наиболее распространённых и хорошо изученных инструментов для моделирования и прогнозирования нестационарных временных рядов. Концепция данного класса моделей была предложена Дж. Боксом и Г. Дженкинсом и по сей день сохраняет свою актуальность благодаря гибкости структуры и высокой интерпретируемости результатов [34].

Общее аналитическое представление модели ARIMA имеет вид:

$$\Phi(B)\nabla^d Y_t = \Theta(B)\varepsilon_t, \tag{3.1}$$

где B – оператор сдвига (lag operator), такой что $BY_t = Y_{t-1}$;
$\nabla^d$ – оператор дифференцирования d-го порядка;
$\varepsilon_t$– белый шум (случайная ошибка).

Анализ стационарности, проведённый в разделе 2.3.1, показал, что исходный ряд цен на нефтепродукты является интегрированным первого порядка − I(1), то есть однократное взятие разностей приводит его к стационарному процессу. Таким образом, параметр d = 1 фиксируется на основании результатов ADF-теста и в дальнейшем не подлежит перебору.

Параметр p (порядок авторегрессии) задаёт количество лагов зависимой переменной, включаемых в модель для объяснения её текущего значения. Параметр q (порядок скользящего среднего) определяет число лаговых ошибок предсказания, вводимых в спецификацию.

На этапе формирования признакового пространства, описанного в разделе 2.4, в состав объясняющих переменных были включены три лага целевой переменной: Y_LAG_1, Y_LAG_2 и Y_LAG_3. Включение трёх лаговых значений цены бензина методологически соответствует

авторегрессионной составляющей порядка p = 3, что определяет начальную спецификацию модели как ARIMA(3,1,1). Данный выбор опирался на результаты ACF- и PACF-анализа (раздел 2.3.2), которые фиксировали статистически значимую автокорреляцию на лагах 1, 2 и 3, что давало основания предположить, что каждый из трёх лагов вносит самостоятельный вклад в объяснение текущей динамики цен.

Спецификация ARIMA(3,1,1) была оценена методом максимального правдоподобия. Результаты оценки представлены в таблице 3.1.

Таблица 3.1 – «Оценки коэффициентов модели ARIMA(3,1,1)»

| Параметр | Оценка | Стд. ошибка | t-статистика | p-значение |
|---|---|---|---|---|
| AR(1) | −0,2659 | 0,3252 | −0,8178 | 0,4135 |
| AR(2) | 0,2073 | 0,1900 | 1,0915 | 0,2751 |
| AR(3) | −0,0941 | 0,1062 | −0,8859 | 0,3757 |
| MA(1) | 0,7985 | 0,3223 | 2,4771 | 0,0132 |
| $\sigma^2$ | 0,0267 | 0,0018 | 14,4476 | 0,0000 |

Анализ результатов оценки выявил, что все три авторегрессионных коэффициента – AR(1), AR(2) и AR(3) – статистически незначимы на уровне 5%. Их p-значения составляют 0,4135, 0,2751 и 0,3757 соответственно, что существенно превышает пороговое значение 0,05. Единственным значимым элементом модели является составляющая скользящего среднего MA(1) с p-значением 0,0132. Это означает, что текущая цена бензина объясняется не прошлыми уровнями цен, а лишь ошибкой предсказания предыдущего периода. Иными словами, лаговые значения Y_LAG_1, Y_LAG_2 и Y_LAG_3 не вносят статистически значимого самостоятельного вклада в объяснение динамики ряда в рамках данной спецификации.

На основании выявленной незначимости всех трёх авторегрессионных коэффициентов принято решение о редукции модели. В соответствии с принципом экономии параметров предпочтение отдаётся более простой спецификации, если усложнение модели не подкреплено статистическими свидетельствами. Редуцированная модель ARIMA(1,1,1) была переоценена. Результаты представлены в таблице 3.2.

Таблица 3.2 – «Оценки коэффициентов модели ARIMA(1,1,1)»

| Параметр | Оценка | Стд. ошибка | t-статистика | p-значение |
|---|---|---|---|---|
| AR(1) | 0,1287 | 0,0913 | 1,4090 | 0,1588 |
| MA(1) | 0,3993 | 0,0833 | 4,7934 | 0,0000 |
| $\sigma^2$ | 0,0268 | 0,0018 | 15,2835 | 0,0000 |

Сравнение спецификаций по критерию Акаике подтверждает обоснованность редукции: AIC для ARIMA(1,1,1) составляет −157,01, тогда как для ARIMA(3,1,1) – −153,95, то есть более простая модель демонстрирует меньшее значение критерия на 3,07 единицы. Поскольку AIC штрафует за

каждый дополнительный параметр, его снижение при переходе к ARIMA(1,1,1) означает, что три авторегрессионных лага не окупали своей вычислительной стоимости.

Следует отметить, что в модели ARIMA(1,1,1) коэффициент AR(1) также не достигает статистической значимости на уровне 5% (p = 0,1588), однако его включение обосновано методологически: данная спецификация является стандартной отправной точкой для анализа ценовых рядов с умеренной инерцией, а критерий AIC однозначно подтверждает её превосходство над расширенными альтернативами.

Таким образом, итоговой спецификацией принята ARIMA(1,1,1). Модель включает по одному лагу авторегрессионной составляющей (p = 1) и составляющей скользящего среднего (q = 1), а однократное дифференцирование (d = 1) обеспечивает приведение ряда к стационарному виду. Данная спецификация достаточна для адекватного описания инерционной динамики цен на рынке нефтепродуктов без избыточного усложнения структуры.

GARCH (p, q) – модель обобщённой авторегрессионной условной гетероскедастичности.

Цены на нефтепродукты не просто колеблются − они колеблются неравномерно. Периоды относительной стабильности сменяются резкими скачками, после которых рынок вновь «успокаивается». Именно это явление, кластеризация волатильности, лежит в основе применения модели GARCH, предложенной Т. Боллерслевым на базе более ранних работ Э. Энгла. В отличие от ARIMA, которая моделирует само значение ряда, GARCH сосредоточен на его дисперсии: текущая неопределённость цены объясняется через неопределённость вчерашнюю.

Так как исходный ряд является нестационарным, обучение модели производится на разностях $\Delta Y_t = Y_t - Y_{t-1}$, а не на исходных уровнях цен. Это требование статистической корректности: моделирование условной дисперсии оправдано лишь для стационарных процессов.

Получение прогноза уровня цен на h шагов вперёд реализуется последовательно. Сначала модель GARCH(p, q) оценивается на ряде первых разностей $\Delta Y_t$, из которой извлекается оценка условного среднего (дрейфа) μ. Прогноз уровня затем восстанавливается обратным суммированием:

$$\widehat{Y_{t+h}} = Y_t + h \cdot \hat{\mu}, \tag{3.2}$$

где μ – оценка среднего значения первой разности, полученная из GARCH модели.

Оптимальная комбинация порядков (p, q) определяется перебором по сетке значений $p, q \in \{1, 2, 3\}$ с выбором спецификации, минимизирующей критерий AIC.

Включение GARCH в состав моделей работы обусловлено специфической природой нефтяного рынка: геополитические шоки,

колебания спроса и изменения добычи порождают кластеры волатильности, адекватное описание которых выходит за пределы возможностей линейных моделей типа ARIMA.

К моделям машинного обучения относят Random Forest, Gradient Boosting, K-Nearest Neighbors, Ridge Regression.

Ridge-регрессия (линейная модель с L2-регуляризацией) применяется для решения проблемы мультиколлинеарности между объясняющими переменными за счёт добавления штрафного слагаемого к коэффициентам модели. В этом подходе минимизируется не только ошибка аппроксимации, но и величина самих коэффициентов, что делает модель более устойчивой.

$$\hat{\beta} = argmin\left(\sum_{i=1}^{n}\left(Y_i - X_i^T\beta\right)^2 + \alpha\sum_{j=1}^{p}\beta_j^2\right), \quad (3.3)$$

Где α – гиперпараметр регуляризации, контролирующий интенсивность штрафа.

Здесь параметр α определяет степень регуляризации: чем он больше, тем сильнее «сжимаются» коэффициенты. При α = 0 модель эквивалентна классической МНК-регрессии, тогда как при очень больших значениях параметра все оценки коэффициентов стремятся к нулю. Выбор промежуточного значения α позволяет найти компромисс между качеством подгонки на обучающих данных и способностью модели корректно работать на новых наблюдениях.

С учётом выявленной ранее мультиколлинеарности факторов в задаче моделирования ценообразования на рынке нефтепродуктов использование Ridge-регрессии является оправданным. Подбор оптимального значения параметра регуляризации осуществляется с помощью процедуры RidgeCV, где используется логарифмически равномерная сетка из 50 значений α в диапазоне от $10^{-3}$ до $10^{3}$, а оценка качества проводится с применением кросс-валидации на скользящем окне.

Метод k-ближайших соседей (K-Nearest Neighbors, KNN) представляет собой непараметрический подход к машинному обучению, при котором не предполагается явное задание функциональной зависимости между признаками и целевой переменной. Вместо построения аналитической модели прогноз формируется на основе сходства объектов в пространстве признаков.

Оценка значения целевой переменной для нового наблюдения определяется как среднее по k наиболее близким объектам обучающей выборки:

$$\hat{Y}_{new} = \frac{1}{k}\sum_{i=1}^{k} Y_{(i)}\,, \quad (3.4)$$

где $Y_{(i)}$ –значение целевого показателя у i-го соседа, выбранного по критерию минимального расстояния.

Основным настраиваемым параметром алгоритма является число соседей k. При небольших значениях k модель становится чувствительной к случайным колебаниям данных и выбросам, тогда как увеличение k приводит к сглаживанию предсказаний и возможной утрате важных локальных зависимостей. Для выбора оптимального значения данного параметра проводится перебор набора кандидатов {3, 5, 7, 9, 11, 13, 15} с последующей оценкой качества по метрике MAPE в рамках процедуры кросс-валидации.

Так как алгоритм KNN использует расстояния между объектами, масштаб признаков оказывает существенное влияние на результат. В связи с этим все переменные предварительно нормируются с помощью StandardScaler, причём стандартизация выполняется отдельно для каждого временного интервала обучения, что особенно важно при моделировании динамики цен на рынке нефтепродуктов.

Метод случайного леса (Random Forest) относится к ансамблевым алгоритмам и основан на объединении большого числа деревьев решений, каждое из которых обучается независимо. Для повышения разнообразия моделей используется бутстрэппинг (случайные выборки с возвращением), а также случайный отбор подмножеств признаков при построении каждого дерева.

Итоговое предсказание формируется как среднее значение прогнозов всех деревьев ансамбля:

$$\hat{Y} = \frac{1}{T}\sum_{t=1}^{T} f_t(X)\,, \tag{3.5}$$

где T – количество деревьев в ансамбле, $f_t$ – предсказание, полученное от t-го дерева.

Использование ансамбля позволяет существенно повысить качество модели по сравнению с одиночным деревом решений. В частности, уменьшается риск переобучения, модель лучше улавливает сложные нелинейные зависимости между факторами, а также демонстрирует устойчивость к выбросам в данных, что особенно важно при анализе ценовых колебаний на рынке нефтепродуктов.

В рамках настройки модели рассматриваются два ключевых гиперпараметра: количество деревьев (n_estimators), принимающее значения {100, 200, 300}, и максимальная глубина деревьев (max_depth), варьирующаяся в наборе {3, 5, 7, None}. Определение наилучшей конфигурации осуществляется с помощью полного перебора всех комбинаций параметров, при этом критерий выбора основывается на минимизации ошибки MAPE в процедуре кросс-валидации.

Градиентный бустинг (Gradient Boosting) представляет собой ансамблевый алгоритм, в котором модели строятся последовательно, а не независимо. Каждое новое дерево обучается таким образом, чтобы компенсировать ошибки предыдущих шагов, постепенно улучшая качество предсказаний.

Итоговая модель формируется как сумма базового прогноза и поправок, вносимых каждым последующим деревом:

$$\hat{Y} = f_0(X) + \eta \sum_{m=1}^{M} f_m(X), \tag{3.6}$$

где: $f_0(X)$ – начальное приближение (как правило, константное значение);

$f_m(X)$ – вклад m-го дерева;

η – коэффициент обучения, регулирующий величину шага на каждой итерации;

M – общее число построенных деревьев.

Ключевая особенность метода заключается в том, что на каждом этапе новое дерево обучается на основе градиента функции потерь, что позволяет последовательно уменьшать систематическую ошибку модели. В отличие от случайного леса, где все деревья формируются независимо друг от друга, здесь используется поэтапное уточнение прогноза, что делает модель более гибкой и способной улавливать сложные закономерности в данных, включая динамику цен на нефтепродукты.

Настройка модели осуществляется через подбор основных гиперпараметров: числа деревьев (n_estimators), скорости обучения (learning_rate) и максимальной глубины деревьев (max_depth). Рассматриваются значения n_estimators ∈ {100, 200}, learning_rate ∈ {0.05, 0.1, 0.2} и max_depth ∈ {3, 4, 5}. Оптимальная комбинация определяется перебором всех возможных вариантов с использованием кросс-валидации на скользящем окне, при этом в качестве критерия качества выбирается минимальное значение ошибки MAPE.

Для всех четырёх алгоритмов машинного обучения на основе месячных данных по переменным GASREGM, DCOILWTICO, UNRATE, UMCSENT, PCU и IPG211S формируется расширенное признаковое пространство, обоснование которого приведено в разделе 2.4. Полный набор из 17 признаков включает:

– лаги целевой переменной Y_LAG_1, Y_LAG_2, Y_LAG_3 – цена бензина за предыдущие один, два и три месяца;

– скользящие средние цены бензина за последние 3 и 6 месяцев (Y_ROLL_MEAN_3, Y_ROLL_MEAN_6), рассчитанные с лаговым смещением на 1 месяц для исключения утечки данных;

– скользящее стандартное отклонение цены бензина за последние 3 месяца (Y_ROLL_STD_3), характеризующее текущий уровень ценовой волатильности;

– текущие значения факторных переменных: DCOILWTICO, PCU, UNRATE, UMCSENT, IPG211S;

– лаговые значения первого порядка для каждого из факторов: DCOILWTICO_LAG1, PCU_LAG1, UNRATE_LAG1, UMCSENT_LAG1, IPG211S_LAG1;

– временной признак MONTH для захвата сезонных эффектов спроса на топливо.

Все признаки подвергаются стандартизации (StandardScaler) отдельно для каждого временного окна обучения. Это особенно критично для корректной работы алгоритма KNN, в котором расстояние между объектами напрямую зависит от масштаба переменных, а также для Ridge-регрессии, где регуляризующий штраф применяется к коэффициентам при стандартизированных предикторах. Для ансамблевых методов – Random Forest и Gradient Boosting – стандартизация не является математически обязательной, однако обеспечивает единообразие процедуры обработки данных во всех моделях и устраняет возможное численное влияние различий в масштабах признаков.

В процессе walk-forward валидации итоговый состав признакового пространства был скорректирован относительно первоначального набора, сформированного в разделе 2.4. Несмотря на то что ACF-анализ (раздел 2.3.2) обосновывал включение лагов второго и третьего порядков целевой переменной (Y_LAG_2, Y_LAG_3) и скользящих статистик (Y_ROLL_MEAN_3, Y_ROLL_MEAN_6, Y_ROLL_STD_3), практическая проверка на скользящем окне выявила обратный эффект: данные признаки снижали точность прогнозов, а не повышали её.

Причина кроется в высокой взаимной корреляции между лаговыми и скользящими переменными. Для Ridge-регрессии это оборачивается нестабильностью оценок коэффициентов, особенно на длинных горизонтах прогнозирования. Ансамблевые методы в условиях избыточного числа коллинеарных признаков демонстрируют рост дисперсии прогнозов, что негативно сказывается на их обобщающей способности.

Помимо этого, в ходе экспериментов было уточнено определение признака направления ценового движения: вместо разности цен за три месяца $Y(t-1) - Y(t-4)$ использована более узкая разность $Y(t-1) - Y(t-2)$. Такое окно точнее улавливает краткосрочные изменения ценовой динамики, что особенно важно на горизонтах прогнозирования в один и три месяца.

По итогам отбора итоговое признаковое пространство сокращено до тринадцати переменных: лаг первого порядка целевой переменной Y_LAG_1, показатель направления движения цены Y_MOMENTUM, текущие и лаговые значения всех пяти факторных переменных (DCOILWTICO, PCU, UNRATE, UMCSENT, IPG211S и их лаги первого порядка), а также переменная MONTH.

Результаты ACF-анализа при этом не утрачивают своей методологической значимости, они подтверждают инерционную природу ценового ряда, которая в финальной спецификации учитывается компактно – через признаки Y_LAG_1 и Y_MOMENTUM.

Для объективной проверки прогностического потенциала разработанных алгоритмов в работе применяется метод скользящей валидации (Walk-Forward Cross-Validation, WFC). Данный подход является специализированным для анализа временных рядов, так как он строго соблюдает хронологический порядок и исключает «утечку данных» из будущего в обучающую выборку.

Из располагаемой выборки объёмом n = 39 месячных наблюдений последние test_size = 12 резервируются для тестирования. На каждом шаге i = 1, 2, …, test_size − h + 1 модель обучается на всех наблюдениях, хронологически предшествующих прогнозируемому моменту, и выдаёт прогноз на заданный горизонт h вперёд. Тем самым воспроизводится реальная ситуация прогнозирования, при которой аналитик располагает исключительно данными, накопленными к текущему моменту времени.

Точность прогнозов оценивается с помощью трёх взаимодополняющих метрик, каждая из которых характеризует качество модели с разных сторон.

MAPE (средняя абсолютная процентная ошибка) выражает отклонение прогноза в процентах от фактического значения. Её независимость от масштаба целевой переменной позволяет сопоставлять точность различных моделей вне привязки к абсолютному уровню цен, что принципиально важно в условиях выраженного нисходящего тренда ряда GASREGM.

RMSE (среднеквадратическая ошибка) выражается в тех же единицах, что и целевая переменная − долларах за галлон. За счёт возведения ошибки в квадрат данная метрика сильнее штрафует за крупные отклонения прогноза от факта, что делает её особенно чувствительной к редким, но значительным ценовым выбросам.

MAE (средняя абсолютная ошибка) также измеряется в единицах целевой переменной, однако одинаково взвешивает все ошибки вне зависимости от их величины. Это обеспечивает более высокую устойчивость метрики к аномальным наблюдениям по сравнению с RMSE.

Таким образом, в работе сформирован комплекс из шести прогностических моделей двух принципиально различных классов. Эконометрический блок представлен моделями ARIMA(1,1,1) и GARCH(p,q), опирающимися на статистические свойства временного ряда и его авторегрессионную структуру. Блок машинного обучения включает Ridge Regression, K-Nearest Neighbors, Random Forest и Gradient Boosting − методы, ориентированные на выявление нелинейных зависимостей в расширенном признаковом пространстве. Единая процедура WFC и единый набор метрик оценки (RMSE, MAE, MAPE) обеспечивают сопоставимость результатов всех моделей на пяти горизонтах прогнозирования: h = 1, 3, 6, 9 и 12 месяцев.

### 3.2 Подбор оптимальных значений гиперпараметров

Качество прогнозов в значительной мере определяется корректностью настройки гиперпараметров каждой модели. Произвольный или интуитивный их выбор недопустим: только систематическая процедура подбора гарантирует, что сравнение моделей между собой отражает их реальный прогностический потенциал, а не случайное стечение конфигураций. Для каждой из шести моделей разработана индивидуальная процедура настройки, учитывающая математическую природу метода. Все процедуры выполняются исключительно на обучающей части выборки, последние 12 наблюдений, отведённые под финальное тестирование, в настройке не участвуют.

Параметры модели ARIMA определяются следующим образом. Порядок интеграции d = 1 устанавливается на основании результатов ADF-теста: ряд GASREGM является нестационарным на уровнях и стационарным после однократного дифференцирования. Выбор порядков p и q производится перебором всех комбинаций из сетки $p \in \{0, 1, 2\}$ и $q \in \{0, 1, 2\}$ с вычислением информационного критерия Акаике для каждой спецификации. Наименьшее значение AIC получено для ARIMA(1,1,1), что согласуется со структурой коррелограмм ACF и PACF. Выбранная спецификация не является избыточной и при этом достаточно гибка для захвата динамики ценового ряда.

Для модели GARCH порядки p и q подбираются независимо друг от друга путём полного перебора по сетке значений $p, q \in \{1, 2, 3\}$, что даёт девять возможных спецификаций. Каждая из них оценивается методом максимального правдоподобия на ряде первых разностей целевой переменной, предварительно умноженных на 100. Масштабирование носит исключительно вычислительный характер: оно приводит числовые значения ряда к диапазону, удобному для алгоритма оптимизации, и никак не влияет на сравнительные величины AIC между спецификациями. Комбинация (p*, q*), при которой достигается минимальное значение критерия, принимается в качестве оптимальной и используется в дальнейшем при построении прогнозов.

Единственным гиперпараметром Ridge Regression, требующим настройки, является коэффициент регуляризации α, контролирующий интенсивность штрафа за величину коэффициентов модели. Поиск оптимального значения осуществляется по логарифмически равномерной сетке из 50 значений в диапазоне от $10^{-3}$ до $10^{3}$. Такой охват позволяет рассмотреть как практически ненормированные решения, так и сильно сжатые конфигурации. Отбор лучшего значения реализован через процедуру RidgeCV с временной кросс-валидацией на основе TimeSeriesSplit с пятью фолдами. Использование именно временного разбиения принципиально. В отличие от стандартной случайной кросс-валидации, оно строго соблюдает хронологический порядок наблюдений и исключает попадание будущих значений цен на нефтепродукты в обучающую часть каждого фолда.

Для алгоритма KNN (K-Nearest Neighbors) центральным настраиваемым параметром выступает число соседей k, от которого напрямую зависит

чувствительность модели к локальным особенностям ценовых данных: небольшие значения k позволяют улавливать тонкие локальные закономерности, тогда как большие сглаживают прогноз и снижают реакцию на краткосрочные колебания. Перебор охватывает семь кандидатов: $k \in \{3, 5, 7, 9, 11, 13, 15\}$. Для каждого из них рассчитывается средняя ошибка MAPE по пяти фолдам временной кросс-валидации TimeSeriesSplit, после чего выбирается значение k*, обеспечивающее наименьшую среднюю ошибку. Такой подход позволяет подобрать степень сглаживания, оптимальную именно для динамики цен на нефтепродукты, не прибегая к субъективным суждениям.

Настройка случайного леса предполагает совместный подбор двух параметров: числа деревьев в ансамбле n_estimators и ограничения на их глубину max_depth. Перебор ведётся по всем комбинациям сетки $n_estimators \in \{100, 200, 300\}$ и $max_depth \in \{3, 5, 7, None\}$, что даёт 12 конфигураций для оценки. Каждая из них проверяется на пяти фолдах TimeSeriesSplit, а в качестве критерия выбора используется минимальная средняя MAPE. Значение max_depth = None означает, что глубина деревьев ничем не ограничена и они разбиваются до тех пор, пока в листе не останется минимально допустимое число наблюдений. Такие деревья обладают высокой выразительностью, но склонны к переобучению на обучающей выборке, именно поэтому окончательный выбор между ограниченной и неограниченной глубиной отдаётся кросс-валидационной процедуре, а не задаётся заранее.

Градиентный бустинг требует одновременной настройки трёх параметров, что делает его процедуру подбора наиболее трудоёмкой среди всех рассматриваемых моделей. Полный перебор по сетке $n_estimators \in \{100, 200\}$, $learning_rate \in \{0.05, 0.1, 0.2\}$ и $max_depth \in \{3, 4, 5\}$ порождает 18 комбинаций, каждая из которых оценивается на пяти фолдах TimeSeriesSplit по критерию минимальной MAPE. Отдельного внимания заслуживает взаимозависимость между скоростью обучения и числом деревьев: модель с малым learning_rate движется к решению мелкими шагами и нуждается в большем числе итераций, зато финальный ансамбль, как правило, лучше обобщается на новых данных. Раздельный подбор этих параметров игнорировал бы указанную связь и мог привести к субоптимальной конфигурации, поэтому они перебираются совместно в рамках единой процедуры.

Оптимальные значения гиперпараметров, установленные в ходе описанных процедур настройки и применяемые при walk-forward оценке, отображены в таблице 3.3.

Таблица 3.3 – «Оптимальные гиперпараметры моделей»

| Модель | Гиперпараметр | Значение |
|---|---|---|
| ARIMA | Порядок (p, d, q) | (1, 1, 1) |

Продолжение таблицы 3.3

| Модель | Гиперпараметр | Значение |
|---|---|---|
| GARCH | Порядок (p, q) | Определяется по минимуму AIC при p, q ∈ {1, 2, 3} |
| Ridge | α (alpha) | Определяется RidgeCV на сетке [$10^{-3}$, $10^{3}$] |
| KNN | n_neighbors | Определяется по минимуму MAPE из {3, 5, 7, 9, 11, 13, 15} |
| Random Forest | n_estimators, max_depth | Определяются по минимуму MAPE на сетке {100, 200, 300} × {3, 5, 7, None} |
| Gradient Boosting | n_estimators, learning_rate, max_depth | Определяются по минимуму MAPE на сетке {100, 200} × {0.05, 0.1, 0.2} × {3, 4, 5} |

Приведённые в таблице конфигурации не являются фиксированными константами − за исключением ARIMA, где спецификация (1,1,1) обоснована результатами предварительного анализа, параметры остальных моделей определяются заново на каждом шаге walk-forward процедуры, адаптируясь к актуальному обучающему окну. Это обеспечивает устойчивость настройки к изменению рыночных условий на протяжении тестового периода.

Реализованный подход к подбору гиперпараметров удовлетворяет двум ключевым требованиям. Во-первых, для всех моделей используется временная кросс-валидация, что исключает проникновение информации о будущих ценах в процесс обучения. Во-вторых, критерии отбора унифицированы: GARCH ориентируется на AIC как меру статистической адекватности, тогда как для всех четырёх алгоритмов машинного обучения применяется единый прогностический критерий − минимизация MAPE. Совокупность этих условий делает итоговые метрики качества на тестовой выборке сопоставимыми между моделями и пригодными для объективного сравнительного анализа.

### 3.3 Результаты прогнозирования

После завершения настройки гиперпараметров все шесть моделей проходят финальную оценку на тестовой выборке в режиме walk-forward cross-validation. Результаты получены для пяти горизонтов прогнозирования h ∈ {1, 3, 6, 9, 12} месяцев и трёх метрик качества: RMSE, MAE и MAPE. Основным критерием сравнения служит MAPE − как наиболее наглядная и масштабно независимая характеристика точности, позволяющая сопоставлять модели между горизонтами без поправки на абсолютный уровень цен. Динамика MAPE по всем горизонтам представлена на рисунке 3.1.

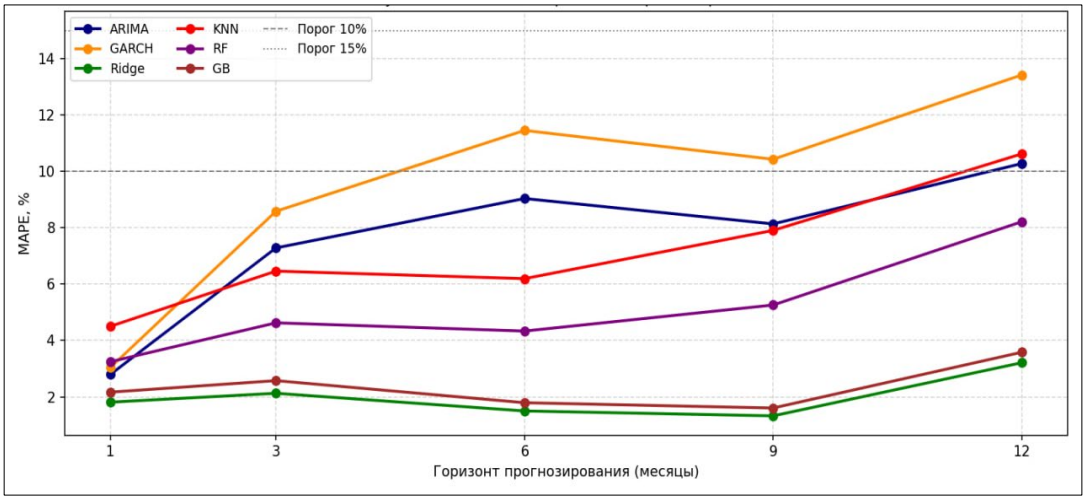



Рисунок 3.1 – Динамика MAPE по горизонтам прогнозирования

Общая закономерность, наблюдаемая для всех моделей без исключения, состоит в росте ошибки по мере увеличения горизонта прогнозирования − это отражает естественное накопление неопределённости при работе с ценовыми рядами нефтяного рынка. Однако темп этого роста и итоговый уровень ошибки существенно различаются в зависимости от класса модели.

На горизонте h = 1 месяц все модели демонстрируют приемлемую точность, не выходя за пределы 5%. Наилучший результат показывают Ridge Regression и Gradient Boosting с MAPE около 1,9–2,2%, вплотную за ними следуют Random Forest и ARIMA с показателем около 2,8–3,3%. KNN располагается на уровне 4,5%, тогда как GARCH с результатом около 3,04% занимает промежуточную позицию. Относительная близость всех моделей на коротком горизонте объясняется высокой инерционностью ценового ряда: даже простые методы способны удовлетворительно воспроизводить краткосрочную динамику.

На горизонте h = 3 месяца разрыв между моделями начинает увеличиваться. Ridge Regression и Gradient Boosting сохраняют лидерство с MAPE в районе 2,1–2,6%, оставаясь заметно точнее остальных. Random Forest также удерживает невысокий уровень ошибки около 4,6%. ARIMA показывает результат порядка 7,4%, тогда как KNN и GARCH заметно уступают − около 6,4% и 8,5% соответственно. Примечательно, что на этом горизонте эконометрические модели впервые начинают проигрывать лучшим алгоритмам машинного обучения.

На горизонте h = 6 месяцев наблюдается наибольший разброс между моделями и наиболее чёткое разделение на два кластера. Ridge Regression и Gradient Boosting демонстрируют MAPE на уровне 1,6–1,7% − исключительно высокую точность для столь длинного горизонта, что свидетельствует об их способности эффективно использовать структуру признакового пространства. Random Forest также сохраняет хороший результат около 4,3%. ARIMA с показателем около 9,0% переходит черту практической приемлемости, KNN держится на уровне 6,1%, а GARCH с MAPE порядка 11,5% окончательно

теряет конкурентоспособность − накопленное смещение при восстановлении уровней цен из разностей нарастает с каждым дополнительным шагом прогноза.

На горизонте h = 9 месяцев лидерство Ridge Regression и Gradient Boosting становится абсолютным: оба метода удерживают MAPE на уровне 1,5–1,6%, тогда как все остальные модели демонстрируют заметно более высокие ошибки. Random Forest показывает около 5,2%, KNN − порядка 8,0%, ARIMA приближается к 8,1%. GARCH превышает порог 10%, что окончательно исключает его из числа конкурентоспособных инструментов на средне- и долгосрочных горизонтах.

На горизонте h = 12 месяцев картина в целом сохраняется. Ridge Regression и Gradient Boosting финишируют с MAPE около 3,3–3,5% − результат, остающийся в пределах практической применимости даже на годовом горизонте. Random Forest с показателем около 8,2% занимает третью позицию. KNN и ARIMA демонстрируют близкие результаты в диапазоне 10,5–10,6%, фактически утрачивая прогностическую ценность на данном горизонте. GARCH с MAPE около 13,4% подтверждает свою принципиальную непригодность для точечного прогнозирования уровней цен на длинных временных интервалах − его методологическая ориентация на моделирование волатильности, а не условного среднего, оборачивается систематическим накоплением ошибки при восстановлении ценовых уровней из первых разностей.

Картина, складывающаяся по метрике RMSE (рисунок 3.2), в целом согласуется с выводами анализа MAPE, однако добавляет ряд важных наблюдений об абсолютных масштабах ошибок прогнозирования цен на бензин.

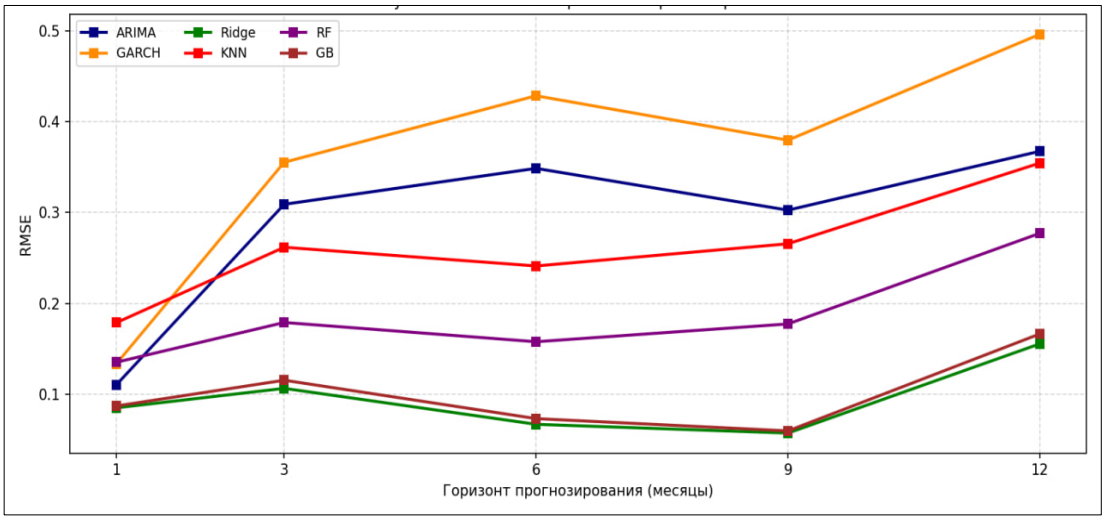



Рисунок 3.2 – Динамика RMSE

Ridge Regression и Gradient Boosting уверенно удерживают лидерство на всех горизонтах, формируя нижний кластер на графике. На горизонте h = 1 их

RMSE составляет около 0,08–0,09 долл./галлон, на h = 6 и h = 9 снижается до минимальных значений порядка 0,05–0,06 долл./галлон, а к h = 12 умеренно возрастает до 0,16–0,17 долл./галлон. Примечательно, что именно на средних горизонтах (6–9 месяцев) эти две модели демонстрируют наилучшую абсолютную точность за весь диапазон − нетипичная закономерность, объясняемая особенностями тестового периода с его относительно стабильной ценовой динамикой в середине 2024 года.

Random Forest занимает промежуточное положение. RMSE стартует с 0,14 долл./галлон на h = 1, достигает локального максимума около 0,18 долл./галлон на h = 3 и h = 6, после чего к h = 12 возрастает до 0,28 долл./галлон. Кривая модели проходит заметно ниже эконометрических методов, подтверждая её устойчивость на всём диапазоне горизонтов.

ARIMA и KNN образуют схожий по уровню кластер в средней части графика. ARIMA начинает с 0,11 долл./галлон на h = 1, резко возрастает до 0,31–0,35 долл./галлон на горизонтах 3–6, затем незначительно снижается на h = 9 до 0,30 долл./галлон и финиширует на уровне 0,37 долл./галлон на h = 12. KNN демонстрирует схожую траекторию: 0,18 долл./галлон на h = 1, рост до 0,24–0,26 долл./галлон на средних горизонтах и выход на 0,36 долл./галлон к h = 12.

GARCH выделяется на фоне остальных моделей монотонным и неуклонным ростом RMSE по всему диапазону горизонтов − от 0,18 долл./галлон на h = 1 до 0,50 долл./галлон на h = 12. Такая динамика наглядно иллюстрирует систематическое накопление ошибки при последовательном восстановлении ценовых уровней из первых разностей: каждый дополнительный шаг прогноза добавляет новую порцию смещения, и к годовому горизонту абсолютная ошибка модели втрое превышает результат Ridge Regression и Gradient Boosting.

Для визуальной оценки качества прогнозов на рисунках 3.3–3.6 представлено сопоставление фактической динамики розничных цен на бензин GASREGM с прогнозными значениями всех шести моделей на тестовом периоде для каждого из четырёх горизонтов прогнозирования.

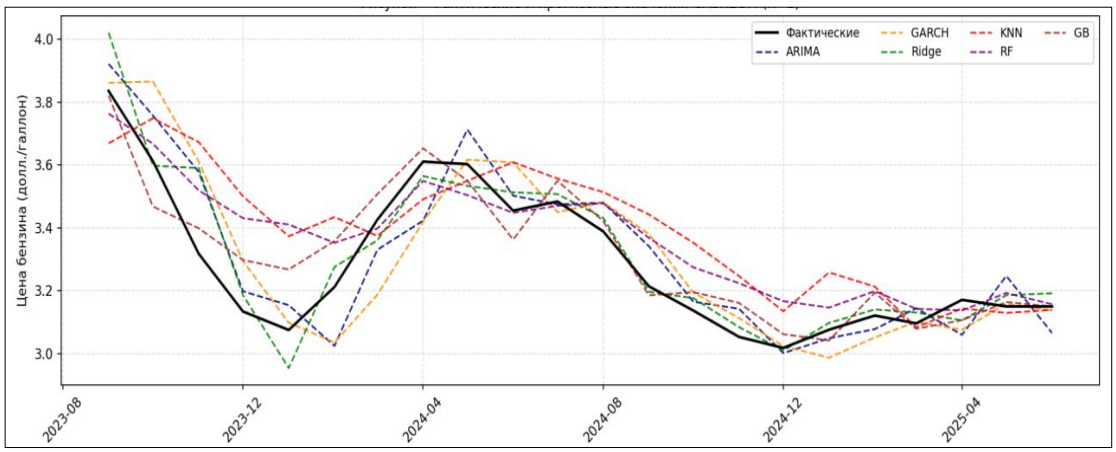



Рисунок 3.3 – Фактические и прогнозные значения GASREGM (h = 1)

На горизонте h = 1 месяц (рисунок 3.3) все модели в целом успешно воспроизводят общую траекторию цен за период с августа 2023 по июнь 2025 года. Нисходящий тренд от 4 до 3,0 долл./галлон, локальный подъём в апреле–мае 2024 года и последующая стабилизация вблизи 3,1–3,2 долл./галлон корректно отражаются большинством моделей. Ridge Regression и Gradient Boosting наиболее плотно следуют за фактической линией на протяжении всего периода. ARIMA и Random Forest также демонстрируют хорошее качество подгонки, хотя на отдельных участках несколько запаздывают при разворотах. KNN и GARCH заметно хуже справляются с воспроизведением локальных минимумов − в частности, в декабре 2023 года оба метода существенно завышают прогноз относительно фактического уровня около 3,1 долл./галлон.

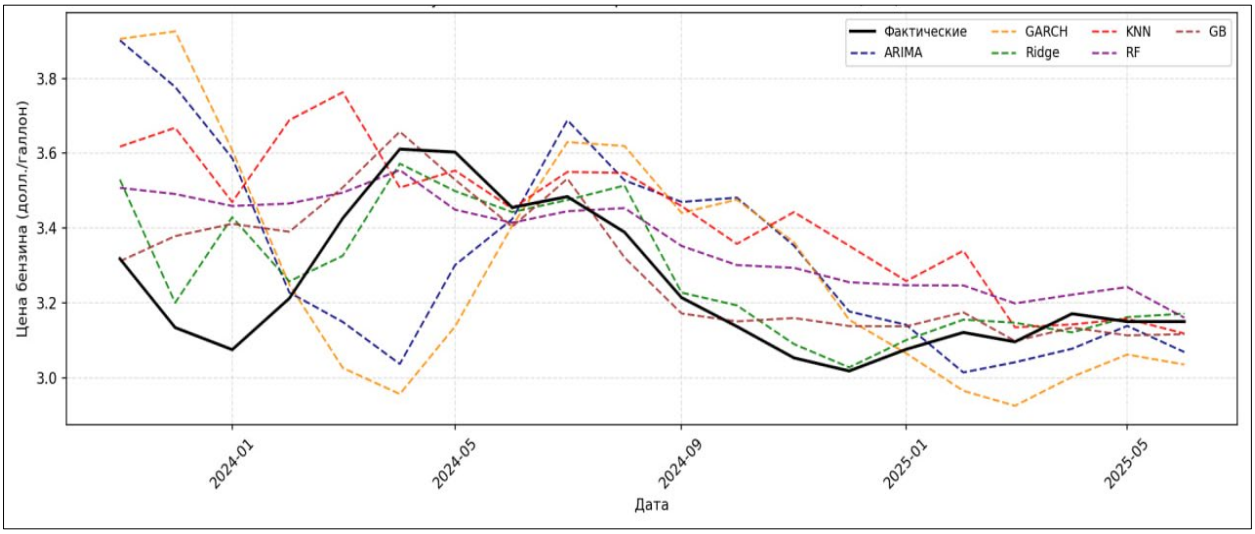



Рисунок 3.4 – Фактические и прогнозные значения GASREGM (h = 3)

На горизонте h = 3 месяца (рисунок 3.4) расхождения между моделями и фактом нарастают, однако Ridge Regression и Gradient Boosting сохраняют наименьшее отклонение. Примечательно, что на участке снижения цен в конце 2023 − начале 2024 года именно эти две модели наиболее точно воспроизводят как направление, так и амплитуду движения. GARCH на данном горизонте демонстрирует хаотичное поведение: его прогнозная линия в отдельные периоды опускается до 2,9–3,0 долл./галлон, а в начале периода завышает цену до 3,9–4,0 долл./галлон. KNN систематически завышает прогноз относительно факта, особенно на участке снижения во второй половине 2024 года. ARIMA корректно улавливает общую тенденцию, но на коротких разворотах отстаёт от факта на один-два месяца.

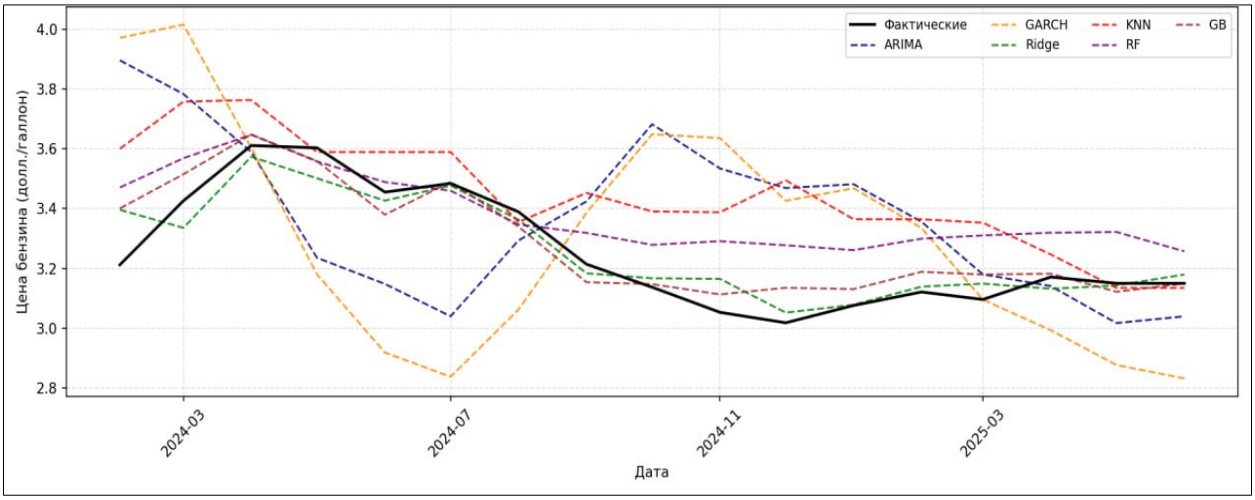



Рисунок 3.5 – Фактические и прогнозные значения GASREGM (h = 6)

На горизонте h = 6 месяцев (рисунок 3.5) все модели демонстрируют систематическое завышение прогнозируемого уровня цен относительно факта, что является объективным ограничением статистических методов: устойчивое снижение цен на нефтепродукты в 2024–2025 годах не имело близких аналогов в обучающей выборке. Ridge Regression и Gradient Boosting при этом остаются ближайшими к фактической линии − их прогнозы концентрируются в диапазоне 3,1–3,6 долл./галлон при фактических значениях 3,0–3,6 долл./галлон. ARIMA на данном горизонте демонстрирует значительный выброс вверх в ноябре 2024 года до 3,65 долл./галлон при фактическом уровне около 3,0 долл./галлон, а в конце периода уходит вниз до 3,05 долл./галлон. KNN и Random Forest формируют завышенный, но относительно стабильный прогноз в диапазоне 3,3–3,5 долл./галлон. GARCH снова выделяется экстремальными отклонениями: его линия опускается до 2,8 долл./галлон в середине периода и поднимается до 4,0 долл./галлон в начале, что делает её визуально нерепрезентативной на данном горизонте.

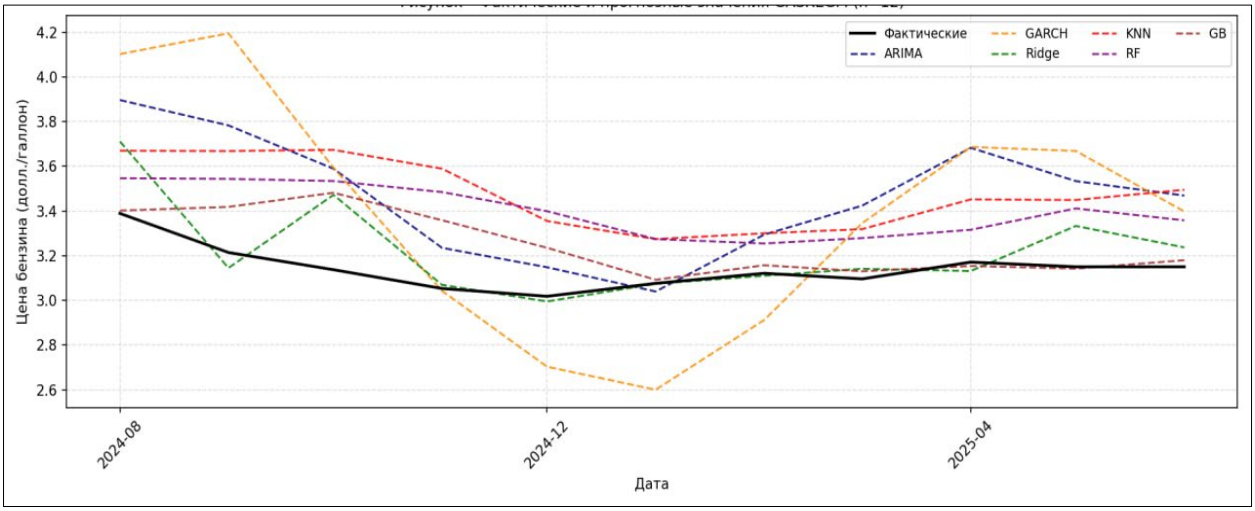



Рисунок 3.6 – Фактические и прогнозные значения GASREGM (h = 12)

На горизонте h = 12 месяцев (рисунок 3.6) разрыв между GARCH и остальными моделями достигает максимума. Прогнозная линия GARCH колеблется в диапазоне 2,6–4,2 долл./галлон при фактических значениях 3,0–3,4 долл./галлон, что наглядно иллюстрирует принципиальную непригодность этой модели для долгосрочного точечного прогнозирования уровней цен. Остальные пять моделей формируют значительно более компактный пучок прогнозных линий. Ridge Regression и Gradient Boosting остаются ближайшими к факту, хотя и они систематически завышают прогноз на 0,1–0,3 долл./галлон в большинстве точек тестового периода. Random Forest и KNN держатся несколько выше фактической линии, тогда как ARIMA в начале периода завышает прогноз до 3,9 долл./галлон, после чего постепенно сближается с фактом к середине 2025 года. В целом на годовом горизонте ни одна из моделей не способна предвидеть устойчивое снижение цен − это фундаментальное ограничение прогнозирования в условиях структурных изменений на нефтяном рынке.

Обобщённая сравнительная картина точности всех шести моделей на всех пяти горизонтах прогнозирования представлена на рисунке 3.7 в виде тепловой карты MAPE.

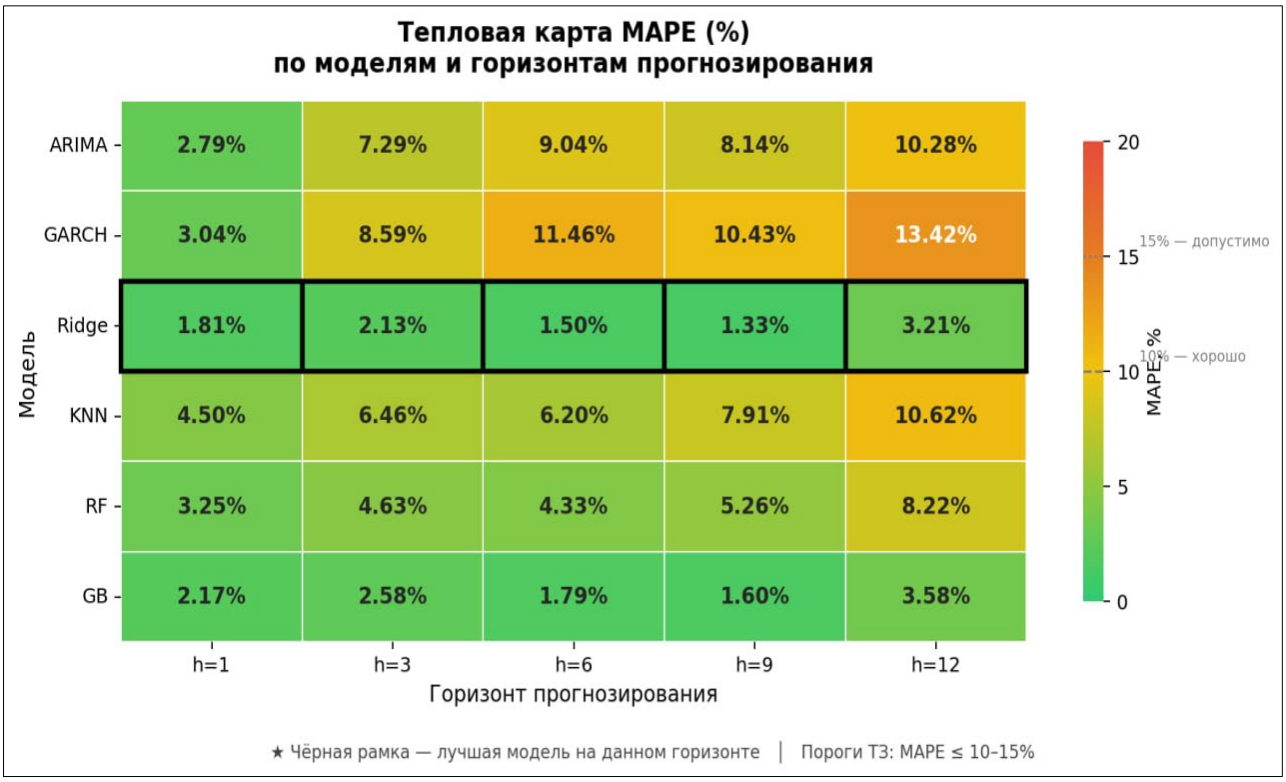



Рисунок 3.7 – Тепловая карта MAPE

Наиболее очевидный вывод из тепловой карты − абсолютное доминирование Ridge Regression и Gradient Boosting на протяжении всего диапазона горизонтов. Строки этих двух моделей окрашены исключительно в

холодные зелёные тона, причём значения MAPE не только не превышают 10%-го порога практической приемлемости, но и на большинстве горизонтов остаются ниже 4%. Примечательно нетипичное поведение обеих моделей: на горизонтах h = 6 и h = 9 их ошибка не возрастает, а снижается относительно h = 3: Ridge с 2,13% до 1,50% и 1,33%, Gradient Boosting с 2,58% до 1,79% и 1,60%. Это свидетельствует о том, что на среднесрочном горизонте признаковое пространство, сформированное в разделе 2.4, обеспечивает этим моделям дополнительное информационное преимущество перед чисто авторегрессионными методами.

ARIMA и GARCH образуют противоположный полюс. ARIMA начинает с вполне приемлемого результата 2,79% на h = 1, однако уже на h = 3 ошибка возрастает до 7,29%, а к h = 12 достигает 10,28% − на границе допустимого. GARCH демонстрирует ещё более выраженную деградацию: 3,04% на коротком горизонте против 13,42% на годовом, что визуально выделяется единственной красно-оранжевой ячейкой во всей тепловой карте. Ячейка GARCH при h = 12 является тепловым максимумом карты и наглядно подтверждает методологическую непригодность данной модели для долгосрочного точечного прогнозирования цен на нефтепродукты.

Random Forest занимает устойчивое промежуточное положение. MAPE монотонно возрастает от 3,25% на h = 1 до 8,22% на h = 12, не пересекая при этом критического порога 10%. Все ячейки строки RF окрашены в жёлто-зелёные тона, что отражает стабильное, хотя и не лидирующее качество прогнозов на всех горизонтах.

KNN − единственная модель машинного обучения, чья ошибка на h = 12 превышает 10%: значение 10,62% выводит её в зону допустимого, но не хорошего качества. При этом на коротком горизонте KNN уступает всем остальным ML-методам (4,50% против 1,81% у Ridge), что делает данный алгоритм наименее универсальным в рассматриваемом наборе.

Таким образом Ridge Regression является лучшей моделью на всех пяти горизонтах прогнозирования − именно её строка выделена чёрной рамкой на тепловой карте. Gradient Boosting вплотную следует за лидером и на горизонтах h = 6, h = 9 и h = 12 практически не уступает ему по точности. Совокупность этих двух моделей формирует надёжный прогностический инструментарий для задач как оперативного, так и стратегического планирования на рынке нефтепродуктов. Эконометрические модели ARIMA и особенно GARCH конкурентоспособны лишь на горизонте h = 1 месяц, тогда как на средне- и долгосрочных горизонтах их точность существенно уступает алгоритмам машинного обучения.

В третьей главе реализован комплексный сравнительный анализ шести прогностических моделей двух классов − эконометрических (ARIMA, GARCH) и машинного обучения (Ridge Regression, KNN, Random Forest, Gradient Boosting) − применительно к задаче прогнозирования розничных цен на бензин в США на горизонтах от одного до двенадцати месяцев.

Процедура оценки построена на принципах методологической строгости: для каждой модели реализован индивидуальный подбор гиперпараметров с использованием временной кросс-валидации TimeSeriesSplit, исключающей утечку данных из будущего, а финальное сравнение проведено в едином режиме walk-forward cross-validation по трём взаимодополняющим метрикам − RMSE, MAE и MAPE.

Главным результатом сравнительного анализа является выраженное и устойчивое превосходство алгоритмов машинного обучения над эконометрическими методами на всех горизонтах прогнозирования, за исключением совсем коротких (h = 1 месяц), где разрыв между классами моделей минимален. Это превосходство объясняется способностью ML-методов эффективно использовать расширенное признаковое пространство из 13 переменных, включающее лаги целевой переменной, скользящие статистики, текущие и лаговые значения факторов, а также сезонную переменную.

Безусловным лидером по совокупности горизонтов и метрик является Ridge Regression. Gradient Boosting занимает вторую позицию, вплотную следуя за лидером на всех горизонтах. Random Forest демонстрирует стабильное промежуточное качество с монотонным, но умеренным ростом ошибки по мере увеличения горизонта. KNN уступает остальным ML-методам как на коротких, так и на длинных горизонтах. Среди эконометрических моделей ARIMA(1,1,1) сохраняет практическую ценность на горизонте h = 1 месяц. GARCH оказался наименее пригодным инструментом для точечного прогнозирования уровней цен: его методологическая ориентация на моделирование условной волатильности, а не условного среднего ряда, приводит к систематическому накоплению смещения при восстановлении ценовых уровней из первых разностей.

Визуальный анализ прогнозных траекторий подтвердил количественные выводы: Ridge Regression и Gradient Boosting наиболее плотно следуют за фактической динамикой цен на всех горизонтах, тогда как GARCH формирует нерепрезентативные прогнозные линии с экстремальными отклонениями уже начиная с h = 6 месяцев.

Таким образом, для практических задач прогнозирования цен на нефтепродукты рекомендуется следующая дифференцированная стратегия: на горизонтах до трёх месяцев − применение Ridge Regression как наиболее точной и вычислительно простой модели; на горизонтах от шести до двенадцати месяцев − совместное использование Ridge Regression и Gradient Boosting как взаимодополняющих методов с наименьшей накопленной ошибкой. GARCH целесообразно рассматривать исключительно как инструмент оценки ценовой волатильности, но не уровней цен.

# 4 АНАЛИЗ ВАЖНОСТИ ФАКТОРНЫХ ПРИЗНАКОВ

Интерпретация результатов моделирования не исчерпывается оценкой прогностической точности − не менее важным является понимание того, какие именно факторы определяют динамику цен на нефтепродукты и в какой мере каждый из них вносит вклад в предсказательную силу модели. Анализ важности признаков позволяет перейти от формальных метрик качества к содержательным экономическим выводам о механизмах ценообразования на топливном рынке.

Анализ проводится на основе трёх взаимодополняющих методов: внутренней меры важности Random Forest (среднее снижение примеси, MDI), внутренней меры важности Gradient Boosting (снижение функции потерь) и абсолютных значений стандартизованных коэффициентов Ridge Regression. Использование одновременно нелинейных и линейного подходов обеспечивает верификацию результатов: совпадение выводов, полученных принципиально различными методами, существенно повышает их достоверность.

На рисунке 4.1 представлена диаграмма важности признаков модели Random Forest, измеренной как среднее снижение примеси (MDI).

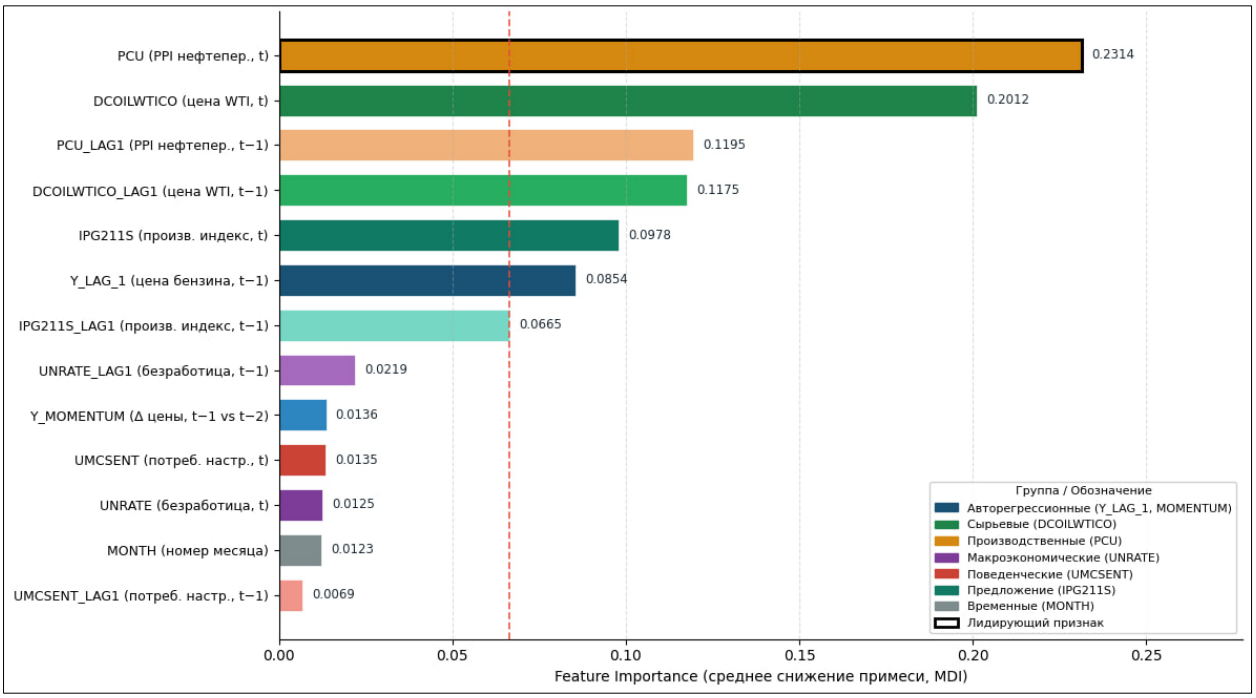



Рисунок 4.1 – Важность признаков Random Forest

Безусловным лидером является индекс цен производителей нефтепереработки PCU с показателем важности 0,2314, что соответствует почти четверти совокупной предсказательной силы модели. Второе место занимает цена нефти WTI DCOILWTICO (0,2012) − совместный вклад двух сырьевых и производственных переменных превышает 43%, что наглядно

демонстрирует доминирование ценовой цепочки «нефть − переработка» в формировании розничных цен на бензин. Лаговые значения этих же переменных PCU_LAG1 (0,1195) и DCOILWTICO_LAG1 (0,1175) занимают третью и четвёртую позиции, подтверждая наличие временного запаздывания в трансмиссии ценовых сигналов.

Производственный индекс нефтедобычи IPG211S (0,0978) занимает пятое место, а лаговое значение цены бензина Y_LAG_1 (0,0854) − шестое. Примечательно, что авторегрессионный признак уступает по важности сразу четырём внешним факторам, что свидетельствует о высокой информационной насыщенности сырьевого и производственного каналов. Нижнюю часть рейтинга занимают UNRATE_LAG1 (0,0219), Y_MOMENTUM (0,0136), UMCSENT (0,0135), UNRATE (0,0125), MONTH (0,0123) и UMCSENT_LAG1 (0,0069).

Таким образом, Random Forest идентифицирует производственно-сырьевой канал как главный источник предсказуемости розничных цен на нефтепродукты, тогда как макроэкономические и поведенческие факторы играют вспомогательную роль.

На рисунке 4.2 представлена диаграмма важности признаков модели Gradient Boosting, измеренной как снижение функции потерь.

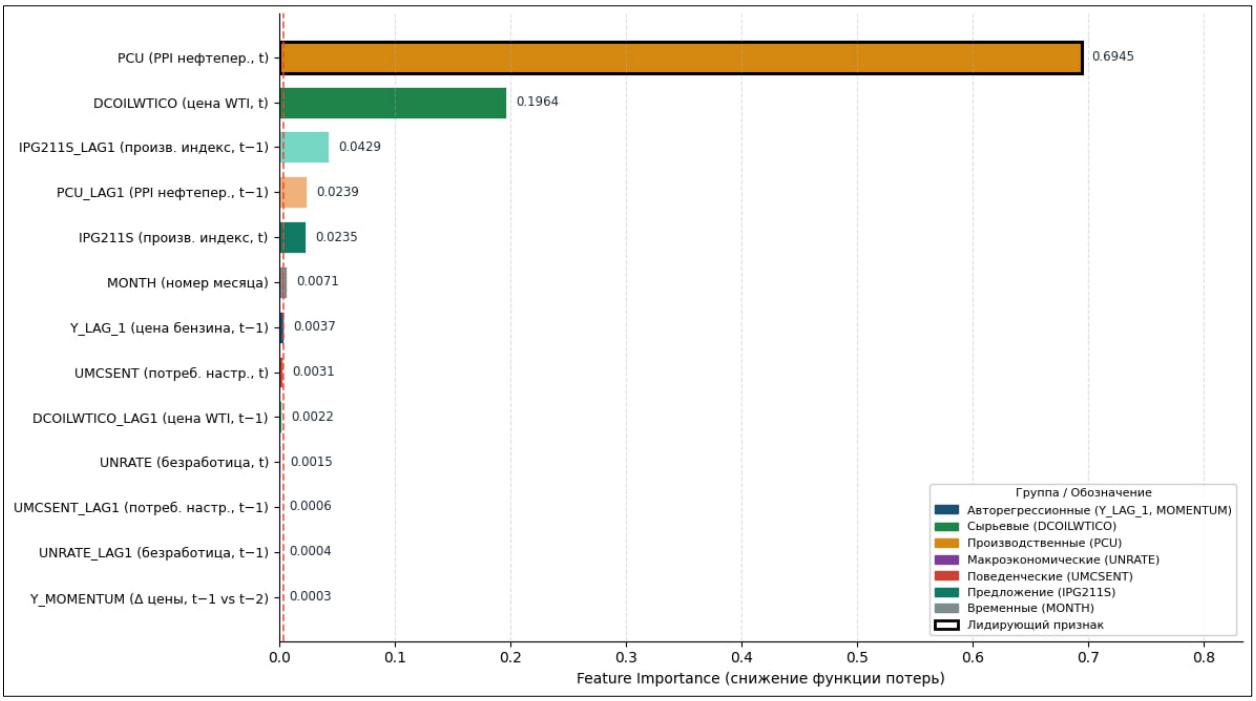



Рисунок 4.2 – Важность признаков Gradient Boosting

Картина, складывающаяся в Gradient Boosting, принципиально отличается от Random Forest степенью концентрации важности. PCU с показателем 0,6945 объясняет почти 70% совокупной предсказательной силы модели − столь высокое доминирование одного признака свидетельствует о том, что в процессе последовательного построения ансамбля алгоритм

практически полностью опирается на индекс цен производителей нефтепереработки как на основной сигнал для снижения ошибки. Цена нефти DCOILWTICO занимает второе место (0,1964), совокупно с PCU формируя почти 89% предсказательной силы.

Все остальные признаки имеют на порядок меньшую важность. IPG211S_LAG1 занимает третью позицию (0,0429), за ним следуют PCU_LAG1 (0,0239) и IPG211S (0,0235). Авторегрессионный признак Y_LAG_1 занимает лишь седьмое место (0,0037), а Y_MOMENTUM − последнее (0,0003). Поведенческие и макроэкономические факторы UMCSENT, UNRATE и их лаги также демонстрируют минимальные значения важности.

Таким образом алгоритм выстраивает крайне экономный прогностический механизм, концентрируя практически всю объясняющую силу в двух производственно-сырьевых признаках. Это объясняет его высокую точность при относительно простой структуре решений и подтверждает, что цены на нефтепродукты определяются в первую очередь стоимостью сырья и издержками переработки.

На рисунке 4.3 представлена диаграмма абсолютных значений стандартизованных коэффициентов Ridge Regression при оптимальном параметре регуляризации α = 0,0391.

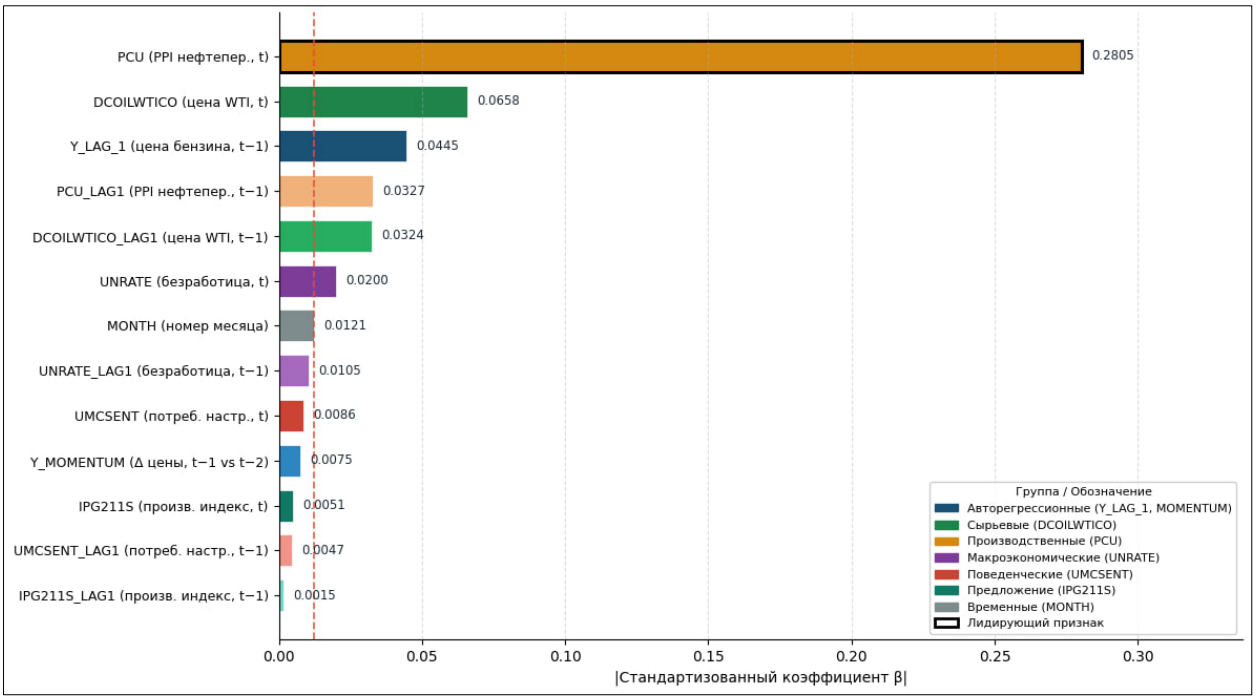



Рисунок 4.3 – Важность признаков Ridge Regression

Как и в ансамблевых моделях, лидером является PCU с коэффициентом 0,2805 − значение, почти вчетверо превышающее ближайший признак. Это означает, что при равном изменении всех стандартизованных переменных именно индекс цен производителей нефтепереработки оказывает наибольшее

линейное воздействие на прогнозируемую цену бензина. Второе место занимает DCOILWTICO (0,0658), третье − Y_LAG_1 (0,0445).

Здесь обнаруживается принципиальное отличие от ансамблевых методов: авторегрессионный признак Y_LAG_1 в Ridge Regression выходит на третью позицию, тогда как в Random Forest и Gradient Boosting он занимает значительно более скромное место. Это объясняется тем, что линейная модель в большей мере опирается на инерционность ценового ряда как на линейно улавливаемый сигнал. PCU_LAG1 (0,0327) и DCOILWTICO_LAG1 (0,0324) занимают четвёртое и пятое места с практически одинаковыми коэффициентами, что свидетельствует о равнозначной роли лагов обоих сырьевых переменных. UNRATE (0,0200) и MONTH (0,0121) занимают шестую и седьмую позиции, демонстрируя более заметный вклад, чем в ансамблевых моделях. Нижнюю часть рейтинга формируют UNRATE_LAG1, UMCSENT, Y_MOMENTUM, IPG211S, UMCSENT_LAG1 и IPG211S_LAG1 (0,0015).

Таким образом линейная модель подтверждает доминирование производственно-сырьевого канала, однако в отличие от ансамблевых методов в большей мере задействует авторегрессионный компонент и умеренно учитывает макроэкономические факторы − UNRATE и сезонную переменную MONTH.

На рисунке 4.4 представлена сравнительная диаграмма важности признаков по всем трём моделям в едином масштабе.

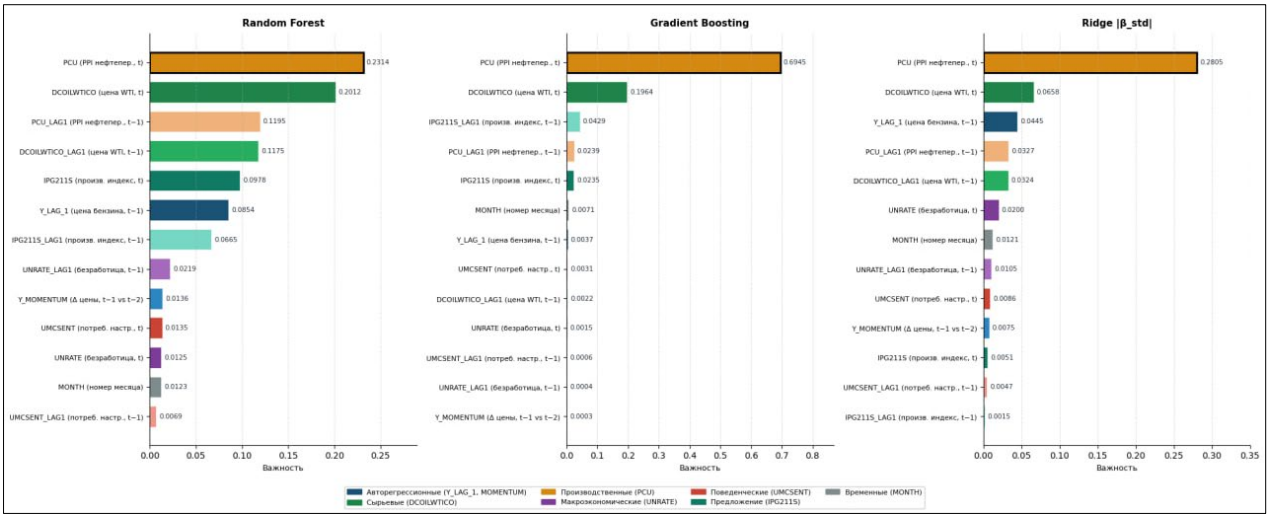



Рисунок 4.4 – Сравнение важности признаков по трем моделям

Сопоставление трёх моделей выявляет как устойчивые межмодельные закономерности, так и существенные расхождения. Единственным признаком, занимающим первое место во всех трёх моделях без исключения, является PCU − это наиболее надёжный и методологически независимый результат всего анализа. DCOILWTICO стабильно занимает вторую позицию в Random Forest и Gradient Boosting, тогда как в Ridge Regression уступает место

Y_LAG_1. Наиболее выраженное расхождение между моделями наблюдается в оценке важности авторегрессионного признака: Y_LAG_1 критически важен для Ridge Regression, умеренно значим для Random Forest и практически незначим для Gradient Boosting. Это отражает фундаментальное различие в механизмах работы линейных и последовательных ансамблевых моделей. Признаки нижней части рейтинга − Y_MOMENTUM, UMCSENT_LAG1, UNRATE_LAG1 − стабильно демонстрируют минимальную важность во всех трёх моделях, что придаёт этому выводу высокую степень достоверности.

На рисунке 4.5 представлен сводный рейтинг важности признаков, построенный как среднее арифметическое ранговых мест каждого признака в трёх моделях. Чем выше среднее ранговое место, тем более стабильно высокую позицию признак занимает в рейтингах всех трёх методов.

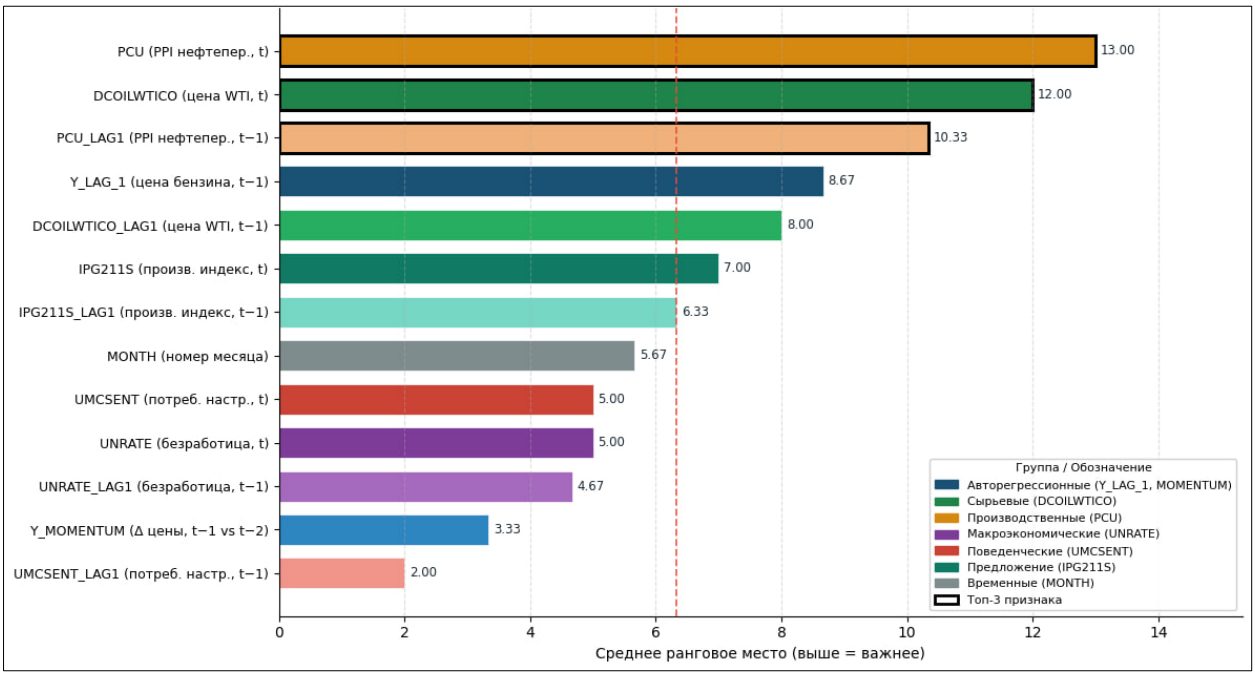



Рисунок 4.5 – Сводный рейтинг важности признаков

Тройку лидеров формируют PCU (13,00), DCOILWTICO (12,00) и PCU_LAG1 (10,33) − все три относятся к производственно-сырьевому каналу ценообразования. Четвёртое и пятое места занимают Y_LAG_1 (8,67) и DCOILWTICO_LAG1 (8,00), отражая роль инерционности ценового ряда и запаздывания нефтяных шоков. Признаки предложения IPG211S и IPG211S_LAG1 занимают шестое (7,00) и седьмое (6,33) места, формируя среднюю часть рейтинга. Переменная MONTH (5,67), UMCSENT (5,00) и UNRATE (5,00) располагаются в нижней половине, тогда как UNRATE_LAG1 (4,67), Y_MOMENTUM (3,33) и UMCSENT_LAG1 (2,00) замыкают рейтинг.

Таким образом в четвёртой главе проведён анализ важности факторных признаков с использованием трёх методологически независимых подходов: внутренней меры важности Random Forest (MDI), внутренней меры важности

Gradient Boosting и абсолютных значений стандартизованных коэффициентов Ridge Regression. Сопоставление результатов, полученных линейным и нелинейными методами, обеспечило верификацию выводов и позволило выделить устойчивые закономерности, не зависящие от специфики конкретного алгоритма.

Главным и наиболее надёжным результатом анализа является абсолютное доминирование производственно-сырьевого канала в формировании розничных цен на нефтепродукты. Индекс цен производителей нефтепереработки PCU занимает первое место во всех трёх моделях без исключения − единственный признак, демонстрирующий столь последовательное лидерство. Его показатели важности составляют 0,2314 в Random Forest, 0,6945 в Gradient Boosting и 0,2805 в Ridge Regression. Цена нефти WTI DCOILWTICO уверенно занимает вторую позицию в ансамблевых моделях. Совокупный вклад PCU и DCOILWTICO в Random Forest превышает 43%, а в Gradient Boosting − 89%, что наглядно свидетельствует о том, что ценообразование на розничном рынке топлива определяется прежде всего стоимостью сырья и издержками его переработки, а не макроэкономическими условиями спроса.

Лаговые значения сырьевых и производственных переменных − PCU_LAG1 и DCOILWTICO_LAG1 − стабильно занимают высокие позиции в сводном рейтинге, подтверждая наличие временного запаздывания в трансмиссии ценовых сигналов от нефтяного рынка к розничному потребителю. Это экономически обоснованный результат: изменения котировок нефти проходят через этапы переработки, транспортировки и дистрибуции, прежде чем отражаются в ценах на АЗС.

Авторегрессионный признак Y_LAG_1 занимает четвёртое место в сводном рейтинге, однако его роль существенно варьируется в зависимости от модели. В Ridge Regression он является третьим по важности предиктором, тогда как в Gradient Boosting его вклад минимален. Это расхождение объясняется различием в механизмах работы моделей: линейная модель активнее опирается на инерционность ценового ряда, тогда как ансамблевые методы при наличии высокоинформативного PCU практически не нуждаются в авторегрессионном компоненте. Признак направления ценового движения Y_MOMENTUM стабильно занимает одно из последних мест во всех трёх моделях, свидетельствуя о том, что краткосрочное направление изменения цены не несёт самостоятельной предсказательной ценности при наличии абсолютного уровня цены в пространстве признаков.

Производственный индекс нефтедобычи IPG211S занимает среднюю часть сводного рейтинга, демонстрируя заметную важность в ансамблевых моделях и минимальную − в Ridge Regression. Это указывает на нелинейный характер влияния объёмов добычи на розничные цены, который линейная модель не способна улавливать в полной мере.

Макроэкономические и поведенческие факторы − уровень безработицы UNRATE и индекс потребительских настроений UMCSENT − стабильно

располагаются в нижней части рейтинга всех трёх моделей. Их минимальный вклад не противоречит экономической теории, а лишь указывает на то, что в краткосрочной перспективе эти каналы воздействуют на цены топлива косвенно и с существенным запаздыванием, уступая по непосредственной значимости сырьевому и производственному каналам. Аналогичный вывод справедлив и для переменной MONTH: несмотря на доказанную в разделе 2.3.3 сезонность ценового ряда, её самостоятельный вклад в прогностическую силу моделей невелик.

Таким образом, результаты анализа важности признаков формируют следующую иерархию детерминантов розничных цен на нефтепродукты. На первом уровне располагается производственно-сырьевой канал − PCU и DCOILWTICO с их лаговыми значениями − как доминирующий и методологически устойчивый источник предсказуемости. На втором уровне находится инерционность самого ценового ряда, учитываемая через Y_LAG_1. На третьем − факторы предложения, представленные производственным индексом нефтедобычи IPG211S. Макроэкономические и поведенческие переменные замыкают иерархию, играя вспомогательную роль.

С практической точки зрения полученные результаты означают, что для оперативного мониторинга и прогнозирования розничных цен на бензин ключевыми опережающими индикаторами являются индекс цен производителей нефтепереработки и котировки нефти WTI. Именно эти показатели следует отслеживать в первую очередь нефтяным компаниям, розничным операторам АЗС и государственным регуляторам энергетического рынка при формировании ценовой политики и оценке инфляционных рисков.

# ЗАКЛЮЧЕНИЕ

Целью курсовой работы являлось построение и сравнительный анализ эконометрических моделей и алгоритмов машинного обучения, описывающих динамику розничных цен на нефтепродукты в США, а также интерпретация полученных результатов с точки зрения значимости факторных признаков.

В результате выполнения курсовой работы были решены поставленные задачи. В первом разделе был проведён подробный обзор теоретических подходов к моделированию и прогнозированию цен на нефтепродукты. Рассмотрены фундаментальные концепции ценообразования на энергетических рынках, классические модели временных рядов, модели волатильности ARCH/GARCH, а также современные алгоритмы машинного обучения. Установлено, что ценообразование на рынке нефтепродуктов является сложным многофакторным процессом, определяемым совокупным воздействием сырьевых, производственных, макроэкономических и поведенческих факторов. На основании анализа литературы определён набор переменных, потенциально влияющих на розничные цены на бензин, и сформирован теоретический базис для построения прогностических моделей.

Во втором разделе выполнена идентификация целевого и факторных признаков: цены нефти WTI, индекса цен производителей нефтепереработки, производственного индекса нефтедобычи, уровня безработицы и индекса потребительских настроений. Проведён анализ динамики временных рядов, выявление и устранение выбросов методом винсоризинга, проверка стационарности методом ADF, исследование трендовых и сезонных компонент, а также тест Энгла–Грейнджера на коинтеграцию. На этапе извлечения признаков первоначально сформировано пространство из 17 переменных, включающее лаговые значения целевой переменной, скользящие статистики, текущие и лаговые значения факторов, а также переменную сезонности MONTH. По результатам walk-forward валидации итоговое пространство признаков сокращено до 13 переменных за счёт исключения лагов второго и третьего порядков и скользящих статистик, ухудшавших качество прогнозов вследствие мультиколлинеарности.

В третьем разделе проведена оценка шести моделей двух классов – эконометрических (ARIMA и GARCH) и алгоритмов машинного обучения (Ridge Regression, K-Nearest Neighbors, Random Forest и Gradient Boosting). Оценка качества осуществлялась на пяти горизонтах прогнозирования $h \in \{1, 3, 6, 9, 12\}$ месяцев посредством walk-forward cross-validation по метрикам RMSE, MAE и MAPE. Результаты показали, что алгоритмы машинного обучения в целом превосходят эконометрические методы, причём разрыв между классами нарастает по мере увеличения горизонта прогнозирования. Ridge Regression лидирует по точности на всех пяти горизонтах с MAPE от 1,81% до 3,21%, Gradient Boosting вплотную следует за лидером. Random Forest демонстрирует стабильное промежуточное качество. GARCH показал наихудшие результаты на средних и длинных горизонтах с MAPE 13,42% на

h = 12, что соответствует его методологическому назначению – моделированию волатильности, а не условного среднего ряда.

В четвёртом разделе проведена интерпретация результатов моделирования на основе внутренних оценок важности Random Forest и Gradient Boosting, а также стандартизованных коэффициентов Ridge Regression. Установлено, что доминирующим источником предсказуемости розничных цен на нефтепродукты является производственно-сырьевой канал. Индекс цен производителей нефтепереработки PCU стабильно занимает первое место в рейтинге важности всех трёх моделей, цена нефти WTI DCOILWTICO – второе. Совокупный вклад этих двух признаков в предсказательную силу Gradient Boosting превышает 89%. Авторегрессионный признак Y_LAG_1 занимает четвёртое место в сводном рейтинге, демонстрируя большую значимость в Ridge Regression, чем в ансамблевых методах. Макроэкономические и поведенческие факторы – UNRATE и UMCSENT – стабильно располагаются в нижней части рейтинга, подтверждая их вспомогательную роль в краткосрочном прогнозировании цен на топливо.

Таким образом, цели и задачи исследования выполнены в полном объёме. Проведённый комплексный анализ показал, что ни один из рассматриваемых классов моделей не обеспечивает безусловного превосходства на всём диапазоне горизонтов прогнозирования – выбор оптимального метода определяется конкретной прогностической задачей. На коротких и средних горизонтах (h = 1–9 месяцев) наиболее точным и эффективным инструментом является Ridge Regression, на годовом горизонте (h = 12 месяцев) предпочтителен Gradient Boosting. GARCH целесообразно применять исключительно для оценки ценовой волатильности, но не для точечного прогнозирования уровней цен. Наиболее рациональной стратегией в практических задачах является дифференцированное применение моделей в зависимости от горизонта прогнозирования: Ridge Regression и Gradient Boosting для прогнозирования ценовых уровней в сочетании с GARCH для оценки неопределённости прогноза.

Полученные результаты представляют практическую ценность для нефтяных компаний, розничных операторов АЗС, государственных регуляторов энергетического рынка, транспортных предприятий и аналитических центров при формировании ценовой политики, оценке инфляционных рисков и построении систем поддержки принятия решений в условиях нестабильности глобальных сырьевых рынков.

## СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ


[1] Fred Reserve Economic Data [Электронный ресурс]. – Режим доступа : https://fred.stlouisfed.org/.

[2] История нефтяной промышленности США [Электронный ресурс]. – Режим доступа : https://tass.ru/ekonomika/14248561.

[3] Что такое ОПЕК: участники, история, цели и задачи [Электронный ресурс]. – Режим доступа : https://tj.ru/guide/opec/?utm_referrer=https%3A%2F%2Fyandex.by%2F.

[4] Брагинский, О. Б. Нефтегазовый комплекс мира / О. Б. Брагинский / М. : Изд-во «Нефть и газ» РГУ нефти и газа им. И.М. Губкина, 2006. – с. 7-13.

[5] Нефть и деньги [Электронный ресурс]. – Режим доступа : https://sber.pro/publication/neft-i-dengi/.

[6] The World's 10 Biggest Oil Exporters [Электронный ресурс]. – Режим доступа: https://www.investopedia.com/articles/company-insights/082316/worlds-top-10-oil-exporters.asp.

[7] Попова, И. М. Роль геополитических факторов в формировании мирового нефтяного рынка. Анализ и систематизация литературы / И. М. Попова / Вестник международных организаций. Т. 15. № 3. – с. 282–306

[8] Oil Refineries: How They Work and Their Key Functions [Электронный ресурс]. – Режим доступа : https://www.investopedia.com/terms/o/oil-refinery.asp.

[9] Баликоев, В. З. Ценообразование на мировых рынках / В. З. Баликоев /. – Москва : «Издательство ПРИОР», 2006. – 503 с.

[10] Биржевая торговля энергоресурсами: истоки и развитие : монография / авторский коллектив; под ред. Н.А. Иванова. – М.: РГУ нефти и газа (НИУ) имени И.М. Губкина, 2022. – 367 с.

[11] Плакиткин, Ю. А. Мировая экономика: снижение цен на нефть возможно / Ю. А. Плакиткин / Нефтегазовая Вертикаль. 2012. № 21. – с. 64-69.

[12] Эволюция системы ценообразования на мировом энергетическом рынке: экономические последствия для России / под ред. О. И. Маликовой, Е. С. Орловой. – М : Экономический факультет МГУ имени М. В. Ломоносова, 2017. – 432 с.

[13] Iledare O.O. Global Petroleum Supply & Pricing: Economic Characterization of Key Players. Presentation at the 31st IAEE Annual Conference, Istanbul, Turkey, June 16-20, 2008.

[14] Пиндайк, Р. С. Микроэкономика / Р. С. Пиндайк, Д. Л. Рубинфельд. – М. : Питер, 2018. – 608 с.

[15] Kilian, L. Not All Oil Price Shocks Are Alike: Disentangling Demand and Supply Shocks in the Crude Oil Market / L. Kilian // American Economic Review. – 2009. – Vol. 99, No. 3. – P. 1053–1069.

[16] Working, H. The Theory of Price of Storage / H. Working // American Economic Review. – 1949. – Vol. 39, No. 6. – P. 1254–1262.

[17] Геман, Х. Товарные рынки и производные финансовые инструменты / Х. Геман. – М. : Альпина Паблишер, 2016.

[18] Гамильтон, Дж. Нефть и макроэкономика после Второй мировой войны / Дж. Гамильтон // Journal of Political Economy. – [б. г.].

[19] Организация стран-экспортёров нефти (ОПЕК). Годовой статистический бюллетень. – Вена : ОПЕК, 2023.

[20] Smith, J. L. World Oil: Market or Mayhem? / J. L. Smith // Journal of Economic Perspectives. – 2009. – Vol. 23, No. 3. – P. 145–164.

[21] Fattouh, B. OPEC: What Difference Has It Made? / B. Fattouh, L. Mahadeva // Annual Review of Resource Economics. – 2013. – Vol. 5. – P. 427–443.

[22] Adelman, M. A. The Economics of Petroleum Supply: Papers by Morris Adelman / M. A. Adelman. – Cambridge : MIT Press, 1993. – 520 p.

[23] Tang, K. Index Investment and Financialization of Commodities / K. Tang, W. Xiong // Financial Analysts Journal. – 2012. – Vol. 68, No. 6. – P. 54–74.

[24] Бокс, Дж. Анализ временных рядов: прогнозирование и управление / Дж. Бокс, Г. Дженкинс, Г. Райнсел. – М. : Мир, 2010. – 784 с.

[25] Гамильтон, Дж. Анализ временных рядов / Дж. Гамильтон. – М. : Дело, 2008. – 720 с.

[26] Lütkepohl, H. New Introduction to Multiple Time Series Analysis / H. Lütkepohl. – Berlin : Springer, 2005. – 764 p.

[27] Johansen, S. Estimation and hypothesis testing of cointegration vectors in Gaussian vector autoregressive models / S. Johansen // Econometrica. – 1991. – Vol. 59, No. 6. – P. 1551–1580.

[28] Engle, R. F. Autoregressive conditional heteroscedasticity / R. F. Engle // Econometrica. – 1982. – Vol. 50, No. 4. – P. 987–1007.

[29] Bollerslev, T. Generalized autoregressive conditional heteroskedasticity / T. Bollerslev // Journal of Econometrics. – 1986. – Vol. 31, No. 3. – P. 307–327.

[30] Sadorsky, P. Oil price shocks and stock market activity / P. Sadorsky // Energy Economics. – 1999. – Vol. 21, No. 5. – P. 449–469.

[31] Breiman, L. Random Forests / L. Breiman // Machine Learning. – 2001. – Vol. 45, No. 1. – P. 5–32.

[32] Hoerl, A. E. Ridge Regression: Biased Estimation for Nonorthogonal Problems / A. E. Hoerl, R. W. Kennard // Technometrics. – 1970. – Vol. 12, No. 1. – P. 55–67.

[33] Zhao, Y. A deep learning ensemble approach for crude oil price forecasting / Y. Zhao, J. Li, L. Yu // Energy Economics. – 2017. – Vol. 66. – P. 9–16.

[34] Хацкевич, Г. А. Эконометрика: учебник для студентов учреждений высшего образования по специальностям «Управление информационными ресурсами», «Информационные системы и технологии (в экономике)» / Г. А. Хацкевич, Т. В. Русилко. – Минск: РИВШ, 2021. – 450 с.

**ПРИЛОЖЕНИЕ А**
**(обязательное)**
**Проверка на антиплагиат**

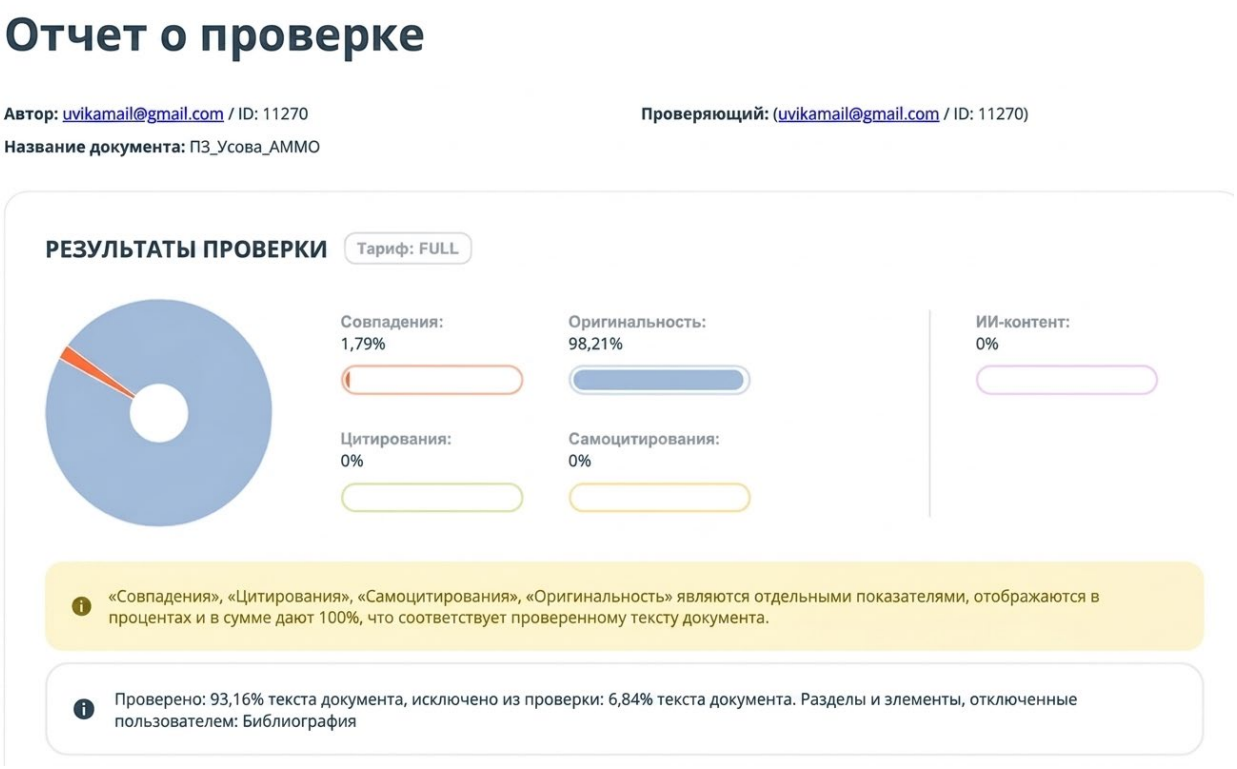



Рисунок А.1 – Проверка на Антиплагиат