УДК 004.912:004.85:378.4

АНАЛИЗ И РАНЖИРОВАНИЕ САЙТОВ БЕЛОРУССКИХ УНИВЕРСИТЕТОВ НА ОСНОВЕ МЕР ТЕКСТОВОГО СХОДСТВА И МЕТОДОВ КЛАСТЕРИЗАЦИИ

ФЕДОСЕНКО Владимир Алексеевич, кандидат технических наук, доцент кафедры «Экономическая информатика»
Белорусский государственный университет информатики и радиоэлектроники
220013, Беларусь, Минск, fedosenko@bsuir.by

УСОВА Виктория Александровна, студент
Белорусский государственный университет информатики и радиоэлектроники
220013, Беларусь, Минск, uvikamail@gmail.com

Аннотация: В работе выполнен автоматический анализ и ранжирование сайтов белорусских университетов методами машинного обучения. По данным, собранным парсингом HTML главных страниц, вычислены матрицы сходства по коэффициентам Сёренсена-Дайса и косинусному расстоянию TF-IDF. Проведена кластеризация методами K-Means и Варда, выполнен семантический анализ на основе нейросетевых эмбеддингов. По результатам взвешенной оценки структурных признаков построен финальный рейтинг исследуемых веб-ресурсов.

Ключевые слова: кластеризация, коэффициент Сёренсена-Дайса, TF-IDF, K-Means, иерархическая кластеризация, метод главных компонент, нейросетевые эмбеддиинги.

ANALYSIS AND RANKING OF WEBSITES OF BELARUSIAN UNIVERSITIES BASED ON MEASURES OF TEXTUAL SIMILARITY AND CLUSTERING METHODS

FEDOSENKO Vladimir Alekseevich, Candidate of Technical Sciences, Associate Professor of the Department of Economic Informatics
Belarusian State University of Informatics and Radioelectronics
220013, Belarus, Minsk, fedosenko@bsuir.by

USOVA Viktoryia Alexandrovna, student
Belarusian State University of Informatics and Radioelectronics
220013, Belarus, Minsk, uvikamail@gmail.com

Abstract. The paper performs automatic analysis and ranking of the websites of Belarusian universities using machine learning methods. Based on the data collected by parsing the HTML of the main pages, similarity matrices were calculated using the Sorensen-Dice coefficients and the TF-IDF cosine distance. Clustering using K-Means and Ward methods was performed, semantic analysis based on neural network embeddings was performed. Based on the results of a weighted assessment of structural features, the final rating of the studied web resources was built.

Keywords: clustering, Sorensen-Dice coefficient, TF-IDF, K-Means, hierarchical clustering, principal component method, neural network embeddings.

ВВЕДЕНИЕ

Официальный сайт университета – основной инструмент взаимодействия с абитуриентами, студентами, работодателями и партнерами. В условиях конкуренции за абитуриентов качество веб-ресурса становится частью стратегии учреждения.

Традиционная оценка сайтов проводится экспертами вручную, что делает ее субъективной и трудоемкой. Методы машинного обучения позволяют автоматизировать этот процесс. Алгоритмы позволяют выделить признаки веб-страниц, рассчитать, на сколько сайты похожи друг на друга, и объективно ранжировать их по набору критериев.

В данной работе рассматриваются сайты десяти университетов Беларуси: БГУИР, БГУ, БНТУ, БГМУ, БГТУ, ВГМУ, БРУ, ГрГУ, ПГУ и ГГУ. Они представляют технические, медицинские и гуманитарные направления подготовки.

Актуальность работы обусловлена развитием автоматического анализа веб-ресурсов в области обработки естественного языка и практическим интересом к объективной оценке цифрового присутствия белорусских университетов.

Цель работы – автоматический анализ и ранжирование сайтов белорусских университетов на основе мер текстового сходства и методов кластеризации.

РЕЗУЛЬТАТЫ

Сбор данных осуществлялся методом автоматического парсинга HTML-кода главных страниц. Данные сайта БГУ, реализованного на JavaScript, собраны вручную. Анализировались только статистические данные главной страницы. Внутренние разделы сайтов, характеристики скорости загрузки, адаптивность под мобильные устройства и элементы, реализованные на JavaScript, в исследование не включались.

Из всех доступных характеристик для анализа отобраны шесть признаков. Отобранными признаками стали количество ссылок на главной странице, количество пунктов главного меню, размер словаря уникальных слов, отношение размера словаря к числу картинок, синтетический признак качества навигации и охвата, наличие поиска по сайту.

Для устранения влияния масштаба применялась Min-Max нормировка, которая приводит каждый признак к диапазону [0,1]. Для вычисления текстовых мер сходства использовались следующие представления: множество слов word_set – для коэффициента Дайса, TF-IDF вектор со словарем до 5000 слов – для косинусного расстояния, нейросетевой эмбеддинг размерности 384 – для семантического анализа.

Коэффициент Сёренсена-Дайса (DSC) применяется для оценки сходства текстов и вычисляется через отношение удвоенного числа общих элементов к сумме мощностей множеств. Значение коэффициента изменяется от 0 до 1: чем

оно выше, тем больше сходство между объектами. Расстояние Дайса определяется как 1 – DSC. Результаты представлены на рисунке 1.

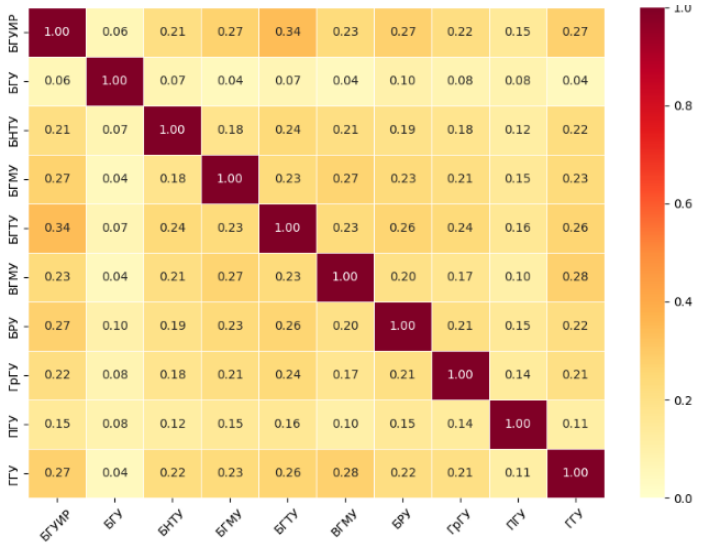


Рис. 1. *Матрица сходства Сёренсена-Дайса*

Тепловая карта показывает, что все значения вне диагонали находятся в диапазоне от 0,04 до 0,34, что свидетельствует о низком текстовом пересечении между сайтами. Наибольшее сходство словарей наблюдается между БГУИР и БГТУ (0,34) – оба являются техническими университетами со схожей тематикой контента.

Метод TF-IDF представляет каждый документ в виде числового вектора, сходство между документами, представленными TF-IDF векторами вычисляется через косинус угла.

В отличие от коэффициента Дайса, TF-IDF подавляет вес общеупотребительных слов и усиливает вес, что обуславливает более низкие значения сходства. Преимущество косинусного расстояния – инвариантность к длине документа. Матрица косинусного сходства на основе TF-IDF векторов представлена на рисунке 2.



Рис. 2. *Матрица косинусного сходства TF-IDF*

Наибольшее сходство вновь зафиксировано между БГУИР и БГТУ, подтверждая тематическую близость технических направлений.

Для группировки сайтов применялось два метода кластеризации. Первый, иерархическая кластеризация, она строит дерево вложенных кластеров – дендрограмму – не требуя предварительного задания их числа. Агломеративный подход с методом Варда, минимизирующим прирост суммарной внутрикластерной дисперсии при каждом объединении. Результаты представлены на рисунке 3.

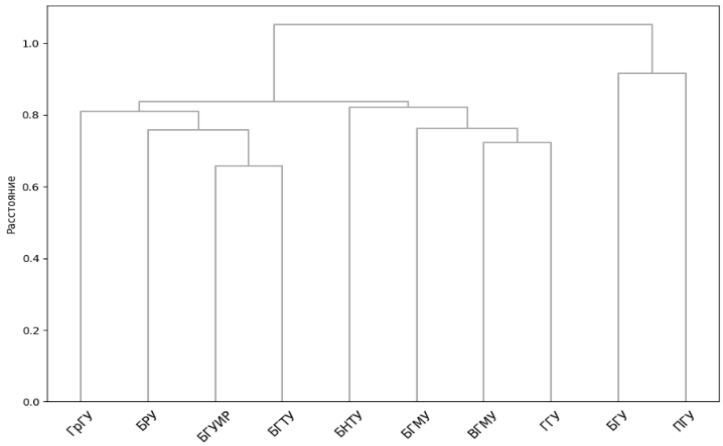


Рис. 3. *Дендрограмма иерархической кластеризации*

Дендрограмма позволяет наглядно проследить порядок объединения университетов в кластеры. На нижнем уровне расстояний (0,65 – 0,8) формируются три устойчивые группы.

Второй, K-Means, он итерационно минимизирует суммарную внутрикластерную дисперсию. Метод локтя применяется для выбора оптимального k: строится график зависимости инерции от числа кластеров, выбирается значение, после которого снижение инерции существенно замедляется. Результаты на рисунке 4.

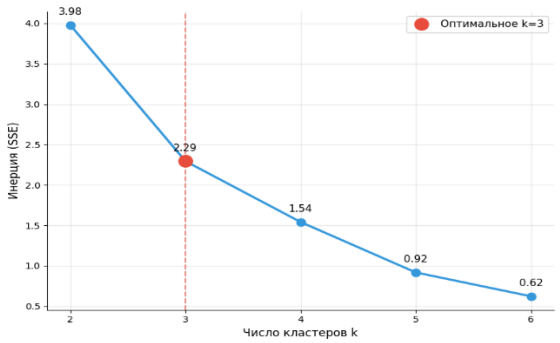


Рис. 4. *Метод локтя для выбора оптимального k*

Переход от k=2 к k=3 дает наибольший относительный выигрыш, и в качестве оптимального выбрано k=3. Результаты кластеризации K-Means (k=3) по структурным признакам представлены на рисунке 5.

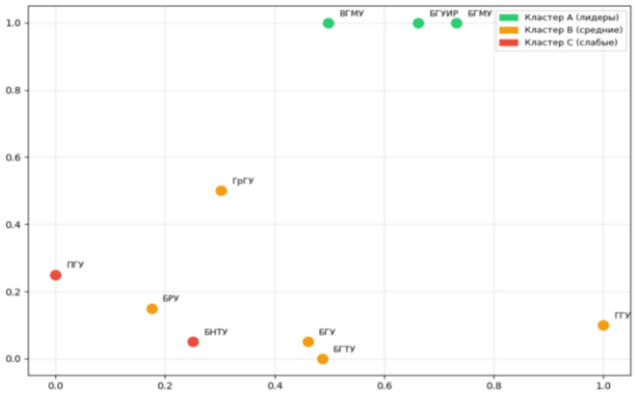


Рис. 5. *K-Means кластеризация по структурным признакам*

Метод главных компонент (PCA) применялся для проекции шестимерного признакового пространства в двумерное с целью визуализации взаимного расположения сайтов и кластеров. Результат проекции на две главные компоненты показан на рисунке 6.



Рис. 6. *PCA-проекция сайтов университетов в двумерное пространство*

Первая главная компонента объясняет 53,6% дисперсии и интерпретируется как общая насыщенность сайта. Вторая объясняет 19,5% дисперсии и отражает соотношение текстового и структурного наполнения. БГУИР, БГМУ, ВГМУ сгруппированы в правой нижней части пространства с высокими значениями PC1, подтверждая их лидерство.

Для детального сравнения профилей топ-5 университетов по всем шести признакам построена радарная диаграмма. Она представлена на рисунке 7.

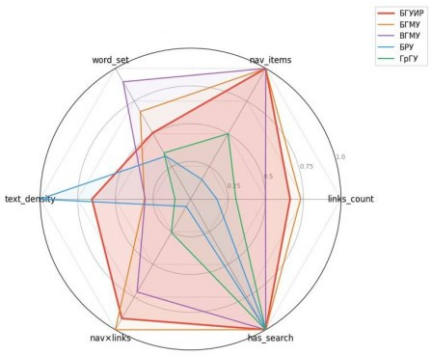


Рис. 7. *Радарная диаграмма профилей топ-5 университетских сайтов*

БГУИР показывает наиболее сбалансированный профиль, по площади фигуры превосходит остальные университеты.

Нейросетевые эмбеддинги, в отличие от словарных методов, сравнивают не слова, а смысл текстов. В работе использовалась модель paraphrase-multilingual-MiniLM-L12-v2 на базе архитектуры Trensformer, предобученная на корпусе из 50 языков, включая русский. Текст сайта преобразуется в вектор размерности 384, сходство вычисляется через косинусное расстояние между эмбеддингами. Результаты анализа представлены на рисунке 8.

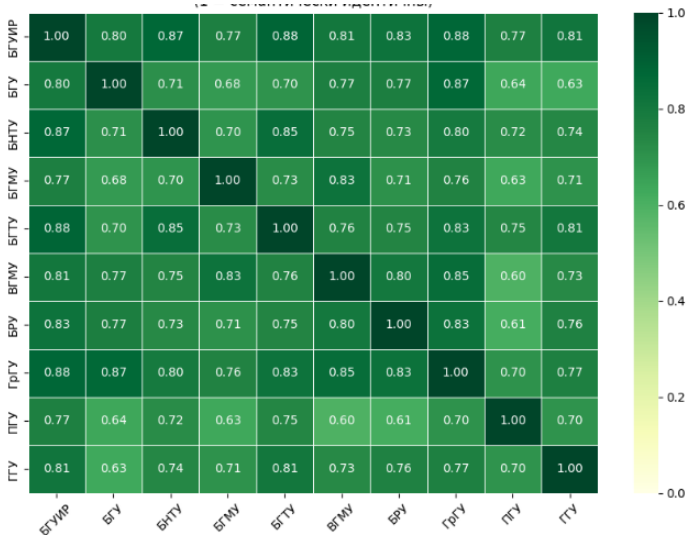


Рис. 8. *Матрица косинусного сходства нейросетевых эмбеддингов*

Матрица сходства показывает значения в диапазоне 0,6 – 0,88, это существенно выше, чем у TF-IDF, поскольку модель улавливает общую тематику всех сайтов. БГУИР демонстрирует наибольшее семантическое сходство с БНТУ (0,87), БГТУ (0,88) и ГрГУ (0,88), что соответствует тематической близости технических и многопрофильных университетов.

Иерархическая кластеризация на основе эмбеддингов дала результаты, отличные от кластеризации по словарным метрикам, рисунок 9.

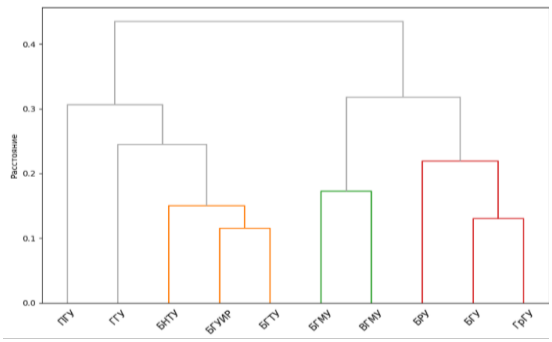


Рис. 9. *Дендрограмма иерархической кластеризации по нейросетевым эмбеддингам*

По графику видно, что БНТУ, БГУИР и БГТУ объединяются на низком уровне расстояния (0,12 – 0,15), образуя компактный кластер технических университетов.

ВЫВОДЫ

Финальный рейтинг сформировался на основе взвешенной суммы нормированных структурных характеристик сайта. Наибольший вес был присвоен количеству пунктов главного меню (0,4), наличию встроенного поиска и информативности текстового содержимого по 0,2, числу ссылок и показателю качества навигации и охвата контента по 0,1. Результаты представлены на рисунке 10.

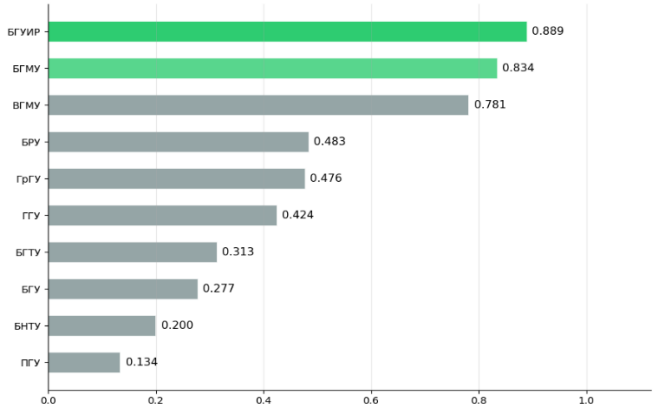


Рис. 10. *Рейтинг университетских сайтов*

По результатам комплексного анализа сайт БГУИР признан лучшим среди десяти исследованных университетских веб-ресурсов. Лидерство БГУИР подтверждается четырьмя независимыми методами: структурными признаками, обоими методами кластеризации, радарной диаграммой и нейросетевыми эмбеддингами.

Таким образом, методы машинного обучения позволяют автоматически и объективно ранжировать университетские сайты, устраняя субъективность экспертной оценки. Нейросетевые эмбеддинги являются перспективным дополнением к классическим метрикам, выявляя тематические группировки, недоступные словарным методам.

Список источников

1. Жилов Р. А. Интеллектуальные методы кластеризации данных // Молодой учёный. 2023. № 45. URL: https://cyberleninka.ru/article/n/intellektualnye-metody-klasterizatsii-dannyh (дата обращения: 14.05.2026).
2. Иванов И. П., Вишняков И. Э., Каркин И. А. Выявление и кластеризация шаблонных текстов в больших массивах сообщений // Труды СПИИРАН. 2022. № 3. URL: https://cyberleninka.ru/article/n/vyyavlenie-i-klasterizatsiya-shablonnyh-tekstov-v-bolshih-massivah-soobscheniy (дата обращения: 14.05.2026).
3. Reimers N., Gurevych I. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks // Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing. 2019. URL: https://arxiv.org/abs/1908.10084 (дата обращения: 14.05.2026).
4. Scikit-learn: Machine Learning in Python. Текст : электронный // Scikit-learn : офиц. сайт. 2024. URL: https://scikit-learn.org/stable/ (дата обращения: 14.05.2026).
5. Sentence Transformers Documentation. Текст : электронный // SBERT : офиц. сайт. 2024. URL: https://www.sbert.net (дата обращения: 14.05.2026).