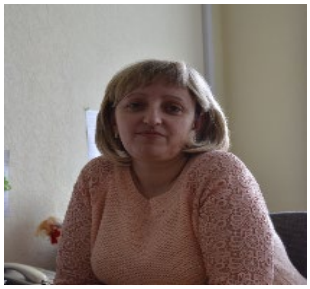
УДК 004.657:004.75-047.44

ЭФФЕКТИВНОЕ УПРАВЛЕНИЕ БОЛЬШИМИ ДАННЫМИ: СРАВНИТЕЛЬНЫЙ АНАЛИЗ ПЛАТФОРМ И ТЕХНОЛОГИЙ ДЛЯ ОБРАБОТКИ ИНФОРМАЦИИ



В.В. Верняховская
Заместитель декана инженерно-экономического факультета БГУИР, магистр экономических наук
verniahovskaya@bsuir.by



О.М. Раптунович
Старший преподаватель кафедры экономической информатики БГУИР, магистр
oraptunovich@gmail.com



В.А. Усова
Студентка инженерно-экономического факультета, специальности Информационные системы и технологии БГУИР
uvikamail@gmail.com

В.В. Верняховская
Окончила Белорусский государственный университет информатики и радиоэлектроники. Магистр экономических наук. Работает заместителем декана инженерно-экономического факультета БГУИР. Направления исследований: трансфер технологий, инновационная деятельность, информационные технологии в маркетинге.

О.М. Раптунович
Окончила Частый Институт Управления и Предпринимательства. Область научных интересов связана с актуальными вопросами экономики, логистики, маркетинга и информационных технологий и способами их решений.

В.А. Усова
Обучается в Белорусском государственном университете информатики и радиоэлектроники. на третьем курсе инженерно-экономического факультета. Область научных интересов связана с актуальными вопросами искусственного интеллекта, машинного обучения, экономики, информационных технологий, анализа данных и автоматизации процессов.

Аннотация. Статья посвящена эффективному управлению большими данными, с фокусом на сравнительный анализ платформ и технологий для обработки информации. Рассматриваются различные инструменты и подходы, применяемые для сбора, хранения и анализа данных. Оценены такие платформы, как Hadoop, Apache Spark, и другие, а также технологии машинного обучения, которые влияют на производительность и масштабируемость обработки данных.

Ключевые слова: большие данные, Hadoop, Apache Spark, машинное обучение, MapReduce, NoSQL базы данных, анализ данных, Kafka, Flink.

Введение. В последние десятилетия данные стали неотъемлемой частью различных сфер жизни и бизнеса. С развитием технологий и увеличением объемов информации, собранной из различных источников, возникла необходимость в системах, способных обрабатывать и анализировать огромные массивы данных. Так родилась концепция «больших данных» (Big Data), которая охватывает объемы информации, значительно превышающие возможности традиционных систем для их обработки и хранения. Большие данные характеризуются не только большими объемами, но и высокой скоростью поступления, разнообразием форматов и источников данных, а также изменчивостью. [1]

С ростом распространенности Интернета вещей, социальных сетей, мобильных устройств и цифровых платформ объем создаваемых данных продолжает увеличиваться с экспоненциальной скоростью. Только за последние несколько лет было создано около 90% всех мировых данных. Если рассматривать более продолжительный период, то с 2010 года общий объем информации в мире вырос более чем в 66 раз (рисунок 1). По прогнозам, общий объем данных, когда-либо созданных в мире, достиг 147 зеттабайт в 2024 году, что на 22,5% больше, чем в предыдущем году. В 2025 году этот показатель увеличился до 181 зеттабайта, а к 2026 году достиг 221 зеттабайта. [2]

Таким образом, только за один год объем произведенных данных во всем мире увеличился почти на 40 зеттабайт, что составляет рост примерно на 22,09% по сравнению с 2025 годом. Данная тенденция подтверждает устойчивое и высокое ежегодное увеличение объема данных, которое на протяжении последних лет не опускается ниже 22%. Это подчеркивает, что влияние больших данных на все сферы человеческой деятельности будет только возрастать, а эффективная обработка, хранение и анализ информации становятся стратегически важными задачами для бизнеса, науки и государственного управления.[3]



Рисунок 1. Статистика объёмов данных, создаваемых ежегодно

Однако работа с большими данными требует применения специализированных технологий и платформ, которые могут масштабироваться и эффективно работать с такими объемами информации. Это включает в себя как методы хранения данных, так и способы их обработки, включая распределенные вычисления и аналитические алгоритмы, которые способны извлекать полезную информацию из хаоса необработанных данных. Важно, чтобы такие платформы поддерживали возможности для работы с различными типами данных – от текстовых и числовых до видео, аудио и логов. Существуют различные платформы и технологии, каждая из которых имеет свои особенности и преимущества в зависимости от характера данных и целей обработки.

Целью данной работы является сравнительный анализ платформ и технологий для эффективного управления большими данными, выявив их ключевые характеристики, преимущества и недостатки для различных типов обработки информации.

Что такое большие данные? Большие данные (Big Data) – это термин, который описывает огромные объемы структурированных и неструктурированных данных, которые сложно обработать с помощью традиционных методов обработки данных и баз данных. Эти данные могут включать в себя текстовую, видео, аудио, графическую и другие формы информации, которые ежедневно генерируются в разных областях человеческой деятельности: от финансов и здравоохранения до социальных сетей и интернета вещей.

Одной из особенностей больших данных является их описание через так называемую модель «3V». Объем (Volume) – это прежде всего огромные массы данных, которые с каждым днем только увеличиваются. К примеру, данные, генерируемые пользователями в социальных сетях, транзакции онлайн-магазинов или измерения с сенсоров, могут достигать колоссальных размеров. Скорость (Velocity) – данные, поступающие с большой частотой, требуют мгновенной обработки и анализа. Примером служат потоки информации о поведении пользователей в реальном времени или данные с устройств Интернета вещей. Разнообразие (Variety) – данные поступают в разных форматах: от текстовых сообщений до аудио, видео и числовых показателей, что усложняет их анализ.

Однако в современном контексте часто встречается расширение модели «3V» на «4V» и даже «5V». Изначально модель «3V» (Volume, Velocity, Variety) была предложена как способ охарактеризовать основные характеристики больших данных, но со временем появились новые аспекты, которые также стали важными для анализа и обработки данных. Дополнительно к трем основным характеристикам часто добавляют следующие: достоверность, ценность. Достоверность (Veracity) – это степень надежности данных. Важно, чтобы данные были точными и достоверными, поскольку ошибка или несоответствие в данных могут привести к неправильным выводам и решениям. Ценность (Value) – под этим подразумевается способность извлекать полезную информацию и знания из больших данных. Большие данные должны быть не только собраны, но и правильно проанализированы, чтобы они приносили реальную ценность для бизнеса, науки или других сфер. Модели «4V» или «5V» включают не только объем, скорость и разнообразие данных, но и акцентируют внимание на их достоверности и ценности. В некоторых случаях добавляются и другие аспекты, например, визуализация (Visualization) данных или вариативность (Variability), которые подчеркивают важность правильной визуализации информации и учет изменений данных со временем.

Источники больших данных разнообразны. Интернет вещей (IoT) предоставляет данные с сенсоров и устройств, которые постоянно фиксируют информацию о своем состоянии. Социальные сети генерируют огромные объемы текстовых и мультимедийных данных, отражающих поведение пользователей. Важную роль в появлении больших данных играют и транзакции, происходящие в электронной коммерции, медицинские исследования, а также научные эксперименты, которые требуют обработки больших объемов данных для получения точных результатов.

Однако объем и сложность данных не означают, что их невозможно обработать. Современные технологии обработки, такие как распределенные вычисления и новые подходы к хранению данных, позволяют эффективно работать с большими объемами информации. Хранилища данных, такие как системы Hadoop или базы данных NoSQL, способны хранить и обрабатывать данные, которые невозможно уместить в традиционные реляционные базы. С помощью инструментов распределенной обработки, например, Apache Spark, можно анализировать огромные объемы данных быстро и эффективно. Это открывает новые горизонты для различных областей – от бизнеса до научных исследований.[4]

Бизнес, например, активно использует аналитику больших данных для оптимизации своих процессов. Прогнозирование спроса, персонализация предложений для клиентов, улучшение качества обслуживания – все это возможно благодаря глубокому анализу данных. В здравоохранении большие данные играют ключевую роль в диагностике и лечении заболеваний, а также в разработке новых лекарств. Использование данных в научных исследованиях помогает не только строить сложные математические модели, но и анализировать экологические данные или данные о космосе.

Тем не менее, несмотря на множество преимуществ, работа с большими данными сопряжена с рядом проблем. Проблемы безопасности и конфиденциальности данных

остаются актуальными, особенно когда речь идет о персональной информации пользователей или чувствительных данных, таких как медицинские истории. Важным является также обеспечение качества и точности данных, поскольку ошибки в информации могут привести к неправильным выводам и решениям.

Таким образом, большие данные – это не просто технологический тренд, а важный ресурс, который меняет способы принятия решений, улучшает нашу повседневную жизнь и открывает новые возможности в самых разных областях.

Платформы и технологии для обработки больших данных. Одним из фундаментальных подходов к обработке больших данных является использование распределенных вычислений. Это позволяет эффективно управлять огромными объемами информации, распределяя задачи между множеством вычислительных узлов. На базе таких технологий можно строить сложные системы хранения и обработки данных.

Один из самых известных инструментов для работы с большими данными – это Apache Hadoop. Hadoop предоставляет платформу для распределенного хранения и обработки данных с помощью технологии MapReduce, которая позволяет параллельно обрабатывать данные на различных узлах. Архитектура MapReduce построена по принципу «главный – подчиненные» (master – workers). В качестве главного выступает сервер JobTracker, раздающий задания подчиненным узлам кластера и контролирующий их выполнение (рисунок 2). [5]

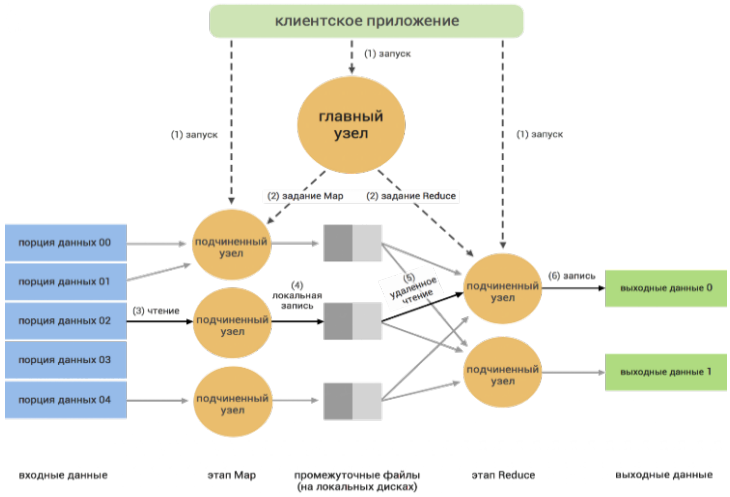


Рисунок 2. Архитектура Hadoop

Это открывает возможности для обработки петабайтов информации. Hadoop использует распределенную файловую систему HDFS (Hadoop Distributed File System), которая эффективно справляется с хранением больших объемов данных на различных машинах.

Однако MapReduce имеет свои ограничения, в частности, он не так быстро обрабатывает данные в реальном времени. Для преодоления этой проблемы была разработана платформа Apache Spark, которая является более гибким и быстрым инструментом для обработки больших данных. В отличие от классического обработчика ядра Apache Hadoop с двухуровневой концепцией MapReduce на базе дискового хранилища, Spark использует специализированные примитивы для рекуррентной обработки в оперативной памяти. Благодаря этому многие вычислительные задачи реализуются в Спарк значительно быстрее. Сравнение Apache Hadoop и Spark представлено на рисунке 3.

Hadoop MapReduce	Apache Spark
Fast	100x faster than MapReduce
Batch Processing	Real-time Processing
Stores Data on Disk	Stores Data in Memory
Written in Java	Written in Scala

Рисунок 3. Сравнение Apache Hadoop и Spark

Стоит отметить, что Spark Streaming, в отличие от, например, Apache Storm, Flink или Samza, не обрабатывает потоки Big Data целиком. Вместо этого реализуется микропакетный подход (micro-batch), когда поток данных разбивается на небольшие пакеты временны*ы*х интервалов.

Для хранения и обработки больших данных не всегда подходят традиционные реляционные базы данных, которые требуют жесткой схемы данных и не могут эффективно работать с огромными объемами информации. В этой связи широко распространены NoSQL базы данных, которые предназначены для обработки неструктурированных и полуструктурированных данных, таких как текст, изображения и видео. [6]

Среди популярных NoSQL баз данных можно выделить следующие.

Cassandra: масштабируемость и высокая доступность. Apache Cassandra – это распределенная NoSQL база данных, предназначенная для хранения больших объемов данных с высокой доступностью и масштабируемостью. Она была разработана для того, чтобы решать проблемы, возникающие при работе с огромными массивами данных в реальном времени. Cassandra используется компаниями, которым необходимо обеспечить бесперебойную работу системы, даже если некоторые узлы базы данных выходят из строя.

Одной из главных особенностей Cassandra является архитектура peer-to-peer, где все узлы в кластере равны. Это означает, что Cassandra не имеет единой точки отказа, а данные могут быть реплицированы на несколько узлов, обеспечивая их доступность даже в случае сбоя. Репликация данных на разных географически удаленных серверах делает Cassandra отличным выбором для приложений с высоким требованием к доступности, таких как системы в сфере финансов, социальных сетей или IoT-устройств.

Еще одной важной особенностью является гибкость в моделировании данных. Cassandra использует модель данных на основе колоночных семей, что позволяет эффективно хранить и обрабатывать данные, которые могут быть неструктурированными или изменяться со временем. Это означает, что Cassandra может хранить огромные объемы данных с различными структурами и легко масштабируется по мере роста количества записей.

Ключевое преимущество Cassandra – это её способность обрабатывать запросы с низкой задержкой даже при высоких объемах данных и больших нагрузках. Именно поэтому Cassandra популярна среди компаний, работающих с большими данными в реальном времени. [7]

MongoDB: гибкость и удобство в работе с документами. MongoDB – это одна из самых популярных и широко используемых NoSQL баз данных, ориентированная на хранение данных в виде документов. В отличие от Cassandra, MongoDB использует формат JSON-подобных документов, что делает её идеальной для работы с неструктурированными или полуструктурированными данными, такими как данные из социальных сетей, веб-приложений или мобильных сервисов.

Каждый документ в MongoDB может содержать различные типы данных, включая массивы и вложенные объекты, что дает разработчикам гибкость при моделировании

данных. Такая структура позволяет быстро адаптировать базу данных под меняющиеся требования, например, если бизнес-логика или структура данных со временем изменяется.

MongoDB использует индексы для ускорения запросов, поддерживает агрегацию (например, подсчет суммы, среднего и других статистических показателей) и имеет встроенные механизмы для выполнения сложных запросов, что делает её мощным инструментом для аналитики. Более того, MongoDB поддерживает горизонтальное масштабирование, позволяя легко увеличивать вычислительные мощности и хранилище путем добавления новых узлов в кластер.

MongoDB часто используется в таких областях, как веб-разработка, мобильные приложения, интернет-магазины и аналитика данных. Она прекрасно подходит для приложений, требующих быстрого доступа к данным, например, для ведения каталогов товаров или хранения пользовательских данных и предпочтений.

HBase: высокая производительность для структурированных данных. Apache HBase – это распределенная и масштабируемая база данных, построенная на основе Google Bigtable, предназначенная для хранения и обработки больших объемов структурированных данных.

HBase используется в приложениях, где требуется высокая скорость записи и чтения данных, а также возможность работы с большими таблицами, состоящими из миллиардов строк и тысяч столбцов.

HBase идеально подходит для хранения данных, которые могут быть эффективно представлены в табличной форме, например, для аналитических платформ, которые нуждаются в хранении больших наборов данных и быстрой их обработке. HBase, как и Cassandra, поддерживает репликацию, что обеспечивает отказоустойчивость и доступность данных. В отличие от MongoDB, где данные хранятся в виде документов, HBase использует структуру таблиц, что позволяет эффективно работать с большими объемами данных в формате ключ-значение.

Один из важнейших аспектов HBase – это её способность обрабатывать данные с очень высокой скоростью записи, что делает её особенно подходящей для приложений, в которых нужно обрабатывать данные в реальном времени, таких как системы мониторинга, аналитика веб-данных или обработка транзакций.

HBase не требует строгого соблюдения схемы данных, что позволяет хранить данные с разной структурой, и даёт возможность гибко масштабировать систему по мере увеличения объема данных. Однако стоит отметить, что в отличие от Cassandra и MongoDB, HBase ориентирована преимущественно на работу с большими объемами данных в «кластерном» режиме и требует настроек на уровне инфраструктуры, чтобы обеспечить её оптимальное функционирование.

Cassandra, MongoDB и HBase – это мощные NoSQL базы данных, каждая из которых имеет свои сильные стороны и особенности, подходящие для разных типов задач. Cassandra отлично справляется с масштабируемыми и отказоустойчивыми системами, MongoDB предоставляет удобство работы с динамическими и полуструктурированными данными, а HBase идеально подходит для аналитических приложений с требованиями к высокой скорости обработки. Выбор между этими базами данных зависит от конкретных требований проекта, объема данных и типа приложения.

С увеличением скорости генерации данных важность обработки информации в реальном времени возрастает. Платформы, которые позволяют обрабатывать данные в реальном времени, предоставляют значительные преимущества для бизнес-анализа, мониторинга и управления.

Apache Kafka и Apache Flink – два мощных инструмента, часто используемых вместе для обработки данных в реальном времени. Kafka – это распределённая платформа для передачи потоковых данных с высокой производительностью и масштабируемостью. Она гарантирует доставку сообщений и может хранить данные в течение определённого

времени, что полезно для анализа и повторной обработки. Kafka разделяет данные на темы и партиции, что помогает улучшить отказоустойчивость и параллельную обработку.

Apache Flink фокусируется на обработке этих данных в реальном времени. Flink идеально подходит для сложной аналитики, машинного обучения и обработки событий, позволяя работать с данными по мере их поступления. Он поддерживает управление состоянием и анализ временных окон, а также позволяет выполнять как потоковую, так и батчевую обработку. Flink гарантирует обработку событий в порядке их поступления, что важно для критически важных приложений.

Kafka и Flink часто работают вместе: Kafka передаёт данные, а Flink выполняет их обработку. Это взаимодействие позволяет эффективно решать задачи мониторинга, аналитики и машинного обучения в реальном времени. Сочетание этих технологий обеспечивает высокую производительность, масштабируемость и гибкость при работе с потоками данных.[8]

Технологии анализа данных и их применение. Технологии анализа данных в последние десятилетия приобрели немалую важность, став неотъемлемой частью многих сфер, таких как бизнес, наука, здравоохранение и государственное управление. Современные инструменты позволяют извлекать ценную информацию из огромных объёмов данных, открывая новые возможности для принятия обоснованных решений и оптимизации процессов.

Машинное обучение (Machine Learning, ML) – это область искусственного интеллекта, которая позволяет компьютерам автоматически улучшать свои результаты, опираясь на данные, без явного программирования. Это один из самых захватывающих и быстро развивающихся разделов технологий, который уже меняет мир вокруг нас. В основе машинного обучения лежит идея, что алгоритмы могут «учиться» из опыта, как человек, но при этом они способны работать с огромными объёмами данных, что делает их гораздо более мощными.[9]

Основной принцип машинного обучения заключается в том, чтобы обучить модель на большом наборе данных, чтобы она могла выявить закономерности и применять их для предсказания новых, ещё не виденных данных.

Машинное обучение делится на несколько типов в зависимости от того, как происходит процесс обучения модели. Наиболее известными являются три основных подхода: обучение с учителем, обучение без учителя и обучение с подкреплением.

Обучение с учителем – это тот тип машинного обучения, при котором алгоритм обучается на заранее размеченных данных, то есть на тех, где для каждого примера уже указаны правильные ответы. Это, как если бы учитель показывал ученику примеры задач с решениями, и ученик затем учился бы решать новые задачи, опираясь на эти примеры.

Обучение без учителя работает иначе. Здесь алгоритм не имеет предварительно размеченных данных, и его задача – найти скрытые структуры в данных. Такое обучение широко используется для кластеризации и ассоциации данных, например, в рекомендационных системах, где алгоритм предлагает пользователю товары на основе его предыдущих покупок.

Обучение с подкреплением – это подход, где модель обучается через пробу и ошибку. Алгоритм взаимодействует с окружающей средой, принимает решения, получает за это награды или наказания и учится оптимизировать свои действия, чтобы максимизировать награду. Обучение с подкреплением широко используется для создания автономных систем, таких как самоуправляемые автомобили или роботы, которые учатся перемещаться в пространстве и выполнять задачи, основываясь на собственном опыте.

Одним из самых популярных направлений машинного обучения в последние годы является глубокое обучение. Это подвид машинного обучения, который использует многослойные нейронные сети, вдохновлённые структурой человеческого мозга. Модели

глубокого обучения способны обрабатывать огромные объёмы данных и выявлять сложные закономерности, которые трудны для понимания традиционными методами. Глубокое обучение отлично подходит для задач, связанных с изображениями, текстами и звуками.

Анализ данных – это процесс извлечения полезной информации из больших объёмов данных с целью поддержки принятия решений. Это более широкая область, включающая в себя как использование статистических методов, так и более современные подходы, такие как машинное обучение и искусственный интеллект. Анализ данных включает несколько ключевых этапов:

Сбор данных. На первом этапе необходимо собрать данные, которые будут использованы для анализа. Это может быть информация из различных источников, таких как базы данных, файлы, сенсоры или интернет (например, социальные сети или веб-страницы).

Предобработка данных. На этом этапе данные очищаются и подготавливаются для дальнейшего анализа. Это может включать удаление пропущенных значений, преобразование переменных, нормализацию данных и удаление выбросов. Предобработка данных – критически важный этап, так как качество данных напрямую влияет на точность и эффективность модели.

Анализ данных. После подготовки данных начинается сам анализ. Это может быть как статистический анализ (например, проверка гипотез, вычисление средних значений и стандартных отклонений), так и более сложные методы, включая алгоритмы машинного обучения. Задача анализа – выявить паттерны, тренды и связи в данных, которые могут привести к полезным инсайтам.

Визуализация данных. Визуализация помогает лучше понять результаты анализа, делая их доступными и наглядными для пользователей. Диаграммы, графики и интерактивные панели позволяют увидеть данные с новой точки зрения и принять более обоснованные решения.

Прогнозирование и моделирование. Включает использование обученных моделей для предсказания будущих значений или событий. Это может быть полезно в бизнесе для прогноза спроса на товары или в здравоохранении для предсказания распространения заболеваний.

Принятие решений. На основе полученных данных и прогнозов принимаются обоснованные решения. Эти решения могут быть стратегическими (например, изменения в бизнес-процессах) или операционными (например, корректировка маркетинговых кампаний или оптимизация производственных процессов).

Машинное обучение и анализ данных продолжают развиваться и находить новые области применения. Совмещение мощных алгоритмов с большими данными открывает новые возможности для более точных прогнозов, оптимизации процессов и создания инновационных продуктов и услуг.

Проблемы и вызовы при работе с большими данными. Работа с большими данными (Big Data) открывает новые горизонты для анализа и принятия решений, однако она также сопровождается рядом серьёзных проблем и вызовов, которые необходимо решать для эффективного и безопасного использования данных. Одной из ключевых проблем является безопасность и конфиденциальность данных, особенно когда речь идет о чувствительной информации, такой как личные данные пользователей или коммерческие тайны. Важно обеспечить, чтобы данные не были украдены или использованы неправомерно, и для этого разрабатываются различные методы защиты, включая шифрование, а также механизмы контроля доступа.

Качество данных – ещё одна серьёзная проблема при работе с большими данными. Даже если объём данных огромен, их ценность сильно зависит от того, насколько они точны, полны и актуальны. Проблемы с качеством данных могут проявляться в виде

ошибок в записях, дублирования данных, пропущенных значений или устаревшей информации. Некачественные данные могут привести к неправильным выводам и решениям, что делает процесс анализа и построения моделей ненадёжным. Поэтому важнейшим этапом работы с большими данными является этап предобработки, где данные очищаются и приводятся к единому формату. Для этого применяются различные алгоритмы и инструменты для удаления ошибок, дополнения недостающих значений и улучшения структуры данных. Однако даже с самыми лучшими методами предобработки важно помнить, что чем больше данных, тем сложнее гарантировать их безупречное качество, что создаёт дополнительные сложности для аналитиков и специалистов по данным.

Производительность – это ещё один важный аспект, который может серьёзно повлиять на успешность работы с большими данными. Когда речь идет о масштабных наборах данных, их обработка и анализ требуют значительных вычислительных ресурсов. В условиях ограниченной мощности серверов или низкой пропускной способности сетей выполнение сложных вычислений может занять много времени, что замедляет процессы принятия решений. Это особенно актуально для задач, требующих обработки данных в реальном времени, таких как мониторинг социальных сетей, анализ потоковых данных или автоматическое обновление моделей прогнозирования. Чтобы справиться с этой проблемой, организации используют распределённые системы обработки данных, которые позволяют эффективно распределять вычислительные задачи между множеством серверов. Однако с ростом объёма данных и сложности задач, потребность в более мощных и быстрых системах только возрастает, что создаёт дополнительные вызовы для специалистов по производительности и инфраструктуре.

Таким образом, работа с большими данными требует внимательного подхода и решения нескольких ключевых проблем. Безопасность и конфиденциальность, качество данных и производительность – это те области, которые нуждаются в постоянном улучшении и развитии технологий. На фоне стремительного роста объёмов данных эти вызовы становятся всё более актуальными, и важно разрабатывать инновационные решения для их эффективного преодоления.

Будущее технологий больших данных. Будущее технологий больших данных обещает быть захватывающим, так как продолжающееся развитие новых технологий открывает новые горизонты для анализа, обработки и использования данных. С каждым годом растёт объём информации, которая генерируется людьми, устройствами и системами, и способность эффективно извлекать из неё ценную информацию становится всё более важной для бизнеса, науки и общества в целом.

Одной из главных тенденций будущего является интеграция технологий искусственного интеллекта и машинного обучения с большими данными. Совмещение этих направлений позволит значительно улучшить точность анализа и предсказаний, а также ускорить процессы принятия решений. Например, уже сейчас используют предсказательную аналитику для оптимизации бизнес-процессов, прогнозирования спроса или диагностики заболеваний. В будущем такие технологии будут ещё более интегрированы в различные сферы жизни, например, в городское управление, где анализ больших данных в сочетании с ИИ будет помогать в реальном времени регулировать транспорт, контролировать энергопотребление или отслеживать экологическую ситуацию.

Также стоит отметить рост роли технологии хранения данных. Традиционные подходы к хранению и обработке больших данных будут эволюционировать с учётом потребностей новых типов данных, таких как видео, изображения, аудио и другие мультимедийные форматы. Развитие облачных технологий и распределённых систем хранения, например, на базе облачных платформ, позволят ещё более эффективно масштабировать инфраструктуру для работы с большими данными, обеспечивая надёжность и доступность данных.

В будущем ожидается также усиление внимания к вопросам этики и безопасности данных. С ростом объёмов собираемой информации возрастает риск её неправомерного использования или утечки. Поэтому разработка стандартов безопасности, защита конфиденциальности пользователей и соблюдение законодательства станут важными задачами для организаций, работающих с большими данными. Технологии, такие как блокчейн, также могут сыграть ключевую роль в обеспечении прозрачности и безопасности обработки данных.

Будущее технологий больших данных обещает стать ещё более захватывающим, поскольку с каждым годом появляются новые инновации, которые помогают нам лучше понимать мир вокруг и принимать более обоснованные решения. Эти технологии будут продолжать развиваться, меняя не только способы ведения бизнеса, но и повседневную жизнь людей, делая её более умной, эффективной и безопасной.

Заключение. Управление большими данными стало неотъемлемой частью современного информационного общества. На основе технологий, таких как Hadoop, Spark, NoSQL базы данных и других, организации могут эффективно обрабатывать и анализировать огромные объемы информации. При этом использование методов машинного обучения и искусственного интеллекта открывает новые возможности для более глубокого анализа данных и принятия более обоснованных решений. Важно отметить, что с развитием технологий Big Data необходимо учитывать вызовы, такие как безопасность данных, их качество и производительность систем. Перспективы использования больших данных связаны с дальнейшим развитием технологий, включая облачные вычисления, квантовые вычисления и автоматизацию процессов обработки данных.

Список литературы

[1] Тесленко И.Б., Губернаторов А.М., Дигилина О.Б., Крылов В.Е. BIG DATA=Большие данные: учебное пособие. Владимир: ВлГУ, 2021. – 123 с.

[2] Сколько данных создается каждый день? [Электронный ресурс]. – Режим доступа: https://inclient.ru/data-create-stats/. – Дата доступа: 01.03.2026

[3] Статистика больших данных за 2026 год [Электронный ресурс]. – Режим доступа: https://www.demandsage.com/big-data-statistics/.– Дата доступа: 01.03.2026

[4] Обработка потоковых данных [Электронный ресурс]. – Режим доступа: https://datareview.info/article/obrabotka-potokovyx-dannyx-storm-spark-i-samza/. – Дата доступа: 01.03.2026

[5] Обработка больших данных: первые шаги в понимании Hadoop MapReduce и Spark [Электронный ресурс]. – Режим доступа: https://devby.io/news/luxoft-big-data#google_vignette. – Дата доступа: 01.03.2026

[6] Модели данных в NoSQL [Электронный ресурс]. – Режим доступа: https://habr.com/ru/companies/otus/articles/760226/. – Дата доступа: 01.03.2026

[7] Модель данных Apache Cassandra [Электронный ресурс]. – Режим доступа: https://bigdataschool.ru/wiki/cassandra#. – Дата доступа: 01.03.2026

[8] Построение архитектуры данных реального времени с помощью Apache Kafka, Flink и Druid [Электронный ресурс]. – Режим доступа: https://clck.ru/3GSU89. – Дата доступа: 01.03.2026

[9] В. В. Воронина, А. В. Михеев, Н. Г. Ярушкина, К. В. Святов. Теория и практика машинного обучения: учебное пособие. Ульяновск : УлГТУ, 2017. – 290 с.

Авторский вклад

Верняховская Вероника Владимировна – постановка задачи исследования, разработка структуры статьи, анализ платформ обработки больших данных (Hadoop, Apache Spark), участие в формировании теоретической и методологической базы исследования.

Раптунович Ольга Михайловна – проведение сравнительного анализа технологий обработки и хранения данных (NoSQL базы данных, Kafka, Flink), описание архитектур и принципов работы рассматриваемых систем, подготовка иллюстративных материалов и участие в написании основной части статьи.

Усова Виктория Александровна – исследование методов анализа данных и машинного обучения, интеграция результатов анализа в общую концепцию работы, формулировка выводов и заключения, а также научное редактирование и финальная подготовка статьи к публикации.

EFFECTIVE MANAGEMENT OF BIG DATA: A COMPARATIVE ANALYSIS OF PLATFORMS AND TECHNOLOGIES FOR INFORMATION PROCESSING

V.V. Verniahovskaya
Master of economics, Deputy Dean of the faculty of engineering and Economics at BSUIR

O.M. Raptunovich
Senior Lecturer at the Department of Economic Informatics BSUIR, master

V.A. Usova
Student of BSUIR, Faculty of Engineering and Economics, specialty Information Systems and Technologies

Abstract. The article is devoted to the effective management of big data, with a focus on a comparative analysis of platforms and technologies for information processing. Discusses various tools and approaches used to collect, store and analyze data. Platforms such as Hadoop, Apache Spark, and others are evaluated, as well as machine learning technologies that affect the performance and scalability of data processing.

Keywords: big data, Hadoop, Apache Spark, machine learning, MapReduce, NoSQL databases, data analysis, Kafka, Flink.